


ডীপ লার্নিং

Introduction to Deep Learning



(উৎস: Wikipedia)

প্রথম অধ্যায় ডীপ লার্নিংয়ের মৌলিক পরিচিতি

Shaon Khan
BSc in IIT, JU

Contents

প্রথম অধ্যায়: ডীপ লার্নিংয়ের মৌলিক পরিচিতি.....	3
১.১ যন্ত্র যখন নিজে থেকে শিখতে শুরু করে.....	3
১.২ ডীপ লার্নিং কী?.....	3
১.৩ কেন প্রথাগত মেশিন লার্নিং যথেষ্ট ছিল না?.....	3
১.৩.১ ম্যানুয়াল ফিচার ইঞ্জিনিয়ারিংয়ের সমস্যা.....	4
১.৩.২ অসংগঠিত উপাত্ত ও উচ্চ-মাত্রিকতার চ্যালেঞ্জ.....	4
১.৩.৩ স্কেল ও জটিল অনৈখিক সম্পর্ক.....	4
১.৩.৪ তুলনামূলক সারসংক্ষেপ: মেশিন লার্নিং বনাম ডীপ লার্নিং.....	5
১.৪ মস্তিষ্ক থেকে অনুপ্রেরণা: জৈবিক নিউরনের গল্প.....	5
১.৫ ডীপ লার্নিং কীভাবে কাজ করে?.....	7
১.৫.১ বহুস্তরীয় কাঠামো (Layered Architecture).....	7
১.৫.২ স্বয়ংক্রিয় বৈশিষ্ট্য নিষ্কাশন.....	7
১.৫.৩ শিক্ষণ প্রক্রিয়া: পূর্বাভাস, তুলনা ও সংশোধন.....	7
১.৬ পারসেপট্রন: প্রথম কৃত্রিম নিউরনের গাণিতিক রূপ.....	7
১.৬.১ ওজন ও বায়াস সংশোধন প্রক্রিয়া (Perceptron Learning Rule).....	8
১.৬.২ ব্যবহারিক উদাহরণ: AND গেট শেখানো.....	9
১.৭ বাস্তব জীবনে ডীপ লার্নিংয়ের প্রয়োগ.....	10
স্বাস্থ্যসেবা (Healthcare).....	10
ব্যবসা ও ই-কমার্স (Business & E-Commerce).....	10
প্রাকৃতিক ভাষা প্রক্রিয়াকরণ (NLP).....	11
ছবি ও কম্পিউটার ভিশন.....	11
স্বয়ংক্রিয় যানবাহন.....	11
১.৭.১ হার্ডওয়্যার প্রেক্ষাপট: CPU বনাম GPU.....	11
অধ্যায় সারসংক্ষেপ.....	13
গুরুত্বপূর্ণ সংজ্ঞা.....	13
গুরুত্বপূর্ণ সূত্রাবলি.....	13
সাধারণ ইন্টারভিউ প্রশ্ন.....	13
বহুনির্বাচনী প্রশ্ন (MCQ).....	14
সংক্ষিপ্ত প্রশ্নাবলি.....	14
পর্যালোচনা প্রশ্নাবলি.....	14
ব্যবহারিক অনুশীলনী.....	15

প্রথম অধ্যায়: ডীপ লার্নিংয়ের মৌলিক পরিচিতি

১.১ যন্ত্র যখন নিজে থেকে শিখতে শুরু করে

একটি শিশুকে বিড়াল চেনানোর জন্য আমরা কখনোই তাকে কোনো গাণিতিক সংজ্ঞা শিখিয়ে দিই না — 'চারটি পা, একটি লেজ, নির্দিষ্ট আকৃতির কান থাকলে সেটি বিড়াল'। বরং তাকে বার বার বিড়াল দেখানো হয়, আর কিছুদিনের মধ্যেই সে নিজে থেকেই শত শত ভিন্ন রঙ, আকার ও ভঙ্গির বিড়ালকে চিনে ফেলে। কম্পিউটার বিজ্ঞানের ইতিহাসে দীর্ঘদিন ধরে আমরা ঠিক উল্টো পথে হেঁটেছি — যন্ত্রকে প্রতিটি নিয়ম আলাদাভাবে লিখে বুঝিয়ে দেওয়া হতো। ডীপ লার্নিং এই দীর্ঘদিনের অভ্যাসটিকেই ভেঙে দিয়েছে।

প্রশ্ন হলো, একটি যন্ত্র কীভাবে অভিজ্ঞতা থেকে শিখতে পারে, মানুষের মস্তিষ্কের মতো? এই অধ্যায়ে আমরা ঠিক এই প্রশ্নের উত্তর খুঁজব — একেবারে মৌলিক ধারণা থেকে শুরু করে গাণিতিক ভিত্তি পর্যন্ত।

১.২ ডীপ লার্নিং কী?

আধুনিক প্রযুক্তির যুগে কৃত্রিম বুদ্ধিমত্তা (Artificial Intelligence, AI) মানুষের জীবনযাত্রাকে দ্রুত রূপান্তরিত করছে। এই বিশাল ক্ষেত্রের একটি গুরুত্বপূর্ণ শাখা হলো মেশিন লার্নিং (Machine Learning, ML), এবং মেশিন লার্নিংয়ের ভেতর থেকেই জন্ম নিয়েছে একটি বৈপ্লবিক পদ্ধতি — ডীপ লার্নিং (Deep Learning, DL)।

সংজ্ঞা

ডীপ লার্নিং হলো মেশিন লার্নিংয়ের এমন একটি শাখা, যেখানে বহুস্তরবিশিষ্ট কৃত্রিম নিউরাল নেটওয়ার্ক (Artificial Neural Network) ব্যবহার করে যন্ত্র বিপুল পরিমাণ উপাত্ত (data) থেকে নিজে থেকেই জটিল প্যাটার্ন চিনতে ও সিদ্ধান্ত নিতে শেখে — কোনো সুনির্দিষ্ট নিয়ম (if-else rule) ছাড়াই।

এটি প্রথাগত প্রোগ্রামিং থেকে সম্পূর্ণ ভিন্ন দৃষ্টিভঙ্গি। প্রথাগত প্রোগ্রামে ইঞ্জিনিয়ারকে প্রতিটি সিদ্ধান্তের জন্য সুনির্দিষ্ট নিয়ম লিখে দিতে হয়; ডীপ লার্নিংয়ে বরং অ্যালগরিদমকে প্রচুর উপাত্ত সরবরাহ করা হয়, আর সে নিজেই সেই উপাত্ত বিশ্লেষণ করে সিদ্ধান্ত নিতে শেখে।

দৈনন্দিন উদাহরণ: একটি প্রথাগত অ্যালগরিদমে বিড়াল চেনাতে হলে কানের আকৃতি, চোখের অবস্থান, গোঁফের বিন্যাস ইত্যাদির সুনির্দিষ্ট গাণিতিক বর্ণনা লিখে দিতে হতো। ডীপ লার্নিং পদ্ধতিতে হাজার হাজার বিড়ালের ছবি ইনপুট হিসেবে দিলেই অ্যালগরিদম নিজে থেকে বিড়ালের মৌলিক বৈশিষ্ট্যগুলো চিনে নেয় — ঠিক যেমনটা একটি শিশু শেখে।

১.৩ কেন প্রথাগত মেশিন লার্নিং যথেষ্ট ছিল না?

ডিসিশন ট্রি, সাপোর্ট ভেক্টর মেশিন বা লজিস্টিক রিগ্রেশনের মতো প্রথাগত মেশিন লার্নিং অ্যালগরিদম উপাত্ত বিশ্লেষণের জগতে একসময় বিপ্লব ঘটিয়েছিল। কিন্তু যখন উপাত্তের ধরন

সাধারণ স্প্রেডশিট থেকে বদলে ছবি, অডিও বা মানুষের ভাষার মতো জটিল ও অসংগঠিত রূপে রূপান্তরিত হলো, তখন এই পদ্ধতিগুলো একের পর এক সীমাবদ্ধতার মুখোমুখি হলো।

১.৩.১ ম্যানুয়াল ফিচার ইঞ্জিনিয়ারিংয়ের সমস্যা

প্রথাগত মেশিন লার্নিং সরাসরি কাঁচা উপাত্ত (raw pixel, raw audio wave) বিশ্লেষণ করতে পারে না। মডেলে ডেটা দেওয়ার আগে অভিজ্ঞ প্রকৌশলীদের হাতে করে প্রয়োজনীয় বৈশিষ্ট্য (feature) বের করে দিতে হতো — যেমন বিড়ালের ছবি চিনতে কানের আকৃতি বা টেক্সচারের বর্ণনা কোড করে লিখে দেওয়া। কোনো গুরুত্বপূর্ণ ফিচার বাদ পড়লে পুরো মডেলটিই ব্যর্থ হতো।


ডীপ লার্নিংয়ের বহুস্তরীয় নেটওয়ার্ক এই সমস্যার সমাধান করে সম্পূর্ণ স্বয়ংক্রিয় ফিচার নিষ্কাশনের (automatic, end-to-end feature extraction) মাধ্যমে। প্রথম স্তরগুলো সাধারণ প্রান্তরেখা শেখে, মাঝের স্তরগুলো সেগুলো একত্র করে আকৃতি তৈরি করে, আর শেষের স্তরগুলো সেই আকৃতি থেকে সম্পূর্ণ বস্তু চিনে নেয় — মানুষের কোনো হস্তক্ষেপ ছাড়াই।

১.৩.২ অসংগঠিত উপাত্ত ও উচ্চ-মাত্রিকতার চ্যালেঞ্জ

প্রথাগত ML সুসংগঠিত টেবিলভিত্তিক উপাত্তে (CSV, স্প্রেডশিট, SQL) চমৎকার কাজ করে, কিন্তু একটি সাধারণ HD ছবিতেই থাকে লক্ষ লক্ষ পিক্সেল। এত বিপুল ইনপুটকে একমাত্রিক করে প্রসেস করতে গেলে মডেল ছবির স্থানিক গঠন হারিয়ে ফেলে এবং কার্যক্ষমতা কমে যায়। কনভোলিউশনাল নিউরাল নেটওয়ার্ক (CNN), রিকারেন্ট নেটওয়ার্ক (RNN) ও ট্রান্সফরমারের মতো আর্কিটেকচার বিশেষভাবে এই ধরনের অসংগঠিত উপাত্তের জন্যই তৈরি হয়েছে।

১.৩.৩ স্কেল ও জটিল অনৈখিক সম্পর্ক

প্রথাগত মডেলের ক্ষমতা একটি নির্দিষ্ট সীমার পর স্থবির হয়ে যায় (plateau) — ডেটা যত বাড়ানো হোক, নির্ভুলতা আর বাড়ে না। অন্যদিকে ডীপ লার্নিং মডেল যত বেশি ডেটা ও স্তর পায়, ততই উন্নত হয়। এছাড়া ReLU-এর মতো নন-লিনিয়ার এক্টিভেশন ফাংশন যুক্ত করার ফলে এটি যেকোনো জটিল অনৈখিক সম্পর্ক আনুমানিক করতে সক্ষম (universal approximation)।



চিত্র ১.২: উপাত্তের পরিমাণ বাড়ার সাথে সাথে ডীপ লার্নিং মডেলের কার্যক্ষমতা ক্রমাগত বৃদ্ধি পায়, যেখানে প্রথাগত মেশিন লার্নিং একটি সীমার পর স্থবির হয়ে যায়।

১.৩.৪ তুলনামূলক সারসংক্ষেপ: মেশিন লার্নিং বনাম ডীপ লার্নিং

মানদণ্ড	প্রথাগত মেশিন লার্নিং (ML)	ডীপ লার্নিং (DL)
সেবা ব্যবহারক্ষেত্র	সুসংগঠিত / টেবিলভিত্তিক ডেটা	অসংগঠিত ডেটা (ছবি, অডিও, টেক্সট)
ফিচার নিষ্কাশন	ম্যানুয়াল, মানুষের অভিজ্ঞতা-নির্ভর	সম্পূর্ণ স্বয়ংক্রিয়
ডেটার চাহিদা	ছোট-মাঝারি ডেটাসেটেও ভালো কাজ করে	বিশাল ডেটাসেট প্রয়োজন
হার্ডওয়্যার	সাধারণ CPU-তেই চলে	সমান্তরাল গণনার জন্য GPU/TPU প্রয়োজন
ব্যাখ্যাযোগ্যতা	বেশি (স্বচ্ছ যুক্তি)	কম ('Black Box')
প্রশিক্ষণের সময়	সেকেন্ড থেকে ঘণ্টা	ঘণ্টা থেকে সপ্তাহ


তাহলে কি ML এখন অপ্রাসঙ্গিক? না। যেখানে ডেটা সুসংগঠিত, কম্পিউটিং বাজেট সীমিত, বা সিদ্ধান্তের স্পষ্ট ব্যাখ্যা জরুরি (যেমন ক্রেডিট স্কোরিং), সেখানে আজও ML-ই যুক্তিসঙ্গত পছন্দ। DL প্রয়োজন হয় যখন উপাত্ত জটিল, অসংগঠিত এবং ম্যানুয়াল ফিচার তৈরি অসম্ভব বা কঠিন — যেমন ছবি শনাক্তকরণ, ভাষা অনুবাদ বা রিয়েল-টাইম বায়ো-সিগন্যাল বিশ্লেষণ।

১.৪ মস্তিষ্ক থেকে অনুপ্রেরণা: জৈবিক নিউরনের গল্প

ডীপ লার্নিংয়ের ধারণাটি নতুন কোনো আবিষ্কার নয় — এর শিকড় প্রকৃতির মধ্যেই লুকিয়ে আছে, নির্দিষ্টভাবে মানুষের মস্তিষ্কের গঠনে। মানুষের মস্তিষ্ক কোটি কোটি ক্ষুদ্র কোষ, নিউরন (Neuron), দ্বারা গঠিত, যারা বৈদ্যুতিক ও রাসায়নিক সংকেতের মাধ্যমে একে অপরের সাথে তথ্য আদান-প্রদান করে। একটি শিশু যখন প্রথমবার কোনো বস্তু দেখে, তার মস্তিষ্কে একটি নতুন সংযোগপথ তৈরি হয়;

বারবার একই বস্তু দেখার ফলে সেই সংযোগ শক্তিশালী হতে থাকে, এবং শিশুটি ধীরে ধীরে বস্তুটি চিনতে শেখে।


একটি জৈবিক নিউরনের তিনটি প্রধান অংশ থাকে — ডেনড্রাইট (Dendrites), যা আশপাশের নিউরন থেকে সংকেত গ্রহণ করে; সোমা (Soma), যা সব সংকেত একত্র করে; এবং অ্যাক্সন (Axon), যা চূড়ান্ত সংকেত পরবর্তী নিউরনে পাঠায়। এখানে একটি গুরুত্বপূর্ণ নীতি কাজ করে — All-or-None Principle। প্রাপ্ত সংকেতের সমষ্টি যদি একটি নির্দিষ্ট থ্রেশহোল্ড (Threshold) অতিক্রম করে, তবেই নিউরনটি উদ্দীপিত (fire) হয়; নইলে তা সম্পূর্ণ নিষ্ক্রিয় থাকে।



চিত্র ১.৩: একটি জৈবিক নিউরনের গঠন — ডেনড্রাইট, সোমা ও অ্যাক্সন (উৎস: Britannica)

১৯৪৩ সালে বিজ্ঞানী ওয়ারেন ম্যাককালোচ ও ওয়াল্টার পিটস দেখিয়েছিলেন যে জৈবিক নিউরন যুক্তিভিত্তিক গেটের (logic gate) মতো আচরণ করতে পারে — একাধিক ইনপুট একসাথে সক্রিয় হয়ে থ্রেশহোল্ড পার করলে তা AND গেটের মতো কাজ করে, আবার যেকোনো একটি ইনপুট যথেষ্ট শক্তিশালী হলেই ফায়ার করলে তা OR গেটের মতো আচরণ করে। এই আবিষ্কারই কৃত্রিম নিউরাল নেটওয়ার্কের প্রথম তাত্ত্বিক ভিত্তি তৈরি করেছিল।

এই জৈবিক প্রক্রিয়াকে গাণিতিক মডেলে রূপান্তরিত করেই তৈরি হয়েছে আর্টিফিশিয়াল নিউরাল নেটওয়ার্ক (Artificial Neural Network, ANN) — যা আজকের ডীপ লার্নিংয়ের ভিত্তিপ্রস্তর।



চিত্র ১.৪: একটি সাধারণ কৃত্রিম নিউরাল নেটওয়ার্কের গঠন — ইনপুট, প্রচ্ছন্ন ও আউটপুট স্তর।

১.৫ ডীপ লার্নিং কীভাবে কাজ করে?

১.৫.১ বহুস্তরীয় কাঠামো (Layered Architecture)

'ডীপ' শব্দটি এসেছে নেটওয়ার্কের ভেতরের বহুস্তরীয় কাঠামো থেকে। একটি নেটওয়ার্ক সাধারণত তিন ধরনের স্তর থাকে — ইনপুট স্তর, যেখানে কাঁচা উপাত্ত প্রবেশ করে; প্রচ্ছন্ন স্তর (Hidden Layers), যেখানে প্রকৃত শিক্ষণ ঘটে, এবং একটি নেটওয়ার্ক যত বেশি 'গভীর' হয় ততই তাতে প্রচ্ছন্ন স্তরের সংখ্যা বাড়ে; এবং আউটপুট স্তর, যা চূড়ান্ত পূর্বাভাস প্রদান করে।

১.৫.২ স্বয়ংক্রিয় বৈশিষ্ট্য নিষ্কাশন

প্রথম প্রচ্ছন্ন স্তরটি সাধারণ বৈশিষ্ট্য শেখে, যেমন ছবির সরলরেখা বা বাঁকা অংশ। পরবর্তী স্তরগুলো এই রেখাগুলোকে একত্র করে জটিল আকৃতি তৈরি করে (যেমন গোল চোখ)। শেষের স্তরগুলো এসব আকৃতি একত্র করে সম্পূর্ণ বস্তু চিনে নেয় (যেমন বিড়ালের মুখ)। উপাত্ত যত গভীরে যায়, মডেল ততই সূক্ষ্ম থেকে জটিল ধারণায় পৌঁছাতে পারে।

১.৫.৩ শিক্ষণ প্রক্রিয়া: পূর্বাভাস, তুলনা ও সংশোধন

ডীপ লার্নিং মূলত তিনটি ধাপে শেখে।

- পূর্বাভাস (Predict): শুরুতে নেটওয়ার্ক এলোমেলো অনুমানের ভিত্তিতে একটি আউটপুট দেয়, যা প্রায় সবসময়ই ভুল হয়।
- তুলনা (Compare): পূর্বাভাসের সাথে প্রকৃত উত্তরের তুলনা করে ত্রুটির (Error) পরিমাণ নির্ণয় করা হয়।
- সংশোধন ও শিক্ষা (Learn): ত্রুটির সংকেত নেটওয়ার্কের শেষ থেকে শুরুর দিকে ফিরিয়ে পাঠানো হয়, এবং নিউরনগুলোর মধ্যবর্তী সংযোগের শক্তি (Weight) সামঞ্জস্য করা হয়।

এই চক্র যখন লক্ষ লক্ষ উপাত্তের উপর হাজার হাজার বার পুনরাবৃত্তি হয়, তখন ত্রুটির পরিমাণ ক্রমশ শূন্যের কাছাকাছি পৌঁছায় এবং মডেল অত্যন্ত নির্ভুলভাবে সিদ্ধান্ত নিতে সক্ষম হয়। ডীপ লার্নিং তাই কোনো অলৌকিক ক্ষমতা নয়, বরং একটি সরল দর্শনের গাণিতিক রূপ — অভিজ্ঞতা লাভ করা, ভুল থেকে শেখা, এবং প্রতিনিয়ত নিজেকে উন্নত করা।

১.৬ পারসেপট্রন: প্রথম কৃত্রিম নিউরনের গাণিতিক রূপ

১৯৫৭ সালে ফ্রাঙ্ক রোজেনব্ল্যাট জৈবিক নিউরনের ধারণাকে গাণিতিক রূপ দিয়ে আবিষ্কার করেন পারসেপট্রন (Perceptron) — কৃত্রিম নিউরাল নেটওয়ার্কের সবচেয়ে মৌলিক একক। কৃত্রিম নিউরনে জৈবিক উপাদানের সমতুল্য তিনটি অংশ থাকে:

- ইনপুট ($x_1, x_2, \dots, x_n$): যে উপাত্ত বা বৈশিষ্ট্য গ্রহণ করা হয়।
- ওজন ($w_1, w_2, \dots, w_n$): প্রতিটি ইনপুটের গুরুত্ব নির্দেশ করে — জৈবিক সিন্যাপসের সংযোগ-শক্তির সমতুল্য।

- বায়াস (b): নিউরনের অভ্যন্তরীণ ঝাঁক, যা নির্ধারণ করে নিউরনটি কত সহজে ফায়ার করবে (b = -Threshold)।

নিউরনটি প্রথমে ইনপুট ও ওজনের ভারিত সমষ্টি নির্ণয় করে:

$$z = \sum_{i=1}^n x_i w_i + b$$

এখানে x_i হলো i -তম ইনপুট, w_i তার সংশ্লিষ্ট ওজন, এবং b বায়াস। যোগফল z নির্ণয়ের পর তা একটি এক্টিভেশন ফাংশনের (Activation Function) মধ্য দিয়ে চালিত হয়, যা সিদ্ধান্ত নেয় নিউরনটি উদ্দীপিত হবে কি না। পারসেপট্রনে ব্যবহৃত হয় স্টেপ ফাংশন (Step Function), যা জৈবিক All-or-None নীতি অনুসরণ করে — z শূন্য বা তার বেশি হলে আউটপুট ১ (নিউরন ফায়ার করেছে), নইলে আউটপুট ০।

১.৬.১ ওজন ও বায়াস সংশোধন প্রক্রিয়া (Perceptron Learning Rule)

একটি পারসেপট্রন ভুল থেকে কীভাবে শেখে, তা নির্ধারণ করে Perceptron Learning Rule, যা পরবর্তীতে ব্যাকপ্রোপাগেশন ও গ্রেডিয়েন্ট ডিসেন্টের ভিত্তি স্থাপন করেছে। মডেলের পূর্বাভাস $\hat{y}$ এবং প্রকৃত লক্ষ্য y হলে, ত্রুটি নির্ণিত হয়:

$$Error = y - \hat{y}$$

এখানে y ও $\hat{y}$ উভয়ের মান ০ বা ১ হওয়ায়, ত্রুটির তিনটি সম্ভাব্য মান থাকতে পারে: Error = 0 (সঠিক অনুমান, কোনো পরিবর্তন প্রয়োজন নেই), Error = 1 (ইনপুটকে শক্তিশালী করতে হবে), এবং Error = -1 (ইনপুটকে দুর্বল করতে হবে)। প্রতিটি ইনপুট সংযোগের ওজন এরপর নিচের সূত্র অনুযায়ী পরিবর্তিত হয়:

Weight Update Formula

$$w_i^{(new)} = w_i^{(old)} + \Delta w_i$$

Change in Weight

$$\Delta w_i = \eta (y - \hat{y}) x_i$$

একসাথে লিখলে

$$w_i^{(new)} = w_i^{(old)} + \eta (y - \hat{y}) x_i$$

এখানে η (ইটা / Learning Rate) হলো শিক্ষণের গতি বা ধাপের পরিমাণ (সাধারণত ০.০১ থেকে ০.১-এর মধ্যে), $(y - \hat{y})$ ত্রুটির দিক ও পরিমাণ নির্দেশ করে, এবং x_i সংশ্লিষ্ট ইনপুটের মান — ইনপুট শূন্য হলে সেই ওজনে কোনো পরিবর্তন হয় না। বায়াসের ইনপুট সর্বদা ১ ধরা হয় বলে বায়াস আপডেটে ইনপুটের কোনো প্রভাব থাকে না:

$$b^{(new)} = b^{(old)} + \eta (y - \hat{y})$$

১.৬.২ ব্যবহারিক উদাহরণ: AND গেট শেখানো

ধরা যাক, আমরা একটি পারসেপ্ট্রনকে AND Gate শেখাতে চাই, যার নিয়ম হলো — উভয় ইনপুট ১ হলেই কেবল আউটপুট ১, অন্য সব ক্ষেত্রে আউটপুট ০। প্রাথমিক অবস্থায় ধরে নিই $w_1 = 0.3$, $w_2 = 0.8$, বায়াস $b = -0.5$ এবং লার্নিং রেট $\eta = 0.1$ ।

ধাপ ১ — ইনপুট (1, 1), প্রকৃত উত্তর $y = 1$

সমষ্টিগত ইনপুট (Linear Combination) নির্ণয় করলে পাই:

$$z = (1 \times 0.3 + 1 \times 0.4) - 0.5 = 0.2$$

যেহেতু $z = 0.2 \geq 0$, তাই স্টেপ এক্টিভেশন ফাংশন অনুযায়ী নিউরনের আউটপুট হবে
 $\hat{y} = 1$

এখন প্রকৃত লক্ষ্যমান (True Label) এবং পূর্বাভাস (Prediction)-এর মধ্যে ত্রুটি (Error) নির্ণয় করলে পাই,
 $\text{Error} = y - \hat{y} = 1 - 1 = 0$

অর্থাৎ, মডেলটি সঠিকভাবে পূর্বাভাস দিতে সক্ষম হয়েছে। যেহেতু ত্রুটির মান শূন্য, তাই ওজন (Weight) এবং বায়াস (Bias)-এর কোনো পরিবর্তন (Update) করার প্রয়োজন নেই। বর্তমান মানগুলোই পরবর্তী ধাপের জন্য অপরিবর্তিত থাকবে।

ধাপ ২ — ইনপুট (1, 0), প্রকৃত উত্তর $y = 0$ (ধরি সাময়িকভাবে $w_1 = 0.6$, $w_2 = 0.4$, $b = -0.5$)

সমষ্টিগত ইনপুট (Linear Combination) নির্ণয় করলে পাই:

$$z = (1 \times 0.6 + 0 \times 0.4) - 0.5 = 0.1$$

যেহেতু $z = 0.1 \geq 0$, তাই স্টেপ এক্টিভেশন ফাংশন অনুযায়ী নিউরনের পূর্বাভাস হবে
 $\hat{y} = 1$

কিন্তু প্রকৃত লক্ষ্যমান (True Label) হলো

$$y = 0$$

সুতরাং ত্রুটি (Error) নির্ণয় করলে পাই,

$$\text{Error} = y - \hat{y} = 0 - 1 = -1$$

ঋণাত্মক ত্রুটি নির্দেশ করে যে মডেলটি ভুলভাবে ধনাত্মক (Positive) শ্রেণি পূর্বাভাস দিয়েছে। তাই Perceptron Learning Rule অনুযায়ী ওজন (Weight) এবং বায়াস (Bias) হালনাগাদ (Update) করতে হবে।

Weight w_1 আপডেট:

$$\begin{aligned} \Delta w_1 &= \eta (y - \hat{y}) x_1 = 0.1 \times (-1) \times 1 = -0.1 \\ w_1^{(new)} &= 0.6 + (-0.1) = 0.5 \end{aligned}$$

Weight w_2 আপডেট:

যেহেতু $x_2 = 0$,

$$\Delta w_2 = 0.1 \times (-1) \times 0 = 0$$

তাই,

$$w_2^{(new)} = 0.4$$

Bias আপডেট:


$$\Delta b = 0.1 \times (-1) = -0.1$$
$$b^{(new)} = -0.5 + (-0.1) = -0.6$$

অতএব, আপডেটের পর নতুন প্যারামিটারগুলো হবে:

$$w_1 = 0.5, w_2 = 0.4, b = -0.6$$

অর্থাৎ, ভুল পূর্বাভাসের কারণে Perceptron Learning Rule ওজন ও বায়াসকে এমনভাবে সংশোধন করেছে, যাতে পরবর্তী পুনরাবৃত্তিতে (Iteration) মডেলটি আরও সঠিক সিদ্ধান্ত নেওয়ার সম্ভাবনা বৃদ্ধি পায়।

এভাবে সম্পূর্ণ ডেটাসেটের উপর বারবার (Epoch) এই চক্র চালিয়ে গেলে পারসেপ্ট্রনটি এমন একটি ওজন ও বায়াসের মানে পৌঁছায় যেখানে সবকটি ইনপুটের জন্য Error = 0 হয়ে যায় — অর্থাৎ মডেলটি সম্পূর্ণভাবে AND গেটের যুক্তি শিখে ফেলে।



চিত্র ১.৫: পারসেপ্ট্রনের গাণিতিক গঠন — ইনপুট, ওজন, বায়াস ও এক্টিভেশন ফাংশনের সমন্বয়।

১.৭ বাস্তব জীবনে ডীপ লার্নিংয়ের প্রয়োগ

ডীপ লার্নিং এখন আর শুধু গবেষণাগারের বিষয় নয়; জটিল ও অসংগঠিত উপাত্ত (ছবি, অডিও, ভিডিও, টেক্সট) বিশ্লেষণ করে প্যাটার্ন খুঁজে বের করার ক্ষমতার কারণে এটি আজ আমাদের দৈনন্দিন জীবনের বহু প্রযুক্তির নীরব চালিকাশক্তি।

স্বাস্থ্যসেবা (Healthcare)

এক্স-রে, এমআরআই ও সিটি স্ক্যান বিশ্লেষণ করে টিউমার বা হাড়ের ফাটল শনাক্ত করতে কনভোলিউশনাল নিউরাল নেটওয়ার্ক (CNN) ব্যবহৃত হয়। এছাড়া ECG বা EEG-র মতো নয়েজযুক্ত বায়ো-সিগন্যাল পরীক্ষার করে হৃদরোগের পূর্বাভাস দেওয়া এবং AlphaFold-এর মতো মডেল দিয়ে প্রোটিনের গঠন অনুমান করে ওষুধ আবিষ্কার ত্বরান্বিত করা সম্ভব হচ্ছে।

ব্যবসা ও ই-কমার্স (Business & E-Commerce)

ইউটিউব, নেটফ্লিক্স বা অ্যামাজনে যে সুপারিশ ব্যবস্থা (recommendation engine) আমাদের পছন্দ অনুযায়ী নতুন কনটেন্ট সাজেস্ট করে, তার ভিত্তি ডীপ লার্নিং। অর্থসংস্থানে এটি লেনদেনের ধরন

বিশ্লেষণ করে জালিয়াতি (fraud) মুহূর্তের মধ্যে শনাক্ত করে এবং অ্যালগরিদমভিত্তিক ট্রেডিং সিদ্ধান্তে সহায়তা করে।

প্রাকৃতিক ভাষা প্রক্রিয়াকরণ (NLP)

ট্রান্সফরমার আর্কিটেকচারভিত্তিক মডেল (যেমন আধুনিক চ্যাটবট ও ভার্চুয়াল অ্যাসিস্ট্যান্ট) মানুষের ভাষার প্রেক্ষাপট বুঝে উত্তর দিতে, তাৎক্ষণিক অনুবাদ করতে এবং কথাকে লিখিত টেক্সটে রূপান্তর করতে সক্ষম।

ছবি ও কম্পিউটার ভিশন

স্মার্টফোনের ফেস আনলক, বিমানবন্দরের বায়োমেট্রিক যাচাই এবং সিসিটিভি ফুটেজে সন্দেহজনক কার্যকলাপ শনাক্তকরণ — এসবই কম্পিউটার ভিশনের বাস্তব প্রয়োগ, যেখানে ছবির প্রতিটি পিক্সেল বিশ্লেষণ করে সিদ্ধান্ত নেওয়া হয়।

স্বয়ংক্রিয় যানবাহন

চালকবিহীন গাড়িতে ক্যামেরা, লিডার ও রাডার থেকে আসা তথ্য বিশ্লেষণ করে পথচারী ও অন্যান্য যানবাহন শনাক্ত করতে ডীপ লার্নিং ব্যবহৃত হয়, পাশাপাশি যন্ত্রাংশের সেন্সর ডেটা বিশ্লেষণ করে পূর্বাভাসমূলক রক্ষণাবেক্ষণও (predictive maintenance) সম্ভব হয়েছে।

ক্ষেত্র	প্রধান প্রযুক্তি/মডেল	মূল উদ্দেশ্য
স্বাস্থ্যসেবা	CNN, অটোএনকোডার	রোগ শনাক্তকরণ ও সিগন্যাল ক্লিনিং
স্বয়ংক্রিয় যানবাহন	CNN, ট্রান্সফরমার	রিয়েল-টাইম অবজেক্ট ডিটেকশন
অর্থসংস্থান	অ্যানোমালি ডিটেকশন নেটওয়ার্ক	জালিয়াতি রোধ ও বাজার বিশ্লেষণ
ভাষা ও ভয়েস	ট্রান্সফরমার (Attention)	ভয়েস অ্যাসিস্ট্যান্ট ও অনুবাদ
ই-কমার্স	ডীপ কোলাবোরেশন ফিল্টারিং	ব্যক্তিগতকৃত কনটেন্ট সাজেশন

১.৭.১ হার্ডওয়্যার প্রেক্ষাপট: CPU বনাম GPU

ডীপ লার্নিং মডেলে বিপুল সংখ্যক ম্যাট্রিক্স গণনা সমান্তরালভাবে সম্পন্ন করতে হয় বলে বিশেষায়িত হার্ডওয়্যার প্রয়োজন হয়।

বৈশিষ্ট্য	CPU	GPU
গঠন	কম কিন্তু শক্তিশালী কোর	হাজার হাজার ছোট কোর
উপযোগিতা	ক্রমিক (sequential) হিসাব	সমান্তরাল (parallel) হিসাব

বৈশিষ্ট্য	CPU	GPU
ডীপ লার্নিংয়ে ব্যবহার	ছোট মডেল, প্রি/পোস্ট-প্রসেসিং	বড় মডেলের প্রশিক্ষণ ও ইনফারেন্স

অধ্যায় সারসংক্ষেপ

- ডীপ লার্নিং হলো মেশিন লার্নিংয়ের এমন একটি শাখা, যেখানে বহুস্তরীয় নিউরাল নেটওয়ার্ক ব্যবহার করে যন্ত্র বিপুল উপাত্ত থেকে নিজে থেকেই প্যাটার্ন শিখে নেয়।
- মানব মস্তিষ্কের নিউরন ও থ্রেশহোল্ড-ভিত্তিক ফ্যারিং প্রক্রিয়াই কৃত্রিম নিউরাল নেটওয়ার্কের মূল অনুপ্রেরণা।
- প্রথাগত মেশিন লার্নিং ম্যানুয়াল ফিচার ইঞ্জিনিয়ারিং ও সীমিত স্কেলেবিলিটির কারণে অসংগঠিত উপাত্তে সীমাবদ্ধ; ডীপ লার্নিং স্বয়ংক্রিয় ফিচার নিষ্কাশনের মাধ্যমে এই সীমাবদ্ধতা অতিক্রম করে।
- পারসেপ্ট্রন হলো কৃত্রিম নিউরাল নেটওয়ার্কের সবচেয়ে মৌলিক একক, যা $z = \sum x_i w_i + b$ সমীকরণ ও একটি এক্টিভেশন ফাংশনের মাধ্যমে কাজ করে।
- নেটওয়ার্ক পূর্বাভাস, তুলনা ও সংশোধন — এই তিন ধাপের মাধ্যমে ধীরে ধীরে ত্রুটি কমিয়ে সঠিক সিদ্ধান্ত নিতে শেখে।
- স্বাস্থ্যসেবা, ব্যবসা, ভাষা প্রক্রিয়াকরণ, কম্পিউটার ভিশন ও স্বয়ংক্রিয় যানবাহন — বাস্তব জীবনের প্রায় প্রতিটি ক্ষেত্রেই ডীপ লার্নিংয়ের ব্যাপক প্রয়োগ দেখা যায়।

গুরুত্বপূর্ণ সংজ্ঞা

- ডীপ লার্নিং (Deep Learning): বহুস্তরীয় নিউরাল নেটওয়ার্কভিত্তিক মেশিন লার্নিংয়ের একটি শাখা যা স্বয়ংক্রিয়ভাবে ফিচার শেখে।
- নিউরন (Neuron): তথ্য গ্রহণ, বিশ্লেষণ ও প্রেরণকারী মৌলিক একক — জৈবিক ও কৃত্রিম উভয় অর্থেই।
- পারসেপ্ট্রন (Perceptron): একটি একক-স্তরবিশিষ্ট কৃত্রিম নিউরন, যা ইনপুট, ওজন, বায়াস ও এক্টিভেশন ফাংশন দিয়ে গঠিত।
- এক্টিভেশন ফাংশন (Activation Function): যে ফাংশন নির্ধারণ করে নিউরনটি উদ্দীপিত হবে কি না।
- লার্নিং রেট (Learning Rate, η): প্রতিটি ধাপে ওজন কতটা পরিবর্তিত হবে তা নিয়ন্ত্রণকারী প্যারামিটার।

গুরুত্বপূর্ণ সূত্রাবলি

- **Weighted Sum:** $z = \sum_{i=1}^n x_i w_i + b$
- **Error Calculation:** $\text{Error} = y - \hat{y}$
- **Weight Update Rule:** $w_i^{(\text{new})} = w_i^{(\text{old})} + \eta (y - \hat{y}) x_i$
- **Bias Update Rule:** $b^{(\text{new})} = b^{(\text{old})} + \eta (y - \hat{y})$

সাধারণ ইন্টারভিউ প্রশ্ন

1. মেশিন লার্নিং ও ডীপ লার্নিংয়ের মধ্যে মূল পার্থক্য কী?
2. পারসেপ্ট্রন কেন XOR সমস্যার সমাধান করতে পারে না?

3. লার্নিং রেট খুব বড় বা খুব ছোট হলে প্রশিক্ষণে কী প্রভাব পড়ে?
4. কেন ডীপ লার্নিং মডেলকে প্রায়ই 'Black Box' বলা হয়?
5. GPU কেন ডীপ লার্নিং প্রশিক্ষণে CPU-র চেয়ে বেশি কার্যকর?

বহুনির্বাচনী প্রশ্ন (MCQ)

1. ডীপ লার্নিং মূলত কোন ধরনের কাঠামোর উপর নির্ভরশীল?
 - (a) (ক) সিদ্ধান্ত বৃক্ষ
 - (b) (খ) বহুস্তরীয় কৃত্রিম নিউরাল নেটওয়ার্ক
 - (c) (গ) লিনিয়ার রিগ্রেশন
 - (d) (ঘ) K-Means ক্লাস্টারিং
2. পারসেপ্ট্রনের বায়াস (b) গাণিতিকভাবে কীসের সমতুল্য?
 - (e) (ক) লার্নিং রেট
 - (f) (খ) ঋণাত্মক থ্রেশহোল্ড
 - (g) (গ) ইনপুটের সংখ্যা
 - (h) (ঘ) এক্টিভেশন ফাংশন
3. নিচের কোনটি অসংগঠিত উপাত্তের (unstructured data) উদাহরণ নয়?
 - (i) (ক) ছবি
 - (j) (খ) অডিও রেকর্ডিং
 - (k) (গ) এক্সেল স্প্রেডশিট
 - (l) (ঘ) প্রাকৃতিক ভাষার টেক্সট

সংক্ষিপ্ত প্রশ্নাবলি

4. 'All-or-None Principle' বলতে কী বোঝায়?
5. স্বয়ংক্রিয় ফিচার নিষ্কাশন কীভাবে ডীপ লার্নিংকে প্রথাগত ML থেকে আলাদা করে?
6. লার্নিং রেট (η)-এর ভূমিকা কী?

পর্যালোচনা প্রশ্নাবলি

6. একটি বাস্তব উদাহরণ দিয়ে ব্যাখ্যা করো কেন ছবি শনাক্তকরণে প্রথাগত মেশিন লার্নিংয়ের চেয়ে ডীপ লার্নিং বেশি কার্যকর।
7. পারসেপ্ট্রনের গাণিতিক গঠন ব্যাখ্যা করে দেখাও কীভাবে এটি ওজন ও বায়াস আপডেট করে ভুল থেকে শেখে।
8. স্বাস্থ্যসেবা ও অর্থসংস্থান — এই দুটি ক্ষেত্রে ডীপ লার্নিংয়ের প্রয়োগ তুলনা করো।

ব্যবহারিক অনুশীলনী

প্রাথমিক ওজন $w_1 = 0.2$, $w_2 = 0.2$, বায়াস $b = -0.2$ এবং লার্নিং রেট $\eta = 0.1$ ধরে একটি পারসেপ্ট্রনকে OR Gate শেখানোর জন্য প্রথম দুটি ইনপুট (0,1) ও (1,0)-এর জন্য ওজন ও বায়াস আপডেটের হিসাব ধাপে ধাপে করো, এবং প্রতিটি ধাপের পর z , $\hat{y}$ ও Error-এর মান লেখো।