


Machine Learning Models



Md. Shaon Khan

B.Sc. in Information Technology — IIT, Jahangirnagar University

সূচিপত্র (Table of Contents)

- অধ্যায় ১ — Simple Linear Regression
- অধ্যায় ২ — Multiple Linear Regression
- অধ্যায় ৩ — Ordinary Least Squares (OLS)
- অধ্যায় ৪ — Logistic Regression
- অধ্যায় ৫ — K-Nearest Neighbors (KNN)
- অধ্যায় ৬ — GridSearchCV in KNN
- অধ্যায় ৭ — Decision Tree
- অধ্যায় ৮ — Random Forest
- অধ্যায় ৯ — Support Vector Machine
- অধ্যায় ১০ — K-Mean Clustering

Simple Linear Regression

১. মূল সমীকরণ (The Core Formula)

সিম্পল লিনিয়ার রিগ্রেশন মূলত একটি ইনপুট ফিচার (X) এবং একটি আউটপুট টার্গেটের (y) মধ্যে সরলরৈখিক সম্পর্ক তৈরি করে। এর গাণিতিক সূত্রটি হলো:

$$\hat{y} = wX + b$$

$\hat{y}$ (y-hat): মডেলের প্রেডিক্ট করা মান (Predicted Value)

X: ইনপুট ফিচার (Independent Variable)

w (Weight/Slope): রেখাটির ঢাল। X এক ইউনিট বাড়লে y কতটুকু বাড়বে বা কমবে, তা w নির্ধারণ করে

b (Bias/Intercept): ইন্টারসেপ্ট। X-এর মান 0 হলে y-এর মান কত হবে, তা এটি নির্দেশ করে

২. কস্ট ফাংশন (Cost Function)

মডেলের প্রেডিকশন আসল ডেটার তুলনায় কতটা ভুল করছে, তা পরিমাপ করার জন্য Mean Squared Error (MSE) কস্ট ফাংশন ব্যবহার করা হয়। এর গাণিতিক রূপ:

$$J(w, b) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

যেহেতু

$$\hat{y}_i = wX_i + b$$

তাই সমীকরণটি দাঁড়ায়:

$$J(w, b) = \frac{1}{n} \sum_{i=1}^n (wX_i + b - y_i)^2$$

n: মোট ডেটা স্যাম্পলের সংখ্যা

y_i : আসল মান (Actual Value)

$\hat{y}_i$: মডেলের প্রেডিক্ট করা মান

৩. কস্ট ফাংশনের ডেরিভেটিভ (Partial Derivatives)

গ্রাডিয়েন্ট ডিসেন্ট পদ্ধতিতে কস্ট ফাংশন (J) এর মান সর্বনিম্ন করার জন্য আমাদের জানতে হবে w এবং b পরিবর্তনের সাথে সাথে কস্ট কতটা পরিবর্তিত হচ্ছে। এর জন্য ক্যালকুলাসের চেইন রুল (Chain Rule) ব্যবহার করে আংশিক অন্তরীকরণ (Partial Derivative) করা হয়:

w-এর সাপেক্ষে ডেরিভেটিভ (dJ/dw):

$$\frac{\partial J}{\partial w} = \frac{2}{n} \sum_{i=1}^n (w X_i + b - y_i) \cdot X_i$$

b-এর সাপেক্ষে ডেরিভেটিভ (dJ/db):

$$\frac{\partial J}{\partial b} = \frac{2}{n} \sum_{i=1}^n (w X_i + b - y_i)$$

(এখানে $wX_i + b - y_i$ অংশটি হলো মূলত প্রেডিকশন এবং আসল মানের মধ্যকার ভুল বা Error)

৪. প্যারামিটার আপডেট সূত্র (Weight & Bias Update)


প্রতিটি ইটারেশনে বা লুপে প্রাপ্ত গ্রাডিয়েন্ট বা ডেরিভেটিভের ওপর ভিত্তি করে লার্নিং রেট (α) গুণ করে w এবং b-কে আপডেট করা হয়, যাতে তারা আস্তে আস্তে সঠিক মানের দিকে এগোতে পারে:

$$w = w - \alpha \cdot \frac{\partial J}{\partial w}$$
$$b = b - \alpha \cdot \frac{\partial J}{\partial b}$$

α (Alpha): লার্নিং রেট (Learning Rate)। এটি নির্ধারণ করে মডেল কতটা বড় বা ছোট স্টেপ ফেলে গ্লোবাল মিনিমামের দিকে নামবে

৫. কস্ট ফাংশন গ্রাফ (Cost Function Graph)

লিনিয়ার রিগ্রেশনের কস্ট ফাংশনের গ্রাফটি দেখতে একটি বাটি বা বোলের (Bowl) মতো হয়, যাকে গাণিতিক ভাষায় Convex Function বলা হয়। গ্রাডিয়েন্ট ডিসেন্ট পাহাড়ের চূড়া থেকে আস্তে আস্তে পা ফেলে বাটির একদম তলানিতে পৌঁছানোর চেষ্টা করে, যেখানে ভুলের পরিমাণ সবচেয়ে কম।



ব্যাকএন্ডে কীভাবে কাজ করে? (Full Backend Workflow)

ধরা যাক, আমাদের কাছে একটি ডেটাসেট আছে। ব্যাকএন্ডে পুরো প্রসেসটি নিচের ধাপে ধাপে সম্পন্ন হয়:

- Initialization: শুরুতেই কম্পিউটার আন্দাজে $w = 0$ এবং $b = 0$ ধরে নেয়
- Forward Pass (Prediction): এই প্রাথমিক w এবং b দিয়ে পুরো ডেটাসেটের জন্য $\hat{y} = wX + b$ সূত্র ব্যবহার করে প্রেডিকশন হিসাব করা হয়
- Compute Cost: প্রেডিকশন বের করার পর আসল মানের সাথে তুলনা করে MSE সূত্রের মাধ্যমে বর্তমান কস্ট বা ভুলের পরিমাণ (J) মাপা হয়
- Backward Pass (Gradient Computation): আংশিক অন্তরীকরণের সূত্রের মাধ্যমে বর্তমান ভুলের জন্য w এবং b কতটা দায়ী (অর্থাৎ গ্রাডিয়েন্ট $\partial J/\partial w$ এবং $\partial J/\partial b$) তা ক্যালকুলেট করা হয়
- Update Parameters: এই গ্রাডিয়েন্ট ব্যবহার করে w এবং b -এর পুরানো মান থেকে লার্নিং রেট গুণ করে নতুন মান আপডেট করা হয়
- Iteration: এই ২ থেকে ৫ নম্বর ধাপটি লুপের মাধ্যমে হাজার হাজার বার (যেমন 1,500 বার) চলতে থাকে। প্রতিবারে বাটের তলানির দিকে নামতে নামতে কস্ট কমতে থাকে এবং একপর্যায়ে স্থির হয়ে যায়

From Scratch (No Scikit-Learn)

```
1 import numpy as np
2
3 def make_prediction(X, w, b):
4     return w * X + b
5
6 def cost_function(X, y, w, b):
7     n = len(y)
8     y_pred = make_prediction(X, w, b)
9     return (1 / n) * np.sum((y_pred - y) ** 2)
10
11 def calculate_gradient(X, y, w, b):
12     n = len(y)
13     y_pred = make_prediction(X, w, b)
14     dw = (2 / n) * np.sum((y_pred - y) * X)
15     db = (2 / n) * np.sum((y_pred - y))
16     return dw, db
17
18 def gradient_descent(X, y, w, b, lr, epochs):
19     for i in range(epochs):
20         dw, db = calculate_gradient(X, y, w, b)
21         w = w - lr * dw
22         b = b - lr * db
23         if i % 100 == 0:
24             print("epoch:", i, "cost:", cost_function(X, y, w, b))
25     return w, b
26
27 X = np.array([1, 2, 3, 4, 5])
28 y = np.array([2, 4, 6, 8, 10])
29
30 w, b = gradient_descent(X, y, 0, 0, 0.01, 1000)
31
32 print("Final w:", w)
33 print("Final b:", b)
```

Linear Regression using Scikit Learn

```

1 import numpy as np
2 from sklearn.linear_model import LinearRegression, SGDRegressor
3 from sklearn.preprocessing import StandardScaler
4
5 X = np.array([1, 2, 3, 4, 5]).reshape(-1, 1)
6 y = np.array([2, 4, 6, 8, 10])
7
8 lr_model = LinearRegression()
9 lr_model.fit(X, y)
10
11 print("Linear Regression")
12 print("w:", lr_model.coef_[0])
13 print("b:", lr_model.intercept_)
14
15 print("Pred:", lr_model.predict(X))

```

SDG Regression using Scikit Learn

```

18 scaler = StandardScaler()
19 X_scaled = scaler.fit_transform(X)
20
21 sgd_model = SGDRegressor(
22     learning_rate="constant",
23     eta0=0.01,
24     max_iter=1000,
25     tol=1e-3
26 )
27
28 sgd_model.fit(X_scaled, y)
29
30 print("\nSGD Regression")
31 print("w:", sgd_model.coef_[0])
32 print("b:", sgd_model.intercept_[0])
33 print("Pred:", sgd_model.predict(X_scaled))

```

কেন এটি প্রয়োজন (Why We Need It)

বাস্তব জীবনে এমন অনেক সমস্যা আছে যেখানে দুটি ভেরিয়েবলের মধ্যে একটি Approximate Linear সম্পর্ক বিদ্যমান — যেমন পড়াশোনার সময় বনাম পরীক্ষার নম্বর, বাসার আয়তন বনাম

মূল্য, বিজ্ঞাপনে ব্যয় বনাম বিক্রয়। Simple Linear Regression এই সম্পর্কটি গাণিতিকভাবে মডেল করে ভবিষ্যদ্বাণী করতে সাহায্য করে।

Assumptions

- Linearity: X ও y-এর মধ্যে সম্পর্ক সরলরৈখিক হতে হবে
- Independence: Observation-গুলো একে অপরের থেকে স্বাধীন (independent) হতে হবে
- Homoscedasticity: Residual-এর Variance সব জায়গায় প্রায় সমান থাকতে হবে
- Normality of Residuals: Error term-গুলো Normal Distribution অনুসরণ করা উচিত

Advantages ও Disadvantages

Advantages	Disadvantages / Limitations
সহজ, দ্রুত এবং Interpretable	শুধু Linear সম্পর্কের জন্য কার্যকর
কম কম্পিউটেশনাল রিসোর্সে চলে	Outlier-এর প্রতি অত্যন্ত sensitive
Closed-form (OLS) সমাধান বিদ্যমান	Multicollinearity হলে সমস্যা হয় (Multiple Feature-এ প্রযোজ্য)
IMPORTANT NOTE MSE সবসময় Non-negative এবং একটি Convex Function — তাই Gradient Descent ব্যবহার করে এর একটি Unique Global Minimum খুঁজে পাওয়া সম্ভব।	
PRACTICAL INSIGHT Forward Pass → Compute Cost → Backward Pass → Update — এই চক্রটিই প্রায় সকল Gradient-Based Machine Learning ও Deep Learning Model-এর মূল ভিত্তি। এই ৪টি ধাপ ভালোভাবে আত্মস্থ করলে Neural Network-এর Backpropagation বুঝতেও সুবিধা হয়।	
REAL-WORLD EXAMPLE হাউজিং মার্কেটে শুধুমাত্র বাসার আয়তন (sq ft) দিয়ে আনুমানিক মূল্য নির্ধারণ, কোনো প্রতিষ্ঠানের বিজ্ঞাপন ব্যয় থেকে বিক্রয় পরিমাণ পূর্বাভাস, কিংবা পড়াশোনার ঘণ্টা থেকে পরীক্ষার নম্বর অনুমান করা — এসব ক্ষেত্রে Simple Linear Regression ব্যাপকভাবে ব্যবহৃত হয়।	
COMMON MISTAKE	

Outlier বাদ না দিয়ে সরাসরি Model Train করা — এতে Slope (w) মারাত্মকভাবে প্রভাবিত হতে পারে।

Feature ও Target-এর মধ্যে সম্পর্ক Non-linear হলেও জোর করে Linear Model ব্যবহার করা।

Learning Rate (α) অত্যধিক বড় নেওয়া, যার ফলে Gradient Descent Diverge করে।

INTERVIEW TIP

Q: কেন আমরা MSE-তে error-কে square করি, absolute value নিই না কেন?

A: Square করলে ফাংশনটি Differentiable এবং Convex হয়, ফলে Gradient Descent সহজে কাজ করতে পারে; এছাড়া বড় error-কে বেশি penalize করা যায়।

Q: OLS এবং Gradient Descent-এর মধ্যে পার্থক্য কী?

A: OLS একটি Closed-form, একবারেই সমাধানকারী পদ্ধতি; Gradient Descent ধাপে ধাপে Iterative ভাবে Optimal মান খুঁজে বের করে।

Quick Revision Notes — Simple Linear Regression

Category	Key Points
Key Formula	$\hat{y} = wX + b$; $J(w,b) = (1/n)\sum(\hat{y}_i - y_i)^2$
Gradient	$\partial J / \partial w = (2/n)\sum(\text{error} \cdot X)$; $\partial J / \partial b = (2/n)\sum(\text{error})$
Update Rule	$w := w - \alpha \cdot \partial J / \partial w$; $b := b - \alpha \cdot \partial J / \partial b$
Cost Surface	Convex (bowl-shaped) → guarantees a global minimum
Exam Focus	Derive gradients via chain rule; explain why MSE is convex
Interview Focus	Assumptions of linear regression; OLS vs Gradient Descent

Multiple Linear Regression

মাল্টিপল লিনিয়ার রিগ্রেশন (Multiple Linear Regression)

মাল্টিপল লিনিয়ার রিগ্রেশন মূলত সিম্পল লিনিয়ার রিগ্রেশনেরই সম্প্রসারিত রূপ, যেখানে একাধিক ইনপুট ফিচার $X_1, X_2, \dots, X_m$ ব্যবহার করা হয়।

১. মূল সমীকরণ (The Core Formula)

যখন একাধিক ফিচার থাকে, তখন প্রেডিকশন হয়:

$$\hat{y} = w_1X_1 + w_2X_2 + \dots + w_mX_m + b$$

এটিকে ভেক্টরাইজড ফর্মে লেখা হয়:

$$\hat{y} = XW + b$$

যেখানে:

- X : ইনপুট ফিচার ম্যাট্রিক্স (সাইজ $n \times m$)
- W : ওয়েট ভেক্টর $[w_1, w_2, \dots, w_m]^T$
- b : বায়াস (স্কেলার)
- $\hat{y}$: প্রেডিক্টেড আউটপুট

২. কস্ট ফাংশন (Cost Function)

Mean Squared Error (MSE):

$$J(W, b) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

ভেক্টর ফর্মে:

$$J(W, b) = \frac{1}{n} \|XW + b - y\|^2$$

৩. কস্ট ফাংশনের ডেরিভেটিভ (Partial Derivatives)

ওয়েটের জন্য গ্রাডিয়েন্ট:

$$\frac{\partial J}{\partial W} = \frac{2}{n} X^T (XW + b - y)$$

বায়াসের জন্য গ্রাডিয়েন্ট:


$$\frac{\partial J}{\partial b} = \frac{2}{n} \sum_{i=1}^n (XW + b - y)$$

৪. প্যারামিটার আপডেট (Weight & Bias Update)

$$W = W - \alpha \cdot \frac{\partial J}{\partial W}$$
$$b = b - \alpha \cdot \frac{\partial J}{\partial b}$$

৫. কস্ট ফাংশন গ্রাফ (Cost Function Graph)

মাল্টিপল ফিচারের ক্ষেত্রে কস্ট ফাংশন একটি **high-dimensional convex surface** তৈরি করে।
এটি দৃশ্যমানভাবে 2D বা 3D বাটি না হলেও গাণিতিকভাবে একটি মাত্র গ্লোবাল মিনিমাম থাকে।



ব্যাকএন্ড ওয়ার্কফ্লো (Full Backend Workflow)

- Initialization: $W = 0, b = 0$
- Forward Pass:

$$\hat{y} = XW + b$$

- Compute Cost: MSE দিয়ে error হিসাব
- Backward Pass:

$$X^T \cdot error$$

- Update Parameters: W এবং b আপডেট
- Convergence: লস মিনিমাম না হওয়া পর্যন্ত লুপ

Python Code

```
1 import numpy as np
2
3 X = np.array([
4     [1.0, 2100.0],
5     [2.0, 1500.0],
6     [3.0, 2800.0],
7     [4.0, 1200.0],
8     [5.0, 3200.0]
9 ])
10
11 y = np.array([45.0, 35.0, 60.0, 28.0, 70.0])
12
13 def predict(X, W, b):
14     return np.dot(X, W) + b
15
16 def compute_cost(X, y, W, b):
17     n = len(X)
18     return (1/n) * np.sum((predict(X, W, b) - y) ** 2)
19
20 def compute_gradient(X, y, W, b):
21     n = len(X)
22     error = predict(X, W, b) - y
23     dW = (2/n) * np.dot(X.T, error)
24     db = (2/n) * np.sum(error)
25     return dW, db
```



```

27 def gradient_descent(X, y, W, b, alpha, iters):
28     for i in range(iters):
29         dw, db = compute_gradient(X, y, W, b)
30
31         W = W - alpha * dw
32         b = b - alpha * db
33
34     return W, b
35
36 X_mean = np.mean(X, axis=0)
37 X_std = np.std(X, axis=0)
38 X_scaled = (X - X_mean) / X_std
39
40 W, b = gradient_descent(X_scaled, y, np.zeros(X.shape[1]), 0.0, 0.01, 50000)
41
42 print(W, b)

```

Using Scikit Learn

```

1 from sklearn.linear_model import LinearRegression, SGDRegressor
2 from sklearn.preprocessing import StandardScaler
3
4 lr = LinearRegression()
5 lr.fit(X, y)
6
7 print(lr.coef_, lr.intercept_)
8
9 scaler = StandardScaler()
10 X_scaled = scaler.fit_transform(X)
11
12 sgd = SGDRegressor(max_iter=10000, eta0=0.01, random_state=42)
13 sgd.fit(X_scaled, y)
14
15 print(sgd.coef_)
16 print(sgd.predict(X_scaled[:1]))

```

লিনিয়ার রিগ্রেশনের ক্ষেত্রে StandardScaler ব্যবহার না করলেও সাধারণত সমস্যা হয় না, কারণ LinearRegression মডেলটি একটি ডাইরেক্ট ম্যাথমেটিক্যাল সলিউশন (OLS) ব্যবহার করে একবারেই ওজন (w) এবং বায়াস (b) এর সঠিক মান বের করে ফেলে। এই পদ্ধতিতে কোনো ধাপে ধাপে ইটারেশন বা লার্নিং প্রসেস নেই, বরং সরাসরি একটি সূত্র ব্যবহার করা হয়: $(X^T X)^{-1} X^T y$ । ফলে ফিচারের মান বড় বা ছোট যাই হোক না কেন, এটি গ্লোবাল মিনিমাম সঠিকভাবে বের করতে পারে এবং স্কেলিং না করলেও এর আউটপুট সাধারণত পরিবর্তিত হয় না।

অন্যদিকে SGD (Stochastic Gradient Descent) সম্পূর্ণ ভিন্নভাবে কাজ করে। এটি ধাপে ধাপে ইটারেশনের মাধ্যমে ধীরে ধীরে সঠিক মানের দিকে এগিয়ে যায়। এখানে ফিচারের স্কেল বড় হলে গ্রাডিয়েন্ট হিসাবের সময় অত্যন্ত বড় মান তৈরি হতে পারে, যার ফলে ওয়েট হঠাৎ অনেক বেশি বেড়ে গিয়ে মডেল অস্থিতিশীল হয়ে যেতে পারে বা কস্ট ফাংশন ডাইভার্জ করে NaN হয়ে যেতে পারে। এছাড়া স্কেল না করা ডেটায় কস্ট ফাংশনের সারফেস অসম বা লম্বাটে হয়ে যায়, ফলে গ্রাডিয়েন্ট ডিসেন্ট সোজা পথে নামতে না পেরে জিগজ্যাগ পথে ধীরে ধীরে কনভার্জ করে। এই কারণে SGD ব্যবহার করার আগে StandardScaler দিয়ে ফিচারগুলোকে একই স্কেলে আনা একদম গুরুত্বপূর্ণ, যাতে ট্রেনিং স্থিতিশীল, দ্রুত এবং নির্ভুল হয়।

COMMON MISTAKE

SGDRegressor ব্যবহারের আগে StandardScaler প্রয়োগ না করা — এটি Training-কে অস্থিতিশীল করে দিতে পারে বা Cost Function NaN হয়ে যেতে পারে।

লিনিয়ার রিগ্রেশন (LinearRegression) এবং SGD কীভাবে কাজ করে

১. Linear Regression (OLS) কীভাবে কাজ করে

লিনিয়ার রিগ্রেশন একটি **direct mathematical solution** ব্যবহার করে। এখানে মডেল কোনো লুপ চালিয়ে শেখে না। বরং পুরো ডেটাসেট একবারে দেখে একটি নির্দিষ্ট গাণিতিক সূত্র ব্যবহার করে সরাসরি সেরা ওজন (w) এবং বায়াস (b) বের করে ফেলে।

এই সূত্রটি হলো:

$$\theta = (X^T X)^{-1} X^T y$$

এখানে মডেল আসলে এমনভাবে কাজ করে যেন সে বলছে:

“আমি পুরো ডেটা একসাথে দেখে সবচেয়ে সঠিক রেখাটা একবারেই হিসাব করে ফেলছি।”

- ◆ তাই এটি দ্রুত
- ◆ তাই এটি স্থিতিশীল
- ◆ এবং ছোট-মাঝারি ডেটাসেটের জন্য খুব ভালো

২. SGD (Stochastic Gradient Descent) কীভাবে কাজ করে

SGD সম্পূর্ণ ভিন্নভাবে কাজ করে। এটি কোনো সরাসরি সূত্র ব্যবহার করে না।

বরং এটি:

- প্রথমে w এবং b র্যান্ডমভাবে নেয়
- তারপর প্রতিটি ডেটা পয়েন্ট বা ছোট ব্যাচ দেখে

- ধাপে ধাপে ভুল কমানোর চেষ্টা করে
- প্রতিবার একটু একটু করে w এবং b আপডেট করে

এটা অনেকটা এমন:

“আমি অন্ধভাবে ধাপে ধাপে হাঁটছি, ভুল হলে দিক ঠিক করছি।”

এই আপডেট হয় এইভাবে:

$$w = w - \alpha \frac{\partial J}{\partial w}$$

৩. কখন কোনটা ব্যবহার করা উচিত

Linear Regression ব্যবহার করা ভালো যখন:

- ডেটাসেট ছোট বা মাঝারি (few thousand rows পর্যন্ত)
- তুমি দ্রুত এবং exact solution চাও
- কম্পিউটেশনাল রিসোর্স সমস্যা না
- ব্যাচ ট্রেনিং দরকার নেই

উদাহরণ:

- house price prediction
- simple business forecasting
- academic projects

SGD ব্যবহার করা ভালো যখন:

- ডেটাসেট অনেক বড় (millions of rows)
- online learning দরকার (data আসতে থাকে নতুন নতুন করে)
- memory সীমিত
- deep learning বা large-scale ML system

উদাহরণ:

- recommendation system
- real-time prediction system
- large-scale industrial ML

OLS (Ordinary Least Squares) কীভাবে কাজ করে

OLS হলো Linear Regression-এর একটি **closed-form solution** যেখানে মডেল কোনো iteration ছাড়াই সরাসরি best parameters (W, b) বের করে ফেলে।

১. Model Equation

Linear Regression-এর মূল সমীকরণ:

$$\hat{y} = XW + b$$

২. Cost Function (MSE)

OLS যেটা মিনিমাইজ করে:

$$J(W, b) = \frac{1}{n} \|XW + b - y\|^2$$

এটি মূলত prediction error-এর square mean।

৩. Goal of OLS

OLS-এর লক্ষ্য:

$$\min_{W, b} J(W, b)$$

অর্থাৎ এমন W এবং b খুঁজে বের করা যাতে error সবচেয়ে কম হয়।

৪. Bias Handling (Important Step)

গণনা সহজ করার জন্য b-কে X-এর সাথে যোগ করা হয়:

$$X' = [X \ 1]$$

এখন সমীকরণ হয়:

$$\hat{y} = X' \theta$$

যেখানে:

- θ = সব parameters (W এবং b একসাথে)

৫. Closed-form Solution (Main Formula)

OLS সরাসরি এই formula ব্যবহার করে solution বের করে:

$$\theta = (X^T X)^{-1} X^T y$$

৬. Step-by-step Mechanism

Step 1: Design Matrix তৈরি

$$X \rightarrow X'$$

Step 2: Matrix Multiplication

$$X^T X$$

Step 3: Inverse নেওয়া

$$(X^T X)^{-1}$$

Step 4: Final multiplication

$$\theta = (X^T X)^{-1} X^T y$$

IMPORTANT NOTE

OLS তখনই কাজ করে যখন $(X^T X)$ Invertible (Non-singular) হয়। যদি Feature-গুলোর মধ্যে Perfect Multicollinearity থাকে, তাহলে এই Matrix Singular হয়ে যায় এবং Inverse বের করা সম্ভব হয় না — এক্ষেত্রে Ridge Regression (L2 Regularization) ব্যবহার করে সমস্যাটি সমাধান করা হয়।

EXAM TIP

এই ছোট, হাতে-গণনাযোগ্য Example ($w=2, b=0$) পরীক্ষায় OLS Derivation বোঝাতে প্রায়ই আসে — Design Matrix তৈরি থেকে Final θ পর্যন্ত প্রতিটি ধাপ আলাদাভাবে দেখাতে পারলে পূর্ণ নম্বর পাওয়া যায়।

OLS (Ordinary Least Squares) — Example

ধরা যাক আমাদের কাছে একটি ছোট dataset আছে:

X (Study Hours)	y (Marks)
1	2
2	4
3	6

আমরা চাই relationship বের করতে:

$$\hat{y} = wX + b$$

১. Design Matrix তৈরি (Bias সহ)

OLS-এ bias যোগ করার জন্য X-কে expand করা হয়:

$$X = \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \end{bmatrix}$$

এখানে:

- প্রথম column = feature (X)
- দ্বিতীয় column = bias (1)

২. Target Vector

$$y = \begin{bmatrix} 2 \\ 4 \\ 6 \end{bmatrix}$$

৩. OLS Formula

$$\theta = (X^T X)^{-1} X^T y$$

এখানে:

$$\theta = \begin{bmatrix} w \\ b \end{bmatrix}$$

8. Step-by-step Calculation

Step 1: Transpose

$$X^T = \begin{bmatrix} 1 & 2 & 3 \\ 1 & 1 & 1 \end{bmatrix}$$

Step 2: Multiply $X^T X$

$$X^T X = \begin{bmatrix} 14 & 6 \\ 6 & 3 \end{bmatrix}$$

Step 3: Inverse

$$(X^T X)^{-1} = \begin{bmatrix} 1.5 & -3 \\ -3 & 7 \end{bmatrix}$$

Step 4: Multiply with $X^T y$

$$X^T y = \begin{bmatrix} 28 \\ 12 \end{bmatrix}$$

Final Result

$$\theta = \begin{bmatrix} w \\ b \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$

৫. Final Model

$$\hat{y} = 2X + 0$$

LinearRegression (sklearn.linear_model.LinearRegression)

এটি OLS (Ordinary Least Squares) এর closed-form solution ব্যবহার করে, তাই এখানে regularization বা learning-related কোনো parameter নেই। টিউন করার মতো parameter খুবই কম।

fit_intercept

Default: True

fit_intercept নির্ধারণ করে Model Bias Term (b বা intercept) শিখবে কিনা। True রাখলে Model $\hat{y} = wX + b$ সূত্রে b-এর মান হিসাব করে। False করলে Model ধরে নেয় Data ইতোমধ্যে Centered, অর্থাৎ $b = 0$ হয়ে যায়। বাস্তবে প্রায় সব ক্ষেত্রেই True রাখা উচিত।

copy_X

Default: True

copy_X নির্ধারণ করে Training-এর সময় Input Data (X) এর একটি Copy তৈরি করে কাজ করবে কিনা। True রাখলে Original Data অপরিবর্তিত থাকে এবং Model Copy-র উপর কাজ করে। False করলে Memory সাশ্রয় হয় কিন্তু Original X Overwrite হয়ে যেতে পারে, তাই সাধারণত True রাখাই নিরাপদ।

n_jobs

Default: None

n_jobs নির্ধারণ করে Computation-এর সময় কতগুলো CPU Core ব্যবহার করা হবে। n_jobs=-1 দিলে System-এর সব Available Core ব্যবহার হয়। এটি Model-এর Accuracy পরিবর্তন করে না, শুধুমাত্র Speed বাড়ায়। বিশেষত Multi-output Regression-এ এটি কার্যকর।

positive

Default: False

positive=True করলে Model সব Coefficient (w)-কে Non-negative অর্থাৎ শূন্য বা ধনাত্মক মানে সীমাবদ্ধ রাখে। যখন জানা থাকে যে Feature এবং Target-এর মধ্যে সম্পর্ক সবসময় ধনাত্মক (যেমন বিজ্ঞাপন খরচ বাড়লে বিক্রয় কমতে পারে না), তখন এটি ব্যবহার করা হয়।

SGDRegressor (sklearn.linear_model.SGDRegressor)

এটি Gradient Descent ভিত্তিক মডেল। এখানেই আসল hyperparameter tuning হয় এবং model performance-এর উপর সবচেয়ে বেশি প্রভাব ফেলে।

SGDRegressor (Stochastic Gradient Descent Regressor) হলো Scikit-Learn-এর একটি Linear Regression Model, যা Normal Equation ব্যবহার না করে Gradient Descent-এর মাধ্যমে Model-এর Weight শিখে। এটি বিশেষভাবে Large Dataset, Online Learning এবং এমন পরিস্থিতির জন্য উপযোগী যেখানে পুরো Dataset একসাথে Memory-তে রাখা সম্ভব নয়। প্রতিটি Training Example অথবা ছোট Batch ব্যবহার করে Weight Update করা হয়, ফলে Training অনেক দ্রুত হয়।

loss

Default: 'squared_error'

loss Parameter নির্ধারণ করে Model কোন Cost Function Minimize করবে। এটি Training-এর সময় Prediction Error কীভাবে পরিমাপ করা হবে তা নিয়ন্ত্রণ করে।

সাধারণ Linear Regression-এর ক্ষেত্রে squared_error সবচেয়ে বেশি ব্যবহৃত হয়। এখানে প্রতিটি Error Square করা হয়:

$$Loss = (y - \hat{y})^2$$

এর ফলে বড় Error-এর জন্য অনেক বেশি Penalty দেওয়া হয়। তাই Dataset-এ যদি Outlier না থাকে, তাহলে squared_error সাধারণত সর্বোত্তম ফলাফল দেয়।

কিন্তু Dataset-এ যদি অনেক Outlier থাকে, তাহলে huber Loss ব্যবহার করা ভালো। Huber Loss ছোট Error-এর জন্য Squared Loss এবং বড় Error-এর জন্য Linear Loss ব্যবহার করে। ফলে কয়েকটি অস্বাভাবিক Data Point Model-কে অতিরিক্ত প্রভাবিত করতে পারে না এবং Model আরও Robust হয়।

penalty

Default: 'l2'

penalty Parameter নির্ধারণ করে Training-এর সময় Regularization ব্যবহার করা হবে কি না এবং হলে কোন ধরনের Regularization ব্যবহার হবে।

Machine Learning-এ একটি সাধারণ সমস্যা হলো Overfitting, যেখানে Model Training Data খুব ভালোভাবে শিখে ফেলে কিন্তু নতুন Data-তে খারাপ Performance দেয়। Regularization এই সমস্যা কমাতে সাহায্য করে।

l2 Regularization Weight-এর বড় মানকে Penalize করে এবং Model-কে Smooth রাখে। এটি সবচেয়ে বেশি ব্যবহৃত Regularization।

$$Loss + \alpha \sum w^2$$

l1 Regularization অনেক Weight-কে শূন্য করে দিতে পারে, ফলে Feature Selection স্বয়ংক্রিয়ভাবে হয়ে যায়।

$$Loss + \alpha \sum |w|$$

আর elasticnet L1 এবং L2 দুটোর সুবিধা একসাথে দেয়। যখন Feature Selection এবং Stable Weight দুটোই দরকার হয়, তখন ElasticNet ব্যবহার করা হয়।

alpha

Default: 0.0001

alpha হলো Regularization-এর Strength। এটি নির্ধারণ করে Regularization Term কতটা শক্তিশালী হবে।

যদি Model Overfit করে, তাহলে alpha বাড়ালে Weight-এর মান ছোট হবে এবং Model সহজ হবে। অন্যদিকে alpha খুব বেশি বড় হলে Model গুরুত্বপূর্ণ Pattern-ও শিখতে পারবে না, ফলে Underfitting দেখা দিতে পারে।

সহজভাবে বলতে গেলে, alpha Model Complexity-এর উপর ব্রেকের মতো কাজ করে। বেশি Alpha মানে বেশি নিয়ন্ত্রণ, কম Alpha মানে Model-কে বেশি স্বাধীনতা দেওয়া।

l1_ratio

Default: 0.15

l1_ratio শুধুমাত্র penalty='elasticnet' হলে কার্যকর হয়। এটি নির্ধারণ করে ElasticNet-এর মধ্যে L1 এবং L2 কত শতাংশ করে থাকবে।

যদি l1_ratio=0 হয়, তাহলে পুরোপুরি L2 Regularization ব্যবহৃত হবে। যদি l1_ratio=1 হয়, তাহলে পুরোপুরি L1 Regularization ব্যবহৃত হবে।

মারামাতি মান ব্যবহার করলে Feature Selection এবং Weight Stabilization দুটোর সুবিধাই পাওয়া যায়।

learning_rate

Default: 'invscaling'

Gradient Descent-এর সবচেয়ে গুরুত্বপূর্ণ বিষয়গুলোর একটি হলো Learning Rate। Learning Rate নির্ধারণ করে প্রতিটি Step-এ Weight কতটুকু পরিবর্তিত হবে।

learning_rate Parameter বলে দেয় Training চলাকালে Learning Rate কীভাবে পরিবর্তিত হবে।

constant ব্যবহার করলে Learning Rate পুরো Training জুড়ে একই থাকে। invscaling ব্যবহার করলে Epoch বাড়ার সাথে সাথে Learning Rate ধীরে ধীরে কমে যায়।

$$\eta_t = \frac{\eta_0}{t^{power_t}}$$

adaptive Strategy ব্যবহার করলে Learning Rate শুরুতে বড় থাকে, কিন্তু Validation Performance উন্নত না হলে ধীরে ধীরে কমে যায়। বাস্তবে অনেক ক্ষেত্রে adaptive ভালো ফলাফল দেয় কারণ এটি দ্রুত Converge করতে সাহায্য করে।

eta0

Default: 0.01

eta0 হলো Initial Learning Rate। Training-এর শুরুতে Weight Update করার জন্য এই মান ব্যবহার করা হয়।

Gradient Descent-এর Update Equation হলো:

$$w_{new} = w_{old} - \eta \frac{\partial J}{\partial w}$$

যদি eta0 খুব বড় হয়, তাহলে Model Optimal Point-এর চারপাশে লাফাতে থাকবে এবং Diverge করতে পারে। আবার যদি খুব ছোট হয়, তাহলে Training অত্যন্ত ধীর হয়ে যাবে।

সাধারণত Convergence Problem দেখা দিলে প্রথমে eta0 পরিবর্তন করা হয়।

max_iter

Default: 1000

max_iter নির্ধারণ করে সর্বোচ্চ কত Epoch Training চলবে।

একটি Epoch বলতে পুরো Dataset-এর উপর একবার সম্পূর্ণ Training বোঝায়। যদি Model Converge করার আগেই Training বন্ধ হয়ে যায়, তাহলে max_iter বাড়ানো প্রয়োজন।

Convergence Warning দেখলে সাধারণত 1000 থেকে 3000 বা 5000 করা হয়।

tol

Default: 1e-3

tol হলো Convergence Threshold। Training চলাকালে যদি Loss-এর উন্নতি এই মানের চেয়ে কম হয়ে যায়, তাহলে Algorithm ধরে নেয় যে Model প্রায় Converge করে ফেলেছে এবং Training বন্ধ করে দেয়।

বড় tol দিলে Training দ্রুত শেষ হয়, কিন্তু Precision কিছুটা কমতে পারে। ছোট tol দিলে Training বেশি সময় চলে এবং আরও ভালো Solution খুঁজে বের করার চেষ্টা করে।

early_stopping

Default: False

early_stopping=True করলে Model Training-এর সময় একটি Validation Set ব্যবহার করে।

যদি Validation Score ধারাবাহিকভাবে উন্নতি না করে, তাহলে Training আগেই বন্ধ হয়ে যায়।

এটি Overfitting প্রতিরোধের একটি অত্যন্ত কার্যকর Technique। কারণ Training Data-তে Performance বাড়লেও Validation Data-তে Performance কমতে শুরু করলে বোঝা যায় Model মুখস্থ করা শুরু করেছে।

validation_fraction

Default: 0.1

যখন early_stopping=True থাকে, তখন Dataset-এর একটি অংশ Validation Set হিসেবে আলাদা করা হয়।

validation_fraction=0.1 মানে Dataset-এর 10% Validation-এর জন্য এবং 90% Training-এর জন্য ব্যবহৃত হবে।

Validation Set ব্যবহার করে Early Stopping সিদ্ধান্ত নেওয়া হয়।

shuffle

Default: True

প্রতিটি Epoch শুরু হওয়ার আগে Data Shuffle করা হবে কি না তা shuffle Parameter নিয়ন্ত্রণ করে।

SGD-তে Data-এর Order খুব গুরুত্বপূর্ণ। যদি Data সবসময় একই ক্রমে Model-এর কাছে যায়, তাহলে Model ভুল Pattern শিখে ফেলতে পারে।

তাই বাস্তবে প্রায় সব ক্ষেত্রেই shuffle=True রাখা হয়।

random_state

random_state Training-এর Random Operations-কে Reproducible করে।

উদাহরণস্বরূপ, Data Shuffle, Validation Split ইত্যাদি Random Process-এর জন্য এটি ব্যবহার করা হয়।

random_state=42

একই Seed ব্যবহার করলে প্রতিবার একই Result পাওয়া যায়, যা Research এবং Experiment Tracking-এর জন্য অত্যন্ত গুরুত্বপূর্ণ।

average

Default: False

SGD-এর Training Process অনেক সময় Noise-এর কারণে Weight-কে বিভিন্ন দিকে নাড়াচাড়া করতে পারে।

average=True করলে Training-এর শেষ দিকে পাওয়া বিভিন্ন Weight-এর Average নেওয়া হয়।

ফলে Final Model আরও Stable হয় এবং অনেক ক্ষেত্রে Generalization Performance উন্নত হয়।

বিশেষ করে Large Dataset এবং Noisy Dataset-এ এটি উপকারী হতে পারে।

warm_start

Default: False

সাধারণত .fit() কল করলে Model নতুন করে Training শুরু করে।

কিন্তু warm_start=True করলে আগের Training-এর Weight সংরক্ষণ করা হয় এবং পরবর্তী .fit() সেখান থেকেই শুরু হয়।

এটি Incremental Learning, Online Learning এবং বড় Dataset Chunk-by-Chunk Training-এর জন্য উপকারী।

epsilon

Default: 0.1

epsilon শুধুমাত্র loss='epsilon_insensitive' বা loss='huber' ব্যবহার করার সময় কার্যকর হয়। এটি নির্ধারণ করে কতটুকু Error পর্যন্ত Penalty দেওয়া হবে না। অর্থাৎ যদি Prediction এবং Actual Value-এর পার্থক্য epsilon-এর মধ্যে থাকে, তাহলে সেটাকে Error হিসেবে গণ্য করা হয় না। squared_error loss ব্যবহার করলে এই parameter কোনো প্রভাব ফেলে না।

n_iter_no_change

Default: 5

n_iter_no_change নির্ধারণ করে কত Epoch ধরে Loss উল্লেখযোগ্যভাবে না কমলে Early Stopping বা Convergence ধরা হবে। early_stopping=True থাকলে এই সংখ্যক Epoch-এ Validation Score না বাড়লে Training বন্ধ হয়ে যায়। এটি বাড়ালে Model বেশি সময় ধৈর্য ধরে Train হয়।

power_t

Default: 0.5

power_t শুধুমাত্র learning_rate='invscaling' হলে ব্যবহৃত হয়। এটি নির্ধারণ করে Learning Rate কত দ্রুত কমবে। এর সূত্র হলো: $\eta = \eta_0 / t^{\text{power_t}}$ । power_t বড় হলে Learning Rate দ্রুত কমে, ছোট হলে ধীরে কমে। সাধারণত Default 0.5 বেশিরভাগ ক্ষেত্রে যথেষ্ট।

Logistic Regression

লজিস্টিক রিগ্রেশন মূলত একটি **ক্লাসিফিকেশন অ্যালগরিদম** (Classification Algorithm), যা বাইনারি ক্লাস (যেমন: 0 অথবা 1, হ্যাঁ অথবা না) প্রেডিক্ট করতে ব্যবহৃত হয়। লিনিয়ার রিগ্রেশন যেখানে $(-\infty$ থেকে $\infty)$ পর্যন্ত যেকোনো মান দিতে পারে, লজিস্টিক রিগ্রেশন সেখানে আউটপুটকে 0 থেকে 1 এর মধ্যকার একটি প্রোবাবিলিটি (Probability) বা সম্ভাবনায় রূপান্তর করে।


১. মূল সমীকরণ ও সিগময়েড ফাংশন (Core Equation & Sigmoid)

প্রথমে linear combination হিসাব করা হয়:

$$z = XW + b$$

এই z -কে sigmoid function-এর মাধ্যমে probability-তে রূপান্তর করা হয়:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



Final prediction:

$$\hat{y} = \sigma(XW + b) = \frac{1}{1 + e^{-(XW+b)}}$$

Sigmoid-এর গুরুত্বপূর্ণ বৈশিষ্ট্য:

$$\begin{aligned} z = 0 & \quad \text{তখন } \sigma(z) = 0.5 \\ z \rightarrow +\infty & \quad \text{তখন } \sigma(z) \rightarrow 1 \\ z \rightarrow -\infty & \quad \text{তখন } \sigma(z) \rightarrow 0 \end{aligned}$$

Odds $\rightarrow$ Sigmoid Function (Full Derivation)

১. Odds কী?

ধরি কোনো event-এর probability হলো p

তাহলে:

$$\text{odds} = \frac{p}{1 - p}$$

মানে: success vs failure ratio

২. Log-Odds (Logit)

Odds-এর log নিলে:

$$\log(\text{odds}) = \log\left(\frac{p}{1-p}\right)$$

৩. Logistic Regression-এর assumption

$$z = \log\left(\frac{p}{1-p}\right)$$

অর্থাৎ:

- $z = \log\text{-odds}$

৪. Log undo করা (Exponential step)

আমরা জানি:

$$z = \log(\text{odds})$$

দুই পাশে exponential নিলে:

$$e^z = \text{odds}$$

৫. Odds বসানো

$$\frac{p}{1-p} = e^z$$

৬. এখন solve করি probability

$$\begin{aligned} p &= e^z(1-p) \\ p &= e^z - pe^z \\ p + pe^z &= e^z \\ p(1 + e^z) &= e^z \end{aligned}$$

৭. Final probability form

$$p = \frac{e^z}{1 + e^z}$$

৮. Sigmoid form এ রূপান্তর

উপরের expression কে rearrange করলে:

$$p = \frac{1}{1 + e^{-z}}$$

৯. Final Result (Sigmoid Function)

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

২. কস্ট ফাংশন (Binary Cross-Entropy / Log Loss)

Logistic Regression-এ Mean Squared Error ব্যবহার করা হয় না, কারণ এটি non-convex সমস্যা তৈরি করে।

তাই ব্যবহার করা হয়:

$$J(W, b) = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Loss Intuition

যখন $y = 1$:

$$\text{Loss} = -\log(\hat{y})$$

- $\hat{y} \approx 1 \rightarrow \text{loss} \approx 0$
- $\hat{y} \approx 0 \rightarrow \text{loss} \rightarrow \infty$

যখন $y = 0$:

$$\text{Loss} = -\log(1 - \hat{y})$$

- $\hat{y} \approx 0 \rightarrow \text{loss} \approx 0$
- $\hat{y} \approx 1 \rightarrow \text{loss} \rightarrow \infty$

৩. প্রাভিয়েন্ট (Partial Derivatives)

Log loss + sigmoid combine করলে খুব সুন্দরভাবে gradient simplify হয়।

Linear part:

$$z = XW + b$$

$$\hat{y} = \sigma(z)$$

Weight gradient:

$$\frac{\partial J}{\partial w_j} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i) x_{ij}$$

Bias gradient:

$$\frac{\partial J}{\partial b} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)$$

Important Note:

এখানে:

- $\hat{y}$ = sigmoid output
- error = $\hat{y} - y$

৪. প্যারামিটার আপডেট (Gradient Descent)

$$W = W - \alpha \cdot \frac{\partial J}{\partial W}$$

$$b = b - \alpha \cdot \frac{\partial J}{\partial b}$$

ব্যাকএন্ড ওয়ার্কফ্লো (Full Process)

Step 1: Initialization

- $W = 0$ বা ছোট random value
- $b = 0$

Step 2: Linear computation

$$z = XW + b$$

Step 3: Activation (Sigmoid)

$$\hat{y} = \frac{1}{1 + e^{-z}}$$

Step 4: Loss computation

$$J(W, b)$$

Step 5: Gradient computation

$$\frac{\partial J}{\partial w_j} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i) x_{ij}$$

Step 6: Update parameters

W, b update

Step 7: Prediction rule

$$\begin{aligned}\hat{y} &\geq 0.5 \Rightarrow 1 \\ \hat{y} &< 0.5 \Rightarrow 0\end{aligned}$$

Python Code

```
1 import numpy as np
2
3 X = np.array([
4     [0.5, 1.5],
5     [1.0, 1.0],
6     [1.5, 0.5],
7     [3.0, 3.5],
8     [2.5, 4.5],
9     [4.0, 3.0]
10 ])
11
12 y = np.array([0, 0, 0, 1, 1, 1])
13
14 def sigmoid(z):
15     return 1 / (1 + np.exp(-z))
16
17 def predict_proba(X, W, b):
18     return sigmoid(np.dot(X, W) + b)
19
20 def predict(X, W, b, threshold=0.5):
21     return (predict_proba(X, W, b) >= threshold).astype(int)
22
23 def compute_cost(X, y, W, b):
24     y_pred = predict_proba(X, W, b)
25     return -np.mean(y*np.log(y_pred) + (1-y)*np.log(1-y_pred))
```

```
27 def compute_gradient(X, y, W, b):
28     error = predict_proba(X, W, b) - y
29     dW = (1/len(X)) * np.dot(X.T, error)
30     db = (1/len(X)) * np.sum(error)
31     return dW, db
32
33 def fit(X, y, lr, iters):
34     W = np.zeros(X.shape[1])
35     b = 0.0
36
37     for i in range(iters):
38         dW, db = compute_gradient(X, y, W, b)
39         W -= lr * dW
40         b -= lr * db
41
42     return W, b
43
44 W, b = fit(X, y, 0.1, 5000)
45
46 print(W, b)
47 print(predict(X, W, b))
```

Using Scikit Learn

```
1 from sklearn.linear_model import LogisticRegression, SGDClassifier
2 from sklearn.preprocessing import StandardScaler
3
4 lr = LogisticRegression(penalty=None)
5 lr.fit(X, y)
6
7 print(lr.coef_, lr.intercept_)
8 print(lr.predict(X))
9
10 scaler = StandardScaler()
11 X_scaled = scaler.fit_transform(X)
12
13 sgd = SGDClassifier(loss="log_loss", max_iter=5000, eta0=0.1, learning_rate
    ="constant")
14 sgd.fit(X_scaled, y)
15
16 print(sgd.coef_, sgd.intercept_)
17 print(sgd.predict(X_scaled))
```

LogisticRegression (sklearn.linear_model.LogisticRegression)

Logistic Regression classification সমস্যার জন্য ব্যবহৃত হয় এবং regularization-এর উপর অনেক বেশি নির্ভরশীল।

Logistic Regression হলো একটি Supervised Machine Learning Algorithm যা মূলত **Classification Problem** সমাধানের জন্য ব্যবহৃত হয়। নামের মধ্যে "Regression" থাকলেও এটি সাধারণত Class Predict করে। Binary Classification (Yes/No, Pass/Fail, Spam/Not Spam) থেকে শুরু করে Multiclass Classification পর্যন্ত এটি ব্যবহার করা যায়।

Linear Regression যেখানে সরাসরি একটি Continuous Value Predict করে, Logistic Regression সেখানে একটি Probability Predict করে এবং সেই Probability-এর ভিত্তিতে Final Class নির্ধারণ করে।

$$P(y = 1) = \frac{1}{1 + e^{-z}}$$

যেখানে,

$$z = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

এই Sigmoid Function-এর কারণে Output সবসময় 0 এবং 1-এর মধ্যে থাকে।

C

Default: 1.0

C হলো Regularization Strength-এর Inverse।

অনেক শিক্ষার্থী প্রথমে বিভ্রান্ত হয় কারণ SGDRegressor বা Ridge Regression-এ Regularization বাড়াতে Parameter-এর মান বাড়তে হয়, কিন্তু Logistic Regression-এ ঠিক উল্টো।

$$C = \frac{1}{\lambda}$$

এখানে λ হলো Regularization Strength।

অর্থাৎ,

- ছোট C $\rightarrow$ বেশি Regularization
- বড় C $\rightarrow$ কম Regularization

যদি Model Training Data খুব ভালো শিখে ফেলে কিন্তু Test Data-তে খারাপ করে, তাহলে Overfitting হচ্ছে। এমন পরিস্থিতিতে C কমানো উচিত।

উল্টোভাবে, যদি Model খুবই Simple হয়ে যায় এবং Training Data-ও ঠিকমতো শিখতে না পারে, তাহলে C বাড়ানো যেতে পারে।

বাস্তবে Logistic Regression-এর সবচেয়ে গুরুত্বপূর্ণ Hyperparameter সাধারণত C।

penalty

Default: 'l2'

penalty নির্ধারণ করে কোন ধরনের Regularization ব্যবহার করা হবে।

Machine Learning Model-এর একটি বড় সমস্যা হলো Overfitting। Regularization এই সমস্যা কমাতে সাহায্য করে।

l2 Regularization Weight-এর বড় মানকে Penalize করে এবং Coefficient-গুলোকে ছোট রাখে।

$$Loss + \lambda \sum w^2$$

এটি সবচেয়ে বেশি ব্যবহৃত Regularization।

l1 Regularization Weight-এর Absolute Value Penalize করে।

$$Loss + \lambda \sum |w|$$

এর ফলে অনেক Coefficient সরাসরি শূন্য হয়ে যায়। তাই Feature Selection-এর জন্য এটি খুব উপকারী।

elasticnet ব্যবহার করলে L1 এবং L2 দুটোর সুবিধা একসাথে পাওয়া যায়।

যদি Feature অনেক বেশি থাকে এবং কোনগুলো গুরুত্বপূর্ণ তা খুঁজতে চান, তাহলে 11 একটি ভালো Choice হতে পারে।

solver

Default: 'lbfgs'

Logistic Regression Training-এর সময় Optimal Weight বের করতে Optimization Algorithm ব্যবহার করে। solver Parameter সেই Algorithm নির্বাচন করে।

সব Solver একই কাজ করলেও তাদের Speed, Memory Usage এবং Supported Penalty আলাদা।

lbfgs

সবচেয়ে জনপ্রিয় এবং Default Solver।

- L2 Support করে
- Small ও Medium Dataset-এর জন্য ভালো
- Multiclass Support করে

সাধারণ ব্যবহারের জন্য এটি যথেষ্ট।

liblinear

- L1 এবং L2 দুটোই Support করে
- Small Dataset-এর জন্য উপযুক্ত
- Binary Classification-এ বেশি ব্যবহৃত

যদি penalty='l1' ব্যবহার করতে চান, তাহলে প্রায়ই liblinear অথবা saga ব্যবহার করতে হয়।

newton-cg

দ্বিতীয়-ধাপ (Second Order) Optimization ব্যবহার করে।

- Smooth Convergence
- Medium Dataset-এর জন্য ভালো

sag

- Large Dataset-এর জন্য দ্রুত
- শুধুমাত্র L2 Support করে

Dataset বড় হলে এটি Training অনেক দ্রুত করতে পারে।

saga

সবচেয়ে Flexible Solver।

- L1 Support করে

- L2 Support করে
- ElasticNet Support করে
- Large Dataset-এ কার্যকর

ElasticNet ব্যবহার করতে চাইলে সাধারণত saga Solver ব্যবহার করা হয়।

class_weight

Default: None

বাস্তব Dataset-এ অনেক সময় Class Distribution সমান থাকে না।

ধরুন,

Class Count

No 950

Yes 50

এখানে Model যদি সবকিছুকে "No" Predict করে, তবুও Accuracy হবে 95%।

কিন্তু বাস্তবে Model কোনো কাজে আসবে না।

এই সমস্যা সমাধানের জন্য class_weight='balanced' ব্যবহার করা হয়।

class_weight='balanced'

এটি Minority Class-কে বেশি Weight দেয়।

ফলে Model শুধু Majority Class শেখার বদলে Minority Class-কেও গুরুত্ব দেয়।

Imbalanced Dataset-এ এটি অত্যন্ত গুরুত্বপূর্ণ Parameter।

max_iter

Default: 100

Training চলাকালে Solver কত Iteration পর্যন্ত চেষ্টা করবে, সেটি max_iter নিয়ন্ত্রণ করে।

যদি Training-এর সময় নিচের Warning আসে:

ConvergenceWarning

তাহলে বুঝতে হবে Model এখনো Converge করতে পারেনি।

এক্ষেত্রে সাধারণত:

max_iter=1000

অথবা

max_iter=5000

ব্যবহার করা হয়।

fit_intercept

Default: True

Logistic Regression-এর Equation হলো:

$$z = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$$

এখানে,

b

হলো Bias বা Intercept।

fit_intercept=True হলে Model Bias Term শিখবে।

বাস্তবে অধিকাংশ ক্ষেত্রেই এটি True রাখা উচিত।

শুধুমাত্র Data যদি ইতোমধ্যে Perfectly Centered হয়, তখন False বিবেচনা করা যেতে পারে।

l1_ratio

l1_ratio শুধুমাত্র নিচের ক্ষেত্রে কাজ করে:

penalty='elasticnet'

এবং

solver='saga'

এটি নির্ধারণ করে L1 এবং L2 কত শতাংশ ব্যবহার হবে।

$$0 \leq l1_ratio \leq 1$$

যদি:

l1_ratio=0

হয়, তাহলে Pure L2।

আর যদি:

l1_ratio=1

হয়, তাহলে Pure L1।

মাঝামাঝি মান দিলে L1 এবং L2-এর মিশ্রণ পাওয়া যায়।

multi_class

Default: 'auto'

যখন Target Variable-এ দুইটির বেশি Class থাকে, তখন Logistic Regression Multiclass Problem কীভাবে Handle করবে তা multi_class নির্ধারণ করে।

One-vs-Rest (OVR)

multi_class='ovr'

এখানে প্রতিটি Class-এর জন্য আলাদা Binary Classifier তৈরি হয়।

ধরুন Class:

- Cat
- Dog
- Bird

তাহলে Model তিনটি আলাদা Binary Problem তৈরি করবে।

- Cat vs Others
- Dog vs Others
- Bird vs Others

Multinomial

multi_class='multinomial'

এখানে সরাসরি Softmax ব্যবহার করা হয়।

$$P(y = i) = \frac{e^{z_i}}{\sum e^{z_j}}$$

সাধারণভাবে Multiclass Problem-এ এটি বেশি Accurate হয়।

বর্তমান Scikit-Learn Version-এ auto সাধারণত Multinomial Approach বেছে নেয় যখন Solver সেটি Support করে।

tol

Default: 1e-4

tol হলো Convergence Threshold।

Training চলাকালে যদি Loss Improvement এই মানের নিচে নেমে যায়, তাহলে Solver ধরে নেয় যে আর উল্লেখযোগ্য উন্নতি সম্ভব নয়।

ফলে Training বন্ধ হয়ে যায়।

বড় tol:

- দ্রুত Training
- কম Precision

ছোট tol:

- ধীর Training
- বেশি Precise Solution

random_state

Training-এর সময় Random Operation-এর জন্য Seed নির্ধারণ করে।

random_state=42

একই Code বারবার চালালে একই Result পাওয়ার জন্য এটি ব্যবহার করা হয়।

Research, Assignment এবং Experiment Tracking-এর ক্ষেত্রে এটি অত্যন্ত গুরুত্বপূর্ণ।

warm_start

Default: False

সাধারণত .fit() কল করলে Logistic Regression শুরু থেকে Training শুরু করে।

কিন্তু:

warm_start=True

দিলে আগের Training-এর Weight ব্যবহার করে নতুন Training শুরু হয়।

এটি Incremental Training অথবা বারবার Model Re-training-এর ক্ষেত্রে উপকারী হতে পারে।

n_jobs

n_jobs নির্ধারণ করে Training-এর সময় কতগুলো CPU Core ব্যবহার করা হবে।

n_jobs=-1

দিলে সিস্টেমের সব Available CPU Core ব্যবহার করা হয়।

এটি Model-এর Accuracy পরিবর্তন করে না।

শুধুমাত্র Training Speed বাড়ায়।

বিশেষ করে Large Dataset এবং Cross Validation-এর সময় এটি কার্যকর।

verbose

Default: 0

verbose নির্ধারণ করে Training-এর সময় কতটুকু Log বা Progress Information Console-এ দেখাবে।

verbose=0 মানে কোনো Output দেখাবে না। verbose=1 বা তার বেশি দিলে প্রতিটি Iteration-এর Progress দেখা যায়, যা Debugging বা দীর্ঘ Training-এর সময় কাজে লাগে।

dual

Default: 'auto'

dual Parameter নির্ধারণ করে Optimization Problem-এর Dual নাকি Primal Formulation ব্যবহার হবে। শুধুমাত্র solver='liblinear' এবং penalty='l2' হলে এটি প্রযোজ্য। সাধারণত $n_samples > n_features$ হলে dual=False (Primal) এবং $n_samples < n_features$ হলে dual=True (Dual) বেশি কার্যকর। 'auto' দিলে Scikit-Learn নিজেই সঠিকটি বেছে নেয়।

Solver ও Penalty Compatibility

Solver	L1	L2	ElasticNet	None
lbfgs	✗	✓	✗	✓
newton-cg	✗	✓	✗	✓
sag	✗	✓	✗	✓
liblinear	✓	✓	✗	✗
saga	✓	✓	✓	✓

LogisticRegression-এর সবচেয়ে গুরুত্বপূর্ণ Parameter

IMPORTANT NOTE

Binary Cross-Entropy ভুল প্রেডিকশনকে exponentially বেশি penalize করে — একদম আত্মবিশ্বাসী কিন্তু ভুল প্রেডিকশনের loss প্রায় ∞ পর্যন্ত যেতে পারে। এটিই Log Loss-কে Classification-এর জন্য কার্যকর করে তোলে।

EXAM TIP

Odds $\rightarrow$ Log-Odds $\rightarrow$ Exponential $\rightarrow$ Algebraic rearrangement — এই ৪-ধাপের Derivation পরীক্ষায় প্রায়ই চাওয়া হয়। প্রতিটি ধাপ মুখস্থ না করে যুক্তি দিয়ে বোঝা ভালো, কারণ এতে ভুল করার সম্ভাবনা কমে যায়।

Advantages, Disadvantages & Real-World Applications

Advantages	Disadvantages
আউটপুট সরাসরি probability হিসেবে interpretable	শুধুমাত্র linearly (বা near-linearly) separable ডেটায় ভালো কাজ করে
কম্পিউটেশনালি সাশ্রয়ী ও দ্রুত train হয়	Outlier-এর প্রতি sensitive
L1/L2 Regularization-এর মাধ্যমে Overfitting নিয়ন্ত্রণযোগ্য	জটিল Non-linear সম্পর্ক ক্যাপচার করতে পারে না

REAL-WORLD EXAMPLE

Email Spam Detection, মেডিকেল ডায়াগনোসিসে রোগী আক্রান্ত/সুস্থ নির্ণয়, ব্যাংকিং-এ Credit Default Prediction, এবং Marketing-এ Customer Churn Prediction — এসব ক্ষেত্রে Logistic Regression একটি জনপ্রিয় Baseline Model।

COMMON MISTAKE

Multiclass সমস্যায় ভুলভাবে Binary Logistic Regression প্রয়োগ করা — `multi_class='multinomial'` বা One-vs-Rest ব্যবহার না করা।

Imbalanced Dataset-এ `class_weight` প্যারামিটার উপেক্ষা করা, যার ফলে Minority Class-এর Recall খুব কম থাকে।

INTERVIEW TIP

Q: কেন Logistic Regression-এ MSE ব্যবহার করা হয় না?

A: Sigmoid-এর সাথে MSE ব্যবহার করলে Cost Function Non-convex হয়ে যায়, ফলে Gradient Descent Local Minima-তে আটকে যেতে পারে। Binary Cross-Entropy ব্যবহার করলে ফাংশনটি Convex থাকে।

Q: Logistic Regression নামে 'Regression' থাকলেও এটি Classification Algorithm কেন?

A: কারণ এটি প্রথমে একটি Continuous Probability মান (Regression-এর মতো) প্রেডিক্ট করে, তারপর একটি Threshold (সাধারণত 0.5) ব্যবহার করে সেটিকে Discrete Class-এ রূপান্তর করে।

Quick Revision Notes — Logistic Regression

Category	Key Points
Key Formula	$\sigma(z) = 1/(1+e^{-z})$; $z = XW + b$
Cost Function	Binary Cross-Entropy (Log Loss)
Gradient	$\partial J/\partial W = (1/n)\sum(\hat{y}-y)x$ — identical form to linear regression!
Decision Rule	$\hat{y} \geq 0.5 \rightarrow \text{Class 1, else Class 0}$
Top Params	C, penalty, solver, class_weight
Exam Focus	Derive sigmoid from odds; explain non-convexity of MSE here
Interview Focus	Why cross-entropy not MSE; solver-penalty compatibility

K-Nearest Neighbors (KNN)

1. Introduction to K-Nearest Neighbors

K-Nearest Neighbors (KNN) হলো Machine Learning-এর একটি জনপ্রিয় Supervised Learning Algorithm, যা Classification এবং Regression উভয় ধরনের সমস্যার সমাধান করতে ব্যবহৃত হয়। এটি একটি Non-Parametric এবং Lazy Learning Algorithm। অন্যান্য অনেক Machine Learning Algorithm-এর মতো KNN Training Phase-এ কোনো Mathematical Model তৈরি করে না। বরং সম্পূর্ণ Training Dataset মেমোরিতে সংরক্ষণ করে রাখে এবং Prediction করার সময় নতুন Data Point-এর সবচেয়ে কাছের প্রতিবেশীদের (Neighbors) খুঁজে বের করে সিদ্ধান্ত নেয়।

KNN-এর মূল ধারণা হলো:

Similar data points tend to exist close to each other in feature space.

অর্থাৎ, যেসব Data Point-এর বৈশিষ্ট্য একরকম, তারা সাধারণত Feature Space-এ কাছাকাছি অবস্থান করে।

2. Why Do We Need KNN?

বাস্তব জীবনে অনেক সমস্যা আছে যেখানে আমাদের একটি নতুন Observation-এর Category বা Value নির্ধারণ করতে হয়।

উদাহরণস্বরূপ:

- Email Spam নাকি Not Spam?
- Customer Product কিনবে নাকি কিনবে না?
- একজন রোগী রোগে আক্রান্ত নাকি সুস্থ?
- একটি বাড়ির সম্ভাব্য মূল্য কত?

এই ধরনের সমস্যার সমাধানে KNN ব্যবহার করা যায়।

KNN-এর বিশেষত্ব হলো এটি Data Distribution সম্পর্কে আগে থেকে কোনো Assumption করে না। ফলে জটিল Non-Linear Data-এর ক্ষেত্রেও এটি অনেক সময় ভালো কাজ করে।

3. Types of Problems Solved by KNN

Classification

Classification সমস্যায় Target Variable একটি Category হয়।

উদাহরণ:

Input	Output
Patient Data	Disease / No Disease
Email	Spam / Not Spam
Student Info	Pass / Fail

Classification-এর ক্ষেত্রে KNN Majority Voting ব্যবহার করে।

Regression

Regression সমস্যায় Target Variable Continuous Numeric Value হয়।

উদাহরণ:

Input	Output
House Features	House Price
Weather Data	Temperature
Employee Data	Salary

Regression-এর ক্ষেত্রে KNN Neighbors-এর Mean বা Median ব্যবহার করে।

4. Working Principle of KNN

KNN-এর সম্পূর্ণ কাজ Distance-এর উপর নির্ভরশীল।

ধরা যাক একটি নতুন Data Point এসেছে।

KNN নিচের ধাপগুলো অনুসরণ করে:

Step 1

একটি K Value নির্বাচন করা হয়।

$$K = 3$$

Step 2

নতুন Data Point থেকে Training Dataset-এর প্রতিটি Observation-এর Distance বের করা হয়।

Step 3

Distance অনুযায়ী ছোট থেকে বড় ক্রমে Sort করা হয়।

Step 4

সবচেয়ে কাছের K সংখ্যক Neighbor নির্বাচন করা হয়।

Step 5

Classification হলে Majority Voting এবং Regression হলে Average নেওয়া হয়।

5. Mathematical Foundation of KNN

KNN-এর সম্পূর্ণ Decision Making Distance Metrics-এর উপর ভিত্তি করে তৈরি।

দুটি Data Point-এর মধ্যকার Distance যত কম হবে, তারা তত বেশি Similar বলে বিবেচিত হবে।

5.1 Euclidean Distance

এটি KNN-এর সবচেয়ে ব্যবহৃত Distance Metric।

জ্যামিতিতে দুটি বিন্দুর সরলরেখার দূরত্ব নির্ণয়ের জন্য এটি ব্যবহার করা হয়।

যদি দুটি Point হয়:

$$P = (x_1, y_1)$$

এবং

$$Q = (x_2, y_2)$$

তাহলে তাদের Euclidean Distance:

$$d(P, Q) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

N-Dimensional Form

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

এই Formula-ই Scikit-Learn-এর KNN-এর Default Distance Metric।

5.2 Manhattan Distance

Euclidean Distance সরলরেখার দূরত্ব মাপে।

কিন্তু Manhattan Distance Grid Path ধরে Distance মাপে।

Formula:

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

High Dimensional Dataset-এর ক্ষেত্রে অনেক সময় Manhattan Distance Euclidean Distance-এর চেয়ে ভালো ফলাফল দেয়।

5.3 Minkowski Distance

Euclidean এবং Manhattan Distance আসলে Minkowski Distance-এর Special Case।

$$d(x, y) = (\sum_{i=1}^n |x_i - y_i|^p)^{1/p}$$

যেখানে,

$$p = 1$$

হলে Manhattan Distance

এবং

$$p = 2$$

হলে Euclidean Distance পাওয়া যায়।

6. Complete Numerical Example

ধরা যাক নিচের Dataset দেওয়া আছে।

Customer	Age	Income	Buy
C1	2	4	No
C2	4	6	Yes
C3	4	2	No
C4	6	8	Yes

এখন নতুন Customer:

$$(3, 5)$$

এবং

$$K = 3$$

প্রথম Customer-এর সাথে Distance:

$$d_1 = \sqrt{(3 - 2)^2 + (5 - 4)^2} = 1.41$$

দ্বিতীয় Customer-এর সাথে:

$$d_2 = 1.41$$

তৃতীয় Customer-এর সাথে:

$$d_3 = 3.16$$

চতুর্থ Customer-এর সাথে:

$$d_4 = 4.24$$

Distance অনুযায়ী Sort করলে:

Customer	Distance	Class
C1	1.41	No
C2	1.41	Yes
C3	3.16	No
C4	4.24	Yes

Nearest 3 Neighbor:

- No
- Yes
- No

Majority Vote:

$$\begin{aligned} No &= 2 \\ Yes &= 1 \end{aligned}$$

Final Prediction:

No

7. Choosing the Optimal K Value

KNN-এর Performance-এর সবচেয়ে গুরুত্বপূর্ণ অংশ হলো K নির্বাচন করা।

K খুব ছোট হলে

$$K = 1$$

Model Noise Follow করতে শুরু করে।

ফলাফল:

- High Variance
- Overfitting

K খুব বড় হলে

$$K = 100$$

Model Local Pattern ভুলে যায়।

ফলাফল:

- High Bias
- Underfitting

সাধারণভাবে:

$$K = \sqrt{N}$$

দিয়ে শুরু করা হয়।

যেখানে N হলো Training Sample-এর সংখ্যা।

8. Feature Scaling in KNN

KNN Distance-Based Algorithm হওয়ার কারণে Feature Scaling অত্যন্ত গুরুত্বপূর্ণ।

ধরা যাক:

Feature	Range
Age	0-100
Salary	0-1,000,000

Distance Calculation-এর সময় Salary পুরো Distance-কে Dominant করে ফেলবে।

ফলে Age-এর Effect প্রায় হারিয়ে যাবে।

এই সমস্যার সমাধানের জন্য:

Standardization

$$z = \frac{x - \mu}{\sigma}$$

Min-Max Scaling

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

প্রয়োগ করা হয়।

9. Curse of Dimensionality

KNN-এর সবচেয়ে বড় সীমাবদ্ধতাগুলোর একটি হলো Curse of Dimensionality।

Feature সংখ্যা বাড়তে থাকলে Data Point-গুলোর মধ্যে Distance-এর পার্থক্য কমতে শুরু করে।

ফলে:

- Nearest Neighbor খুঁজে পাওয়া কঠিন হয়
- Prediction Accuracy কমে যায়
- Computation Cost বৃদ্ধি পায়

এই কারণে High-Dimensional Dataset-এ KNN অনেক সময় দুর্বল পারফর্ম করে।

10. Computational Complexity

Operation	Complexity
Training	$O(1)$
Memory	$O(N)$
Prediction	$O(ND)$

যেখানে,

- N = Number of Samples
- D = Number of Features

এই কারণেই KNN-এর Training Fast হলেও Prediction তুলনামূলক Slow হয়।

KNN ব্যবহার করার সময় নিচের Parameters সবচেয়ে গুরুত্বপূর্ণ।

KNeighborsClassifier(

 n_neighbors=5,
 weights='distance',
 metric='minkowski',
 p=2,
 algorithm='auto'

)

```
from sklearn.datasets import load_wine
from sklearn.model_selection import train_test_split
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

wine = load_wine()

X = wine.data
y = wine.target

print("Shape of X:", X.shape)
print("Shape of y:", y.shape)

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
    stratify=y
)
```

```

knn_pipeline = Pipeline([
    ("scaler", StandardScaler()),
    ("model", KNeighborsClassifier(
        n_neighbors=5,
        weights="uniform",
        metric="minkowski",
        p=2
    ))
])

knn_pipeline.fit(X_train, y_train)
y_pred = knn_pipeline.predict(X_test)
accuracy = accuracy_score(y_test, y_pred)

print("\nAccuracy:")
print(accuracy)

print("\nClassification Report:")
print(classification_report(y_test, y_pred))

print("\nConfusion Matrix:")
print(confusion_matrix(y_test, y_pred))

```

Distance Metric Comparison

Distance Metric	Formula (সংক্ষেপে)	ব্যবহারের প্রসঙ্গ
Euclidean (p=2)	$\sqrt{\sum (x_i - y_i)^2}$	সাধারণ, continuous low-dimensional data-তে default
Manhattan (p=1)	$\sum x_i - y_i $	High-dimensional বা grid-like data-তে কার্যকর
Minkowski (general)	$(\sum x_i - y_i ^p)^{1/p}$	p tune করে Euclidean/Manhattan-এর মধ্যে নমনীয়তা পাওয়া যায়
EXAM TIP K নির্বাচনের rule of thumb $K \approx \sqrt{N}$ মুখস্থ রাখুন এবং Manual Distance Calculation (Euclidean) করে Majority Voting দেখানোর Numerical Example পরীক্ষায় প্রায়ই আসে।		
COMMON MISTAKE K = 1 ব্যবহার করে Model-কে অত্যন্ত Noise-sensitive করে ফেলা — এটি Training Accuracy-তে চমৎকার মনে হলেও Test Set-এ খারাপ Generalize করে।		

Even K ব্যবহার করা, যা Binary Classification-এ Tie (সমান ভোট) তৈরি করতে পারে — সাধারণত Odd K ব্যবহার করাই নিরাপদ।

Advantages ও Disadvantages

Advantages	Disadvantages
বোঝা এবং বাস্তবায়ন করা সহজ	Prediction Phase ধীরগতির (Computationally Expensive)
Data Distribution সম্পর্কে কোনো Assumption করে না	Curse of Dimensionality-তে আক্রান্ত হয়
Classification ও Regression উভয় ক্ষেত্রে ব্যবহারযোগ্য	Feature Scaling বাধ্যতামূলক
Multi-class সমস্যায় স্বাভাবিকভাবেই কাজ করে	Memory-ভিত্তিক (পুরো ডেটাসেট সংরক্ষণ করতে হয়)

REAL-WORLD EXAMPLE

Recommendation System-এ Similar Users/Items খুঁজে বের করা, Image Recognition-এ Pattern Matching, এবং Medical Diagnosis-এ Similar Patient History অনুসন্ধান — এসব ক্ষেত্রে KNN ব্যাপকভাবে ব্যবহৃত হয়।

INTERVIEW TIP

Q: KNN-কে 'Lazy Learner' বলা হয় কেন?

A: কারণ এটি Training Phase-এ কোনো Model তৈরি করে না, শুধু ডেটা সংরক্ষণ করে রাখে; প্রকৃত Computation ঘটে শুধু Prediction Phase-এ।

Q: KNN-এ Feature Scaling কেন গুরুত্বপূর্ণ?

A: কারণ KNN সম্পূর্ণভাবে Distance-এর উপর নির্ভরশীল; বড় Scale-এর Feature ছোট Scale-এর Feature-কে Dominate করে ফেলে।

K-Nearest Neighbors (KNN) হলো একটি **Instance-Based** এবং **Lazy Learning Algorithm**। অন্যান্য Machine Learning Algorithm-এর মতো এটি Training-এর সময় কোনো Mathematical Model তৈরি করে না। বরং Training Data-কে Memory-তে সংরক্ষণ করে রাখে এবং নতুন Data আসলে তার কাছাকাছি থাকা Data Point-গুলোর Class দেখে Prediction করে।

ধরুন একটি নতুন Student-এর তথ্য দেওয়া হলো এবং জানতে হবে সে Pass করবে নাকি Fail। KNN প্রথমে Training Data-তে সবচেয়ে কাছের K জন Student খুঁজে বের করবে, তারপর তাদের Majority Vote-এর ভিত্তিতে Final Prediction দেবে।

এই কারণেই KNN-কে অনেক সময় "Similarity Based Learning" Algorithm বলা হয়।

n_neighbors

Default: 5

n_neighbors বা K হলো KNN-এর সবচেয়ে গুরুত্বপূর্ণ Hyperparameter। এটি নির্ধারণ করে Prediction করার সময় কতগুলো Nearest Neighbor বিবেচনা করা হবে।

ধরুন,

$$K = 5$$

তাহলে নতুন Data Point-এর সবচেয়ে কাছের 5টি Neighbor খুঁজে বের করা হবে এবং তাদের Vote গণনা করা হবে।

যদি K খুব ছোট হয়, যেমন:

$$n_neighbors=1$$

তাহলে Model Training Data-এর Noise পর্যন্ত শিখে ফেলতে পারে। ফলে Overfitting দেখা দেয়।

অন্যদিকে K খুব বড় হলে অনেক দূরের Data Point-ও Decision-এ অংশ নেয়। তখন Model অত্যন্ত Smooth হয়ে যায় এবং Underfitting হতে পারে।

সাধারণভাবে:

- Small Dataset $\rightarrow K = 3$ বা 5
- Medium Dataset $\rightarrow K = 5$ বা 7
- Large Dataset $\rightarrow K = 11, 15, 21$ ইত্যাদি

ব্যবহার করা হয়।

KNN-এর Performance-এর উপর সবচেয়ে বেশি প্রভাব ফেলে `n_neighbors`।

weights

Default: 'uniform'

KNN-এ Neighbor-এর Vote কীভাবে গণনা করা হবে তা `weights` Parameter নিয়ন্ত্রণ করে।

Default Mode:

`weights='uniform'`

এখানে প্রতিটি Neighbor-এর Vote সমান গুরুত্ব পায়।

ধরুন $K=5$ ।

তাহলে ৫ জন Neighbor-এর প্রত্যেকের Vote-এর Weight হবে সমান।

অন্য Option:

`weights='distance'`

এখানে কাছের Neighbor-এর Vote বেশি গুরুত্বপূর্ণ হয়।

Weight গণনা হয়:

$$Weight = \frac{1}{Distance}$$

ফলে খুব কাছের Neighbor Prediction-এ বেশি প্রভাব ফেলে এবং দূরের Neighbor-এর প্রভাব কমে যায়।

যখন Dataset-এর Density সমান নয় অথবা Local Pattern বেশি গুরুত্বপূর্ণ, তখন `distance` সাধারণত ভালো Result দেয়।

metric

Default: 'minkowski'

KNN-এর মূল ভিত্তি হলো Distance Calculation।

কোন Formula ব্যবহার করে Distance বের করা হবে, সেটি metric Parameter নির্ধারণ করে।

ভুল Distance Metric নির্বাচন করলে "Nearest Neighbor" ভুলভাবে নির্ধারিত হতে পারে এবং Model-এর Accuracy কমে যেতে পারে।

Euclidean Distance

metric='euclidean'

Formula:

$$d = \sqrt{\sum (x_i - y_i)^2}$$

এটি Straight-Line Distance।

Continuous Numerical Data-এর জন্য এটি সবচেয়ে বেশি ব্যবহৃত Metric।

Manhattan Distance

metric='manhattan'

Formula:

$$d = \sum |x_i - y_i|$$

এটি Grid-Based Distance।

যদি Movement শুধুমাত্র Horizontal এবং Vertical Direction-এ সম্ভব হয়, তাহলে Manhattan Distance বেশি উপযুক্ত।

High-Dimensional Dataset-এ অনেক সময় এটি Euclidean-এর চেয়ে ভালো কাজ করে।

Minkowski Distance

metric='minkowski'

Formula:

$$d = (\sum |x_i - y_i|^p)^{1/p}$$

এটি Euclidean এবং Manhattan-এর General Form।

Scikit-Learn Default হিসেবে এটিই ব্যবহার করে।

Chebyshev Distance

metric='chebyshev'

Formula:

$$d = \max(|x_i - y_i|)$$

এখানে শুধুমাত্র Maximum Difference বিবেচনা করা হয়।

Cosine Distance

metric='cosine'

Text Mining, NLP এবং Document Similarity Problem-এ বেশি ব্যবহৃত হয়।

এটি Distance-এর পরিবর্তে Vector-এর Angle Measure করে।

p

Default: 2

p শুধুমাত্র তখন কাজ করে যখন:

metric='minkowski'

হয়।

এটি Minkowski Distance-এর Power Parameter।

যদি

$p=1$

হয়, তাহলে Minkowski Distance Manhattan Distance-এ রূপান্তরিত হয়।

$$d = \sum |x_i - y_i|$$

যদি

$p=2$

হয়, তাহলে এটি Euclidean Distance হয়ে যায়।

$$d = \sqrt{\sum (x_i - y_i)^2}$$

এই কারণে অনেক সময় আলাদা করে `metric='euclidean'` না লিখেও `metric='minkowski', p=2` ব্যবহার করা হয়।

algorithm

Default: 'auto'

KNN Prediction-এর সময় Nearest Neighbor Search করার জন্য কোন Internal Search Algorithm ব্যবহার হবে তা নির্ধারণ করে।

এটি Accuracy পরিবর্তন করে না।

শুধুমাত্র Computation Speed পরিবর্তন করে।

Auto

`algorithm='auto'`

Scikit-Learn Dataset দেখে নিজেই Best Algorithm নির্বাচন করে।

বেশিরভাগ ক্ষেত্রে এটিই যথেষ্ট।

Brute Force

algorithm='brute'

প্রতিটি Data Point-এর সাথে Distance Calculate করে।

Small Dataset-এর জন্য ভালো।

KD Tree

algorithm='kd_tree'

কম Dimension-এর Dataset-এ দ্রুত Search করতে পারে।

সাধারণত:

$$Dimensions < 20$$

হলে কার্যকর।

Ball Tree

algorithm='ball_tree'

High-Dimensional Dataset-এ KD Tree-এর চেয়ে ভালো কাজ করতে পারে।

leaf_size

Default: 30

KD Tree এবং Ball Tree-এর Leaf Node-এর Size নির্ধারণ করে।

এটি শুধুমাত্র Performance Optimization-এর জন্য ব্যবহৃত হয়।

ছোট Leaf Size:

- Tree গভীর হয়
- Memory বেশি লাগে

- Query দ্রুত হতে পারে

বড় Leaf Size:

- Tree কম গভীর হয়
- Memory কম লাগে
- Query ধীর হতে পারে

সাধারণ Dataset-এ Default Value পরিবর্তনের প্রয়োজন হয় না।

n_jobs

Default: None

Prediction বা Neighbor Search-এর সময় কতগুলো CPU Core ব্যবহার হবে তা নির্ধারণ করে।

n_jobs=-1

দিলে System-এর সব CPU Core ব্যবহার করা হয়।

এটি Accuracy পরিবর্তন করে না।

শুধুমাত্র Computation Time কমায়।

বিশেষ করে Large Dataset-এ এটি উপকারী।

KNN-এর আরও গুরুত্বপূর্ণ Parameter

অনেক Note-এ এগুলো বাদ যায়, কিন্তু বাস্তবে এগুলোও গুরুত্বপূর্ণ।

radius

Radius Neighbors Algorithm-এর ক্ষেত্রে ব্যবহৃত হয়।

radius=1.0

একটি নির্দিষ্ট Radius-এর ভেতরের Neighbor-গুলো বিবেচনা করা হয়।

তবে সাধারণ KNeighborsClassifier-এ এটি খুব বেশি ব্যবহৃত হয় না।

metric_params

Distance Metric-এর জন্য অতিরিক্ত Parameter পাঠাতে ব্যবহৃত হয়।

যখন Custom Distance Function ব্যবহার করা হয়, তখন এটি কাজে লাগে।

outlier_label

Radius-Based Neighbor Model-এ Outlier Handle করার জন্য ব্যবহৃত হয়।

effective_metric_

Training-এর পরে Model আসলে কোন Metric ব্যবহার করেছে তা জানায়।

effective_metric_params_

Metric-এর Final Parameter Value দেখায়।

Quick Revision Notes — KNN

Category	Key Points
Key Formula	Euclidean: $\sqrt{\sum (x_i - y_i)^2}$; Minkowski: $(\sum x_i - y_i ^p)^{1/p}$
Type	Non-parametric, Lazy Learner, Instance-based
Complexity	Training $O(1)$, Prediction $O(N \cdot D)$
K too small	Overfitting (High Variance)
K too large	Underfitting (High Bias)
Must-do	Feature scaling before fitting
Exam Focus	Manual distance computation & majority voting
Interview Focus	Curse of dimensionality; lazy vs eager learning

GridSearchCV in KNN

1. Why Do We Need GridSearchCV?

KNN-এর সবচেয়ে গুরুত্বপূর্ণ Hyperparameter হলো:

$$K = n_neighbors$$

কিন্তু প্রশ্ন হলো:

K কত নেব?

3?

5?

7?

11?

21?

যদি ভুল K নির্বাচন করি তাহলে Model-এর Performance অনেক কমে যেতে পারে।

ধরো:

K	Accuracy
3	88%
5	92%
7	95%
9	93%
11	90%

এখানে দেখা যাচ্ছে:

$$K = 7$$

সবচেয়ে ভালো।

কিন্তু Dataset দেখে আগে থেকে এটা জানা সম্ভব না।

তাই আমাদের বিভিন্ন K পরীক্ষা করতে হবে।

এই কাজটিই GridSearchCV স্বয়ংক্রিয়ভাবে করে।

2. What is GridSearchCV?

GridSearchCV হলো Scikit-Learn-এর একটি Hyperparameter Tuning Technique।

এটি বিভিন্ন Parameter Combination পরীক্ষা করে এবং Best Combination খুঁজে বের করে।

ধরো তুমি KNN-এর জন্য নিচের Parameters পরীক্ষা করতে চাও:

```
n_neighbors = [3,5,7,9]
weights = ['uniform','distance']
```

তাহলে মোট Combination হবে:

n_neighbors	weights
3	uniform
3	distance
5	uniform
5	distance
7	uniform
7	distance
9	uniform
9	distance

মোট:

$$4 \times 2 = 8$$

টি Model Train হবে।

3. Why Is It Called Grid Search?

ধরো Parameter Space হলো:

Parameter	Values
K	3,5,7
Weight	uniform,distance
p	1,2

তাহলে Grid তৈরি হবে:

K	Weight	p
3	uniform	1
3	uniform	2
3	distance	1
3	distance	2
5	uniform	1
5	uniform	2
5	distance	1
5	distance	2
7	uniform	1
7	uniform	2
7	distance	1
7	distance	2

মোট:

$$3 \times 2 \times 2 = 12$$

Combination।

GridSearchCV এই পুরো Grid Search করে।

তাই নাম:

Grid Search

4. What Does CV Mean?

CV = Cross Validation

Grid Search শুধু Train/Test Split ব্যবহার করে না।

বরং Cross Validation ব্যবহার করে।

5. Cross Validation Intuition

ধরো Dataset-এ:

1000

Samples আছে।

আমরা

$cv = 5$

দিলাম।

তাহলে Dataset 5 ভাগে ভাগ হবে।

Fold-1

Fold-2

Fold-3

Fold-4

Fold-5

Iteration 1:

Train:

2 3 4 5

Validation:

1

Iteration 2:

Train:

1 3 4 5

Validation:

2

Iteration 3:

Train:

1 2 4 5

Validation:

3

Iteration 4:

Train:

1 2 3 5

Validation:

4

Iteration 5:

Train:

1 2 3 4

Validation:

5

এরপর Average Accuracy বের করা হয়।

$$CV\ Score = \frac{Score_1 + Score_2 + Score_3 + Score_4 + Score_5}{5}$$

6. Backend Working of GridSearchCV

ধরি:

n_neighbors=[3,5,7]

weights=['uniform','distance']

Combination:

(3,uniform)

(3,distance)

(5,uniform)

(5,distance)

(7,uniform)

(7,distance)

মোট:

6

Combination I

এবং

cv=5

তাহলে:

$$6 \times 5 = 30$$

বার Model Train হবে।

GridSearchCV:

1. First Combination নেয়
2. 5 Fold CV চালায়
3. Average Score বের করে
4. Next Combination নেয়
5. Repeat করে

শেষে Highest Score যেটা দেয় সেটাকে Best Model ঘোষণা করে।

7. Important KNN Hyperparameters

GridSearchCV সাধারণত KNN-এর নিচের Parameters Tune করে।

n_neighbors

সবচেয়ে গুরুত্বপূর্ণ Parameter।

`n_neighbors = [3,5,7,9,11]`

ছোট K

→ Overfitting

বড় K

→ Underfitting

weights

Uniform

সব Neighbor-এর Vote সমান।

`weights='uniform'`

Distance

কাছের Neighbor-এর Vote বেশি।

weights='distance'

Weight:

$$w = \frac{1}{d}$$

p

Minkowski Distance Power।

p = 1

Manhattan

Distance

p = 2

Euclidean

Distance

metric

metric='minkowski'

Default।

অন্যান্য:

euclidean
manhattan
cosine
chebyshev

8. Example of Full Search Space

```
param_grid = {  
    "model__n_neighbors":[  
        3,5,7,9,11,15  
    ],  
    "model__weights":[  
        "uniform",  
        "distance"  
    ],  
    "model__p":[  
        1,  
        2  
    ]  
}
```

Total Models:

$$6 \times 2 \times 2 = 24$$

If

cv=5

Then

$$24 \times 5 = 120$$

Model Fits

9. Important Outputs

After Training:

Best Parameters

```
grid.best_params_
```

Output:

```
{  
'n_neighbors':7,  
'weights':'distance',
```

```
'p':2  
}
```

Best Score

grid.best_score_

Output:

0.972

Meaning:

97.2%

Cross Validation Accuracy

Best Model

grid.best_estimator_

Returns:

Best Trained Pipeline

10. Advantages of GridSearchCV

Automatic Hyperparameter Tuning

নিজে নিজে Combination পরীক্ষা করে।

Uses Cross Validation

Result বেশি Reliable।

Finds Optimal Model

Best Parameters খুঁজে দেয়।

Easy to Use

Scikit-Learn-এ কয়েক লাইনের Code।

11. Disadvantages

Slow

Combination বেশি হলে সময় বেশি লাগে।

Computationally Expensive

Large Dataset-এ Costly।

Exhaustive Search

সব Combination পরীক্ষা করে।

কখনও কখনও অপ্রয়োজনীয়ও হতে পারে।

```
from sklearn.datasets import load_wine
from sklearn.model_selection import train_test_split
from sklearn.model_selection import GridSearchCV

from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier

wine = load_wine()

X = wine.data
y = wine.target

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
    stratify=y
)

pipe = Pipeline([
    ("scaler", StandardScaler()),
    ("model", KNeighborsClassifier())
])
```

```
param_grid = {  
    "model__n_neighbors": [3,5,7,9,11,15],  
    "model__weights": [  
        "uniform",  
        "distance"  
    ],  
    "model__p": [  
        1,  
        2  
    ]  
}
```

```
grid = GridSearchCV(  
    estimator=pipe,  
    param_grid=param_grid,  
    cv=5,  
    scoring="accuracy",  
    n_jobs=-1  
)
```

```
grid.fit(X_train, y_train)  
  
print("Best Parameters:")  
print(grid.best_params_)
```

```
print("Best Parameters:")  
print(grid.best_params_)
```

```
print("\nBest CV Score:")  
print(grid.best_score_)
```

```
print("\nBest Pipeline:")  
print(grid.best_estimator_)
```

```
test_accuracy = grid.score(X_test, y_test)
```

```
print("\nTest Accuracy:")  
print(test_accuracy)
```

refit

Default: True

refit নির্ধারণ করে GridSearchCV Best Parameters খুঁজে পাওয়ার পরে সম্পূর্ণ Training Data দিয়ে আবার Model Refit করবে কিনা। True রাখলে grid.best_estimator_ থেকে সরাসরি Prediction করা যায়। False করলে শুধু Best Parameters জানা যাবে কিন্তু সরাসরি Predict করা যাবে না।

verbose

Default: 0

verbose নির্ধারণ করে GridSearchCV-এর Search চলাকালে কতটুকু Progress দেখাবে। verbose=0 মানে কোনো Log নেই। verbose=2 বা 3 দিলে প্রতিটি Fold এবং Parameter Combination-এর Score Console-এ দেখা যায়, যা বড় Search Space-এ কতটুকু এগোলো তা বোঝার জন্য কার্যকর।

pre_dispatch

Default: '2*n_jobs'

pre_dispatch নির্ধারণ করে Parallel Execution-এর সময় একসাথে কতগুলো Job Memory-তে রাখা হবে। এটি Memory Usage নিয়ন্ত্রণ করে। অনেক বড় Dataset বা বেশি Combination-এ Memory সমস্যা হলে এই মান কমিয়ে দেওয়া যায়, যেমন pre_dispatch=8।

error_score

Default: np.nan

error_score নির্ধারণ করে কোনো Combination Train করার সময় Error বা Exception আসলে সেই Combination-এর Score হিসেবে কী মান বসানো হবে। Default nan মানে Error হলে সেই Combination-এর Score NaN হয়ে যাবে। 'raise' দিলে Error সরাসরি Raise হবে এবং পুরো Training বন্ধ হয়ে যাবে, যা Debugging-এর জন্য সুবিধাজনক।

return_train_score

Default: False

return_train_score=True করলে GridSearchCV প্রতিটি Fold-এ Validation Score-এর পাশাপাশি Training Score-ও cv_results_-এ সংরক্ষণ করে। Train এবং Validation Score একসাথে তুলনা করলে Overfitting বা Underfitting সহজে সনাক্ত করা যায়। তবে এটি True করলে Computation সময় কিছুটা বাড়ে।

PRACTICAL INSIGHT

Combination সংখ্যা বেশি হলে GridSearchCV-এর বদলে RandomizedSearchCV ব্যবহার করা ভালো, যা সব Combination না পরীক্ষা করে র‍্যান্ডমভাবে কিছু Combination Sample করে দ্রুত একটি ভালো Result দেয়।

INTERVIEW TIP

Q: GridSearchCV-তে cv=5 মানে কী?

A: ডেটাসেটকে ৫টি Fold-এ ভাগ করে প্রতিবার ৪টি Fold দিয়ে Train এবং ১টি Fold দিয়ে Validate করা হয়; এই প্রক্রিয়া ৫ বার পুনরাবৃত্তি হয়ে Average Score বের করা হয়।

Q: GridSearchCV এবং RandomizedSearchCV-এর মধ্যে পার্থক্য কী?

A: GridSearchCV সব Combination Exhaustively পরীক্ষা করে, যেখানে RandomizedSearchCV একটি নির্দিষ্ট সংখ্যক Combination র‍্যান্ডমভাবে Sample করে — তাই বড় Search Space-এ এটি অনেক দ্রুত।

Quick Revision Notes — GridSearchCV


Category	Key Points
Key Formula	Total Fits = (Combinations) × (cv folds)
Purpose	Exhaustive hyperparameter search with cross-validation
Key Outputs	best_params_, best_score_, best_estimator_
Trade-off	Reliability (CV) vs Computation cost (exhaustive)
Alternative	RandomizedSearchCV for large search spaces
Exam Focus	Compute total model fits given grid size and cv
Interview Focus	GridSearchCV vs RandomizedSearchCV vs Bayesian Optimization

Decision Tree

Decision Tree (ডিসিশন ট্রি) হলো মেশিন লার্নিংয়ের একটি অত্যন্ত জনপ্রিয়, সহজ এবং শক্তিশালী Supervised Learning Algorithm, যা ক্লাসিফিকেশন (Classification) এবং রিগ্রেশন (Regression) উভয় ধরনের সমস্যার সমাধানে ব্যবহৃত হয়।

সহজ কথায়, এটি দেখতে একটি উল্টানো গাছের মতো, যার ওপরের দিকে থাকে মূল রুট বা কাণ্ড এবং নিচের দিকে ডালপালা বেয়ে চূড়ান্ত পাতা বা সিদ্ধান্তে পৌঁছানো যায়।

DECISION TREE



উদাহরণ (Intuition)

ধরুন, ছুটির দিনে আপনি বন্ধুদের সাথে বাইরে খেলতে যাবেন কি না, তা নিয়ে সিদ্ধান্ত নিতে চান। আপনার মনের ভেতর ঠিক নিচের মতো একটি চিন্তা কাজ করবে:

- প্রথম প্রশ্ন (রুট):** বাইরে কি আজ বৃষ্টি হচ্ছে?
 - যদি হ্যাঁ হয় → আপনি বাইরে যাবেন না (চূড়ান্ত সিদ্ধান্ত)।
 - যদি না হয় → আপনি পরবর্তী প্রশ্নে যাবেন।
- দ্বিতীয় প্রশ্ন:** বাইরে কি প্রচণ্ড গরম বা রোদ?
 - যদি হ্যাঁ হয় → আপনি বাইরে যাবেন না।
 - যদি না হয় → আপনি বাইরে খেলতে যাবেন (চূড়ান্ত সিদ্ধান্ত)।

মেশিন লার্নিংয়ে ডিসিশন ট্রি ঠিক এইভাবেই ডেটাসেটের ফিচারগুলোর ওপর ভিত্তি করে একটার পর একটা "হ্যাঁ/না" (Yes/No) বা "সত্য/মিথ্যা" (True/False) প্রশ্ন তৈরি করে ডেটাকে ছোট ছোট ভাগে ভাগ করে ফেলে।

ডিসিশন ট্রি-এর মূল গাঠনিক উপাদান (Core Structure)

একটি ডিসিশন ট্রি মূলত ৩টি প্রধান অংশ নিয়ে গঠিত হয়:

- Root Node (মূল নোড):** এটি গাছের একদম শুরুর বা শীর্ষের নোড। পুরো ডেটাসেটটি এখান থেকেই প্রথম বিভাজন (Split) শুরু করে। আমাদের উদাহরণে "বৃষ্টি হচ্ছে কি না" ছিল রুট নোড।
- Internal/Decision Node (অভ্যন্তরীণ নোড):** এগুলো হলো মাঝখানের ডালপালা বা প্রশ্নগুলোর নোড, যেখানে ডেটার কোনো একটি বৈশিষ্ট্যের ওপর ভিত্তি করে নতুন সিদ্ধান্ত নেওয়া হয় এবং ট্রি-টি আরও নিচে নেমে যায়।
- Leaf Node (পাতা বা চূড়ান্ত নোড):** এগুলো হলো গাছের একদম শেষ প্রান্তের নোড। এর নিচে আর কোনো ডালপালা গজায় না। এটিই মূলত আমাদের চূড়ান্ত প্রেডিকশন বা আউটপুট (যেমন: বাইরে যাব নাকি যাব না) নির্দেশ করে।

কেন এটি এত জনপ্রিয়? (Advantages)

- **সহজে বোঝা যায় (Interpretable):** এটি কীভাবে সিদ্ধান্ত নিচ্ছে তা মানুষ খুব সহজেই বুঝতে পারে (অনেকটা হোয়াইট-বক্স মডেলের মতো)।
- **ডেটা প্রিপারেশন কম লাগে:** এর জন্য খুব বেশি ফিচার স্কেলিং (যেমন: StandardScaler বা MinMaxScaler) করার প্রয়োজন হয় না, কারণ এটি ডেটার মানের আকারের চেয়ে থ্রেশহোল্ড স্প্লিটের ওপর বেশি নির্ভর করে।
- **Non-linear ডেটায় দারুণ কাজ করে:** ডেটার ভেতরে যদি সরলরৈখিক সম্পর্ক না থেকে জটিল বা আঁকাবাঁকা সম্পর্ক থাকে, তবুও এটি চমৎকার প্যাটার্ন খুঁজে বের করতে পারে।

তবে ডিসিশন ট্রি-এর একটি বড় সীমাবদ্ধতা হলো এটি খুব দ্রুত ডেটা মুখস্থ করে ফেলে, যাকে মেশিন লার্নিংয়ের ভাষায় Overfitting (High Variance) বলা হয়। এই ওভারফিটিং দূর করার জন্য পরবর্তীতে গাছের ডালপালা কেটে ছোট করা হয় (Pruning) অথবা একাধিক ডিসিশন ট্রি একসাথে মিলিয়ে Random Forest-এর মতো উন্নত অ্যালগরিদম ব্যবহার করা হয়।

ডিসিশন ট্রি (Decision Tree) Classification (ক্লাসিফিকেশন) এবং Regression (রিগ্রেশন) উভয় সমস্যার জন্যই ব্যবহার করা যায়। টার্গেট ভ্যারিয়েবলের বা আউটপুটের ধরনের ওপর ভিত্তি করে এটিকে দুই ভাগে ভাগ করা হয়:

১. Decision Tree Classifier (শ্রেণিবিভাগকারী)

- কখন ব্যবহার হয়: যখন আপনার আউটপুট বা টার্গেট ভ্যারিয়েবলটি কোনো ক্যাটাগরি, শ্রেণি বা ডিসক্রিট লেবেল (Discrete Label) হয়।
- কীভাবে প্রেডিক্ট করে: এটি গাছের শেষ প্রান্তে বা লিফ নোডে (Leaf Node) থাকা স্যাম্পলগুলোর মেজরিটি ভোটিং (Majority Voting) বা সংখ্যাগরিষ্ঠের ভোটের ভিত্তিতে ফাইনাল ক্লাস প্রেডিক্ট করে।
- বাস্তব উদাহরণ: কোনো ইমেইল 'Spam' নাকি 'Not Spam'।
 - একজন যাত্রী টাইটানিকে 'Survived' (বঁচে গেছেন) নাকি 'Not Survived' (মারা গেছেন)।

২. Decision Tree Regressor (মান অনুমানকারী)

- কখন ব্যবহার হয়: যখন আপনার আউটপুট বা টার্গেট ভ্যারিয়েবলটি কোনো কন্টিনিউয়াস বা ধারাবাহিক সংখ্যা (Continuous Numeric Value) হয়।
- কীভাবে প্রেডিক্ট করে: এটি লিফ নোডে (Leaf Node) পৌঁছানো ডেটা পয়েন্টগুলোর মানের গড় (Mean) বা মিডিয়ান (Median) হিসাব করে চূড়ান্ত সংখ্যাটি প্রেডিক্ট করে।
- বাস্তব উদাহরণ:
 - একটি বাড়ির আয়তন ও লোকেশন দেখে তার 'দাম' বা 'মূল্য' (Price) কত হবে তা অনুমান করা।
 - আবহাওয়ার ডেটা বিশ্লেষণ করে আগামীকালের 'তাপমাত্রা' (Temperature) কত ডিগ্রি হবে তা প্রেডিক্ট করা।

The Mathematical Split

গাছটি কীভাবে ডালপালা মেলবে বা ডেটাকে কোন পয়েন্টে কাটবে (Split), তার গাণিতিক পরিমাপ দুই ক্ষেত্রে ভিন্ন:

- **Classifier-এর ক্ষেত্রে:** ডেটার বিশুদ্ধতা পরিমাপ করার জন্য Gini Impurity (জিনি ইম্পিউরিটি) অথবা Information Gain / Entropy (এনট্রপি) ব্যবহার করা হয়। লক্ষ্য থাকে প্রতিটা স্প্লিটে ডেটাকে যতটা সম্ভব নিখুঁতভাবে আলাদা করা।
- **Regressor-এর ক্ষেত্রে:** ডেটার বিস্তৃতি বা ভুল পরিমাপের জন্য Variance Reduction (ভ্যারিয়েন্স রিডাকশন) অথবা Mean Squared Error (MSE) ব্যবহার করা হয়। লক্ষ্য থাকে এমনভাবে ডেটা ভাগ করা যাতে প্রতিটা ভাগের ভেতরের সংখ্যাগুলোর নিজেদের মধ্যকার দূরত্ব বা এরর সর্বনিম্ন হয়।

কোন ক্ষেত্রে সবচেয়ে বেশি ব্যবহার হয় এবং কেন?

উত্তর: Classification

- **কারণ ১ (সহজ সিদ্ধান্ত):** বাস্তব জীবনের বেশিরভাগ ব্যবসায়িক সিদ্ধান্ত বা শ্রেণিবিভাগ "হ্যাঁ/না" (Yes/No) বা নির্দিষ্ট কিছু ক্যাটাগরির ওপর ভিত্তি করে হয় (যেমন: কাস্টমার প্রোডাক্ট কিনবে নাকি কিনবে না)। ডিসিশন ট্রি-এর "IF-ELSE" লজিক এই ধরনের সমস্যা খুব নিখুঁতভাবে সমাধান করতে পারে।

- **রিগ্রেশনে সীমাবদ্ধতা:** রিগ্রেশনের ক্ষেত্রে (যেমন: বাড়ির দাম অনুমান করা) ডিসিশন ট্রি ডেটাকে ছোট ছোট বক্রে ভাগ করে প্রতিটা বক্রে গড় মান দেয়। এর ফলে আউটপুটের গ্রাফটি মসৃণ (*Smooth*) না হয়ে সিঁড়ির মতো ধাপযুক্ত (*Step – like*) হয়, যা অনেক সময় নিখুঁত সংখ্যাচক প্রেডিকশন দিতে পারে না। তাই রিগ্রেশনের জন্য মানুষ লিনিয়ার রিগ্রেশন বা অন্যান্য অ্যালগরিদম বেশি পছন্দ করে।

কোন কোন সেক্টরে সবচেয়ে বেশি ব্যবহার হয়?

ডিসিশন ট্রি এবং এর উন্নত রূপ (যেমন: Random Forest, XGBoost) মূলত নিচের সেক্টরগুলোতে ব্যাপকভাবে ব্যবহৃত হয়:

১. ব্যাংকিং ও ফাইন্যান্স সেক্টর (Banking & Finance)

- **ক্রেডিট স্কোরিং (Credit Scoring):** একজন কাস্টমারকে লোন বা ক্রেডিট কার্ড দেওয়া নিরাপদ কি না (ল্যোন ডিফল্টার হবে কি না), তা ক্লাসিফাই করতে।
- **জালিয়াতি শনাক্তকরণ (Fraud Detection):** কোনো ক্রেডিট কার্ডের ট্রানজেকশন আসল নাকি জালিয়াতি (*Fraud*), তা তাৎক্ষণিকভাবে ধরে ফেলতে।

২. স্বাস্থ্যসেবা ও চিকিৎসা বিজ্ঞান (Healthcare & Medicine)

- **রোগ নির্ণয় (Disease Diagnosis):** রোগীর লক্ষণ (রক্তচাপ, সুগার লেভেল, বয়স) দেখে তার টিউমারটি ম্যালিগন্যান্ট (ক্যান্সার) নাকি বিনাইন (সাধারণ), তা শ্রেণিবদ্ধ করতে।
- **ঝুঁকি মূল্যায়ন (Risk Assessment):** রোগীর মেডিকেল হিস্ট্রি দেখে ভবিষ্যতে তার হার্ট অ্যাটাকের ঝুঁকি কতটা, তা বের করতে।

৩. ই-কমার্স ও মার্কেটিং (E-commerce & Marketing)

- **কাস্টমার চার্ন প্রেডিকশন (Customer Churn):** কোনো কাস্টমার আপনার সার্ভিস বা সাবস্ক্রিপশন ছেড়ে চলে যাবে কি না, তা আগে থেকে অনুমান করতে।
- **টার্গেটেড মার্কেটিং:** কাস্টমারের বয়স, লিঙ্গ ও ব্রাউজিং হিস্ট্রি দেখে সে কোন ক্যাটাগরির প্রোডাক্ট কিনতে পারে, তা ক্লাসিফাই করে সঠিক অফার পাঠানো।

৪. মানব সম্পদ বিভাগ (Human Resources - HR)

- **প্রার্থী বাছাই (Candidate Screening):** শত শত জীবনবৃত্তান্ত (CV) থেকে কোন প্রার্থী ইন্টারভিউয়ের জন্য যোগ্য (Shortlisted) আর কে যোগ্য নয়, তা ডিসিশন ট্রি ফিল্টারিংয়ের মাধ্যমে দ্রুত আলাদা করতে।

Why we need Decision Tree instead of Linear Regression, Logistic Regression and KNN?

বাস্তব প্রজেক্টের কাজের অভিজ্ঞতার ওপর ভিত্তি করে ডিসিশন ট্রি-এর প্রয়োজনীয়তাকে ৪টি প্রধান সুবিধায় ভাগ করা যায়:

১. জটিল এবং নন-লিনিয়ার ডেটা হ্যান্ডলিং (Handling Complex Non-linear Relations)

- **লিনিয়ার ও লজিস্টিক রিগ্রেশনের সীমাবদ্ধতা:** এই দুটি মডেল ধরে নেয় যে ইনপুট ফিচার এবং টার্গেট ভ্যারিয়েবলের মধ্যে একটি সরলরৈখিক সম্পর্ক (Linear Relationship) বিদ্যমান। কিন্তু বাস্তব দুনিয়ার ডেটা (যেমন: টাইটানিক ডেটাসেট বা বাড়ির দাম) সাধারণত অত্যন্ত আঁকাবাঁকা বা নন-লিনিয়ার হয়। রিগ্রেশন মডেল দিয়ে জোর করে এই ডেটা ফিট করতে গেলে মডেলটির Bias হাই হয়ে যায় (Underfitting ঘটে)।
- **ডিসিশন ট্রি-এর সুবিধা:** ডিসিশন ট্রি ডেটার মধ্যে কোনো সরলরৈখিক সম্পর্ক খোঁজে না। এটি ডেটাসেটকে টুকরো টুকরো বক্সে ভাগ (Feature Space Partitioning) করে কাজ করে। ফলে ডেটার সম্পর্ক যত জটিল বা আঁকাবাঁকাই হোক না কেন, এটি খুব সহজেই সেই প্যাটার্ন ক্যাপচার করতে পারে।

২. ফিচার স্কেলিং এবং আউটলায়ার থেকে মুক্তি (No Need for Feature Scaling & Outlier Robustness)

- **KNN এবং রিগ্রেশনের সীমাবদ্ধতা:** KNN সম্পূর্ণভাবে দূরত্বের (Distance Metrics যেমন: Euclidean Distance) ওপর ভিত্তি করে কাজ করে। ফলে কোনো ফিচারের স্কেল যদি বড় হয় (যেমন: Salary ০-১,০০০,০০০ বনাম Age ০-১০০), তবে বড় ফিচারটি পুরো দূরত্বকে ডমিনেন্ট করে। তাই KNN এবং রিগ্রেশন ব্যবহারের আগে StandardScaler বা MinMaxScaler দিয়ে ডেটা স্কেল করা বাধ্যতামূলক। এছাড়া এগুলো আউটলায়ারের প্রতি অত্যন্ত সংবেদনশীল (Sensitive)।
- **ডিসিশন ট্রি-এর সুবিধা:** ডিসিশন ট্রি একটি Scale-Independent অ্যালগরিদম। এটি দূরত্বের হিসাব করে না, বরং প্রতিটা ফিচারের জন্য কাস্টম থ্রেশহোল্ড (যেমন: Age > 30 কিনা) চেক করে। তাই আপনার ডেটাতে ফিচার স্কেলিং না করলেও এটি নিখুঁত কাজ করে।

এবং চরম আউটলায়ার থাকলেও গাছের স্প্লিটিং মেকানিজমে কোনো নেতিবাচক প্রভাব পড়ে না।

৩. চরম ব্যাখ্যাযোগ্যতা বা হোয়াইট-বক্স মেকানিজম (Extreme Interpretability)

- **লজিস্টিক রিগ্রেশন ও KNN-এর সীমাবদ্ধতা:** KNN-কে "Lazy Learner" বলা হয়, কারণ এটি ব্যাকএন্ডে কোনো গাণিতিক মডেল বা সূত্র তৈরি করে না, শুধু ডেটা মেমোরিতে জমিয়ে রাখে। বড় প্রজেক্টে বা ইন্টারভিউতে মডেল কীভাবে প্রেডিক্ট করছে তা KNN বা লজিস্টিক রিগ্রেশনের জটিল সহগ (Coefficients) থেকে সাধারণ মানুষের পক্ষে বোঝা কঠিন।
- **ডিসিশন ট্রি-এর সুবিধা:** ডিসিশন ট্রি-কে White-Box Model বলা হয়। এটি একটি স্পষ্ট ভিজ্যুয়াল ফ্লোচার্ট বা "IF-ELSE" নিয়মের সেট তৈরি করে সিদ্ধান্ত নেয়। কোনো ব্যাংকের ম্যানেজার বা ডাক্তার খুব সহজেই গাছের ডালপালা দেখে বুঝতে পারেন যে কেন একজন কাস্টমারকে লোন দেওয়া হলো না কিংবা কেন একজন রোগীকে উচ্চ ঝুঁকিপূর্ণ বলা হলো।

৪. ক্যাটাগরিক্যাল ফিচারের স্বাভাবিক হ্যান্ডলিং (Natural Handling of Categorical Data)

- **অন্যান্য মডেলের সীমাবদ্ধতা:** লিনিয়ার/লজিস্টিক রিগ্রেশন এবং KNN-এ ক্যাটাগরিক্যাল ডেটা (যেমন: Sex বা Embarked) সরাসরি পাস করলে মডেল এরর দেয়। এদের জন্য ওয়ান-হট এনকোডিং (One-Hot Encoding) করা বাধ্যতামূলক, যা হাই-কার্ডিনালিটি ডেটার ক্ষেত্রে কলামের সংখ্যা বহুগুণ বাড়িয়ে দেয় (Column Explosion ঘটে)।
- **ডিসিশন ট্রি-এর সুবিধা:** ডিসিশন ট্রি ক্যাটাগরিক্যাল এবং নিউমেরিক্যাল উভয় ধরনের ডেটা একসাথে খুব স্বাভাবিকভাবে সামলাতে পারে। এটি সরাসরি টেক্সট বা ক্যাটাগরির ওপর ভিত্তি করে ডালপালা মেলতে পারে (যেমন: Sex == 'male' হলে বামে যাও, female হলে ডানে যাও), ফলে অতিরিক্ত ওয়ান-হট এনকোডিংয়ের ওপর এর নির্ভরশীলতা অনেক কম।


Example over a small dataset:

Customer	Age	Income	Student	Buy (Target)
C1	22	Low	Yes	Yes
C2	45	Low	No	No
C3	28	High	No	Yes
C4	35	High	Yes	Yes
C5	19	High	No	No

ডিসিশন ট্রি-এর লজিক্যাল গঠন (The Tree Structure)

আমরা যদি এই ডেটার ওপর একটি ডিসিশন ট্রি ট্রেন করি, তবে সে ব্যাকঅ্যান্ডে ইনফরমেশন গেইন (Information Gain) হিসাব করে নিচের মতো একটি গাছের কাঠামো তৈরি করবে:

1. **রুট নোড (Income):** আয় কি High?
 - যদি **না (Low)** হয় → সে ২ নম্বর প্রশ্ন বা সাব-নোডে যাবে।
 - যদি **হ্যাঁ (High)** হয় → সে ৩ নম্বর প্রশ্ন বা সাব-নোডে যাবে।
2. **সাব-নোড ১ (Student):** সে কি একজন শিক্ষার্থী?
 - হ্যাঁ → **Buy: Yes**
 - না → **Buy: No**
3. **সাব-নোড ২ (Age):** বয়স কি ২০-এর ওপরে?
 - হ্যাঁ → **Buy: Yes**
 - না → **Buy: No**



ডিসিশন ট্রির ব্যাকএন্ডে গাছ তৈরির গাণিতিক প্রক্রিয়া

১. মূল লক্ষ্য: বিশুদ্ধতা (Purity) অর্জন

ডিসিশন ট্রি (Decision Tree) অ্যালগরিদমের প্রধান উদ্দেশ্য হলো ডেটাসেটকে এমনভাবে ধারাবাহিকভাবে বিভক্ত করা, যাতে প্রতিটি চূড়ান্ত নোডে (Leaf Node) একই শ্রেণির (Class) ডেটা থাকে। অর্থাৎ, প্রতিটি বিভাজনের মাধ্যমে ডেটার বিশুদ্ধতা (Impurity) কমিয়ে আনা এবং যতটা সম্ভব বিশুদ্ধ (Pure) নোড তৈরি করাই এই অ্যালগরিদমের মূল লক্ষ্য।

অবিশুদ্ধ নোড (Impure Node)

যদি কোনো নোডে একাধিক শ্রেণির ডেটা একসঙ্গে উপস্থিত থাকে, তবে সেটিকে অবিশুদ্ধ নোড বলা হয়। উদাহরণস্বরূপ, একটি নোডে যদি সমান সংখ্যক **Yes** এবং **No** শ্রেণির ডেটা থাকে, তবে সেই নোডে অনিশ্চয়তা সর্বাধিক থাকে। ফলে শুধুমাত্র সেই নোডের তথ্যের ভিত্তিতে সঠিক সিদ্ধান্ত গ্রহণ করা সম্ভব হয় না।

বিশুদ্ধ নোড (Pure Node)

অন্যদিকে, যদি কোনো নোডে কেবলমাত্র একটি শ্রেণির ডেটা উপস্থিত থাকে, যেমন সবগুলোই **Yes** অথবা সবগুলোই **No**, তাহলে সেই নোডকে সম্পূর্ণ বিশুদ্ধ (Pure Node) বলা হয়। এ ধরনের

নোডে আর কোনো বিভাজনের প্রয়োজন হয় না এবং এটিই ডিসিশন ট্রির চূড়ান্ত পাতা বা **Leaf Node** হিসেবে বিবেচিত হয়।

২. অবিশুদ্ধতা পরিমাপের গাণিতিক পদ্ধতি (Mathematical Metrics)

ডিসিশন ট্রি কোন ফিচারের ভিত্তিতে ডেটা ভাগ করবে তা নির্ধারণ করার জন্য বিভিন্ন গাণিতিক পরিমাপক (Metric) ব্যবহার করে। এই পরিমাপকগুলোর মাধ্যমে প্রতিটি সম্ভাব্য বিভাজনের গুণগত মান মূল্যায়ন করা হয়। সর্বাধিক ব্যবহৃত তিনটি পদ্ধতি হলো:

- Entropy
- Information Gain
- Gini Impurity

২.১ Entropy (এনট্রপি): বিশৃঙ্খলার পরিমাপ


Entropy হলো কোনো নোডের অনিশ্চয়তা বা বিশৃঙ্খলার (Disorder) পরিমাপ। একটি নোডে বিভিন্ন শ্রেণির ডেটা যত বেশি মিশ্রিত থাকবে, এনট্রপির মান তত বেশি হবে। বিপরীতভাবে, নোড যত বেশি বিশুদ্ধ হবে, এনট্রপির মান তত কম হবে।

এর গাণিতিক সূত্র হলো,

$$Entropy(S) = - \sum_{i=1}^c p_i \log_2(p_i)$$

এখানে,

- S হলো বর্তমান নোডের ডেটাসেট।
- c হলো মোট শ্রেণির সংখ্যা।
- p_i হলো i -তম শ্রেণির ডেটার অনুপাত (Probability)।



এনট্রপির মানের ব্যাখ্যা

- যদি নোডে ৫০% Yes এবং ৫০% No থাকে, তাহলে অনিশ্চয়তা সর্বাধিক হয় এবং Entropy-এর মান হয় 1.0।
- যদি নোডে ১০০% একই শ্রেণির ডেটা থাকে, তাহলে কোনো অনিশ্চয়তা থাকে না এবং Entropy-এর মান হয় 0।

অতএব, ডিসিশন ট্রির লক্ষ্য হলো প্রতিটি বিভাজনের মাধ্যমে Entropy-এর মান ক্রমান্বয়ে কমিয়ে আনা।

২.২ Information Gain (ইনফরমেশন গেইন): তথ্য অর্জনের পরিমাণ

Entropy শুধুমাত্র বর্তমান নোডের বিশৃঙ্খলা পরিমাপ করে। কিন্তু কোন ফিচার ব্যবহার করলে সেই বিশৃঙ্খলা সবচেয়ে বেশি কমবে, তা নির্ধারণ করার জন্য Information Gain ব্যবহার করা হয়।

প্রথমে প্রতিটি সম্ভাব্য ফিচার ব্যবহার করে ডেটাকে বিভক্ত করা হয়। এরপর বিভাজনের আগে ও পরে Entropy-এর পরিবর্তন নির্ণয় করা হয়। এই পরিবর্তনের পরিমাণই Information Gain নামে পরিচিত।

এর গাণিতিক সূত্র হলো,

$$Information\ Gain = Entropy(Parent) - Weighted\ Average\ Entropy(Children)$$

এখানে,

- **Parent Entropy** হলো বিভাজনের পূর্বের নোডের Entropy।
- **Children Entropy** হলো বিভাজনের পর সৃষ্ট সকল সাব-নোডের ওজনযুক্ত (Weighted) গড় Entropy।

Information Gain-এর সিদ্ধান্ত

ডিসিশন ট্রি প্রতিটি ফিচারের জন্য Information Gain গণনা করে।

যে ফিচারের Information Gain সর্বাধিক হয়, অর্থাৎ যে ফিচারটি ডেটার বিশৃঙ্খলা সবচেয়ে বেশি কমাতে সক্ষম হয়, সেই ফিচারকেই পরবর্তী Decision Node অথবা Root Node হিসেবে নির্বাচন করা হয়।

২.৩ Gini Impurity (জিনি ইম্পিউরিটি): দ্রুত বিশুদ্ধতা পরিমাপ


Entropy গণনার সময় লগারিদমিক ($\log_2$) অপারেশন ব্যবহৃত হয়, যা তুলনামূলকভাবে বেশি কম্পিউটেশনাল সময় গ্রহণ করে। এই কারণে বাস্তব প্রয়োগে অনেক লাইব্রেরি, বিশেষ করে **Scikit-Learn**, ডিফল্টভাবে Entropy-এর পরিবর্তে **Gini Impurity** ব্যবহার করে।

Gini Impurity-এর সূত্র হলো,

$$Gini = 1 - \sum_{i=1}^c (p_i)^2$$

এখানে,

- p_i হলো প্রতিটি শ্রেণির Probability।



$$E(S) = \sum_{i=1}^c -p_i \log_2 p_i$$

$$Gini(E) = 1 - \sum_{j=1}^c p_j^2$$

Gini Impurity-এর মানের ব্যাখ্যা

- সম্পূর্ণ বিশুদ্ধ নোডের Gini মান 0।
- দুটি শ্রেণির সমান অনুপাত থাকলে Gini-এর মান 0.5, যা সর্বোচ্চ অবিশুদ্ধতার নির্দেশক।

ডিসিশন ট্রি সর্বদা এমন বিভাজন নির্বাচন করে যাতে সাব-নোডগুলোর Gini Impurity যত সম্ভব কম হয়।

৩. ডিসিশন ট্রির ব্যাকএন্ড ওয়ার্কফ্লো

model.fit() মেথড কল করার পর ডিসিশন ট্রি একটি ধারাবাহিক গাণিতিক প্রক্রিয়ার মাধ্যমে নিজস্ব কাঠামো তৈরি করে। এই প্রক্রিয়াটি নিম্নলিখিত ধাপগুলো অনুসরণ করে।

ধাপ ১: Parent Node-এর বিশুদ্ধতা নির্ণয়

প্রথমে সম্পূর্ণ Training Dataset-কে একটি Parent Node হিসেবে বিবেচনা করা হয়। এরপর ওই নোডের Entropy অথবা Gini Impurity গণনা করা হয়।

ধাপ ২: সমস্ত ফিচার ও সম্ভাব্য Threshold পরীক্ষা করা

এরপর প্রতিটি Feature একে একে বিশ্লেষণ করা হয়।

যদি Feature সংখ্যাসূচক (Numerical) হয়, তাহলে সম্ভাব্য বিভিন্ন Threshold পরীক্ষা করা হয়।

যেমন,

- Age > 20
- Age > 25
- Age > 30

আবার যদি Feature শ্রেণিভিত্তিক (Categorical) হয়, তাহলে প্রতিটি Category অনুযায়ী সম্ভাব্য বিভাজন পরীক্ষা করা হয়।

প্রতিটি ক্ষেত্রেই ডেটাকে সাময়িকভাবে (Temporarily) দুই ভাগে বিভক্ত করা হয়।

ধাপ ৩: প্রতিটি বিভাজনের গুণগত মান মূল্যায়ন

প্রতিটি সম্ভাব্য বিভাজনের পরে সৃষ্ট সাব-নোডগুলোর Entropy অথবা Gini Impurity পুনরায় গণনা করা হয়।

এরপর Information Gain নির্ণয় করা হয় এবং দেখা হয়, কোন বিভাজন Parent Node-এর তুলনায় সবচেয়ে বেশি বিশৃঙ্খলা কমাতে সক্ষম হয়েছে।

ধাপ ৪: সর্বোত্তম বিভাজন নির্বাচন

যে Feature এবং Threshold সর্বোচ্চ Information Gain প্রদান করে অথবা সর্বনিম্ন Gini Impurity সৃষ্টি করে, সেটিকে চূড়ান্ত Split হিসেবে নির্বাচন করা হয়।

এরপর Parent Node-কে স্থায়ীভাবে (Permanently) সেই নিয়ম অনুযায়ী দুই বা ততোধিক সাব-নোডে বিভক্ত করা হয়।

ধাপ ৫: পুনরাবৃত্তিমূলক (Recursive) প্রক্রিয়া

একবার প্রথম বিভাজন সম্পন্ন হলে একই প্রক্রিয়া প্রতিটি নতুন সাব-নোডের জন্য পুনরায় চালানো হয়।

অর্থাৎ,

- পুনরায় Entropy বা Gini গণনা করা হয়।
- সম্ভাব্য সকল Feature পরীক্ষা করা হয়।
- সর্বোত্তম Split নির্বাচন করা হয়।
- নতুন Sub-node তৈরি করা হয়।

এই Recursive প্রক্রিয়া বারবার চলতে থাকে যতক্ষণ না অ্যালগরিদমের থামার কোনো শর্ত পূরণ হয়।

৪. ডিসিশন ট্রি কখন বৃদ্ধি বন্ধ করে? (Stopping Criteria)

যদি ডিসিশন ট্রিকে কোনো সীমাবদ্ধতা ছাড়া প্রশিক্ষণ দেওয়া হয়, তাহলে এটি প্রতিটি Leaf Node সম্পূর্ণ বিশুদ্ধ না হওয়া পর্যন্ত বিভাজন চালিয়ে যেতে পারে। এর ফলে মডেলটি শুধুমাত্র প্রকৃত প্যাটার্ন নয়, বরং Training Dataset-এর Noise এবং ব্যতিক্রমী তথ্যও শিখে ফেলে। এই সমস্যাকে **Overfitting** বলা হয়।

Overfitting প্রতিরোধ করার জন্য বিভিন্ন Hyperparameter ব্যবহার করা হয়।

max_depth

গাছ সর্বোচ্চ কত স্তর পর্যন্ত বৃদ্ধি পাবে তা নির্ধারণ করে।

উদাহরণস্বরূপ,

`max_depth = 3`

দেওয়া হলে গাছ তিন স্তরের বেশি বৃদ্ধি পাবে না।

min_samples_split

কোনো নোডকে নতুনভাবে বিভক্ত করার জন্য সেখানে ন্যূনতম কতটি Sample থাকতে হবে, তা নির্ধারণ করে।

min_samples_leaf

প্রতিটি Leaf Node-এ সর্বনিম্ন কতটি Sample থাকতে হবে, তা নির্ধারণ করে। এর ফলে খুব ছোট বা অপ্রয়োজনীয় Leaf তৈরি হওয়ার সম্ভাবনা কমে যায়।

Example of Decision Tree over a Categorical Dataset:

ধরা যাক, একটি দোকান জানতে চায় কোনো গ্রাহক পণ্য কিনবে কিনা। এজন্য নিচের ডেটাসেটটি সংগ্রহ করা হয়েছে।

ID	Income	Student	Buy
1	High	Yes	Yes
2	High	Yes	Yes
3	High	No	No
4	High	No	No
5	Low	Yes	Yes
6	Low	Yes	Yes
7	Low	No	No
8	Low	No	Yes

এখানে,

- **Features**
 - Income
 - Student
- **Target**
 - Buy

ধাপ ১: Parent Node-এর Entropy গণনা

প্রথমে সম্পূর্ণ ডেটাসেটকে Parent Node ধরা হবে।

মোট ডেটা = 8

Buy = Yes = 5

Buy = No = 3

অতএব,

$$P(Yes) = \frac{5}{8} = 0.625$$
$$P(No) = \frac{3}{8} = 0.375$$

Entropy-এর সূত্র,

$$Entropy(S) = -\sum p_i \log_2(p_i)$$

সুতরাং,

$$Entropy(S) = -\left(\frac{5}{8} \log_2 \frac{5}{8} + \frac{3}{8} \log_2 \frac{3}{8}\right)$$

গণনা করলে,

$$\log_2(0.625) = -0.678$$
$$\log_2(0.375) = -1.415$$

অতএব,

$$Entropy = -(0.625 \times -0.678 + 0.375 \times -1.415)$$
$$= 0.954$$

অতএব,

$$Entropy(Parent) = 0.954$$

ধাপ ২: Feature = Income পরীক্ষা করা

Income-এর দুটি মান আছে।

- High
- Low

Income = High

Buy
Yes
Yes
No
No

Yes = 2

No = 2

অতএব,

$$\begin{aligned} Entropy(High) &= -\left(\frac{2}{4}\log_2\frac{2}{4} + \frac{2}{4}\log_2\frac{2}{4}\right) \\ &= 1.0 \end{aligned}$$

Income = Low

Buy
Yes
Yes
No
Yes

Yes = 3

No = 1

$$\begin{aligned} Entropy(Low) &= -\left(\frac{3}{4}\log_2\frac{3}{4} + \frac{1}{4}\log_2\frac{1}{4}\right) \\ &= 0.811 \end{aligned}$$

Weighted Entropy

$$\begin{aligned} &= \frac{4}{8} \times 1 + \frac{4}{8} \times 0.811 \\ &= 0.9055 \end{aligned}$$

Information Gain (Income)

$$\begin{aligned} IG &= 0.954 - 0.9055 \\ &= 0.0485 \end{aligned}$$

ধাপ ৩: Feature = Student পরীক্ষা করা

Student-এর দুটি মান।

- Yes
- No

Student = Yes

Buy
Yes
Yes
Yes
Yes

Yes = 4

No = 0

$$Entropy = 0$$

Student = No

Buy
No
No
No
Yes

Yes = 1

No = 3

$$Entropy = -\left(\frac{1}{4}\log_2 \frac{1}{4} + \frac{3}{4}\log_2 \frac{3}{4}\right)$$

$$= 0.811$$

Weighted Entropy

$$= \frac{4}{8} \times 0 + \frac{4}{8} \times 0.811$$

$$= 0.4055$$

Information Gain

$$IG = 0.954 - 0.4055$$

$$= 0.5485$$

ধাপ ৪: Information Gain তুলনা

Feature Information Gain

Income 0.0485

Student 0.5485

স্পষ্টভাবে দেখা যাচ্ছে,

$$0.5485 > 0.0485$$


অতএব,

Student Feature সর্বাধিক Information Gain প্রদান করেছে।

সুতরাং,

Student হবে Root Node।

ধাপ ৫: প্রথম Split



Student = Yes

ডেটা

Buy
Yes
Yes
Yes
Yes

সবগুলো একই ক্লাস।

Entropy = 0

এটি একটি **Leaf Node**।

Student = Yes



Buy = Yes

Student = No

ডেটা

Income	Buy
High	No
High	No
Low	No
Low	Yes

এখানে

Yes = 1

No = 3

এখন এই নোডটি বিশুদ্ধ নয়।

অতএব, আবার Feature নির্বাচন করতে হবে।

এখানে অবশিষ্ট Feature হলো

Income

ধাপ ৬: Student = No নোডে Income দিয়ে Split

Income = High

Buy
No
No

Entropy = 0

Income = Low

Buy
No
Yes

Entropy

$$= -\left(\frac{1}{2} \log_2 \frac{1}{2} + \frac{1}{2} \log_2 \frac{1}{2}\right) = 1$$

Weighted Entropy

$$= \frac{2}{4} \times 0 + \frac{2}{4} \times 1 = 0.5$$

বর্তমান Parent Entropy

$$0.811$$


Information Gain

$$= 0.811 - 0.5 = 0.311$$

অতএব,

Income দিয়ে আবার Split করা হবে।

Final Decision Tree



এখানে Income = Low শাখায় এখনও দুটি ভিন্ন ক্লাস (Yes এবং No) রয়েছে। যেহেতু আর কোনো Feature অবশিষ্ট নেই, তাই বাস্তব অ্যালগরিদম সাধারণত Majority Class নির্বাচন করে অথবা নির্ধারিত Stopping Criteria অনুযায়ী সেই নোডকে Leaf Node বানিয়ে দেয়।

Dataset

ID	Income	Student	Buy
1	High	Yes	Yes
2	High	Yes	Yes
3	High	No	No
4	High	No	No
5	Low	Yes	Yes
6	Low	Yes	Yes
7	Low	No	No
8	Low	No	Yes

ধাপ ১: Parent Gini

মোট ৮টি ডেটা

- Yes = 5
- No = 3

$$\begin{aligned}Gini &= 1 - (P_{Yes}^2 + P_{No}^2) \\&= 1 - \left(\left(\frac{5}{8} \right)^2 + \left(\frac{3}{8} \right)^2 \right) \\&= 1 - (0.3906 + 0.1406) \\&= \boxed{0.4688}\end{aligned}$$

ধাপ ২: Income Feature

Income = High

Yes = 2, No = 2

$$Gini = 1 - (0.5^2 + 0.5^2) = 0.5$$

Income = Low

Yes = 3, No = 1

$$Gini = 1 - \left(\left(\frac{3}{4} \right)^2 + \left(\frac{1}{4} \right)^2 \right) = 0.375$$

Weighted Gini

$$= \frac{4}{8}(0.5) + \frac{4}{8}(0.375) = 0.4375$$

Gini Gain (Reduction)

$$0.4688 - 0.4375 = \boxed{0.0313}$$

ধাপ ৩: Student Feature

Student = Yes

Yes = 4, No = 0

$$Gini = 0$$

Student = No

Yes = 1, No = 3

$$Gini = 1 - \left(\left(\frac{1}{4} \right)^2 + \left(\frac{3}{4} \right)^2 \right) = 0.375$$

Weighted Gini

$$= \frac{4}{8}(0) + \frac{4}{8}(0.375) = 0.1875$$


Gini Gain (Reduction)

$$0.4688 - 0.1875 = \boxed{0.2813}$$

ধাপ ৪: সিদ্ধান্ত

Feature	Weighted Gini	Gini Reduction
Income	0.4375	0.0313
Student	0.1875	0.2813

যেহেতু Student Feature-এর Weighted Gini সবচেয়ে কম (0.1875) এবং Gini Reduction সবচেয়ে বেশি (0.2813), তাই Student-কেই Root Node হিসেবে নির্বাচন করা হবে।



Classification-এ আমরা Entropy বা Gini ব্যবহার করি, কারণ সেখানে লক্ষ্য থাকে ক্লাস (Yes/No) আলাদা করা। কিন্তু Regression Tree-তে লক্ষ্য থাকে Continuous Value (যেমন: Price, Salary, House Price) পূর্বাভাস দেওয়া। তাই এখানে Variance বা Mean Squared Error (MSE) ব্যবহার করা হয়।

Dataset

ধরা যাক, আমরা পড়ার সময় (Study Hours) দেখে পরীক্ষার নম্বর (Marks) পূর্বাভাস দিতে চাই।

ID	Study Hours	Marks
1	1	40
2	2	45
3	3	50
4	4	80
5	5	85
6	6	90

Target = **Marks**

ধাপ ১: সম্ভাব্য Split নির্বাচন

ধরি,

Split = Study Hours $\leq$ 3

তাহলে Dataset দুই ভাগে বিভক্ত হবে।

Left Node

Hours	Marks
1	40
2	45
3	50

Mean

$$= \frac{40 + 45 + 50}{3} = 45$$

Variance

$$\begin{aligned} &= \frac{(40 - 45)^2 + (45 - 45)^2 + (50 - 45)^2}{3} \\ &= \frac{25 + 0 + 25}{3} = 16.67 \end{aligned}$$

Right Node

Hours	Marks
4	80
5	85
6	90

Mean

$$= \frac{80 + 85 + 90}{3} = 85$$

Variance

$$\begin{aligned} &= \frac{(80 - 85)^2 + (85 - 85)^2 + (90 - 85)^2}{3} \\ &= \frac{25 + 0 + 25}{3} = 16.67 \end{aligned}$$

ধাপ ২: Weighted Variance

Left-এ ৩টি Sample

Right-এ ৩টি Sample

$$Weighted\ Variance = \frac{3}{6}(16.67) + \frac{3}{6}(16.67) = 16.67$$

ধাপ ৩: অন্য একটি Split পরীক্ষা

ধরি,

Study Hours ≤ 4

Left Node

Marks

40, 45, 50, 80

Mean

$$= \frac{40 + 45 + 50 + 80}{4} = 53.75$$

Variance

$$= 242.19$$

Right Node

Marks

85, 90

Mean

$$= 87.5$$

Variance

$$= 6.25$$

Weighted Variance

$$\begin{aligned} &= \frac{4}{6}(242.19) + \frac{2}{6}(6.25) \\ &= 163.54 \end{aligned}$$

ধাপ ৪: সিদ্ধান্ত

Split Weighted Variance

Study Hours ≤ 3 **16.67**


Study Hours ≤ 4 163.54

যেহেতু

16.67 < 163.54

তাই **Study Hours ≤ 3** হবে **Best Split**।

Decision Tree



Prediction

Study Hours	Prediction
2	45
3	45
5	85
6	85

এখানে প্রতিটি Leaf Node কোনো Class Label সংরক্ষণ করে না। বরং সেই Leaf-এর সকল Target Value-এর Mean (Average) সংরক্ষণ করে।

ডিসিশন ট্রি ক্লাসিফায়ার এবং ডিসিশন ট্রি রিগ্রেসরের মধ্যে পার্থক্য

বিষয়	Decision Tree Classifier	Decision Tree Regressor
পূর্বাভাসের ধরন	শ্রেণিভিত্তিক (Categorical) মান পূর্বাভাস দেয়	ধারাবাহিক সংখ্যাসূচক (Continuous Numerical) মান পূর্বাভাস দেয়
Target Variable-এর ধরন	Categorical (যেমন: Yes/No, Spam/Not Spam)	Numerical (যেমন: Price, Salary, Temperature)
মূল উদ্দেশ্য	ডেটাকে বিভিন্ন শ্রেণিতে (Class) ভাগ করা	কোনো সংখ্যাসূচক মান (Value) পূর্বাভাস দেওয়া
Split করার মানদণ্ড	Entropy, Information Gain অথবা Gini Impurity	Variance Reduction অথবা Mean Squared Error (MSE) Reduction
Impurity Measure	বিভিন্ন Class কতটা মিশ্রিত আছে তা পরিমাপ করে	সংখ্যাগুলোর বিচ্ছুরণ (Variation) কতটা তা পরিমাপ করে
Leaf Node-এর আউটপুট	একটি Class Label (যেমন: Yes বা No) সংরক্ষণ করে	Target Value-এর গড় (Mean/Average) সংরক্ষণ করে
সেরা Split নির্বাচন	সর্বোচ্চ Information Gain অথবা সর্বনিম্ন Gini বিশিষ্ট Split নির্বাচন করে	সর্বনিম্ন Variance অথবা সর্বনিম্ন MSE বিশিষ্ট Split নির্বাচন করে
Decision Rule	ভিন্ন ভিন্ন Class আলাদা করার চেষ্টা করে	কাছাকাছি সংখ্যাসূচক মানগুলোকে একই দলে রাখার চেষ্টা করে
আউটপুটের উদাহরণ	Buy = Yes	House Price = 25,00,000 টাকা
Evaluation Metrics	Accuracy, Precision, Recall, F1-score, ROC-AUC	MAE, MSE, RMSE, R ² Score
Scikit-Learn Class	DecisionTreeClassifier	DecisionTreeRegressor
সাধারণ ব্যবহার	Spam Detection, Disease Classification, Customer Churn Prediction	House Price Prediction, Salary Prediction, Sales Forecasting

Scikit-Learn-এর DecisionTreeClassifier Hyperparameter:

১. মোস্ট ইম্পোর্টেন্ট প্যারামিটারসমূহ (The Heavy Hitters)

গাছের সাইজ নিয়ন্ত্রণ করতে, ওভারফিটিং রোধ করতে এবং ইন্টারভিউতে সবচেয়ে বেশি ফোকাস করা হয় এই প্যারামিটারগুলোর ওপর।

max_depth: None (default)

- **কাজ কী:** এটি আপনার তৈরি হওয়া গাছের সর্বোচ্চ গভীরতা বা লেভেল (Level) নির্ধারণ করে।
- **কখন 'None' (Default) রাখব:** ডেটাসেট যদি খুব ছোট হয় এবং আপনি যদি দেখতে চান গাছটি সর্বোচ্চ কতদূর পর্যন্ত যেতে পারে, তখন এটি ডিফল্ট রাখা যায়। None থাকলে গাছটি বাড়তেই থাকবে যতক্ষণ না সব পাতা ১০০% বিশুদ্ধ হচ্ছে বা min_samples_split-এর চেয়ে কম স্যাম্পল থাকছে।
- **ঝুঁকি কী:** এটি ডিফল্ট রেখে দিলে গাছটি একদম শেষ সীমানা পর্যন্ত মুখস্থ করতে থাকবে এবং মারাত্মক **Overfitting (High Variance)** ঘটবে।
- **অন্যান্য অপশন ও কখন ব্যবহার করব:** এখানে যেকোনো পূর্ণসংখ্যা (যেমন: 3, 5, 10) দেওয়া যায়। বাস্তব প্রজেক্টে ওভারফিটিং বন্ধ করার সবচেয়ে প্রথম হাতিয়ার হলো এটি। সবসময় ছোট মান (যেমন: max_depth=3 বা 5) দিয়ে শুরু করা ভালো, যাতে মডেলটি জেনারেলাইজড বা সুষম থাকে।

criterion: "gini" (default)

- **কাজ কী:** প্রতিটা ধাপে ডালপালা মেলানোর জন্য বা ডেটা ভাগ (Split) করার কোয়ালিটি মাপার জন্য ব্যাকএন্ডে কোন গাণিতিক সূত্র ব্যবহার করা হবে, তা এটি নির্ধারণ করে।
- **কখন 'gini' (Default) ব্যবহার করব:** বাস্তব প্রজেক্টে দ্রুত ট্রেনিং শেষ করার জন্য এটি ব্যবহার করা হয়। জিনি ইম্পিউরিটির গাণিতিক সূত্রে কোনো লগারিদম ($\log_2$) হিসাব করতে হয় না, তাই এটি কম্পিউটেশনালি অত্যন্ত ফাস্ট এবং দ্রুত রেজাল্ট দেয়।
- **অন্যান্য অপশন:** "entropy" অথবা "log_loss" (উভয়ই শ্যানন ইনফরমেশন গেইনের ওপর ভিত্তি করে কাজ করে)।
- **কখন এবং কেন 'entropy' ব্যবহার করব:** যখন আপনি অত্যন্ত সূক্ষ্ম এবং সুষমভাবে ডেটা ভাগ করতে চান। এনট্রপি নোডের ভেতরের বিশৃঙ্খলাকে আরও নিখুঁতভাবে মাপে, তবে এর সূত্রে $\log_2$ থাকায় কম্পিউটারের প্রসেসিং টাইম সামান্য বেশি লাগে। বড় ডেটাসেটে জিনি আর এনট্রপির এক্যুরেসির মধ্যে খুব বেশি তফাৎ পাওয়া যায় না, তাই ডিফল্ট 'gini' রাখাই স্ট্যান্ডার্ড।

min_samples_split: 2 (default)

- **কাজ কী:** মাঝখানের কোনো একটি নোডকে (Internal Node) ভেঙে নতুন ডালপালা তৈরি করার জন্য ওই নোডে নূন্যতম কয়টি ডেটা স্যাম্পল থাকতে হবে, তা এটি ঠিক করে।
- **কখন '2' (Default) রাখব:** যখন আপনি গাছের স্প্লিটিং প্রক্রিয়ায় কোনো বাধা দিতে চান না। তবে ২ রাখা মানে নোডে মাত্র ২টি স্যাম্পল থাকলেও গাছ সেটিকে ভেঙে আরও নিচে নামবে, যা ওভারফিটিংয়ের ঝুঁকি বাড়ায়।
- **অন্যান্য অপশন ও কখন ব্যবহার করব:** এখানে পূর্ণসংখ্যা (যেমন: 10, 50) অথবা ফ্লোট ভগ্নাংশ (যেমন: 0.05 অর্থাৎ মোট ডেটার ৫%) দেওয়া যায়।
- **কেন পরিবর্তন করব:** ওভারফিটিং কমানোর জন্য। যদি আপনি min_samples_split=50 দেন, তবে কোনো নোডে ৫০টির কম ডেটা থাকলে গাছ সেটিকে আর ভাঙবে না, সরাসরি ওখানেই থামিয়ে দেবে।

min_samples_leaf: 1 (default)

- **কাজ কী:** একটি চূড়ান্ত পাতা বা লিফ নোডে (Leaf Node) নূন্যতম কয়টি স্যাম্পল থাকতেই হবে, তা এটি ফিক্স করে।
- **কখন '1' (Default) রাখব:** ডিফল্ট ১ রাখা মানে গাছের শেষ পাতায় মাত্র ১টি স্যাম্পল থাকলেও মডেল খুশি। এটি মডেলকে চরম মুখস্থবিদ্যার দিকে ঠেলে দেয়।
- **অন্যান্য অপশন ও কখন ব্যবহার করব:** এখানেও পূর্ণসংখ্যা বা ফ্লোট ভগ্নাংশ দেওয়া যায় (যেমন: 5, 10 বা 0.02)।
- **কেন পরিবর্তন করব:** এটি মডেলকে স্মুথ (Smooth) করতে সাহায্য করে। যদি min_samples_leaf=10 দেওয়া হয়, তবে কোনো স্প্লিট করার কারণে যদি বাম বা ডান ডালের কোনো একটিতে ১০টির কম স্যাম্পল চলে যাওয়ার পরিস্থিতি তৈরি হয়, তবে ডিসিশন ট্রি ওই স্প্লিটটি বাতিল করে দেবে। এটি ওভারফিটিং কমানোর অত্যন্ত শক্তিশালী একটি প্যারামিটার।

২. মিডিয়াম ইম্পর্টেন্ট প্যারামিটারসমূহ (Advanced Tuning)

মডেলের পারফরম্যান্স আরও নিখুঁত করতে এবং ডেটার বিশেষ পরিস্থিতি সামলাতে এগুলো ব্যবহার করা হয়।

class_weight: None (default)

- **কাজ কী:** ইমব্যালেন্সড ডেটাসেটের (Imbalanced Dataset) ক্ষেত্রে মাইনোরিটি ক্লাসকে বা ছোট ক্লাসকে অতিরিক্ত গুরুত্ব বা ওজন দেওয়ার জন্য এটি ব্যবহৃত হয়।
- **কখন 'None' (Default) রাখব:** যখন আপনার ডেটাসেটে সব ক্লাসের অনুপাত প্রায় সমান থাকে (যেমন: ৫০% Yes, ৫০% No)।
- **অন্যান্য অপশন:** "balanced" অথবা কাস্টম ডিকশনারি {0: 1, 1: 5}।
- **কখন এবং কেন 'balanced' ব্যবহার করব:** যখন ডেটা প্রবলভাবে ইমব্যালেন্সড (যেমন: টাইটানিকে মারা গেছে ৮০%, বেঁচেছে মাত্র ২০%)। class_weight='balanced' দিলে মডেলটি স্বয়ংক্রিয়ভাবে ছোট ক্লাসকে বেশি গুরুত্ব দেয়, ফলে মডেলের রিকল (Recall) এবং এফ১-স্কোর (F1-score) উন্নত হয়।

max_features: None (default)

- **কাজ কী:** প্রতিটা স্প্লিটে সেরা শর্তটি খোঁজার সময় ডিসিশন ট্রি সর্বোচ্চ কয়টি ফিচার স্ক্যান করবে, তা এটি নিয়ন্ত্রণ করে।
- **কখন 'None' (Default) রাখব:** যখন ডেটাসেটে ফিচারের সংখ্যা কম (যেমন: ১০-১৫টি কলাম) এবং আপনি চান মডেলটি প্রতিবার সব ফিচার দেখে সেরা সিদ্ধান্তটি নিক।
- **অন্যান্য অপশন:** "sqrt" (ফিচার সংখ্যার বর্গমূল), "log2" (ফিচার সংখ্যার লগ বেস ২) অথবা সরাসরি কোনো সংখ্যা বা ভগ্নাংশ।
- **কখন এবং কেন পরিবর্তন করব:** যখন ডেটাসেটে ফিচারের সংখ্যা বিশাল (যেমন: ৫০০ বা ১০০০ কলাম)। তখন প্রতিটা নোডে সব ফিচার চেক করতে গেলে মডেল স্লো হয়ে যায়। max_features='sqrt' দিলে সে প্রতি স্প্লিটে র্যান্ডমলি কিছু ফিচার বেছে নিয়ে তার মধ্য থেকে সেরাটি খোঁজে। এটি মূলত **Random Forest** অ্যালগরিদমের মূল ভিত্তি।

ccp_alpha: 0.0 (default)

- **কাজ কী:** এটি গাছের পোস্ট-প্রুনিং (Post-Pruning) বা বড় হয়ে যাওয়া গাছের অপ্রয়োজনীয় ডালপালা কেটে ছোট ফেলার জটিল গাণিতিক প্যারামিটার।

- **কখন '0.0' (Default) রাখব:** ডিফল্ট শূন্য রাখা মানে মডেলটি কোনো ডালপালা কাটবে না, গাছ যেভাবে বাড়ে সেভাবেই থাকবে।
- **অন্যান্য অপশন ও কখন ব্যবহার করব:** এখানে যেকোনো অ-ঋণাত্মক ফ্লোট মান (যেমন: 0.01, 0.015) দেওয়া যায়। যখন গাছটি অলরেডি সম্পূর্ণ বড় হয়ে ওভারফিট করে ফেলেছে, তখন কস্ট-কমপ্লেক্সিটি অ্যালগরিদম দিয়ে দুর্বল ডালগুলো কেটে মডেলকে জেনারেলাইজড করতে এটি টিউন করা হয়।

random_state: None (default)

- **কাজ কী:** মডেলের শাফলিং এবং র্যান্ডম অপারেশনগুলোকে নিয়ন্ত্রণ করে কোডের আউটপুটকে প্রতিবার একই রকম বা রিপ্ৰোডিউসিবল (*Reproducible*) রাখে।
- **কখন 'None' (Default) রাখব:** যদি আপনি কোড প্রতিবার রান করার সময় সামান্য ভিন্ন ভিন্ন গাছ বা আউটপুট দেখতে চান (রিসার্চের সময় সাধারণত রাখা হয় না)।
- **অন্যান্য অপশন ও কখন ব্যবহার করব:** এখানে যেকোনো ফিক্সড পূর্ণসংখ্যা (কনভেনশন হিসেবে 42 বা 0) দেওয়া উচিত। অ্যাসাইনমেন্ট, পরীক্ষা বা টিম প্রজেক্টে যেন আপনার কোড অন্য কম্পিউটারে রান করলেও অবিকল একই গাছ এবং একই এক্যুরেসির রেজাল্ট দেয়, তা নিশ্চিত করতে এটি ফিক্স করা বাধ্যতামূলক।

৩. লেস ইম্পোর্টেন্ট প্যারামিটারসমূহ (Rarely Used)

সাধারণ মডেলিংয়ে এগুলো খুব একটা পরিবর্তন করার প্রয়োজন হয় না, ডিফল্ট মানই চমৎকার কাজ করে।

splitter: "best" (default)

- **কাজ কী:** নোড ভাগ করার সময় ফিচারগুলোর মধ্য থেকে থ্রেশহোল্ড বেছে নেওয়ার স্ট্র্যাটেজি।
- **কখন 'best' (Default) রাখব:** সবসময়। এটি গাণিতিকভাবে সবচেয়ে নিখুঁত এবং সর্বোত্তম স্প্লিটিং পয়েন্টটি খুঁজে বের করে।
- **অন্যান্য অপশন:** "random"।
- **কখন এবং কেন 'random' ব্যবহার করব:** যখন ডেটাসেট অনেক বিশাল এবং আপনি চান মডেলটি বেস্ট পয়েন্ট না খুঁজে র্যান্ডমলি একটি ভালো পয়েন্ট নিয়ে দ্রুত ট্রেনিং শেষ করুক (কম্পিউটেশনাল টাইম বাঁচাতে)।

max_leaf_nodes: None (default)

- **কাজ কী:** একটি গাছে সর্বোচ্চ কয়টি শেষ পাতা বা লিফ নোড থাকতে পারবে তার সংখ্যা বেঁধে দেওয়া।
- **কখন 'None' (Default) রাখব:** যখন আপনি max_depth বা অন্যান্য প্যারামিটার দিয়ে অলরেডি গাছ নিয়ন্ত্রণ করছেন। None মানে অসীম সংখ্যক লিফ নোড হতে পারে।
- **অন্যান্য অপশন ও কখন ব্যবহার করব:** যেকোনো পূর্ণসংখ্যা। এটিও ওভারফিটিং কমানোর আরেকটি বিকল্প রাস্তা, তবে সাধারণত max_depth টিউন করলে এটির আলাদা প্রয়োজন পড়ে না।

min_impurity_decrease: 0.0 (default)

- **কাজ কী:** একটি নোডকে তখনই ভাঙা হবে, যদি সেই স্প্লিটের কারণে ইম্পিউরিটি বা অবিশুদ্ধতার হ্রাস পাওয়ার মান এই থ্রেশহোল্ডের চেয়ে সমান বা বড় হয়।
- **কখন '0.0' (Default) রাখব:** ডিফল্ট ০.০ রাখা মানে ইম্পিউরিটি সামান্য কমলেও (অর্থাৎ সামান্য তথ্য লাভ হলেও) গাছটি স্প্লিট করবে। সাধারণত এটি ডিফল্ট রেখেই বাকি প্যারামিটার টিউন করা হয়।

monotonic_cst: None (default)

- **কাজ কী:** ফিচারের ওপর মোনোটোনিক বা একমুখী শর্তারোপ করা (যেমন: বয়স বাড়লে ইন্সুরেন্সের প্রিমিয়াম শুধু বাড়বেই, কখনো কমবে না—এমন লজিক এনফোর্স করা)। এটি বাইনারি ক্লাসিফিকেশনের ক্ষেত্রে পজিটিভ ক্লাসের প্রোবাবিলিটির ওপর কাজ করে। সাধারণ প্রজেক্টে এটি None রাখা হয়।

min_weight_fraction_leaf: 0.0 (default)

- **কাজ কী:** একটি লিফ নোডে থাকার জন্য স্যাম্পলগুলোর ওজনের নূন্যতম যোগফলের অনুপাত। যদি স্যাম্পল ওয়েট (sample_weight) ব্যবহার না করা হয়, তবে সব স্যাম্পলের ওজন সমান থাকে এবং এটি min_samples_leaf-এর মতোই কাজ করে। সাধারণত এটি পরিবর্তন করার প্রয়োজন হয় না।

বাকি থাকা কম ব্যবহৃত প্যারামিটারসমূহ (Remaining Parameters)

এগুলো সাধারণত অ্যাডভান্সড রিসার্চ বা কাস্টম প্রজেক্ট ছাড়া খুব একটা পরিবর্তন করতে হয় না।

min_weight_fraction_leaf: 0.0 (default)

- **কাজ কী:** এটি min_samples_leaf-এর মতোই কাজ করে, তবে এটি সরাসরি স্যাম্পলের সংখ্যার বদলে স্যাম্পলগুলোর ওজনের (Weights) নূন্যতম অনুপাত হিসাব করে।
- **কখন এবং কেন ব্যবহার করব:** যদি আপনি মডেল ডট ফিট (model.fit) করার সময় sample_weight প্যারামিটার দিয়ে কিছু ডেটা রো-কে বেশি বা কম গুরুত্ব দিয়ে থাকেন। তখন এই নোডের ওজন সামগ্রিক ওজনের নির্দিষ্ট শতাংশ (যেমন: 0.05 বা ৫%) এর নিচে নেমে গেলে গাছ সেখানে ডালপালা মেলানো বন্ধ করে দেবে। যদি কোনো ওজনের তারতম্য না থাকে, তবে সব স্যাম্পলের ওজন সমান (1) ধরা হয় এবং এটি ডিফল্ট 0.0 রাখাই স্ট্যান্ডার্ড।

min_impurity_decrease: 0.0 (default)

- **কাজ কী:** একটি নোডকে তখনই স্প্লিট বা ভাগ করা হবে, যদি সেই ভাগের কারণে ইম্পিউরিটি (Gini বা Entropy) হ্রাস পাওয়ার মান এই থ্রেশহোল্ডের চেয়ে সমান বা বড় হয়।
- **গাণিতিক ব্যাকএন্ড সূত্র:**

$$\Delta i = \frac{N_t}{N} \times \left(\text{impurity} - \frac{N_{tR}}{N_t} \times \text{right_impurity} - \frac{N_{tL}}{N_t} \times \text{left_impurity} \right)$$

(এখানে N হলো মোট স্যাম্পল, N_t হলো বর্তমান নোডের স্যাম্পল, এবং L/R হলো বাম ও ডান চাইল্ড নোডের স্যাম্পল)

- **কখন এবং কেন পরিবর্তন করব:** যখন আপনি চান গাছটি ছোটখাটো বা অর্থহীন ফিচারের জন্য ডালপালা না মেলুক। যদি আপনি min_impurity_decrease=0.01 সেট করেন, তবে যে স্প্লিটটি ডেটার বিশুদ্ধতা অন্তত 0.01 পরিমাণ উন্নত করতে পারবে না, ডিসিশন ট্রি সেই স্প্লিটটি বাতিল করে দেবে। এটিও ওভারফিটিং নিয়ন্ত্রণে সাহায্য করে।

monotonic_cst: None (default)

- **কাজ কী:** এটি ফিচারের ওপর মোনোটোনিক বা একমুখী গাণিতিক শর্ত (Monotonicity Constraint) জোরপূর্বক চাপিয়ে দিতে ব্যবহৃত হয় (Scikit-Learn ভার্সন ১.৪-এ নতুন যুক্ত হয়েছে)।
- **অপশনসমূহ:** প্রতিটা ফিচারের জন্য একটি অ্যারে আকারে 1 (Monotonic Increase), -1 (Monotonic Decrease) অথবা 0 (No Constraint) দেওয়া যায়।

- **কখন এবং কেন ব্যবহার করব:** ধরুন আপনি একটি ক্রেডিট কার্ড লোন প্রজেক্ট করছেন, যেখানে আপনি নিশ্চিত করতে চান যে "কাস্টমারের আয় বাড়লে লোন পাওয়ার প্রোবাবিলিটি সবসময় বাড়বেই, কখনো কমবে না"। তখন আয়ের কলামের জন্য 1 সেট করা হয়। মনে রাখুন, এটি মাল্টি-ক্লাস ক্লাসিফিকেশন (Classes > 2) সাপোর্ট করে না, শুধু বাইনারি ক্লাসিফিকেশনের পজিটিভ ক্লাসের প্রোবাবিলিটির ওপর কাজ করে।

ডিসিশন ট্রির মূল অ্যাট্রিবিউটসমূহ (Important Attributes)

মডেল ডট ফিট (model.fit(X_train, y_train)) করার পর, মডেলটি ব্যাকএন্ডের লার্নিং থেকে কী কী তথ্য মেমোরিতে জমা করে রেখেছে, তা আমরা এই অ্যাট্রিবিউটগুলো দিয়ে দেখতে পারি। এদের শেষে সবসময় একটি আন্ডারস্কোর (_) থাকে।

feature_importances_

- **কাজ কী:** এটি একটি অ্যারে ব্যাক করে যা দেখায় যে, আপনার দেওয়া ফিচারগুলোর মধ্যে কোন কলামটি টার্গেট ভ্যারিয়েবল প্রেডিক্ট করতে সবচেয়ে বেশি ভূমিকা পালন করেছে।
- **ব্যাকএন্ড মেকানিজম:** যে ফিচারটি গাছের যত ওপরের দিকে (রুট নোডের কাছাকাছি) স্প্লিট করতে ব্যবহৃত হয়েছে এবং যার কারণে জিনি বা এনট্রপি সবচেয়ে বেশি কমেছে, তার ইম্পোর্টেন্স তত বেশি হয়। সব ফিচারের গুরুত্বের যোগফল সবসময় 1.0 হয়। এটি **Feature Selection**-এর জন্য সবচেয়ে জনপ্রিয় একটি টুল।

tree_

- **কাজ কী:** এটি ডিসিশন ট্রির আসল ব্যাকএন্ড অবজেক্ট (Underlying Tree Object)।
- **কেন প্রয়োজন:** গাছটি ভেতরে ভেতরে কীভাবে তৈরি হলো—তার নোড সংখ্যা কত, কোন নোডের বামে বা ডানে কী আছে, তা যদি আপনি পাইথন কোড দিয়ে স্ক্র্যাপ বা কাস্টমাইজ করতে চান, তবে model.tree_ ব্যবহার করে একদম র লেভেলের আর্কিটেকচার অ্যাক্সেস করা যায়।

classes_

- **কাজ কী:** আপনার টার্গেট ভ্যারিয়েবলে (y) আসলে কী কী শ্রেণি বা লেবেল ছিল, তার একটি ইউনিক অ্যারে দেখায়।

- **উদাহরণ:** টাইটানিক ডেটাসেটে `model.classes_` রান করলে আউটপুট আসবে `array([0, 1])`।

n_features_in_

- **কাজ কী:** মডেলটি ট্রেন করার সময় ইনপুট ম্যাট্রিক্সে (`X_train`) সর্বমোট কতগুলো ফিচার বা কলাম দেখেছিল, তার সুনির্দিষ্ট সংখ্যা জানায়।

feature_names_in_

- **কাজ কী:** ট্রেনিং ডেটায় থাকা সব কলামের অফিশিয়াল নামের একটি অ্যারে দেখায় (এটি তখনই কাজ করে যখন আপনার ইনপুট ডেটা একটি `pandas DataFrame` বা স্ট্রিং কলামযুক্ত হয়)।

n_classes_

- **কাজ কী:** টার্গেট কলামে মোট কয়টি ক্লাস বা ক্যাটাগরি আছে তার সংখ্যা দেয়। বাইনারি ক্লাসিফিকেশনে এর মান হবে 2।

n_outputs_

- **কাজ কী:** মডেলটি ফিট করার সময় কয়টি আউটপুট ভ্যারিয়েবল প্রেডিক্ট করার জন্য ট্রেন করা হয়েছিল তার সংখ্যা। সাধারণ সিঙ্গেল-আউটপুট প্রজেক্টে এর মান সবসময় 1 হয়।

Decision Tree Code using Sci-Kit Learn:

```
import numpy as np
import pandas as pd
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score, classification_report

iris = load_iris()
X = pd.DataFrame(iris.data, columns=iris.feature_names)
y = pd.Series(iris.target)

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

default_pipeline = Pipeline(
    steps=[
        ('model', DecisionTreeClassifier(random_state=42))
    ]
)

default_pipeline.fit(X_train, y_train)

y_pred_default = default_pipeline.predict(X_test)
print("--- Default Model Performance ---")
print(f"Test Accuracy: {accuracy_score(y_test, y_pred_default):.4f}")
print(classification_report(y_test, y_pred_default, target_names=iris.target_names))
```

Using Grid Search CV:

```
from sklearn.model_selection import GridSearchCV

tuning_pipeline = Pipeline(
    steps=[
        ('model', DecisionTreeClassifier(random_state=42))
    ]
)

param_grid = {
    'model__criterion': ['gini', 'entropy'],
    'model__max_depth': [3, 4, 5, None],
    'model__min_samples_split': [2, 5, 10],
    'model__min_samples_leaf': [1, 2, 4]
}

grid_search = GridSearchCV(
    estimator=tuning_pipeline,
    param_grid=param_grid,
    cv=5,
    scoring='accuracy',
    n_jobs=-1
)

grid_search.fit(X_train, y_train)

print("--- GridSearchCV Tuning Results (No Scaling) ---")
print("Best Parameters Found:", grid_search.best_params_)
print(f"Best CV Accuracy: {grid_search.best_score_:.4f}")

best_model_pipeline = grid_search.best_estimator_
y_pred_tuned = best_model_pipeline.predict(X_test)

print("\n--- Tuned Model Performance on Test Set ---")
print(f"Test Accuracy: {accuracy_score(y_test, y_pred_tuned):.4f}")
print(classification_report(y_test, y_pred_tuned, target_names=iris.target_names))

importances = best_model_pipeline.named_steps['model'].feature_importances_
for name, importance in zip(iris.feature_names, importances):
    print(f"{name:20s}: {importance:.4f}")
```

প্রশ্ন ১: Decision Tree-তে Gini Impurity এবং Entropy-এর মধ্যে প্রধান পার্থক্য কী? Scikit-Learn কেন ডিফল্ট হিসেবে criterion="gini" ব্যবহার করে?

উত্তর:

Gini Impurity এবং Entropy উভয়ই Decision Tree-এর প্রতিটি নোডের বিশুদ্ধতা (Purity) বা অবিশুদ্ধতা (Impurity) পরিমাপের জন্য ব্যবহৃত হয়। Entropy তথ্য তত্ত্ব (Information Theory)-এর উপর ভিত্তি করে কাজ করে এবং Information Gain ব্যবহার করে সর্বোত্তম Split নির্বাচন করে। এর গণনায় লগারিদম ($\log_2$) ব্যবহৃত হওয়ায় এটি তুলনামূলকভাবে বেশি কম্পিউটেশনাল সময় প্রয়োজন করে।

অন্যদিকে, Gini Impurity-এর সূত্র তুলনামূলকভাবে সহজ এবং এতে কোনো লগারিদমিক গণনা প্রয়োজন হয় না। ফলে এটি দ্রুত গণনা করা যায়। এই কারণেই Scikit-Learn ডিফল্টভাবে criterion="gini" ব্যবহার করে। তবে বাস্তবে Gini এবং Entropy উভয়ের Performance সাধারণত খুব কাছাকাছি হয়।

প্রশ্ন ২: Decision Tree-তে Overfitting কেন ঘটে এবং এটি প্রতিরোধ করার প্রধান উপায়গুলো কী?

উত্তর:

Decision Tree-কে যদি কোনো সীমাবদ্ধতা ছাড়া প্রশিক্ষণ দেওয়া হয়, তাহলে এটি যতক্ষণ সম্ভব Data Split করতে থাকে এবং প্রতিটি Leaf Node-কে যতটা সম্ভব বিশুদ্ধ করার চেষ্টা করে। এর ফলে মডেলটি শুধুমাত্র প্রকৃত Pattern নয়, বরং Training Data-এর Noise এবং ব্যতিক্রমী তথ্যও শিখে ফেলে। এই অবস্থাকে Overfitting বলা হয়।

Overfitting প্রতিরোধের জন্য সাধারণত নিচের Hyperparameter-গুলো ব্যবহার করা হয়:

- max_depth : Tree-এর সর্বোচ্চ গভীরতা নির্ধারণ করে।
- min_samples_split : একটি Node Split করার জন্য ন্যূনতম Sample সংখ্যা নির্ধারণ করে।
- min_samples_leaf : প্রতিটি Leaf Node-এ ন্যূনতম কতটি Sample থাকতে হবে তা নির্ধারণ করে।
- ccp_alpha : Cost-Complexity Pruning-এর মাধ্যমে অপ্রয়োজনীয় Branch অপসারণ করে।

প্রশ্ন ৩: যদি max_depth=None এবং min_samples_split=2 একসাথে ব্যবহার করা হয়, তাহলে Decision Tree-এর আচরণ কেমন হবে?

উত্তর:

যখন max_depth=None এবং min_samples_split=2 একসাথে ব্যবহার করা হয়, তখন Decision Tree-এর গভীরতার ওপর কোনো সীমা থাকে না। মডেলটি যতক্ষণ Node বিশুদ্ধ না হয়, Split করার জন্য পর্যাপ্ত Sample থাকে এবং একটি বৈধ Split পাওয়া যায়, ততক্ষণ পর্যন্ত Tree বৃদ্ধি পেতে থাকে।

ফলে Tree অত্যন্ত গভীর হয়ে যেতে পারে এবং Training Data-এর Noise পর্যন্ত শিখে ফেলতে পারে। এর ফলে Training Accuracy অনেক বেশি হলেও Test Data বা নতুন Data-এর উপর Performance কমে যেতে পারে, যা Overfitting-এর একটি সাধারণ লক্ষণ।

প্রশ্ন ৪: feature_importances_ অ্যাট্রিবিউট কীভাবে কাজ করে এবং এটি কেন গুরুত্বপূর্ণ?

উত্তর:

feature_importances_ প্রতিটি Feature Decision Tree তৈরির সময় মোট কতটুকু Impurity কমাতে সাহায্য করেছে, তার একটি পরিমাপ প্রদান করে। কোনো Feature যদি বারবার গুরুত্বপূর্ণ Split তৈরি করে এবং প্রতিবার উল্লেখযোগ্য পরিমাণে Gini Impurity বা Entropy কমায়, তাহলে তার Importance বেশি হয়।

সমস্ত Feature Importance-এর যোগফল সর্বদা 1.0 হয়।

এই Attribute ব্যবহার করে গুরুত্বপূর্ণ Feature শনাক্ত করা, অপয়োজনীয় Feature বাদ দেওয়া এবং Feature Selection সম্পাদন করা সহজ হয়। ফলে Model আরও কার্যকর এবং ব্যাখ্যাযোগ্য (Interpretable) হয়।

প্রশ্ন ৫: Decision Tree-কে কেন একটি White-Box Model বলা হয়? কোন পরিস্থিতিতে এটি Logistic Regression-এর তুলনায় বেশি কার্যকর?

উত্তর:

Decision Tree-কে একটি **White-Box Model** বলা হয়, কারণ এর সিদ্ধান্ত গ্রহণের প্রতিটি ধাপ সহজেই দেখা, বোঝা এবং ব্যাখ্যা করা যায়। এটি মূলত ধারাবাহিক **IF-ELSE** নিয়মের মাধ্যমে সিদ্ধান্ত গ্রহণ করে, ফলে কোনো Prediction কীভাবে এসেছে তা সহজেই অনুসরণ করা সম্ভব।

যখন Feature এবং Target Variable-এর মধ্যে জটিল (Complex) এবং Non-linear সম্পর্ক থাকে, তখন Decision Tree সাধারণত Logistic Regression-এর তুলনায় ভালো ফলাফল প্রদান করতে পারে। কারণ Decision Tree সহজেই Non-linear Decision Boundary শিখতে পারে, যেখানে Logistic Regression মূলত Linear Decision Boundary-এর উপর নির্ভর করে।

Quick Revision

১. মূল ধারণা (Core Intuition)

- **Type:** এটি একটি অত্যন্ত জনপ্রিয় Supervised Machine Learning Algorithm, যা ক্লাসিফিকেশন ও রিগ্রেশন উভয় ক্ষেত্রে কাজ করে।
- **Mechanism:** এটি মানুষের চিন্তাভাবনার মতো ডেটার বিভিন্ন বৈশিষ্ট্যের ওপর ভিত্তি করে একটার পর একটা "IF-ELSE" বা "Yes/No" কন্ডিশন তৈরি করে পুরো ডেটাসেটকে ছোট ছোট ভাগে ভাগ করে ফেলে।
- **White-Box Model:** এর সিদ্ধান্ত নেওয়ার পুরো প্রক্রিয়াটি একটি ফ্লোচার্ট বা গাছের ডালপালার মতো দৃশ্যমান হওয়ায় একে হোয়াইট-বক্স মডেল বলা হয় (Highly Interpretable)।

২. গাঠনিক উপাদান (Tree Anatomy)

- **Root Node (মূল নোড):** গাছের একদম শীর্ষের নোড, যেখান থেকে প্রথম স্প্লিট বা বিভাজন শুরু হয়।
- **Internal / Decision Node:** মাঝখানের নোডগুলো, যা কোনো ফিচারের শর্ত নির্দেশ করে এবং ডেটাকে আরও নিচে ভাগ করে দেয়।
- **Leaf Node (চূড়ান্ত পাতা):** গাছের একদম শেষ প্রান্তের নোড। এর নিচে আর কোনো স্প্লিট হয় না, এটিই মূলত চূড়ান্ত প্রেডিকশন বা আউটপুট।

৩. ব্যাকগ্রাউন্ডের গাণিতিক পরিমাপ (Mathematical Formulation)

মডেলটি কোন ফিচারের কোন মান দিয়ে নোড ভাগ করবে, তা নির্ধারণ করতে নিচের ৩টি ডিফল্ট ম্যাট্রিক্স ব্যবহার করে:

- **Entropy (এনট্রপি):** ডেটার মধ্যকার এলোমেলো অবস্থা বা বিশৃঙ্খলার পরিমাপ। সম্পূর্ণ অবিশুদ্ধ নোডে এর মান 1.0 এবং সম্পূর্ণ বিশুদ্ধ নোডে এর মান 0 হয়।

$$Entropy(S) = - \sum p_i \log_2 p_i$$

- **Information Gain (তথ্য লাভ):** কোনো ফিচার দিয়ে ডেটা ভাগ করলে এনট্রপি বা বিশৃঙ্খলা কতটুকু কমছে তার পরিমাপ। ডিসিশন ট্রি সবসময় সর্বোচ্চ Information Gain থাকা ফিচারটিকে স্প্লিট করার জন্য বেছে নেয়।
- **Gini Impurity (জিনি ইম্পিউরিটি):** Scikit-Learn-এর ডিফল্ট মেকানিজম। এটি কম্পিউটেশনালি অত্যন্ত ফাস্ট কারণ এতে কোনো লগারিদম হিসাব করতে হয় না। সম্পূর্ণ বিশুদ্ধ নোডের জিনি ইম্পিউরিটি হয় 0।

$$Gini = 1 - \sum (p_i)^2$$

৪. প্রধান হাইপারপ্যারামিটার ও ওভারফিটিং নিয়ন্ত্রণ (Top Hyperparameters)

ডিসিশন ট্রিকে বাধা না দিলে সে শেষ পর্যন্ত ডেটা মুখস্থ করে Overfitting (High Variance) ঘটায়। এটি বন্ধ করার মূল ব্রেকগুলো হলো:

- **max_depth:** গাছের সর্বোচ্চ গভীরতা বা লেভেল ফিক্সড করে দেওয়া। ওভারফিটিং কমানোর প্রধান হাতিয়ার।
- **min_samples_split:** একটি নোডকে ভাগ করার জন্য নূন্যতম কয়টি স্যাম্পল থাকতে হবে (ডিফল্ট: ২)। এর মান বাড়ালে ওভারফিটিং কমে।
- **min_samples_leaf:** একটি চূড়ান্ত পাতায় নূন্যতম কয়টি স্যাম্পল থাকতেই হবে (ডিফল্ট: ১)। এর মান বাড়ালে মডেল স্মুথ হয়।
- **max_features:** প্রতি স্প্লিটে সেরা শর্ত খোঁজার জন্য সর্বোচ্চ কয়টি ফিচার স্ক্যান করা হবে (যেমন: "sqrt", "log2")।
- **class_weight:** ইমব্যালেন্সড ডেটাসেটে ছোট ক্লাসকে বেশি গুরুত্ব দিতে "balanced" মোড ব্যবহার করা হয়।

৫. সুবিধা ও সীমাবদ্ধতা (Pros & Cons)

Advantages (সুবিধাসমূহ)	Disadvantages / Limitations
সহজে বোঝা এবং ব্যাখ্যা করা যায় (Interpretability)	খুব দ্রুত Overfitting বা ডেটা মুখস্থ করার প্রবণতা দেখায়
ফিচার স্কেলিং বাধ্যতামূলক নয় (Scale-Independent)	ডেটার সামান্য পরিবর্তনে পুরো গাছের গঠন বদলে যায় (Unstable)
আউটলায়ারের প্রতি অত্যন্ত Robust (প্রভাব পড়ে না)	রিগ্রেশনের ক্ষেত্রে আউটপুট মসৃণ না হয়ে সিঁড়ির মতো ধাপযুক্ত হয়


ক্যাটাগরিক্যাল ও নিউমেরিক্যাল ডেটা
একসাথে সামলাতে পারে

ক্যাটাগরির সংখ্যা অনেক বেশি হলে (High
Cardinality) গাছ জটিল হয়

Random Forest

Random Forest (র্যান্ডম ফরেস্ট) হলো মেশিন লার্নিংয়ের অত্যন্ত শক্তিশালী, জনপ্রিয় এবং বহুমুখী একটি Supervised Learning Algorithm, যা ক্লাসিফিকেশন (Classification) এবং রিগ্রেশন (Regression) দুই ধরনের সমস্যার সমাধানই নিখুঁতভাবে করতে পারে।

সহজ কথায়, অনেকগুলো ডিসিশন ট্রি (Decision Tree) বা সিদ্ধান্ত-গাছ একসাথে মিলে যে জঙ্গল বা ফরেস্ট তৈরি করে, সেটিই হলো র্যান্ডম ফরেস্ট। এটি একটি Ensemble Learning মেথড, যার মূল মন্ত্র হলো—"একটি একক গাছের সিদ্ধান্তের চেয়ে পুরো জঙ্গলের সম্মিলিত সিদ্ধান্ত অনেক বেশি নিখুঁত ও শক্তিশালী।"



ধরুন, আপনি ছুটিতে কোথাও ঘুরতে যাবেন এবং একটি সুন্দর জায়গা সিলেক্ট করতে চান।

- **ডিসিশন ট্রির পদ্ধতি:** আপনি আপনার একজন বন্ধুকে জিজ্ঞেস করলেন। সে তার ব্যক্তিগত অভিজ্ঞতা অনুযায়ী আপনাকে কক্সবাজার যাওয়ার পরামর্শ দিল। এখানে ভুল হওয়ার সম্ভাবনা বা বায়াসড (Biased) হওয়ার চান্স বেশি, কারণ এটি মাত্র একজন মানুষের মত।
- **র্যান্ডম ফরেস্টের পদ্ধতি:** আপনি ১ জনের কাছে না গিয়ে আপনার ২০ জন বন্ধুকে আলাদা আলাদাভাবে জিজ্ঞেস করলেন। কেউ বলল সিলেট, কেউ বলল সাজেক, আবার বেশিরভাগ বন্ধু বলল কক্সবাজার। এবার আপনি সবার মতামত নিয়ে ভোটিং (Majority Voting) করলেন এবং দেখলেন যে ২০ জনের মধ্যে ১৪ জনই কক্সবাজারের পক্ষে। আপনি

মেজরিটি ভোটের ভিত্তিতে সিদ্ধান্ত নিলেন কক্সবাজার যাবেন। র্যান্ডম ফরেস্ট ঠিক এইভাবেই কাজ করে।


র্যান্ডম ফরেস্টের ব্যাকগ্রাউন্ড মেকানিজম

র্যান্ডম ফরেস্ট মূলত দুটি প্রধান স্তরের ওপর দাঁড়িয়ে কাজ করে:


১. Bagging বা Bootstrap Aggregating (বুটস্ট্রাপ অ্যাগ্রিগেটিং)

আপনার কাছে যদি একটি মূল ডেটাসেট থাকে, র্যান্ডম ফরেস্ট সব গাছকে ছবছ এক ডেটা দেয় না। সে মূল ডেটাসেট থেকে এলোমেলোভাবে (Row Sampling with replacement) ডেটা তুলে ছোট ছোট সাব-ডেটাসেট তৈরি করে এবং এক একটি ডিসিশন ট্রি-কে ট্রেন করার জন্য দেয়। একে বলে Bootstrapping।

Bagging



Boosting



২. Feature Randomness (ফিচারের র্যান্ডমনেস)

শুধু ডেটা রো (Row) নয়, প্রতিটা ডিসিশন ট্রি নোড স্প্লিট করার সময় ডেটাসেটের সব কলাম বা ফিচার দেখতে পায় না। সে সম্পূর্ণ র্যান্ডমলি কিছু ফিচার (যেমন: মোট ১০টি ফিচারের মধ্যে ৩টি)

বেছে নিয়ে তার মধ্য থেকে সেরা স্প্লিট খুঁজে নেয় (`max_features='sqrt'`)। এর ফলে জঙ্গলের প্রতিটা গাছ একে অপরের থেকে সম্পূর্ণ আলাদা ও স্বাধীনভাবে গড়ে ওঠে।

৩. Aggregation (একত্রীকরণ বা চূড়ান্ত সিদ্ধান্ত)

সবগুলো গাছ যখন ট্রেন হয়ে যায়, তখন নতুন কোনো ডেটা প্রেডিক্ট করার জন্য সেটিকে জঙ্গলের সব গাছের মধ্য দিয়ে পাস করানো হয়:

- **Classification-এর ক্ষেত্রে:** সব গাছের আউটপুটের মধ্যে Majority Voting বা সংখ্যাগরিষ্ঠের ভোটের ভিত্তিতে ফাইনাল ক্লাস নির্ধারণ করা হয়।
- **Regression-এর ক্ষেত্রে:** প্রতিটি গাছের দেওয়া প্রেডিকশনের গড় বা গড় মান (Average /Mean) হিসাব করে চূড়ান্ত সংখ্যাটি আউটপুট দেওয়া হয়।

র্যান্ডম ফরেস্টের প্রধান সুবিধাসমূহ (Advantages)

1. **ওভারফিটিং মুক্ত (Robust to Overfitting):** ডিসিশন ট্রির সবচেয়ে বড় দুর্বলতা হলো ওভারফিটিং। র্যান্ডম ফরেস্ট অনেকগুলো গাছের ফলাফলের গড় বা ভোট নেয় বলে এতে ওভারফিটিংয়ের সম্ভাবনা প্রায় থাকে না বললেই চলে।
2. **মিসিং ভ্যালু হ্যান্ডলিং:** ডেটাসেটে যদি বড় অঙ্কের মিসিং ভ্যালু থাকে, তবুও এটি তার ব্যাকঅ্যান্ড প্রক্সিমিটি অ্যালগরিদম দিয়ে চমৎকার এক্যুরেসী ধরে রাখতে পারে।
3. **ফিচার ইম্পোর্টেন্স (Feature Importance):** ডিসিশন ট্রির মতো এটিও ট্রেনিং শেষে `feature_importances_` প্রপার্টি ব্যবহার করে ডেটাসেটের কোন কলামটি প্রেডিকশনের জন্য সবচেয়ে বেশি গুরুত্বপূর্ণ, তা নিখুঁতভাবে জানিয়ে দেয়।
4. **স্কেলিংয়ের প্রয়োজন নেই:** ডিসিশন ট্রির মতো র্যান্ডম ফরেস্টও কোনো প্রকার ফিচার স্কেলিং (StandardScaler বা MinMaxScaler) করার প্রয়োজন পড়ে না।

সীমাবদ্ধতা (Limitations)

- **ব্ল্যাক-বক্স মডেল (Black-box Nature):** একক ডিসিশন ট্রিকে খুব সহজে `plot_tree` দিয়ে ভিজ্যুয়ালাইজ করে সাধারণ মানুষকে বোঝানো যায় (White-box)। কিন্তু র্যান্ডম ফরেস্টে যখন ৫০০টি গাছ একসাথে কাজ করে, তখন ঠিক কোন লজিকে সিদ্ধান্ত এসেছে তা ট্র্যাক করা অসম্ভব হয়ে পড়ে। তাই এটি একটি ব্ল্যাক-বক্স মডেল।

- **ধীরগতি (Slow to Predict):** র্যান্ডম ফরেস্ট ট্রেনিংয়ের সময় সমান্তরালভাবে (Parallely) কাজ করলেও, রিয়েল-টাইম প্রোডাকশনে প্রতিটি গাছের মধ্য দিয়ে ডেটা পাস করে ভোট গণনা করতে লিনিয়ার মডেলের চেয়ে সামান্য বেশি সময় নিতে পারে।

র্যান্ডম ফরেস্ট (Random Forest) ক্লাসিফিকেশন এবং রিগ্রেশন দুই ধরনের সমস্যার সমাধান করে।

১. Classification (শ্রেণিবিভাগ) এর ক্ষেত্রে:

- **মেকানিজম:** ক্লাসিফিকেশন সমস্যার জন্য র্যান্ডম ফরেস্ট তার জঙ্গলের প্রতিটি ডিসিশন ট্রি-কে আলাদা আলাদাভাবে ডেটা প্রেডিক্ট করতে দেয়।
- **চূড়ান্ত সিদ্ধান্ত:** সব গাছ থেকে প্রেডিকশন পাওয়ার পর, মডেলটি **Majority Voting (সংখ্যার ভোট)** গণনা করে। যে ক্লাস বা ক্যাটাগরিটি সবচেয়ে বেশি গাছ প্রেডিক্ট করেছে (যেমন: ১০০টি গাছের মধ্যে ৭০টি গাছ বলল 'Yes' আর ৩০টি গাছ বলল 'No'), মেজরিটি ভোটের ভিত্তিতে চূড়ান্ত আউটপুট হবে 'Yes'।

২. Regression (মান অনুমান) এর ক্ষেত্রে:

- **মেকানিজম:** রিগ্রেশন সমস্যার ক্ষেত্রে (যেখানে আউটপুট কোনো সংখ্যা হয়), জঙ্গলের প্রতিটি ডিসিশন ট্রি স্বাধীনভাবে একটি সংখ্যা বা মান প্রেডিক্ট করে।
- **চূড়ান্ত সিদ্ধান্ত:** সব গাছের দেওয়া সংখ্যাবাচক প্রেডিকশনগুলোর গড় বা গড় মান (Average/Mean) হিসাব করা হয়। এই গড় মানটিই হয় মডেলের চূড়ান্ত প্রেডিকশন (যেমন: ৫টি গাছ একটি বাড়ির দাম বলল যথাক্রমে ৫০, ৫২, ৪৮, ৫১ এবং ৪৯ লাখ টাকা; তাহলে র্যান্ডম ফরেস্ট এদের গড় করে চূড়ান্ত দাম বলবে ৫০.২ লাখ টাকা)।

Decision Tree থেকে Random Forest-এ রূপান্তর এবং এর প্রয়োজনীয়তা

Bias (বায়াস)

- Core Concept: একটি মেশিন লার্নিং মডেলের সরল অনুমানের কারণে যে ভুলের সৃষ্টি হয়, তাকে বায়াস বলে। মডেল যদি ডেটার ভেতরের আসল এবং জটিল প্যাটার্ন ধরতে না পারে, তবে তাকে High Bias বলা হয়। এর ফলে মডেলটি ট্রেনিং ডেটা এবং টেস্ট ডেটা-উভয় ক্ষেত্রেই খুব খারাপ পারফর্ম করে, যাকে মেশিন লার্নিংয়ের ভাষায় Underfitting বলা হয় (যেমন: একটি জটিল লিনিয়ার-নয় এমন ডেটার ওপর সাধারণ Linear Regression ব্যবহার করা)। অন্যদিকে, মডেল যদি ডেটার প্যাটার্ন খুব ভালোভাবে ধরতে পারে, তবে তাকে Low Bias বলা হয়।

Variance (ভ্যারিয়েন্স)

- Core Concept: ট্রেনিং ডেটার সামান্য পরিবর্তনের কারণে মডেলের প্রেডিকশনে যে পরিমাণ ওলটপালট বা বিচ্যুতির সৃষ্টি হয়, তাকে ভ্যারিয়েন্স বলে। মডেল যদি ট্রেনিং ডেটার প্রতিটি নয়েজ (Noise) ও ব্যতিক্রমী পয়েন্ট মুখস্থ করে ফেলে, তবে তাকে High Variance বলা হয়। এর ফলে মডেলটি ট্রেনিং সেটে ১০০% এক্যুরেসী দিলেও নতুন কোনো টেস্ট ডেটার সামনে গেলেই সম্পূর্ণ ফেইল করে, যাকে Overfitting বলা হয় (যেমন: গভীর ডালপালা বিশিষ্ট একটি আনপ্রুন্ড Decision Tree)। আর মডেল যদি নতুন ডেটাতেও স্থিতিশীল পারফর্ম করে, তবে তাকে Low Variance বলা হয়।

2. The 4 Quadrants Matrix

মেশিন লার্নিং মডেলের কার্যক্ষমতা বুঝতে একটি জনপ্রিয় বুলস-আই (Bulls-eye) বা লক্ষ্যভেদের ডার্টবোর্ডের উদাহরণ ব্যবহার করা হয়, যেখানে বোর্ডের একদম কেন্দ্রটি (Center) হলো আমাদের আসল বা সঠিক উত্তর:


Low Bias, Low Variance (আদর্শ মডেল)

- ব্যাখ্যা: এই মডেলের প্রেডিকশনগুলো একদম নিখুঁত এবং কেন্দ্রের খুব কাছাকাছি থাকে (Low Bias)। একই সাথে ডেটা পরিবর্তন করলেও এর সিদ্ধান্ত বদলে যায় না,

সবগুলো শট এক জায়গাতেই পড়ে (Low Variance)। এটিই মেশিন লার্নিংয়ের সবচেয়ে কাঙ্ক্ষিত ও সুষম মডেল।

Low Bias, High Variance (ওভারফিটিং)

- ব্যাখ্যা: এই মডেলটি গড়ে সঠিক উত্তরের কাছাকাছি পৌঁছাতে পারে (Low Bias)। কিন্তু এর প্রেডিকশনগুলোর মধ্যে ছড়ানো-ছিটানো ভাব বা অস্থিরতা অনেক বেশি (High Variance)। অর্থাৎ, ট্রেনিং ডেটা সামান্য পরিবর্তন হলেই এর প্রেডিকশনগুলো চারদিকে ছড়িয়ে পড়ে। এটি Overfitting-এর স্পষ্ট লক্ষণ।



High Bias, Low Variance (আন্ডারফিটিং)

- ব্যাখ্যা: এই মডেলের সবগুলো প্রেডিকশন খুব কাছাকাছি এক জায়গাতেই পড়ে (Low Variance), কিন্তু সেগুলো আসল লক্ষ্য বা কেন্দ্র থেকে অনেক দূরে অবস্থান করে (High Bias)। মডেলটি ভুল লজিকে অনড় থাকে। এটি Underfitting-এর উদাহরণ।


High Bias, High Variance (সবচেয়ে বাজে মডেল)

- ব্যাখ্যা: এই মডেলটির প্রেডিকশনগুলো যেমন লক্ষ্যভ্রষ্ট বা কেন্দ্র থেকে দূরে (High Bias), তেমনই সেগুলো একে অপরের থেকে চরমভাবে ছড়ানো-ছিটানো (High Variance)। এটি সবচেয়ে অস্থিতিশীল এবং অকেজো মডেল।

3. The Bias-Variance Trade-off

- The Conflict: গাণিতিক ও বাস্তবিকভাবে একই সাথে বায়াস এবং ভ্যারিয়েন্স-উভয়কেই একসাথে শূন্যে নামিয়ে আনা অসম্ভব। আপনি যদি মডেলকে খুব জটিল (Complex) বানাতে যান (যেমন: Deep Neural Networks বা Deep Decision Trees), তবে বায়াস কমবে কিন্তু ভ্যারিয়েন্স আশঙ্কাজনকভাবে বেড়ে যাবে। আবার

মডেলকে খুব সরল (Simple) রাখলে ভ্যারিয়েন্স কম থাকবে ঠিকই, কিন্তু বায়াস বেড়ে যাবে।



- The Goal: মেশিন লার্নিং ইঞ্জিনিয়ারদের মূল লক্ষ্য হলো মডেলের জটিলতার এমন একটি সর্বোত্তম বিন্দু বা সুইট স্পট (Sweet Spot) খুঁজে বের করা, যেখানে Total Error (যা বায়াস এবং ভ্যারিয়েন্সের বর্গের যোগফল) সর্বনিম্ন হয়। র্যান্ডম ফরেস্ট (Random Forest) অ্যালগরিদমটি মূলত প্রতিটি গাছের লো-বায়াস ক্ষমতাকে ধরে রেখে, ব্যাগিং প্রক্রিয়ার মাধ্যমে হাই-ভ্যারিয়েন্সকে টেনে নিচে নামিয়ে এনে এই চমৎকার ভারসাম্যটি বজায় রাখে।

The Evolution

- **মূল সমস্যা:** একটি একক ডিসিশন ট্রি ট্রেনিং ডেটাসেটের শেষ সীমা পর্যন্ত ডালপালা গজাতে থাকে এবং ডেটাকে ১০০% বিশুদ্ধ (Pure) করার চেষ্টা করে। এর ফলে এটি ডেটার ভেতরের নয়েজ (Noise) বা ছোটখাটো ভুল প্যাটার্নও মুখস্থ করে ফেলে এবং মডেলটিতে হাই ভ্যারিয়েন্স বা ওভারফিটিং (Overfitting) দেখা দেয়। এমন মডেল নতুন কোনো টেস্ট ডেটার মুখোমুখি হলে সঠিক সিদ্ধান্ত দিতে পারে না।
- **সমাধান:** ডিসিশন ট্রির জটিল নন-লিনিয়ার সম্পর্ক ধরার ক্ষমতাকে অক্ষুণ্ণ রেখে ওভারফিটিং দূর করার জন্য র্যান্ডম ফরেস্টের আগমন ঘটে। এখানে একটিমাত্র গভীর ও জটিল গাছের ওপর নির্ভর না করে, শত শত ভিন্ন ভিন্ন স্বাধীন ডিসিশন ট্রি (একটি জঙ্গল) তৈরি করা হয়। প্রতিটি গাছের নিজস্ব ভুল বা ত্রুটিগুলো যখন একত্রিত করে গড় করা হয়, তখন সামগ্রিক জঙ্গলের সিদ্ধান্তটি অত্যন্ত সুষম ও নিখুঁত হয়ে ওঠে।

Why We Moved to Random Forest

- **ওভারফিটিং ও ভ্যারিয়েন্স নিয়ন্ত্রণ (Reduction in Variance):** একটি একক ডিসিশন ট্রিতে লো বায়াস (Low Bias) কিন্তু হাই ভ্যারিয়েন্স (High Variance) থাকে। র্যান্ডম ফরেস্ট শত শত গাছের ফলাফলের গড় বা ভোট নেয় বলে এই হাই ভ্যারিয়েন্স বা ওভারফিটিংয়ের ঝুঁকি স্বয়ংক্রিয়ভাবে কমে যায়। কোনো একটি গাছের ভুল সিদ্ধান্ত বাকি গাছগুলোর সঠিক সিদ্ধান্তের ভিড়ে ঢাকা পড়ে যায়।
- **ফিচারের র্যান্ডমনেস (Feature Randomness):** একটি সাধারণ ডিসিশন ট্রি প্রতিটি নোড স্প্লিট করার সময় ডেটাসেটের উপলব্ধ সবকটি কলাম স্ক্যান করে সেরা কলামটি বেছে নেয়, যার ফলে শক্তিশালী ফিচারগুলোই বারবার ঘুরেফিরে আসে। কিন্তু র্যান্ডম ফরেস্ট প্রতি স্প্লিটে সম্পূর্ণ র্যান্ডমলি নির্দিষ্ট সংখ্যক ফিচারের একটি সাবসেট (*max_features*) বেছে নেয়। এর ফলে জঙ্গলের গাছগুলোর মধ্যে চরম গাঠনিক বৈচিত্র্য তৈরি হয় এবং ডেটার ভেতরে লুকিয়ে থাকা দুর্বল ফিচারের গুরুত্বপূর্ণ প্যাটার্নও উন্মোচিত হয়।
- **গাঠনিক স্থিতিশীলতা (Structural Stability):** একটি একক ডিসিশন ট্রি অত্যন্ত সংবেদনশীল বা আনস্টেবল। ট্রেনিং ডেটার সামান্য পরিবর্তন বা দু-একটি নতুন রো

যুক্ত হলে এর রুট নোডের স্প্লিট বদলে যেতে পারে, যা পুরো গাছের গঠন ও সিদ্ধান্ত ওলটপালট করে দেয়। র্যান্ডম ফরেস্ট বুটস্ট্রাপ স্যাম্পলিং ব্যবহারের মাধ্যমে প্রতিটি গাছকে ডেটার ভিন্ন ভিন্ন অংশ দিয়ে ট্রেন করে, ফলে ডেটার আংশিক পরিবর্তনে পুরো ফরেস্টের ওপর কোনো নেতিবাচক প্রভাব পড়ে না।

- **ব্যখ্যাযোগ্যতা হ্রাস পাওয়া (Loss of Full Interpretability):** একটি একক গাছ থেকে যখন আমরা শত শত গাছের জঙ্গলে স্থানান্তরিত হই, তখন মডেলটি একটি স্পষ্ট হোয়াইট-বক্স (White-Box) থেকে জটিল ব্ল্যাক-বক্স (Black-Box) সিস্টেমে পরিণত হয়। একসাথে ৫০০টি গাছের হাজার হাজার কন্ডিশনাল পাথ (if-else রুলস) ট্র্যাক করা মানুষের পক্ষে অসম্ভব হয়ে পড়ে। উচ্চমাত্রার এক্যুরেসী অর্জনের জন্য এটিই হলো র্যান্ডম ফরেস্টের প্রধান ট্রেড-অফ (Trade-off)।

ডিসিশন ট্রি বনাম র্যান্ডম ফরেস্ট (Decision Tree vs Random Forest)

বৈশিষ্ট্য	Decision Tree	Random Forest
গঠন	মাত্র একটি একক গাছ দিয়ে গঠিত হয়।	শত শত ডিসিশন ট্রির সমন্বয়ে গঠিত জঙ্গল।
ওভারফিটিং ঝুঁকি	অত্যন্ত বেশি (High Variance)। খুব দ্রুত ডেটা মুখস্থ করে ফেলে।	অত্যন্ত কম। অনেক গাছের গড় নেওয়ার ফলে ওভারফিটিং স্বয়ংক্রিয়ভাবে দূর হয়।
এক্যুরেসী	মঝঝি বা তুলনামূলক কম।	সাধারণত অত্যন্ত নিখুঁত এবং উচ্চ এক্যুরেসী দেয়।
কম্পিউটেশন টাইম	খুব দ্রুত ট্রেন হয়।	ট্রেনিং হতে কিছুটা বেশি সময় ও মেমোরি লাগে।

এনসেম্বল লার্নিংয়ের প্রধান দুটি পদ্ধতি

১. Bagging (Bootstrap Aggregating) বা সমান্তরাল পদ্ধতি

- **কাজের প্রক্রিয়া:** এই পদ্ধতিতে মূল ডেটাসেট থেকে এলোমেলোভাবে প্রতিস্থাপনের মাধ্যমে (With replacement) একাধিক স্বাধীন সাব-ডেটাসেট বা বুটস্ট্র্যাপ স্যাম্পল তৈরি করা হয়। এরপর প্রতিটি স্যাম্পলের ওপর আলাদা আলাদা মডেলকে (যেমন: ডিসিশন ট্রি) সম্পূর্ণ স্বাধীন এবং সমান্তরালভাবে (Parallely) ট্রেন করা হয়।
- **চূড়ান্ত সিদ্ধান্ত:** সবকটি মডেলের ট্রেনিং শেষে তাদের আউটপুটগুলোকে একত্রিত করা হয়। ক্লাসিফিকেশনের ক্ষেত্রে মেজরিটি ভোটিং (Majority Voting) এবং রিগ্রেশনের ক্ষেত্রে সব মডেলের প্রেডিকশনের গড় (Averaging) হিসাব করে চূড়ান্ত সিদ্ধান্ত নেওয়া হয়।
- **প্রধান লক্ষ্য:** এই পদ্ধতির মূল লক্ষ্য হলো মডেলের ভ্যারিয়েন্স (Variance) বা ওভারফিটিংয়ের ঝুঁকি কমিয়ে আনা।
- **উদাহরণ:** Random Forest।

২. Boosting বা ধারাবাহিক পদ্ধতি

- **কাজের প্রক্রিয়া:** বুস্টিং পদ্ধতিতে মডেলগুলো সমান্তরালভাবে কাজ করে না, বরং সিকোয়েন্সিয়াল বা ধারাবাহিকভাবে (One after another) কাজ করে। এখানে প্রথমে একটি দুর্বল বেস মডেল (Weak Learner) দিয়ে ট্রেনিং শুরু করা হয়। প্রথম মডেলটি ট্রেন করার পর যে ডেটা পয়েন্টগুলোতে ভুল প্রেডিকশন বা ত্রুটি (Errors) থেকে যায়, পরবর্তী মডেলটি তৈরি করার সময় সেই ভুল ডেটাগুলোর ওপর বেশি গুরুত্ব বা ওয়েট (Weight) দেওয়া হয়।
- **ভুল থেকে শিক্ষা:** এভাবে প্রতিটি নতুন মডেল তার আগের মডেলের করা ভুলগুলো থেকে শিক্ষা নিয়ে নিজেকে ক্রমান্বয়ে উন্নত করতে থাকে। অর্থাৎ, আগের মডেলের দুর্বলতাকে পরের মডেলটি এসে সংশোধন করে।
- **চূড়ান্ত সিদ্ধান্ত:** সবকটি মডেল ধারাবাহিকভাবে ট্রেন হওয়ার পর, তাদের ওজনের ওপর ভিত্তি করে একটি ভরযুক্ত যোগফল (Weighted Average/Sum) তৈরি করে চূড়ান্ত প্রেডিকশন দেওয়া হয়।
- **প্রধান লক্ষ্য:** এই পদ্ধতির মূল লক্ষ্য হলো মডেলের বায়াস (Bias) বা ভুলের পরিমাণ কমিয়ে আনা এবং মডেলের শক্তি বৃদ্ধি করা। তবে এটি ব্যাগিংয়ের চেয়ে ওভারফিট করার ক্ষেত্রে কিছুটা বেশি সংবেদনশীল।
- **উদাহরণ:** XGBoost, AdaBoost, Gradient Boosting (GBM)।

Mathematical Intuition

- **Core Philosophy:** র্যান্ডম ফরেস্ট গাণিতিকভাবে বৈচিত্র্যময় ও স্বাধীন ডিসিশন ট্রি তৈরির জন্য Law of Large Numbers-এর নীতি ব্যবহার করে। প্রতিটি একক গাছের ভুল বা নয়েজ একে অপরের থেকে আলাদা হওয়ায়, যখন শত শত গাছের ফলাফলকে একত্রিত করা হয়, তখন সেই ত্রুটিগুলো পরস্পরকে নাকচ (Cancel out) করে দেয় এবং সামগ্রিক ভ্যারিয়েন্স শূন্যের কাছাকাছি নেমে আসে।

Gini Index / Entropy

- **Impurity Measurement:** জঙ্গলের ভেতরের প্রতিটি ডিসিশন ট্রি নোড স্প্লিট করার সময় নিচের যেকোনো একটি গাণিতিক সূত্র দিয়ে তথ্যের বিশুদ্ধতা পরিমাপ করে:
- **Gini Impurity:**

$$Gini = 1 - \sum_{i=1}^c (p_i)^2$$

(এখানে p_i হলো কোনো নোডে একটি নির্দিষ্ট ক্লাসের ডেটার অনুপাত। সম্পূর্ণ বিশুদ্ধ নোডের জিনি মান হয় 0 এবং সম্পূর্ণ অবিশুদ্ধ বা সমান অনুপাতের নোডের মান হয় 0.5)

- **Entropy:**

$$Entropy = - \sum_{i=1}^c p_i \log_2 p_i$$

(বিশুদ্ধতার গাণিতিক পরিমাপ। সম্পূর্ণ বিশুদ্ধ নোডে এর মান 0 এবং সর্বোচ্চ অবিশুদ্ধ নোডে এর মান 1.0 হয়)

Information Gain

- **Optimization Metric:** একটি নোডকে ভাঙার পর জিনি ইম্পিউরিটি বা এনট্রপি কতটা হ্রাস পেল, তা ইনফরমেশন গেইন দিয়ে পরিমাপ করা হয়। প্রতিটি গাছ এমন ফিচার এবং থ্রেশহোল্ড বেছে নেয় যার জন্য নিচের এই সমীকরণের মান সর্বোচ্চ হয়:

$$Information\ Gain = Impurity(Parent) - \sum \left(\frac{N_{Child}}{N_{Parent}} \times Impurity(Child) \right)$$

Random Feature Selection

- **Feature Subsetting:** সাধারণ ডিসিশন ট্রি নোড ভাঙার সময় সব ফিচার (d) স্ক্যান করে। কিন্তু র্যান্ডম ফরেস্ট প্রতিটি স্প্লিটে র্যান্ডমলি m সংখ্যক ফিচারের একটি সাবসেট বেছে নেয়।

- **Standard Convention:** ক্লাসিফিকেশনের ক্ষেত্রে সাধারণত $m = \sqrt{d}$ এবং রিগ্রেশনের ক্ষেত্রে $m = d/3$ কলাম নেওয়া হয়। গাণিতিকভাবে এটি গাছগুলোর মধ্যকার কোরিলেশন বা পারস্পরিক মিল কমিয়ে দেয়, যা জঙ্গলকে আরও শক্তিশালী করে।

Training Algorithm

- **Step 1 (Bootstrapping):** মূল ডেটাসেট থেকে প্রতিস্থাপনের নীতি মেনে (With replacement) $n_estimators$ সংখ্যক ভিন্ন ভিন্ন বুটস্ট্র্যাপ স্যাম্পল তৈরি করা হয়।
- **Step 2 (Tree Growth):** প্রতিটি স্যাম্পল ডেটার ওপর একটি করে ডিসিশন ট্রি ট্রেন করা হয়। গাছ বৃদ্ধির সময় প্রতিটি নোডে শুধুমাত্র র্যান্ডমলি সিলেক্টেড $max_features$ কলামের মধ্য থেকে সেরা স্প্লিটটি বেছে নেওয়া হয়। কোনো প্রকার প্রুনিং (Pruning) ছাড়াই গাছগুলোকে সর্বোচ্চ গভীরতা পর্যন্ত বাড়তে দেওয়া হয়।
- **Step 3 (Ensemble):** এই প্রক্রিয়াটি লুপের মতো চলতে থাকে যতক্ষণ না নির্ধারিত সংখ্যক (T) স্বাধীন গাছ তৈরি সম্পন্ন হচ্ছে।

Prediction Algorithm

- **Step 1 (Individual Prediction):** নতুন কোনো টেস্ট ডেটা রো (x) ইনপুট হিসেবে আসলে, সেটিকে জঙ্গলের প্রতিটি ট্রেনড গাছের মধ্য দিয়ে পাস করানো হয়। প্রতিটি গাছ সম্পূর্ণ স্বাধীনভাবে নিজের একটি আউটপুট ($h_t(x)$) প্রদান করে।
- **Step 2 (Classification Aggregation):** ক্লাসিফিকেশনের ক্ষেত্রে ফাইনাল প্রেডিকশন হলো মেজরিটি ভোট:

$$\hat{Y} = \text{mode}\{h_1(x), h_2(x), \dots, h_T(x)\}$$

- **Step 3 (Regression Aggregation):** রিগ্রেশনের ক্ষেত্রে ফাইনাল প্রেডিকশন হলো সব গাছের আউটপুটের গাণিতিক গড়:

$$\hat{Y} = \frac{1}{T} \sum_{t=1}^T h_t(x)$$

Time & Space Complexity

- **Training Time Complexity:**

$$O(T \cdot m \cdot N \log N)$$

(এখানে T = number of trees, N = number of samples, এবং m = number of random features) যেহেতু প্রতিটি গাছ সমান্তরালভাবে বা মাল্টি-থ্রেডিং ব্যবহার করে ট্রেন করা যায়, তাই বড় ডেটাসেটেও এটি বেশ দ্রুত কাজ করে।

- **Prediction Time Complexity:**

$$O(T \cdot \text{depth})$$

(টেস্ট টাইমে প্রতিটি গাছের গভীরতা বা depth বরাবর ডেটা ট্রান্সার করতে হয়, যা রিয়েল-টাইম প্রেডিকশনের জন্য অত্যন্ত ফাস্ট)

- **Space Complexity:**

$$O(T \cdot \text{number of nodes})$$

(যেহেতু শত শত গভীর ডিসিশন ট্রির প্রতিটি নোডের শর্ত ও মান মেমোরিতে ধরে রাখতে হয়, তাই র্যান্ডম ফরেস্টের মডেল সাইজ বা মেমোরি কস্ট লিনিয়ার মডেলের চেয়ে অনেক বেশি হয়)

Number of Trees (n_estimators): 3

Maximum Features (max_features): 2

ID	Study Hours	Attendance	Assignment	Pass (Target)
1	2	Low	No	No
2	3	Medium	Yes	No
3	5	High	Yes	Yes
4	6	High	Yes	Yes
5	4	Medium	No	Yes

Total instances (N) = 5

Class distribution: Pass = Yes → {3, 4, 5} (3টি) | Pass = No → {1, 2} (2টি)

Bootstrap Sampling

Random Forest এ প্রতিটি Decision Tree কে আলাদা Bootstrap Sample দিয়ে train করা হয়। Bootstrap Sampling হলো sampling with replacement — অর্থাৎ একটি instance একাধিকবার সিলেক্ট হতে পারে। প্রতিটি sample এ মোট N = 5টি row থাকবে, কিন্তু কিছু row repeat হবে এবং কিছু বাদ পড়বে (Out-of-Bag)।

Bootstrap Sample Size = N = 5 (original dataset এর সমান)

Sampling: with replacement → প্রতিবার random index $\in \{1, 2, 3, 4, 5\}$ থেকে বাছাই

BOOTSTRAP SAMPLE 1 — TREE 1

Row	ID	Pass
1	1	No
2	3	Yes
3	3	Yes
4	4	Yes
5	5	Yes

Yes=4, No=1 | OOB: ID {2}

BOOTSTRAP SAMPLE 2 — TREE 2

Row	ID	Pass
1	2	No
2	2	No
3	3	Yes
4	4	Yes
5	5	Yes

Yes=3, No=2 | OOB: ID {1}

BOOTSTRAP SAMPLE 3 — TREE 3

Row	ID	Pass
1	1	No
2	2	No
3	4	Yes
4	4	Yes
5	5	Yes

Yes=3, No=2 | OOB: ID {3}

Random Feature Selection ($\text{max_features} = 2$)

Random Forest এর একটি মূল বৈশিষ্ট্য হলো – প্রতিটি split এর সময় সব feature ব্যবহার না করে randomly একটি subset বাছাই করা হয়। এখানে মোট 3টি feature আছে (Study Hours, Attendance, Assignment) এবং $\text{max_features} = 2$ । অর্থাৎ প্রতি split এ যেকোনো 2টি feature থেকে সেরাটি বেছে নেওয়া হবে।

All features: {Study Hours, Attendance, Assignment} $\rightarrow$ total = 3
max_features = 2 $\rightarrow$ প্রতিটি split এ randomly 2টি বাছাই করতে হবে

Tree 1 — Feature Selection

✓ Study Hours ✓ Attendance ✗ Assignment

Random selection: **Study Hours** এবং **Attendance** chosen $\rightarrow$ **Assignment** এই split এ বিবেচিত হবে না।

Tree 2 — Feature Selection

✗ Study Hours ✓ Attendance ✓ Assignment

Random selection: **Attendance** এবং **Assignment** chosen $\rightarrow$ **Study Hours** এই split এ বিবেচিত হবে না।

Tree 3 — Feature Selection

✓ Study Hours ✗ Attendance ✓ Assignment

Random selection: **Study Hours** এবং **Assignment** chosen $\rightarrow$ **Attendance** এই split এ বিবেচিত হবে না।

Gini Impurity – সূত্র ও ধারণা

Decision Tree এ সেরা split খুঁজে বের করতে Gini Impurity ব্যবহার করা হয়। Gini Impurity একটি node এর অশুদ্ধতা (impurity) পরিমাপ করে। $\text{Gini} = 0$ মানে node সম্পূর্ণ pure (সব একই class), $\text{Gini} = 0.5$ মানে সর্বোচ্চ impurity (binary case)।

Gini(node) = 1 - Σ p_i²

যেখানে p_i = node এ class i এর proportion

Weighted Gini (split এর জন্য):

Gini_split = (|Left| / |Total|) × Gini(Left) + (|Right| / |Total|) × Gini(Right)

Information Gain = Gini(Parent) - Gini_split

→ যে split এ Information Gain সবচেয়ে বেশি, সেটিই সেরা split।

Tree 1 — সম্পূর্ণ Gini Calculation

Bootstrap Sample 1 (features: Study Hours, Attendance)

Row	ID	Study Hours	Attendance	Pass
1	1	2	Low	No
2	3	5	High	Yes
3	3	5	High	Yes
4	4	6	High	Yes
5	5	4	Medium	Yes

Step 1 — Root Node Gini Impurity

Total = 5 | Yes = 4 | No = 1

p(Yes) = 4/5 = 0.80 | p(No) = 1/5 = 0.20

Gini(Root) = 1 - (0.80² + 0.20²) = 1 - (0.64 + 0.04) = 1 - 0.68 = 0.3200

Step 2 — Feature: Attendance (Low/Medium vs High)

Split: Attendance = High (Right) vs Non-High (Left)

Left (Low or Medium): Row {1, 5} → Yes=1 (ID5), No=1 (ID1) → n=2

$$p(\text{Yes})=1/2=0.5, p(\text{No})=1/2=0.5$$

$$\text{Gini}(\text{Left}) = 1 - (0.5^2 + 0.5^2) = 1 - 0.5 = \mathbf{0.5000}$$

Right (High): Row {2,3,4} → Yes=3, No=0 → n=3

$$p(\text{Yes})=3/3=1.0, p(\text{No})=0$$

$$\text{Gini}(\text{Right}) = 1 - (1^2 + 0^2) = 1 - 1 = \mathbf{0.0000} \text{ (pure!)}$$

$$\text{Weighted Gini} = (2/5) \times 0.5 + (3/5) \times 0.0 = 0.20 + 0.0 = \mathbf{0.2000}$$

$$\text{Information Gain} = 0.3200 - 0.2000 = \mathbf{0.1200}$$

Step 3 — Feature: Study Hours (threshold = 3.5 → ≤ 3.5 vs > 3.5)

Split: Study Hours ≤ 3.5 (Left) vs Study Hours > 3.5 (Right)

Left (≤ 3.5): Row {1} (Study=2) → Yes=0, No=1 → n=1

$$\text{Gini}(\text{Left}) = 1 - (0^2 + 1^2) = 0 \text{ (pure)}$$

Right (> 3.5): Row {2,3,4,5} → Yes=4, No=0 → n=4

$$\text{Gini}(\text{Right}) = 1 - (1^2 + 0^2) = 0 \text{ (pure)}$$

$$\text{Weighted Gini} = (1/5) \times 0 + (4/5) \times 0 = \mathbf{0.0000}$$


$$\text{Information Gain} = 0.3200 - 0.0000 = \mathbf{0.3200}$$

Tree 1 Root Split Decision:

Study Hours (IG = 0.3200) > Attendance (IG = 0.1200)

→ **Best Split: Study Hours ≤ 3.5**

Tree 1 — Structure



Tree 1 — max depth reached, both leaves are pure

Tree 2 — সম্পূর্ণ Gini Calculation

Bootstrap Sample 2 (features: Attendance, Assignment)

Row	ID	Attendance	Assignment	Pass
1	2	Medium	Yes	No
2	2	Medium	Yes	No
3	3	High	Yes	Yes
4	4	High	Yes	Yes
5	5	Medium	No	Yes

Step 1 — Root Node Gini Impurity

Total=5 | Yes=3 | No=2

$p(\text{Yes})=3/5=0.60$ | $p(\text{No})=2/5=0.40$

$\text{Gini}(\text{Root}) = 1 - (0.60^2 + 0.40^2) = 1 - (0.36 + 0.16) = 1 - 0.52 = 0.4800$

Step 2 — Feature: Attendance (High vs Non-High)

Left (Non-High = Medium): Row {1,2,5} → Yes=1(ID5), No=2(ID2,2) → n=3

$$p(\text{Yes})=1/3\approx 0.333, p(\text{No})=2/3\approx 0.667$$

$$\text{Gini}(\text{Left}) = 1 - (0.333^2 + 0.667^2) = 1 - (0.111 + 0.444) = 1 - 0.556 = \mathbf{0.4444}$$

Right (High): Row {3,4} → Yes=2, No=0 → n=2

$$\text{Gini}(\text{Right}) = 1 - (1^2 + 0^2) = \mathbf{0.0000} \text{ (pure)}$$

$$\text{Weighted Gini} = (3/5) \times 0.4444 + (2/5) \times 0.0 = 0.2667 + 0 = \mathbf{0.2667}$$

$$\text{Information Gain} = 0.4800 - 0.2667 = \mathbf{0.2133}$$

Step 3 — Feature: Assignment (Yes vs No)

Left (Assignment=No): Row {5} → Yes=1, No=0 → n=1

$$\text{Gini}(\text{Left}) = 0 \text{ (pure)}$$

Right (Assignment=Yes): Row {1,2,3,4} → Yes=2(ID3,4), No=2(ID2,2) → n=4

$$p(\text{Yes})=2/4=0.5, p(\text{No})=2/4=0.5$$

$$\text{Gini}(\text{Right}) = 1 - (0.5^2 + 0.5^2) = 1 - 0.5 = \mathbf{0.5000}$$

$$\text{Weighted Gini} = (1/5) \times 0 + (4/5) \times 0.5 = 0 + 0.4 = \mathbf{0.4000}$$

$$\text{Information Gain} = 0.4800 - 0.4000 = \mathbf{0.0800}$$

Tree 2 Root Split Decision:

Attendance (IG = 0.2133) > Assignment (IG = 0.0800)

→ **Best Split: Attendance = High**

Tree 2 — Second Level Split (Left child: Non-High Attendance)

Left node এ 3টি row আছে (ID2, ID2, ID5) — Yes=1, No=2। এটি impure। এখন Assignment দিয়ে split করব।

Step 4 — Left Child: Assignment split (only feature left)

$Gini(\text{Left-node}) = 0.4444$

Assignment=Yes: Row {1,2} (ID2,ID2) $\rightarrow$ Yes=0, No=2 $\rightarrow n=2$

$Gini = 1 - (0^2 + 1^2) = 0$ (pure)


Assignment=No: Row {5} $\rightarrow$ Yes=1, No=0 $\rightarrow n=1$

$Gini = 0$ (pure)

Weighted Gini = $(2/3) \times 0 + (1/3) \times 0 = 0.0000$

IG = $0.4444 - 0 = 0.4444 \rightarrow$ Split করা!

Tree 2 — Structure



Tree 2 — depth 2, all leaves pure

Tree 3 — সম্পূর্ণ Gini Calculation

Bootstrap Sample 3 (features: Study Hours, Assignment)

Row	ID	Study Hours	Assignment	Pass
1	1	2	No	No
2	2	3	Yes	No
3	4	6	Yes	Yes
4	4	6	Yes	Yes
5	5	4	No	Yes

Step 1 — Root Node Gini Impurity

Total=5 | Yes=3 | No=2

$p(\text{Yes})=0.60$, $p(\text{No})=0.40$

Gini(Root) = $1 - (0.36 + 0.16) = 0.4800$

Step 2 — Feature: Study Hours (threshold = 3.5)

Left (≤ 3.5): Row {1,2} $\rightarrow$ Yes=0, No=2 $\rightarrow$ n=2

Gini(Left) = $1 - (0^2 + 1^2) = 0$ (pure)

Right (> 3.5): Row {3,4,5} $\rightarrow$ Yes=3 (ID 4,4,5), No=0 $\rightarrow$ n=3

Gini(Right) = $1 - (1^2 + 0^2) = 0$ (pure)

Weighted Gini = 0

Information Gain = $0.4800 - 0 = 0.4800$

Step 3 — Feature: Assignment (Yes vs No)

Left (No): Row {1,5} → Yes=1(ID5), No=1(ID1) → n=2

$$\text{Gini(Left)} = 1 - (0.5^2 + 0.5^2) = \mathbf{0.5000}$$

Right (Yes): Row {2,3,4} → Yes=2(ID4,4), No=1(ID2) → n=3

$$p(\text{Yes}) = 2/3 \approx 0.667, p(\text{No}) = 1/3 \approx 0.333$$

$$\text{Gini(Right)} = 1 - (0.667^2 + 0.333^2) = 1 - (0.444 + 0.111) = \mathbf{0.4444}$$

$$\text{Weighted Gini} = (2/5) \times 0.5 + (3/5) \times 0.4444 = 0.2 + 0.2667 = \mathbf{0.4667}$$


$$\text{Information Gain} = 0.4800 - 0.4667 = \mathbf{0.0133}$$

Tree 3 Root Split Decision:

Study Hours (IG = 0.4800) >> Assignment (IG = 0.0133)

→ **Best Split: Study Hours ≤ 3.5**

Tree 3 — Structure



Tree 3 — depth 1, both leaves pure (perfect separation)

নতুন Instance — Prediction

নতুন data point:

Study Hours = 4 | Attendance = High | Assignment = Yes

Tree 1 এ Traverse

Root: Study Hours ≤ 3.5 ? $\rightarrow 4 > 3.5 \rightarrow$ Right branch

Right leaf: Predict = **Yes**

Tree 1 Prediction $\rightarrow$ Yes

Tree 2 এ Traverse

Root: Attendance = High? $\rightarrow$ High = Yes $\rightarrow$ Right branch

Right leaf: Predict = **Yes**

Tree 2 Prediction $\rightarrow$ Yes

Tree 3 এ Traverse

Root: Study Hours ≤ 3.5 ? $\rightarrow 4 > 3.5 \rightarrow$ Right branch

Right leaf: Predict = **Yes**

Tree 3 Prediction $\rightarrow$ Yes

§ 9

Majority Voting — চূড়ান্ত সিদ্ধান্ত

Random Forest এ সমস্ত tree এর individual prediction collect করে **Majority Vote** নেওয়া হয়। Classification task এ যে class বেশি vote পায়, সেটিই final prediction।

Tree 1 $\rightarrow$ Yes

+

Tree 2 $\rightarrow$ Yes

+

Tree 3 $\rightarrow$ Yes

=

Yes: 3 votes

Vote Count:

Yes = 3 votes | No = 0 votes

Majority Class = Yes (3 out of 3 trees agree)

FINAL PREDICTION

✓ **Pass = Yes**

Study Hours=4, Attendance=High, Assignment=Yes → এই student টি Pass করবে।
Confidence: 3/3 trees → 100% vote unanimity

মানদণ্ড: Squared Error (MSE) | n_estimators = 3 | max_features = 2

ধাপ ১: মূল ডেটাসেট

ID	Study Hours	Sleep Hours	Attendance	Marks (Target)
1	2	8	Low	40
2	3	7	Medium	50
3	4	7	Medium	60
4	5	6	High	75
5	6	6	High	90

ধাপ ২: Bootstrap Sampling

র‍্যান্ডম ফরেস্টে প্রতিটি ট্রিকে একটি Bootstrap Sample দিয়ে প্রশিক্ষণ দেওয়া হয়। এটি হলো মূল ডেটাসেট থেকে পুনরাবৃত্তিসহ (with replacement) র‍্যান্ডমভাবে n সংখ্যক নমুনা নেওয়া (এখানে n = 5)।

Bootstrap Sample 1 (Tree 1 এর জন্য)

নির্বাচিত সারি (পুনরাবৃত্তিসহ): ID → 1, 2, 2, 4, 5

ID	Study Hours	Sleep Hours	Attendance	Marks
1	2	8	Low	40
2	3	7	Medium	50
2	3	7	Medium	50
4	5	6	High	75
5	6	6	High	90

Bootstrap Sample 2 (Tree 2 এর জন্য)

নির্বাচিত সারি (পুনরাবৃত্তিসহ): ID → 1, 3, 3, 4, 5

ID	Study Hours	Sleep Hours	Attendance	Marks
1	2	8	Low	40
3	4	7	Medium	60
3	4	7	Medium	60
4	5	6	High	75
5	6	6	High	90

Bootstrap Sample 3 (Tree 3 এর জন্য)

নির্বাচিত সারি (পুনরাবৃত্তিসহ): ID → 2, 3, 4, 4, 5

ID	Study Hours	Sleep Hours	Attendance	Marks
2	3	7	Medium	50
3	4	7	Medium	60
4	5	6	High	75
4	5	6	High	75
5	6	6	High	90

ধাপ ৩: র্যান্ডম ফিচার নির্বাচন ($\text{max_features} = 2$)

প্রতিটি নোড বিভাজনের সময় ৩টি উপলব্ধ ফিচার থেকে মাত্র ২টি ফিচার র্যান্ডমভাবে বেছে নেওয়া হয়।

- Tree 1: Study Hours, Attendance
- Tree 2: Study Hours, Sleep Hours
- Tree 3: Study Hours, Attendance

ধাপ ৪: মূল সূত্র — Squared Error (MSE)

একটি নোডে $y_1, y_2, \dots, y_n$ মান থাকলে Mean Squared Error হবে:

$$MSE = (1/n) \times \sum (y_i - \bar{y})^2$$

যেখানে $\bar{y}$ = সেই নোডের সকল টার্গেট মানের গড়।

একটি বিভাজনের Weighted MSE:

$$MSE_{split} = (n_{left} / n) \times MSE_{left} + (n_{right} / n) \times MSE_{right}$$

MSE হ্রাস (Information Gain):

$$Gain = MSE_{parent} - MSE_{split}$$

যে বিভাজনে Gain সর্বোচ্চ (অর্থাৎ Weighted MSE সর্বনিম্ন), সেটিই নির্বাচন করা হয়।

ধাপ ৫: Tree 1 – সম্পূর্ণ গণনা

Bootstrap Sample 1 এর ডেটা:

Study Hours	Attendance	Marks
2	Low	40
3	Medium	50
3	Medium	50
5	High	75
6	High	90

নির্বাচিত ফিচার: Study Hours, Attendance

৫.১ – Root Node MSE (Parent)

$$\bar{y}_{parent} = (40 + 50 + 50 + 75 + 90) / 5 = 305 / 5 = 61$$

$$MSE_{parent} = [(40-61)^2 + (50-61)^2 + (50-61)^2 + (75-61)^2 + (90-61)^2] / 5$$

$$= [(-21)^2 + (-11)^2 + (-11)^2 + (14)^2 + (29)^2] / 5$$

$$= [441 + 121 + 121 + 196 + 841] / 5$$

$$= 1720 / 5 = 344$$

$$\text{MSE}_{\text{parent}} = 344$$

৫.২ – ফিচার: Study Hours এর উপর বিভাজন পরীক্ষা

সম্ভাব্য Split Points (পরপর unique মানের মধ্যবিন্দু): 2.5, 4.0, 5.5

Split A: Study Hours ≤ 2.5

বাম দিক (Left): {40} $\rightarrow \bar{y}_L = 40$, $\text{MSE}_L = 0$

ডান দিক (Right): {50, 50, 75, 90} $\rightarrow \bar{y}_R = (50+50+75+90)/4 = 265/4 = 66.25$

$$\text{MSE}_R = [(50-66.25)^2 + (50-66.25)^2 + (75-66.25)^2 + (90-66.25)^2] / 4$$

$$= [(-16.25)^2 + (-16.25)^2 + (8.75)^2 + (23.75)^2] / 4$$

$$= [264.0625 + 264.0625 + 76.5625 + 564.0625] / 4$$

$$= 1168.75 / 4 = 292.1875$$

$$\text{MSE}_{\text{split}} = (1/5) \times 0 + (4/5) \times 292.1875 = 233.75$$

$$\text{Gain} = 344 - 233.75 = 110.25$$

Split B: Study Hours ≤ 4.0

বাম দিক: {40, 50, 50} $\rightarrow \bar{y}_L = 140/3 = 46.67$

$$\text{MSE}_L = [(40-46.67)^2 + (50-46.67)^2 + (50-46.67)^2] / 3$$

$$= [(-6.67)^2 + (3.33)^2 + (3.33)^2] / 3$$

$$= [44.49 + 11.09 + 11.09] / 3$$

$$= 66.67 / 3 = 22.22$$

ডান দিক: {75, 90} $\rightarrow \bar{y}_R = 165/2 = 82.5$

$$\text{MSE}_R = [(75-82.5)^2 + (90-82.5)^2] / 2$$

$$= [(-7.5)^2 + (7.5)^2] / 2$$

$$= [56.25 + 56.25] / 2 = \mathbf{56.25}$$

$$\text{MSE}_{\text{split}} = (3/5) \times 22.22 + (2/5) \times 56.25$$

$$= 13.33 + 22.50 = \mathbf{35.83}$$

$$\text{Gain} = 344 - 35.83 = 308.17 \leftarrow \text{এখন পর্যন্ত সর্বোচ্চ}$$

Split C: Study Hours ≤ 5.5

বাম দিক: {40, 50, 50, 75} $\rightarrow \bar{y}_L = 215/4 = 53.75$

$$\text{MSE}_L = [(40-53.75)^2 + (50-53.75)^2 + (50-53.75)^2 + (75-53.75)^2] / 4$$

$$= [(-13.75)^2 + (-3.75)^2 + (-3.75)^2 + (21.25)^2] / 4$$

$$= [189.0625 + 14.0625 + 14.0625 + 451.5625] / 4$$

$$= 668.75 / 4 = \mathbf{167.1875}$$

ডান দিক: {90} $\rightarrow \bar{y}_R = 90, \text{MSE}_R = 0$

$$\text{MSE}_{\text{split}} = (4/5) \times 167.1875 + (1/5) \times 0 = \mathbf{133.75}$$

$$\text{Gain} = 344 - 133.75 = \mathbf{210.25}$$

৫.৩ – ফিচার: Attendance এর উপর বিভাজন পরীক্ষা

Split D: Attendance = Low বনাম {Medium, High}

বাম দিক (Low): {40} $\rightarrow \bar{y}_L = 40, \text{MSE}_L = 0$

ডান দিক (Medium, High): {50, 50, 75, 90} $\rightarrow \bar{y}_R = 66.25, \text{MSE}_R = 292.1875$

$$\text{MSE}_{\text{split}} = (1/5) \times 0 + (4/5) \times 292.1875 = \mathbf{233.75}$$

$$\text{Gain} = 344 - 233.75 = 110.25$$

Split E: Attendance $\in \{\text{Low, Medium}\}$ বনাম $\{\text{High}\}$

বাম দিক (Low, Medium): $\{40, 50, 50\} \rightarrow \bar{y}_L = 46.67, \text{MSE}_L = 22.22$

ডান দিক (High): $\{75, 90\} \rightarrow \bar{y}_R = 82.5, \text{MSE}_R = 56.25$

$$\text{MSE}_{\text{split}} = (3/5) \times 22.22 + (2/5) \times 56.25 = 13.33 + 22.50 = 35.83$$

$$\text{Gain} = 344 - 35.83 = 308.17 \leftarrow \text{Split B এর সমান}$$

৫.৪ – Tree 1 এর সেরা বিভাজন

Split	ফিচার	শর্ত	Gain
A	Study Hours	≤ 2.5	110.25
B	Study Hours	≤ 4.0	308.17
C	Study Hours	≤ 5.5	210.25
D	Attendance	Low বনাম বাকি	110.25
E	Attendance	$\{\text{Low, Med}\}$ বনাম High	308.17

Split B ও Split E উভয়ের Gain = 308.17 সমান। আমরা **Study Hours ≤ 4.0** নির্বাচন করি।

Root Split: Study Hours ≤ 4.0

৫.৫ – Tree 1 দ্বিতীয় স্তর: বাম নোড (Study Hours ≤ 4.0)

নমুনা: $\{40, 50, 50\} \rightarrow \bar{y} = 46.67, \text{MSE} = 22.22$

Study Hours ≤ 2.5 বিভাজন চেষ্টা:

বাম: {40} $\rightarrow$ MSE = 0

ডান: {50, 50} $\rightarrow \bar{y} = 50$, MSE = 0

MSE_split = $(1/3) \times 0 + (2/3) \times 0 = 0$

Gain = $22.22 - 0 = 22.22 \rightarrow$ নিখুঁত বিভাজন

সেরা বিভাজন: Study Hours ≤ 2.5

৫.৬ – Tree 1 দ্বিতীয় স্তর: ডান নোড (Study Hours > 4.0)

নমুনা: {75, 90} $\rightarrow \bar{y} = 82.5$, MSE = 56.25

Study Hours ≤ 5.5 বিভাজন চেষ্টা:


বাম: {75} $\rightarrow$ MSE = 0

ডান: {90} $\rightarrow$ MSE = 0

MSE_split = 0, Gain = **56.25** $\rightarrow$ নিখুঁত বিভাজন

৫.৭ – Tree 1: চূড়ান্ত কাঠামো

Root: Study Hours ≤ 4.0 ?



ধাপ ৬: Tree 2 – সম্পূর্ণ গণনা

Bootstrap Sample 2 এর ডেটা:

Study Hours	Sleep Hours	Marks
2	8	40
4	7	60
4	7	60
5	6	75
6	6	90

নির্বাচিত ফিচার: Study Hours, Sleep Hours

৬.১ – Root Node MSE (Parent)

$$\bar{y}_{\text{parent}} = (40 + 60 + 60 + 75 + 90) / 5 = 325 / 5 = \mathbf{65}$$

$$\begin{aligned}\text{MSE}_{\text{parent}} &= [(40-65)^2 + (60-65)^2 + (60-65)^2 + (75-65)^2 + (90-65)^2] / 5 \\ &= [(-25)^2 + (-5)^2 + (-5)^2 + (10)^2 + (25)^2] / 5 \\ &= [625 + 25 + 25 + 100 + 625] / 5 \\ &= 1400 / 5 = \mathbf{280}\end{aligned}$$

৬.২ – ফিচার: Study Hours এর উপর বিভাজন পরীক্ষা

Split Points: 3.0, 4.5, 5.5

Split A: Study Hours $\leq$ 3.0

বাম: {40} $\rightarrow$ $\text{MSE}_L = 0$

ডান: {60, 60, 75, 90} $\rightarrow \bar{y}_R = 285/4 = 71.25$

$$\begin{aligned}\text{MSE}_R &= [(60-71.25)^2 + (60-71.25)^2 + (75-71.25)^2 + (90-71.25)^2] / 4 \\ &= [(-11.25)^2 + (-11.25)^2 + (3.75)^2 + (18.75)^2] / 4 \\ &= [126.5625 + 126.5625 + 14.0625 + 351.5625] / 4 \\ &= 618.75 / 4 = \mathbf{154.6875}\end{aligned}$$

$$\text{MSE}_{\text{split}} = (1/5) \times 0 + (4/5) \times 154.6875 = \mathbf{123.75}$$

$$\mathbf{\text{Gain} = 280 - 123.75 = 156.25}$$

Split B: Study Hours $\leq$ 4.5

বাম: {40, 60, 60} $\rightarrow \bar{y}_L = 160/3 = 53.33$

$$\begin{aligned}\text{MSE}_L &= [(40-53.33)^2 + (60-53.33)^2 + (60-53.33)^2] / 3 \\ &= [(-13.33)^2 + (6.67)^2 + (6.67)^2] / 3\end{aligned}$$

$$= [177.69 + 44.49 + 44.49] / 3$$

$$= 266.67 / 3 = \mathbf{88.89}$$

$$\text{ডান: } \{75, 90\} \rightarrow \bar{y}_R = 82.5, \text{MSE}_R = 56.25$$

$$\text{MSE}_{\text{split}} = (3/5) \times 88.89 + (2/5) \times 56.25$$

$$= 53.33 + 22.50 = \mathbf{75.83}$$

$$\text{Gain} = 280 - 75.83 = 204.17 \leftarrow \text{এখন পর্যন্ত সর্বোচ্চ}$$

Split C: Study Hours ≤ 5.5

$$\text{বাম: } \{40, 60, 60, 75\} \rightarrow \bar{y}_L = 235/4 = 58.75$$

$$\text{MSE}_L = [(40-58.75)^2 + (60-58.75)^2 + (60-58.75)^2 + (75-58.75)^2] / 4$$

$$= [(-18.75)^2 + (1.25)^2 + (1.25)^2 + (16.25)^2] / 4$$

$$= [351.5625 + 1.5625 + 1.5625 + 264.0625] / 4$$

$$= 618.75 / 4 = \mathbf{154.6875}$$

$$\text{ডান: } \{90\} \rightarrow \text{MSE}_R = 0$$

$$\text{MSE}_{\text{split}} = (4/5) \times 154.6875 + (1/5) \times 0 = \mathbf{123.75}$$

$$\text{Gain} = 280 - 123.75 = \mathbf{156.25}$$

৬.৩ – ফিচার: Sleep Hours এর উপর বিভাজন পরীক্ষা

Split Points: 6.5, 7.5

Split D: Sleep Hours ≤ 6.5

$$\text{বাম (Sleep } \leq 6.5): \{75, 90\} \rightarrow \bar{y}_L = 82.5, \text{MSE}_L = 56.25$$

$$\text{ডান (Sleep } > 6.5): \{40, 60, 60\} \rightarrow \bar{y}_R = 53.33, \text{MSE}_R = 88.89$$

$$\begin{aligned}\text{MSE}_{\text{split}} &= (2/5) \times 56.25 + (3/5) \times 88.89 \\ &= 22.50 + 53.33 = \mathbf{75.83}\end{aligned}$$

$$\text{Gain} = 280 - 75.83 = 204.17 \leftarrow \text{Split B এর সমান}$$

Split E: Sleep Hours ≤ 7.5

বাম (Sleep ≤ 7.5): {60, 60, 75, 90} $\rightarrow \bar{y}_L = 71.25$, $\text{MSE}_L = 154.6875$

ডান (Sleep > 7.5): {40} $\rightarrow \text{MSE}_R = 0$

$$\text{MSE}_{\text{split}} = (4/5) \times 154.6875 + (1/5) \times 0 = \mathbf{123.75}$$

$$\text{Gain} = 280 - 123.75 = 156.25$$

৬.৪ – Tree 2 এর সেরা বিভাজন

Split	ফিচার	শর্ত	Gain
A	Study Hours	≤ 3.0	156.25
B	Study Hours	≤ 4.5	204.17
C	Study Hours	≤ 5.5	156.25
D	Sleep Hours	≤ 6.5	204.17
E	Sleep Hours	≤ 7.5	156.25

নির্বাচিত বিভাজন: Study Hours ≤ 4.5

৬.৫ – Tree 2 দ্বিতীয় স্তর: বাম নোড (Study Hours $\leq$ 4.5)

নমুনা: {40, 60, 60} $\rightarrow \bar{y} = 53.33$, MSE = 88.89

Study Hours $\leq$ 3.0 বিভাজন:

বাম: {40} $\rightarrow$ MSE = 0 | ডান: {60, 60} $\rightarrow$ MSE = 0

MSE_split = 0, Gain = 88.89 $\rightarrow$ নিখুঁত বিভাজন

৬.৬ – Tree 2 দ্বিতীয় স্তর: ডান নোড (Study Hours $>$ 4.5)

নমুনা: {75, 90} $\rightarrow \bar{y} = 82.5$, MSE = 56.25


Study Hours $\leq$ 5.5 বিভাজন:

বাম: {75} $\rightarrow$ MSE = 0 | ডান: {90} $\rightarrow$ MSE = 0

MSE_split = 0, Gain = 56.25 $\rightarrow$ নিখুঁত বিভাজন

৬.৭ – Tree 2: চূড়ান্ত কাঠামো

Root: Study Hours $\leq$ 4.5?



ধাপ ৭: Tree 3 – সম্পূর্ণ গণনা

Bootstrap Sample 3 এর ডেটা:

Study Hours	Attendance	Marks
3	Medium	50
4	Medium	60
5	High	75
5	High	75
6	High	90

নির্বাচিত ফিচার: Study Hours, Attendance

৭.১ – Root Node MSE (Parent)

$$\bar{y}_{\text{parent}} = (50 + 60 + 75 + 75 + 90) / 5 = 350 / 5 = 70$$

$$\begin{aligned} \text{MSE}_{\text{parent}} &= [(50-70)^2 + (60-70)^2 + (75-70)^2 + (75-70)^2 + (90-70)^2] / 5 \\ &= [(-20)^2 + (-10)^2 + (5)^2 + (5)^2 + (20)^2] / 5 \\ &= [400 + 100 + 25 + 25 + 400] / 5 \\ &= 950 / 5 = 190 \end{aligned}$$

৭.২ – ফিচার: Study Hours এর উপর বিভাজন পরীক্ষা

Split Points: 3.5, 4.5, 5.5

Split A: Study Hours $\leq$ 3.5

বাম: {50} $\rightarrow$ MSE_L = 0

ডান: {60, 75, 75, 90} $\rightarrow \bar{y}_R = 300/4 = 75$

$$\begin{aligned} \text{MSE}_R &= [(60-75)^2 + (75-75)^2 + (75-75)^2 + (90-75)^2] / 4 \\ &= [225 + 0 + 0 + 225] / 4 \\ &= 450 / 4 = \mathbf{112.5} \end{aligned}$$

$$\text{MSE}_{\text{split}} = (1/5) \times 0 + (4/5) \times 112.5 = \mathbf{90}$$

$$\mathbf{\text{Gain} = 190 - 90 = 100}$$

Split B: Study Hours ≤ 4.5

$$\text{বাম: } \{50, 60\} \rightarrow \bar{y}_L = 55$$

$$\text{MSE}_L = [(50-55)^2 + (60-55)^2] / 2 = [25 + 25] / 2 = \mathbf{25}$$

$$\text{ডান: } \{75, 75, 90\} \rightarrow \bar{y}_R = 240/3 = 80$$

$$\begin{aligned} \text{MSE}_R &= [(75-80)^2 + (75-80)^2 + (90-80)^2] / 3 \\ &= [25 + 25 + 100] / 3 \\ &= 150 / 3 = \mathbf{50} \end{aligned}$$

$$\text{MSE}_{\text{split}} = (2/5) \times 25 + (3/5) \times 50 = 10 + 30 = \mathbf{40}$$

$$\mathbf{\text{Gain} = 190 - 40 = 150} \leftarrow \text{এখন পর্যন্ত সর্বোচ্চ}$$

Split C: Study Hours ≤ 5.5

$$\text{বাম: } \{50, 60, 75, 75\} \rightarrow \bar{y}_L = 260/4 = 65$$

$$\begin{aligned} \text{MSE}_L &= [(50-65)^2 + (60-65)^2 + (75-65)^2 + (75-65)^2] / 4 \\ &= [225 + 25 + 100 + 100] / 4 \\ &= 450 / 4 = \mathbf{112.5} \end{aligned}$$

$$\text{ডান: } \{90\} \rightarrow \text{MSE}_R = 0$$

$$\text{MSE}_{\text{split}} = (4/5) \times 112.5 + (1/5) \times 0 = \mathbf{90}$$

$$\text{Gain} = 190 - 90 = 100$$

৭.৩ – ফিচার: Attendance এর উপর বিভাজন পরীক্ষা

Split D: Attendance = Medium বনাম High

বাম (Medium): {50, 60} $\rightarrow \bar{y}_L = 55$, $\text{MSE}_L = 25$

ডান (High): {75, 75, 90} $\rightarrow \bar{y}_R = 80$, $\text{MSE}_R = 50$

$$\text{MSE}_{\text{split}} = (2/5) \times 25 + (3/5) \times 50 = 10 + 30 = 40$$

$$\text{Gain} = 190 - 40 = 150 \leftarrow \text{Split B এর সমান}$$

৭.৪ – Tree 3 এর সেরা বিভাজন

Split	ফিচার	শর্ত	Gain
A	Study Hours	≤ 3.5	100
B	Study Hours	≤ 4.5	150
C	Study Hours	≤ 5.5	100
D	Attendance	Medium বনাম High	150

নির্বাচিত বিভাজন: $\text{Study Hours} \leq 4.5$

৭.৫ – Tree 3 দ্বিতীয় স্তর: বাম নোড ($\text{Study Hours} \leq 4.5$)

নমুনা: {50, 60} $\rightarrow \bar{y} = 55$, $\text{MSE} = 25$

Study Hours ≤ 3.5 বিভাজন:

বাম: {50} $\rightarrow \text{MSE} = 0$ | ডান: {60} $\rightarrow \text{MSE} = 0$

$\text{MSE}_{\text{split}} = 0$, $\text{Gain} = 25 \rightarrow$ নিখুঁত বিভাজন

৭.৬ – Tree 3 দ্বিতীয় স্তর: ডান নোড (Study Hours > 4.5)

নমুনা: {75, 75, 90} $\rightarrow \bar{y} = 80$, MSE = 50

Study Hours ≤ 5.5 বিভাজন:


বাম: {75, 75} $\rightarrow \bar{y} = 75$, MSE = 0

ডান: {90} $\rightarrow$ MSE = 0

MSE_split = 0, Gain = 50 $\rightarrow$ নিখুঁত বিভাজন

৭.৭ – Tree 3: চূড়ান্ত কাঠামো

Root: Study Hours ≤ 4.5 ?



ধাপ ৮: নতুন ডেটার জন্য ভবিষ্যদ্বাণী

নতুন ইনপুট: Study Hours = 4, Sleep Hours = 7 (Tree 2 এর জন্য ধরা হয়েছে),
Attendance = High

Tree 1 এর ভবিষ্যদ্বাণী (ফিচার: Study Hours, Attendance)

- Root: Study Hours $\leq 4.0?$ $\rightarrow 4 \leq 4.0 \rightarrow$ **হ্যাঁ**, বাম দিকে যাও
- নোড: Study Hours $\leq 2.5?$ $\rightarrow 4 \leq 2.5 \rightarrow$ **না**, ডান দিকে যাও
- পাতা: ভবিষ্যদ্বাণী = 50

Tree 2 এর ভবিষ্যদ্বাণী (ফিচার: Study Hours, Sleep Hours)

- Root: Study Hours $\leq 4.5?$ $\rightarrow 4 \leq 4.5 \rightarrow$ **হ্যাঁ**, বাম দিকে যাও
- নোড: Study Hours $\leq 3.0?$ $\rightarrow 4 \leq 3.0 \rightarrow$ **না**, ডান দিকে যাও
- পাতা: ভবিষ্যদ্বাণী = 60

Tree 3 এর ভবিষ্যদ্বাণী (ফিচার: Study Hours, Attendance)

- Root: Study Hours $\leq 4.5?$ $\rightarrow 4 \leq 4.5 \rightarrow$ **হ্যাঁ**, বাম দিকে যাও
- নোড: Study Hours $\leq 3.5?$ $\rightarrow 4 \leq 3.5 \rightarrow$ **না**, ডান দিকে যাও
- পাতা: ভবিষ্যদ্বাণী = 60

ধাপ ৯: চূড়ান্ত ভবিষ্যদ্বাণী – গড় গণনা (Averaging)

গুরুত্বপূর্ণ নোট: Regressor এর ক্ষেত্রে Random Forest Majority Voting ব্যবহার করে না (সেটি Classifier এর জন্য)। Regression এ সকল ট্রির ভবিষ্যদ্বাণীর গড় নেওয়া হয়।

ট্রি	ভবিষ্যদ্বাণী
Tree 1	50
Tree 2	60

Tree 3	60
--------	----

চূড়ান্ত ভবিষ্যদ্বাণী = $(50 + 60 + 60) / 3 = 170 / 3 \approx 56.67$

নতুন শিক্ষার্থীর প্রাপ্ত নম্বরের ভবিষ্যদ্বাণী ≈ 56.67

Classifier:

n_estimators

- **Default:** ১০০
- **কাজ কী:** র্যান্ডম ফরেস্ট মডেলের ভেতরে মোট কতগুলো ডিসিশন ট্রি (Decision Tree) বা সিদ্ধান্ত-গাছ তৈরি হবে, তা এটি ঠিক করে।
- **অন্যান্য অপশন:** যেকোনো পজিটিভ পূর্ণসংখ্যা (যেমন: ৫০, ২০০, ৫০০)।
- **কখন কোনটি ব্যবহার করব:** যদি ডেটাসেট অনেক ছোট হয় বা কম্পিউটারের র‍্যাম/প্রসেসর কম শক্তির হয়, তবে এটি কমিয়ে ৫০ করা যায়। আর যদি ডেটাসেট অনেক বড় হয় এবং আপনার সর্বোচ্চ এক্যুরেসী বা স্থায়িত্বের প্রয়োজন পড়ে, তবে এটি বাড়িয়ে ৩০০ বা ৫০০ করা উচিত।

max_features

- **Default:** "sqrt" (মোট ফিচারের সংখ্যার বর্গমূল)
- **কাজ কী:** গাছের প্রতিটা নোড স্প্লিট বা ভাগ করার সময় র্যান্ডমলি সর্বোচ্চ কয়টি ফিচার (কলাম) স্ক্যান করা হবে, তা এটি নিয়ন্ত্রণ করে।
- **অন্যান্য অপশন:** "log2" (লগ বেস ২), কোনো নির্দিষ্ট সংখ্যা (যেমন: ৩, ৫) বা ভগ্নাংশ (যেমন: ০.৫ অর্থাৎ মোট ফিচারের ৫০%)। এছাড়া None দিলে প্রতিবার সব ফিচার স্ক্যান করে।
- **কখন কোনটি ব্যবহার করব:** ডেটাসেটে যদি শত শত কলাম (High Dimensionality) থাকে, তবে ডিফল্ট "sqrt" বা "log2" রাখাই সবচেয়ে বেস্ট, কারণ এটি গাছগুলোর মধ্যে বৈচিত্র্য বাড়ায়। কিন্তু যদি কলামের সংখ্যা খুব কম হয় (যেমন: মাত্র ৩-৪টি কলাম), তখন এটি None রাখা ভালো যাতে মডেল সব কলাম দেখার সুযোগ পায়।

max_depth

- **Default:** None
- **কাজ কী:** জঙ্গলের প্রতিটি একক গাছের সর্বোচ্চ গভীরতা বা লেভেল কতটুকু হতে পারবে, তা এটি বেঁধে দেয়। None থাকলে গাছগুলো একদম শেষ সীমা পর্যন্ত বাড়তে থাকে।
- **অন্যান্য অপশন:** যেকোনো পূর্ণসংখ্যা (যেমন: ৫, ১০, ১৫)।
- **কখন কোনটি ব্যবহার করব:** যদি দেখেন মডেলটি ট্রেনিং ডেটায় চমৎকার রেজাল্ট দিলেও টেস্ট ডেটায় ফেইল করছে (ওভারফিটিং হচ্ছে), তখন গাছের এই অনিয়ন্ত্রিত বৃদ্ধি থামাতে এখানে একটি নির্দিষ্ট গভীরতা (যেমন: max_depth=10 বা 12) সেট করতে হবে।

min_samples_split

- **Default:** ২
- **কাজ কী:** একটি নোডকে ভেঙে নতুন দুটি ডাল তৈরি করার জন্য ওই নোডে নূন্যতম কয়টি ডেটা স্যাম্পল থাকতে হবে, তা এটি ঠিক করে।
- **অন্যান্য অপশন:** যেকোনো পূর্ণসংখ্যা (যেমন: ৫, ১০, ৫০) বা ভগ্নাংশ।
- **কখন কোনটি ব্যবহার করব:** যখন মডেলের ওভারফিটিং বন্ধ করার প্রয়োজন পড়ে। যদি আপনি এখানে min_samples_split=10 দেন, তবে কোনো নোডে ১০টির কম ডেটা থাকলে গাছ সেটিকে আর ভাঙবে না, ওখানেই থামিয়ে দেবে। বড় এবং নয়েজি ডেটাসেটে এর মান বাড়িয়ে দেওয়া উচিত।

min_samples_leaf

- **Default:** ১
- **কাজ কী:** একটি গাছের একদম শেষ পাতা বা লিফ নোডে (Leaf Node) নূন্যতম কয়টি ডেটা স্যাম্পল থাকতেই হবে, তা ফিক্স করে।
- **অন্যান্য অপশন:** যেকোনো পূর্ণসংখ্যা (যেমন: ২, ৫, ১০) বা ভগ্নাংশ।

- **কখন কোনটি ব্যবহার করব:** এটিও ওভারফিটিং কমানোর এবং মডেলের আউটপুটকে মসৃণ বা স্মুথ করার জন্য ব্যবহৃত হয়। যদি ডেটাসেটে অনেক আউটলায়ার বা ভুল ডেটা থাকে, তবে এর মান বাড়িয়ে ৫ বা ১০ করে দিলে ক্ষুদ্রাতিক্ষুদ্র ও অর্থহীন প্যাটার্নের জন্য নতুন কোনো পাতা তৈরি হওয়া বন্ধ হয়ে যায়।

bootstrap

- **Default:** True
- **কাজ কী:** প্রতিটি গাছ ট্রেন করার সময় বুটস্ট্রাপ স্যাম্পলিং (Row sampling with replacement) পদ্ধতি ব্যবহার করা হবে কি না, তা এটি নির্ধারণ করে।
- **অন্যান্য অপশন:** False
- **কখন কোনটি ব্যবহার করব:** এটি সবসময় True রাখাই র্যান্ডম ফরেস্টের মূল নিয়ম। তবে যদি আপনার ডেটাসেট অত্যন্ত নিখুঁত হয় এবং আপনি চান প্রতিটি গাছ পুরো ডেটাসেটটি দেখেই তৈরি হোক (কোনো রো বাদ না পড়ুক), শুধুমাত্র তখনই এটি False করা হয়।

oob_score

- **Default:** False
- **কাজ কী:** বুটস্ট্রাপ স্যাম্পলিংয়ের সময় যে ৩৬.৮% ডেটা ট্রেনিং থেকে বাদ পড়ে যায়, সেগুলো ব্যবহার করে মডেলের ট্রেনিং চলাকালীনই একটি ইন্টারনাল ভ্যালিডেশন স্কোর হিসাব করা হবে কি না, তা এটি ঠিক করে।
- **অন্যান্য অপশন:** True
- **কখন কোনটি ব্যবহার করব:** যখন আপনার ডেটাসেট ছোট এবং আপনি ভ্যালিডেশনের জন্য আলাদা করে মূল্যবান ডেটা নষ্ট করতে চান না (যেমন: train_test_split বা K-Fold না করে)। তখন oob_score=True করে দিলে আলাদা টেস্ট সেট ছাড়াই মডেলের রিয়েল এক্যুরেসীর ধারণা পাওয়া যায়।

n_jobs

- **Default:** None (কম্পিউটারের মাত্র ১টি প্রসেসর কোর ব্যবহার করে)
- **কাজ কী:** মডেল ট্রেনিং ও প্রেডিকশনের সময় ব্যাকএন্ডে সিপিইউ-এর কয়টি কোর সমান্তরালভাবে কাজ করবে, তা এটি নিয়ন্ত্রণ করে।
- **অন্যান্য অপশন:** যেকোনো পূর্ণসংখ্যা বা -1।
- **কখন কোনটি ব্যবহার করব:** বাস্তব জীবনের বড় প্রজেক্টে সবসময় এটি -1 ব্যবহার করা উচিত। n_jobs=-1 দিলে এটি কম্পিউটারের সবগুলো প্রসেসর কোরকে একসাথে কাজে লাগিয়ে শত শত গাছ ট্রেন করার প্রক্রিয়াটিকে সুপার-ফাস্ট করে তোলে।

random_state

- **Default:** None
- **কাজ কী:** বুটস্ট্রাপ স্যাম্পলিং এবং ফিচার সিলেকশনের র্যান্ডম বা এলোমেলো প্রক্রিয়াটিকে একটি নির্দিষ্ট গাণিতিক বীজ দিয়ে লক করে দেয়।
- **অন্যান্য অপশন:** যেকোনো ফিক্সড পূর্ণসংখ্যা (যেমন: 0, 42)।
- **কখন কোনটি ব্যবহার করব:** টিম প্রজেক্ট, অ্যাসাইনমেন্ট বা কোড পরীক্ষার সময় এটি যেকোনো একটি ফিক্সড সংখ্যায় সেট করা বাধ্যতামূলক। এটি নিশ্চিত করে যে কোডটি আপনার কম্পিউটারে বা অন্য কারো কম্পিউটারে যতবারই রান করা হোক না কেন, প্রতিবার অবিকল একই গাছ এবং একই এক্যুরেসী স্কোর পাওয়া যাবে।

class_weight

- **Default:** None (সব ক্লাসকে সমান গুরুত্ব দেয়)
- **কাজ কী:** ইমব্যালেন্সড ডেটাসেটের ক্ষেত্রে ছোট বা মাইনোরিটি ক্লাসকে অতিরিক্ত গাণিতিক গুরুত্ব বা ওজন দেওয়ার জন্য এটি ব্যবহৃত হয়।
- **অন্যান্য অপশন:** "balanced" অথবা কাস্টম ডিকশনারি।
- **কখন কোনটি ব্যবহার করব:** যখন ডেটা প্রবলভাবে ইমব্যালেন্সড (যেমন: ক্রেডিট কার্ড জালিয়াতির ডেটা মাত্র ১% আর নরমাল ডেটা ৯৯%)। তখন

`class_weight='balanced'` দিলে মডেল স্বয়ংক্রিয়ভাবে ওই ১% ছোট ক্লাসকে বেশি প্রাধান্য দেয়, যার ফলে মডেলের প্রেডিকশন কোয়ালিটি বা রিকল (*Recall*) উন্নত হয়।

Regressor:

criterion

- **Default:** "squared_error"
- **কাজ কী:** রিগ্রেশন সমস্যার ক্ষেত্রে প্রতিটি ডিসিশন ট্রির নোড ভাগ বা স্প্লিট করার কোয়ালিটি মাপার জন্য ব্যাকএন্ডে কোন গাণিতিক লস ফাংশন (Loss Function) বা পরিমাপক ব্যবহার করা হবে, তা এটি নির্ধারণ করে।
- **অন্যান্য অপশন:** "absolute_error", "friedman_mse", "poisson"
- **কখন কোনটি ব্যবহার করব:**
 - **"squared_error" (Mean Squared Error - MSE):** এটি আপনার ডেটাসেটে থাকা বড় বড় ভুলগুলোকে (Large Errors) বেশি গাণিতিক শাস্তি বা গুরুত্ব দেয়। ডেটা যদি সাধারণ বা নরমাল ডিস্ট্রিবিউশন মেনে চলে, তবে এটি সবচেয়ে দ্রুত এবং সেরা ফলাফল দেয়।
 - **"absolute_error" (Mean Absolute Error - MAE):** এটি প্রতিটি ভুলের পরম মান হিসাব করে। আপনার ডেটাসেটে যদি প্রচুর আউটলায়ার (Outliers) বা অস্বাভাবিক বড়/ছোট মান থাকে, তখন এই অপশনটি ব্যবহার করা উচিত। কারণ এটি আউটলায়ারের প্রতি অত্যন্ত প্রতিরোধী (Robust)। তবে ব্যাকএন্ডে এটি প্রসেস হতে MSE-এর চেয়ে অনেক বেশি সময় নেয়।
 - **"friedman_mse":** এটি মূলত জিবিএম (Gradient Boosting) অ্যালগরিদমের উদ্ভাবক জেরোম ফ্রিডম্যানের তৈরি একটি বিশেষ পরিমাপক। এটি সাধারণ MSE-এর ওপর ভিত্তি করেই কাজ করে, তবে কিছু বিশেষ ক্ষেত্রে এটি ডালপালা গজানোর জন্য আরও নিখুঁত থ্রেশহোল্ড খুঁজে বের করতে পারে।

- **"poisson"**: যখন আপনার টার্গেট কলামের ডেটা কোনো কাউন্ট বা গণনা নির্দেশ করে (যেমন: "আজকে দোকানে কতজন কাস্টমার আসবে" বা "এই রাস্তায় প্রতি ঘণ্টায় কয়টি গাড়ি চলে") এবং ডেটাটি পয়সঁ ডিস্ট্রিবিউশন (Poisson Distribution) মেনে চলে, তখন এই ক্রাইটেরিয়নটি ব্যবহার করলে লস সবচেয়ে কম হয়।

max_features

- **Default:** 1.0 (অর্থাৎ, মোট ফিচারের ১০০% বা সবগুলোই স্ক্যান করবে)
- **কাজ কী:** রিগ্রেশন গাছের প্রতিটা নোড স্প্লিট বা ভাগ করার সময় র্যান্ডমলি সর্বোচ্চ কয়টি কলাম বা ফিচার বিবেচনা করা হবে, তা এটি নিয়ন্ত্রণ করে।
- **অন্যান্য অপশন:** "sqrt", "log2", কোনো নির্দিষ্ট সংখ্যা (int) বা ভগ্নাংশ (float)।
- **কখন কোনটি ব্যবহার করব:** ক্লাসিফায়ারের ডিফল্ট ছিল "sqrt", কিন্তু রিগ্রেশনের ডিফল্ট হলো 1.0। এর মানে হলো ডিফল্ট অবস্থায় রিগ্রেশনের প্রতিটি গাছ নোড ভাগের সময় সব ফিচার চেক করার সুযোগ পায়। তবে আপনার ডেটাসেটে যদি ফিচারের সংখ্যা অনেক বেশি হয় এবং গাছগুলোর মধ্যে বৈচিত্র্য (Diversity) বাড়িয়ে ওভারফিটিং কমাতে চান, তবে এটি পরিবর্তন করে কাস্টম ফ্লোট মান (যেমন: 0.3 বা ৩০%) অথবা ক্লাসিফায়ারের মতো "sqrt" সেট করা অত্যন্ত কার্যকর।

Code:

Classification:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.pipeline import Pipeline
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix, ConfusionMatrixDisplay

digits = load_digits()
X = pd.DataFrame(digits.data)
y = pd.Series(digits.target)

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

rf_pipeline = Pipeline(
    steps=[
        ('model', RandomForestClassifier(random_state=42, n_jobs=-1))
    ]
)
```

```

param_grid = {
    'model__n_estimators': [50, 100, 200],
    'model__max_features': ['sqrt', 'log2'],
    'model__max_depth': [10, 20, None],
    'model__min_samples_split': [2, 5]
}

grid_search = GridSearchCV(
    estimator=rf_pipeline,
    param_grid=param_grid,
    cv=5,
    scoring='accuracy',
    n_jobs=-1
)

grid_search.fit(X_train, y_train)

print("--- GridSearchCV Tuning Results ---")
print("Best Parameters Found:", grid_search.best_params_)
print(f"Best CV Accuracy: {grid_search.best_score_:.4f}\n")

best_rf_pipeline = grid_search.best_estimator_
y_pred = best_rf_pipeline.predict(X_test)

print("--- Final Model Performance on Test Set ---")
print(f"Test Accuracy: {accuracy_score(y_test, y_pred):.4f}\n")
print(classification_report(y_test, y_pred))

cm = confusion_matrix(y_test, y_pred)
disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=digits.target_names)
disp.plot(cmap=plt.cm.Blues)
plt.title("Random Forest Confusion Matrix - Digits Dataset")
plt.show()

```

Code Regressor:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import fetch_california_housing
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.pipeline import Pipeline
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error, r2_score, mean_absolute_error

housing = fetch_california_housing()
X = pd.DataFrame(housing.data, columns=housing.feature_names)
y = pd.Series(housing.target)

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

rf_reg_pipeline = Pipeline(
    steps=[
        ('model', RandomForestRegressor(random_state=42, n_jobs=-1))
    ]
)
```

```

param_grid = {
    'model__n_estimators': [50, 100],
    'model__criterion': ['squared_error', 'absolute_error'],
    'model__max_features': [0.5, 'sqrt'],
    'model__max_depth': [10, None]
}

grid_search = GridSearchCV(
    estimator=rf_reg_pipeline,
    param_grid=param_grid,
    cv=3,
    scoring='neg_mean_squared_error',
    n_jobs=-1
)

grid_search.fit(X_train, y_train)

print("--- GridSearchCV Tuning Results ---")
print("Best Parameters Found:", grid_search.best_params_)

best_rf_reg_pipeline = grid_search.best_estimator_
y_pred = best_rf_reg_pipeline.predict(X_test)

mse = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)
mae = mean_absolute_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print("--- Final Model Performance on Test Set ---")
print(f"Mean Absolute Error (MAE): {mae:.4f}")
print(f"Mean Squared Error (MSE): {mse:.4f}")
print(f"Root Mean Squared Error (RMSE): {rmse:.4f}")
print(f"R-squared Score (R2 Score): {r2:.4f}\n")

plt.figure(figsize=(8, 6))
plt.scatter(y_test, y_pred, alpha=0.3, color='crimson')
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], 'k--', lw=2)
plt.xlabel('Actual Price')
plt.ylabel('Predicted Price')
plt.title('Actual vs Predicted Prices - California Housing')
plt.show()

```

Interview Questions

Q1: Out-of-Bag (OOB) কী এবং এটি ব্যবহারের সুবিধা কী?

- **Answer:** র্যান্ডম ফরেস্টে বুটস্ট্র্যাপ স্যাম্পলিং করার সময় প্রতিস্থাপনের নীতির কারণে প্রতিটি গাছের ট্রেনিং সেট থেকে গড়ে প্রায় ৩৬.৮% ডেটা বাদ পড়ে যায়। এই বাদ পড়া ডেটাপয়েন্টগুলোকে **Out-of-Bag (OOB)** স্যাম্পল বলা হয়। মডেল ট্রেনিং শেষ হওয়ার পর, প্রতিটি গাছকে তার নিজস্ব ওওবি স্যাম্পল দিয়ে টেস্ট করে যে গড় স্কোর পাওয়া যায়, সেটিই ওওবি স্কোর। এর বড় সুবিধা হলো—এটি ব্যবহার করলে আলাদা করে কোনো টেস্ট সেট বা ক্রস-ভ্যালিডেশন (K-Fold CV) ছাড়াই মডেলের জেনারেলাইজেশন ক্ষমতা বা রিয়েল-টাইম এক্যুরেসী নিখুঁতভাবে পরিমাপ করা যায়।

Q2: Random Forest-কে কেন একটি 'Black-Box' মডেল বলা হয়?

- **Answer:** একটি একক ডিসিশন ট্রিকে খুব সহজে গ্রাফ বা ডায়াগ্রামের সাহায্যে ভিজ্যুয়ালাইজ করা যায় এবং এর প্রতিটি শর্ত (if-else রুলস) সহজে ট্র্যাকিং করা যায় (White-Box)। কিন্তু র্যান্ডম ফরেস্ট যখন ১০০ থেকে ৫০০টি গভীর গাছ একসাথে কাজ করে, তখন প্রতিটি গাছের নিজস্ব র্যান্ডম ফিচার ও র্যান্ডম ডেটা স্যাম্পল থাকে। কোনো একটি নির্দিষ্ট প্রেডিকশনের জন্য ব্যাকএন্ডে ৫০০টি গাছের হাজার হাজার জটিল শর্ত ও ভোটিং মেকানিজম একসাথে ট্র্যাক করা মানুষের পক্ষে অসম্ভব হয়ে পড়ে। গাণিতিক লজিক স্পষ্টভাবে ব্যাখ্যা করা যায় না বলেই একে **Black-Box** মডেল বলা হয়।

Q3: Random Forest-এর দুটি গাছ কি কখনো লব্ধ এক হতে পারে? যদি না হয়, তবে কেন?

- **Answer:** তাত্ত্বিকভাবে বা বাস্তবে শত শত গাছের মধ্যে দুটি গাছ লব্ধ এক হওয়া প্রায় অসম্ভব। এর পেছনে দুটি মূল কারণ রয়েছে: প্রথমত, **Bootstrap Sampling**-এর কারণে প্রতিটি গাছ সম্পূর্ণ আলাদা ও এলোমেলো ডেটার সাবসেট পায়। দ্বিতীয়ত এবং সবচেয়ে বড় কারণ হলো **Feature Randomness**; প্রতিটি নোড ভাগার সময় গাছগুলো সব কলাম দেখতে পায় না, বরং সম্পূর্ণ র্যান্ডমলি সিলেক্টেড কিছু কলাম (যেমন: $max_features = \sqrt{d}$) থেকে সেরা স্প্লিট বেছে নেয়। এই দ্বিমুখী র্যান্ডমনেসের কারণে জঙ্গলের প্রতিটি গাছের গঠন একে অপরের থেকে সম্পূর্ণ ভিন্ন ও স্বাধীন হয়।

Q4: আপনার ডেটাসেটে যদি প্রচুর আউটলায়ার (Outliers) থাকে, তবে রিগ্রেশনের ক্ষেত্রে আপনি কোন Criterion ব্যবহার করবেন এবং কেন?

- **Answer:** ডেটাসেটে প্রচুর আউটলায়ার থাকলে আমি `criterion='absolute_error'` (Mean Absolute Error - MAE) ব্যবহার করব। ডিফল্ট ক্রাইটেরিয়ন `squared_error` (MSE) ভুলের মানকে বর্গ (Square) করে হিসাব করে, যার ফলে একটি বড় আউটলায়ারের ভুল পুরো মডেলের ওপর বিশাল নেতিবাচক প্রভাব ফেলে। অন্যদিকে, MAE ভুলের পরম মান (Absolute value) নেয়, যা আউটলায়ারের প্রতি অত্যন্ত প্রতিরোধী (**Robust to outliers**) এবং মডেলের চূড়ান্ত গড় সিদ্ধান্তকে সহজে বিচ্যুত হতে দেয় না।

Q5: Random Forest কি ওভারফিট করতে পারে? যদি করে, তবে তা কীভাবে সমাধান করবেন?

- **Answer:** সাধারণ ডিসিশন ট্রির মতো র্যান্ডম ফরেস্ট সহজে ওভারফিট করে না, কারণ ব্যাগিং বা এভারেজিং প্রক্রিয়াটি ভ্যারিয়েন্স কমিয়ে আনে। তবে ডেটাসেটে যদি চরম মাত্রায় নয়েজ থাকে এবং হাইপারপ্যারামিটার নিয়ন্ত্রণ না করা হয়, তবে এটিও ওভারফিট করতে পারে। এর প্রধান সমাধানগুলো হলো:
- `max_depth`-এর মান একটি নির্দিষ্ট সংখ্যায় (যেমন: ১০ বা ১৫) বেঁধে দেওয়া।
- `min_samples_leaf`-এর মান বাড়িয়ে (যেমন: ৫ বা ১০) শেষ পাতার নূন্যতম ডেটা ফিল্ল করা।
- `n_estimators` বা জঙ্গলে গাছের সংখ্যা বাড়িয়ে মডেলকে আরও সুষম করা।

Summary

- **Core Concept:** র্যান্ডম ফরেস্ট হলো একটি অত্যন্ত শক্তিশালী এবং স্থিতিশীল এনসেম্বল লার্নিং অ্যালগরিদম, যা বুটস্ট্র্যাপ স্যাম্পলিং এবং ফিচারের র্যান্ডমনেস ব্যবহার করে শত শত ডিসিশন ট্রির সমন্বয়ে জঙ্গল তৈরি করে।
- **Mechanism:** এটি ক্লাসিফিকেশনের জন্য মেজরিটি ভোটিং (Majority Voting) এবং রিগ্রেশনের জন্য গড় (Averaging) মেথড ব্যবহার করে চূড়ান্ত প্রেডিকশন দেয়।


- **Strength:** এর সবচেয়ে বড় শক্তি হলো এটি কোনো প্রকার ফিচার স্কেলিং ছাড়াই র-ডেটাসেটে চমৎকার কাজ করে এবং ওভারফিটিংয়ের হাত থেকে মডেলকে স্বয়ংক্রিয়ভাবে রক্ষা করে।
- **Trade-off:** উচ্চমাত্রার এক্যুরেসী এবং স্ট্যাবিলিটি দিলেও, এটি মেমোরিতে অনেক বেশি জায়গা নেয় এবং এর ব্ল্যাক-বক্স প্রকৃতির কারণে মডেলের ভেতরের লজিক পুরোপুরি ব্যাখ্যা করা যায় না।

Support Vector Machine

সাপোর্ট ভেক্টর মেশিন (SVM) হলো একটি অত্যন্ত শক্তিশালী ও গাণিতিকভাবে সুসংহত সুপারভাইজড মেশিন লার্নিং অ্যালগরিদম। এর প্রধান উদ্দেশ্য হলো উচ্চ-মাত্রা বিশিষ্ট উপাত্ত স্পেসে (High-Dimensional Space) এমন একটি সর্বোত্তম সিদ্ধান্ত সীমানা বা Hyperplane নির্ধারণ করা, যা বিভিন্ন শ্রেণীভুক্ত উপাত্ত বিন্দুগুলোকে (Data Points) পরস্পরের থেকে সর্বোচ্চ দূরত্বে বা Maximum Margin-এ পৃথক করতে পারে।


সাপোর্ট ভেক্টর (Support Vectors):

হাইপারপ্লেনের অবস্থান ও অভিযোজন (Orientation) নির্ধারণের জন্য যে নির্দিষ্ট উপাত্ত বিন্দুগুলো সরাসরি দায়ী, সেগুলোকে সাপোর্ট ভেক্টর বলা হয়। এই বিন্দুগুলো সিদ্ধান্ত সীমানার সবচেয়ে নিকটে অবস্থান করে। যদি এই বিশেষ বিন্দুগুলোকে ডেটাসেট থেকে অপসারণ করা হয়, তবে সমগ্র হাইপারপ্লেনের অবস্থান পরিবর্তিত হয়ে যাবে।



মার্জিন (Margin): হাইপারপ্লেন থেকে উভয় পাশের নিকটবর্তী সাপোর্ট ভেক্টরগুলোর লম্ব দূরত্বের সমষ্টিকে মার্জিন বলা হয়। SVM-এর গাণিতিক লক্ষ্য হলো এই মার্জিনের মান সর্বোচ্চ (Maximize) করা, যাতে মডেলটির সাধারণীকরণ ক্ষমতা (Generalization Power) বৃদ্ধি পায় এবং টেস্ট ডেটায় ভুলের পরিমাণ সর্বনিম্ন হয়।

- **শ্রেণীবিভাগ (Classification):** এটি দ্বিমাত্রিক (Binary) এবং বহুমাত্রিক (Multi-class) উভয় প্রকার জটিল শ্রেণীবিভাগ মেলাতে সক্ষম।
- **রিগ্রেশন (Regression):** সংখ্যাচক মান অনুমানের জন্য এর একটি বিশেষ সংস্করণ রয়েছে, যা **Support Vector Regression (SVR)** নামে পরিচিত।



- **উচ্চ-মাত্রিক উপাত্ত (High-Dimensional Data):** যখন উপাত্ত সেটে নমুনার সংখ্যার (Rows) তুলনায় বৈশিষ্ট্যের সংখ্যা (Columns/Features) অনেক বেশি থাকে (যেমন: বায়োইনফরমেটিক্স, জিনোম সিকোয়েন্সিং বা টেক্সট ক্লাসিফিকেশন), তখন SVM অনন্য কর্মদক্ষতা প্রদর্শন করে।
- **অরৈখিক উপাত্ত বিন্যাস (Non-Linear Data):** উপাত্ত যখন সরলরেখায় বিভাজনযোগ্য হয় না, তখন SVM তার বিখ্যাত **Kernel Trick** ব্যবহার করে উপাত্তগুলোকে একটি উচ্চতর মাত্রার ক্ষেত্রে (Higher Dimensional Space) রূপান্তরিত করে এবং একটি রৈখিক হাইপারপ্লেন দ্বারা পৃথক করে।

মেশিন লার্নিং শাস্ত্রে SLR, MLR, Logistic Regression, Decision Tree, Random Forest এবং KNN-এর মতো প্রতিষ্ঠিত মডেল থাকা সত্ত্বেও নিম্নলিখিত কাঠামোগত সুবিধার কারণে SVM অপরিহার্য:

- **Logistic Regression বনাম SVM:** লজিস্টিক রিগ্রেশন ক্লাসগুলোকে পৃথক করার জন্য যেকোনো একটি সাধারণ রৈখিক রেখা টানে, যা মূলত ট্রেনিং লস কমাতে সাহায্য করে। বিপরীতে, SVM খোঁজে Optimal Hyperplane, যা দুই ক্লাসের মধ্যকার দূরত্ব সর্বোচ্চ রাখে। এর ফলে নতুন ও অজানা উপাত্তের ওপর SVM-এর নির্ভুলতা লজিস্টিক রিগ্রেশনের চেয়ে অনেক বেশি স্থিতিশীল হয়।
- **KNN বনাম SVM:** KNN একটি অলস শিক্ষণ পদ্ধতি (Lazy Learner)। এটি টেস্ট টাইমে প্রতিটি নতুন নমুনার জন্য সম্পূর্ণ ডেটাসেটের দূরত্বের গাণিতিক হিসাব করে, যা বৃহৎ ডেটাসেটে অত্যন্ত ধীরগতির এবং মেমোরি সাপেক্ষ। পক্ষান্তরে, SVM ট্রেনিং শেষে শুধুমাত্র সাপোর্ট ভেক্টরগুলোকে মেমোরিতে ধারণ করে। ফলে এর প্রেডিকশন স্পিড অত্যন্ত দ্রুত এবং মেমোরি সাশ্রয়ী।
- **Decision Tree ও Random Forest বনাম SVM:** বৃক্ষ-ভিত্তিক মডেলগুলো উপাত্ত ক্ষেত্রকে অক্ষ-বরাবর লম্বালম্বিভাবে (Axis-aligned splitting) খণ্ড বিখণ্ড করে। উপাত্তের বিন্যাস যদি বৃত্তাকার বা জটিল প্যাটার্নের হয়, তবে এই মডেলগুলো অতিরিক্ত ডালপালা গজিয়ে ওভারফিটিং (Overfitting) তৈরি করে। কিন্তু SVM তার RBF (Radial Basis Function) কার্নেল প্রয়োগ করে অতি সহজেই যেকোনো জটিল ও আঁকাবাঁকা বৃত্তাকার সীমানা নিখুঁতভাবে চিহ্নিত করতে পারে।
- **SLR/MLR বনাম SVM (SVR):** সাধারণ রৈখিক রিগ্রেশন মডেলগুলো আউটলায়ার (Outliers) বা অস্বাভাবিক মান দ্বারা তীব্রভাবে প্রভাবিত ও বিচ্যুত হয়। কিন্তু SVM রিগ্রেশন (SVR) তার মার্জিনাল বাউন্ডারির ভেতরের সুনির্দিষ্ট ত্রুটিকে (epsilon) সম্পূর্ণ উপেক্ষা করে, যা মডেলটিকে আউটলায়ারের বিরুদ্ধে অত্যন্ত প্রতিরোধী (Robust) করে তোলে।

সাপোর্ট ভেক্টর মেশিন (SVM)-কে কি লজিস্টিক রিগ্রেশন (Logistic Regression)-এর একটি উন্নত সংস্করণ বা বর্ধিত রূপ (Enhanced Version) বলা চলে? উপযুক্ত গাণিতিক ও জ্যামিতিক যুক্তিসহ আলোচনা করো।

তাত্ত্বিক এবং গাণিতিক দৃষ্টিকোণ থেকে সাপোর্ট ভেক্টর মেশিন (SVM) এবং লজিস্টিক রিগ্রেশন (Logistic Regression) দুটি ভিন্ন নীতিমালার ওপর ভিত্তি করে প্রতিষ্ঠিত পৃথক ক্লাসিফিকেশন অ্যালগরিদম। লজিস্টিক রিগ্রেশন যেখানে সম্ভাব্যতা (Probability) এবং সর্বোচ্চ সম্ভাব্যতা অনুমানের (Maximum Likelihood Estimation) ওপর ভিত্তি করে কাজ করে, সেখানে SVM জ্যামিতিক মার্জিন এবং অস্টিমাইজেশন তত্ত্বের ওপর ভিত্তি করে গড়ে উঠেছে। তবে, লজিস্টিক রিগ্রেশনের কিছু মৌলিক সীমাবদ্ধতা দূরীকরণ এবং ক্লাসিফিকেশন বাউন্ডারিকে জ্যামিতিকভাবে অধিক শক্তিশালী করার কারণে, লিনিয়ারলি সেপারেবল ও নন-লিনিয়ার ডেটা ক্লাসিফিকেশনের ক্ষেত্রে SVM-কে লজিস্টিক রিগ্রেশনের একটি "উন্নত বা বর্ধিত রূপ" (Enhanced Version) হিসেবে বিবেচনা করা যৌক্তিক।

নিচে প্রধান ৫টি গাঠনিক ও জ্যামিতিক রূপান্তরের মাধ্যমে এই উন্নয়ন প্রক্রিয়াটি ব্যাখ্যা করা হলো:

লস ফাংশনের উন্নয়ন (Loss Function Enhancement)

লজিস্টিক রিগ্রেশন এবং SVM-এর কার্যপদ্ধতির মূল পার্থক্য নিহিত রয়েছে এদের লস ফাংশনের (Loss Function) মধ্যে:

- **লজিস্টিক রিগ্রেশন (Cross-Entropy Loss):** এটি লিনিয়ার কম্বিনেশন $z = wx + b$ কে সিগময়েড ফাংশনে রূপান্তর করে সম্ভাবনা হিসাব করে। এর লস ফাংশন (Log Loss) প্রতিটি ডেটা পয়েন্টের দূরত্বের ওপর ভিত্তি করে ক্রমাগত পরিবর্তিত হয়। ফলে এটি সঠিক ও ভুল—উভয় প্রকার ক্লাসিফাইড পয়েন্টের আত্মবিশ্বাসের মাত্রা নিয়ে কাজ করে এবং প্রতিটি বিন্দুর জন্য কম-বেশি লস গণনা করে।
- **SVM (Hinge Loss):** SVM-এ লগ-লসকে প্রতিস্থাপন করা হয় হিঞ্জ লস (Hinge Loss) দ্বারা, যার গাণিতিক রূপ:

$$\text{Hinge Loss} = \max\{0, 1 - y_i(wx + b)\}$$

এই লস ফাংশনের অন্যতম বৈশিষ্ট্য হলো, যদি কোনো ডেটা পয়েন্ট সঠিকভাবে ক্লাসিফাইড হয় এবং মার্জিনের বাইরে থাকে ($y_i(wx + b) \geq 1$), তবে তার জন্য লসের মান সরাসরি **০ (Zero)** হয়ে যায়। এটি মডেলটিকে কেবল বাউন্ডারির নিকটবর্তী জটিল পয়েন্টগুলোর ওপর ফোকাস করতে বাধ্য করে।

মার্জিন ম্যাক্সিমাইজেশন এবং জ্যামিতিক বাউন্ডারি (Margin Maximization)

- **লজিস্টিক রিগ্রেশন:** লজিস্টিক রিগ্রেশনের মূল লক্ষ্য হলো এমন একটি ডিসিশন বাউন্ডারি ($wx + b = 0$) খুঁজে বের করা যা ডেটাসেটকে আলাদা করতে পারে। কিন্তু জ্যামিতিকভাবে এই বাউন্ডারিটি ডেটা পয়েন্ট থেকে কতটা দূরে থাকবে, তার কোনো সুনির্দিষ্ট নিয়ন্ত্রণ বা লক্ষ্য এতে থাকে না। এর ফলে বাউন্ডারিটি কোনো নির্দিষ্ট ক্লাসের অতি নিকটে চলে যেতে পারে, যা নতুন টেস্ট ডেটার ক্ষেত্রে ভুল সিদ্ধান্তের (Overfitting) ঝুঁকি বাড়ায়।
- **SVM (Maximum Margin Classifier):** SVM এই ধারণাকে উন্নত করে ডিসিশন বাউন্ডারির দুই পাশে একটি 'নিরাপদ অঞ্চল' বা **মার্জিন (Margin)** তৈরি করে। এর উদ্দেশ্য হলো মার্জিনের দূরত্ব $M = \frac{2}{|w|}$ কে সর্বোচ্চ (Maximize) করা। এই ম্যাক্সিমাম মার্জিন বৈশিষ্ট্যের কারণে মডেলটির সাধারণীকরণ ক্ষমতা (Generalization Ability) বহুগুণ বৃদ্ধি পায়।

আউটলায়ার প্রতিরোধ ক্ষমতা (Robustness to Outliers)

- **লজিস্টিক রিগ্রেশন:** লজিস্টিক রিগ্রেশনের লস ফাংশন পুরো ডেটাসেটের সব বিন্দুর ওপর নির্ভরশীল। ফলে ডিসিশন বাউন্ডারি থেকে অনেক দূরে অবস্থিত কোনো আউটলায়ার (Outlier) বা ভুল ডেটার সামান্য পরিবর্তনেও সম্পূর্ণ ডিসিশন বাউন্ডারিটি স্থানচ্যুত বা প্রভাবিত হতে পারে।
- **SVM:** SVM-এর ডিসিশন বাউন্ডারি কেবলমাত্র মার্জিনের ওপর বা মার্জিনের ভেতরে অবস্থিত নির্দিষ্ট কিছু বিন্দুর ওপর নির্ভর করে নির্ধারিত হয়, যাদের সাপোর্ট ভেক্টর (Support Vectors) বলা হয়। মার্জিনের বাইরে অবস্থিত অন্য হাজারটি বিন্দু পরিবর্তন বা অপসারণ করলেও ডিসিশন বাউন্ডারির কোনো পরিবর্তন হয় না। এই কারণে SVM আউটলায়ারের বিরুদ্ধে অত্যন্ত শক্তিশালী (Robust to Outliers)।

কার্নেল ট্রিক এবং নন-লিনিয়ার ডেটা ব্যবস্থাপন (The Kernel Trick)

- **লজিস্টিক রিগ্রেশন:** জটিল এবং বাস্তব জীবনের নন-লিনিয়ার ডেটা ক্লাসিফাই করার জন্য লজিস্টিক রিগ্রেশনে ম্যানুয়ালি উচ্চ-মাত্রার পলিনোমিয়াল ফিচার তৈরি করতে হয়, যা অত্যন্ত জটিল এবং কম্পিউটেশনালি ব্যয়বহুল।
- **SVM:** SVM-এ **কার্নেল ট্রিক (Kernel Trick)** নামক একটি উন্নত গাণিতিক কৌশল ব্যবহার করা হয়। এর মাধ্যমে মূল ইনপুট স্পেসের (Input Space) নন-লিনিয়ার ডেটাকে কোনো রূপান্তর ছাড়াই উচ্চ মাত্রার ফিচার স্পেসে (Feature Space) রূপান্তর করা যায় এবং সেখানে একটি লিনিয়ার হাইপারপ্লেন দ্বারা ডেটা আলাদা করা সম্ভব হয়। Linear,

Polynomial, এবং RBF (Gaussian) কার্নেল ব্যবহারের এই সুবিধা ক্লাসিফিকেশনের দক্ষতাকে লজিস্টিক রিগ্রেশনের তুলনায় বহুগুণ বাড়িয়ে দেয়।


সফট মার্জিন ও হাইপারপ্যারামিটার নিয়ন্ত্রণ (C)


লজিস্টিক রিগ্রেশনে ভুল ক্লাসিফিকেশনের ওপর জ্যামিতিক কঠোরতা নিয়ন্ত্রণের সরাসরি কোনো প্যারামিটার নেই। পক্ষান্তরে, SVM-এ হাইপারপ্যারামিটার C (Penalty Parameter) ব্যবহারের মাধ্যমে 'হার্ড মার্জিন' (যেখানে কোনো ভুল গ্রহণযোগ্য নয়) এবং 'সফট মার্জিন' (যেখানে কিছু ভুল বা ওভারল্যাপিং অনুমোদন করা হয়)-এর মধ্যে একটি চমৎকার ভারসাম্য রক্ষা করা যায়। এটি মডেলের ওভারফিটিং এবং আন্ডারফিটিং সমস্যা খুব নিখুঁতভাবে নিয়ন্ত্রণ করতে পারে।


পরিশেষে বলা যায় যে, যদিও লজিস্টিক রিগ্রেশন এবং SVM-এর তাত্ত্বিক সূত্রপাত ভিন্ন, তবুও লজিস্টিক রিগ্রেশনের ডিসিশন বাউন্ডারিকে জ্যামিতিক মার্জিন দ্বারা সুসংহত করা, হিঞ্জ লসের মাধ্যমে অপ্ৰয়োজনীয় বিন্দুর প্রভাব মুক্ত করা, এবং কার্নেল ট্রিকের সাহায্যে জটিল নন-লিনিয়ার ডেটা প্রক্রিয়াকরণের ক্ষমতা যোগ করার মাধ্যমে SVM ক্লাসিফিকেশন প্রক্রিয়াকে এক নতুন উচ্চতায় নিয়ে গেছে। অতএব, ব্যবহারিক ও কার্যকারিতার দিক থেকে **SVM-কে লজিস্টিক রিগ্রেশনের একটি অত্যন্ত শক্তিশালী এবং উন্নত সংস্করণ (Enhanced Version) বলা সম্পূর্ণ যুক্তিযুক্ত।**


মেশিন লার্নিং এবং সাপোর্ট ভেক্টর মেশিন (SVM) বোঝার জন্য ডেটার জ্যামিতিক রূপ জানা অত্যন্ত জরুরি। নিচে মাত্রার (Dimension) ওপর ভিত্তি করে প্রধান ৫টি জ্যামিতিক উপাদান সংক্ষেপে আলোচনা করা হলো:

Geometric Concepts in SVM

- 1. Point**
 A point represents a single data instance.
 

In n -dimensional space:
 $x = [x_1, x_2, \dots, x_n]^T$
- 2. Line**
 A line in 2D space separates the two classes.
 

Linear Equation:
 $w_1 x_1 + w_2 x_2 + b = 0$
 This is a line.
- 3. Plane**
 A plane in 3D space separates the two classes.
 

Linear Equation:
 $w_1 x_1 + w_2 x_2 + w_3 x_3 + b = 0$
 This is a plane.
- 4. Hyperplane**
 A hyperplane in n -dimensional space separates the two classes.
 

Linear Equation:
 $w^T x + b = 0$
 This is a hyperplane.
- 5. Linear Equation (General)**
 The general form of linear equation in n -dimensional space.

$w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b = 0$
 or $w^T x + b = 0$

This equation represents a hyperplane.

১. বিন্দু (Point)

- বহুমাত্রিক স্থানে একটি বিন্দু মূলত একটি একক ডেটা ইনস্ট্যান্স বা রেকর্ডকে নির্দেশ করে।
- গাণিতিক রূপ:** n -ডাইমেনশনাল স্পেসে একে একটি ভেক্টর হিসেবে প্রকাশ করা হয়:

$$x = [x_1, x_2, \dots, x_n]^T$$

২. রেখা (Line)

- দ্বিমাত্রিক (2D) স্থানে দুটি ভিন্ন ক্লাস বা ডেটা দলকে আলাদা করার জন্য ডিসিশন বাউন্ডারি হিসেবে একটি সরলরেখা ব্যবহার করা হয়।
- লিনিয়ার সমীকরণ (Linear Equation):**

$$w_1 x_1 + w_2 x_2 + b = 0$$

৩. সমতল (Plane)

- ত্রিমাত্রিক (3D) স্থানে দুটি ক্লাসকে পৃথক করার বাউন্ডারি হিসেবে একটি চ্যাপ্টা সমতল পৃষ্ঠ বা প্লেন ব্যবহৃত হয়।

- **লিনিয়ার সমীকরণ (Linear Equation):**

$$w_1x_1 + w_2x_2 + w_3x_3 + b = 0$$

৪. হাইপারপ্লেন (Hyperplane)

- যখন ডেটার মাত্রা n -ডাইমেনশনে রূপ নেয়, তখন ক্লাস দুটিকে আলাদা করার বাউন্ডারিকে **হাইপারপ্লেন** বলা হয়।

- **লিনিয়ার সমীকরণ (Linear Equation):**

$$w^T x + b = 0$$

৫. সাধারণ লিনিয়ার সমীকরণ (Linear Equation - General)

- এটি হলো n -ডাইমেনশনাল স্পেসে যেকোনো ডিসিশন বাউন্ডারি প্রকাশের একটি সাধারণ গাণিতিক রূপ। এই সমীকরণটি মূলত একটি **হাইপারপ্লেন**-কে নির্দেশ করে।

- **সাধারণ রূপ:**

$$w_1x_1 + w_2x_2 + \dots + w_nx_n + b = 0 \quad \text{অথবা} \quad w^T x + b = 0$$

ম্যাক্সিমাম মার্জিন ক্লাসিফায়ার (Maximum Margin Classifier)

SVM-কে একটি ম্যাক্সিমাম মার্জিন ক্লাসিফায়ার বলা হয়। এটি কেবল দুই ক্লাসের ডেটাকে আলাদাই করে না, বরং উভয় ক্লাসের নিকটবর্তী ডেটা পয়েন্ট থেকে সমান দূরত্ব বজায় রেখে সম্ভাব্য সবচেয়ে চওড়া রাস্তা বা সর্বোচ্চ মার্জিন (Maximum Margin) তৈরি করে সিদ্ধান্ত রেখা নির্ধারণ করে।


ম্যাক্সিমাম মার্জিন কেন গুরুত্বপূর্ণ (Why Maximum Margin is important)

- **Better Generalization:** মার্জিনের মান যত বড় হবে ($M = \frac{2}{|w|}$), মডেলটির নতুন ও অজানা ডেটার ওপর সঠিক প্রেডিকশন দেওয়ার ক্ষমতা (Generalization Ability) তত বেশি বৃদ্ধি পায়।

Overfitting রোধ: মার্জিন ছোট হলে ডিসিশন বাউন্ডারি কোনো একটি ক্লাসের খুব কাছাকাছি চলে যায়, যা ওভারফিটিংয়ের ঝুঁকি বাড়ায়। ম্যাক্সিমাম মার্জিন মডেলকে এই ঝুঁকি থেকে মুক্ত রাখে।

3.1 What is Support Vector Machine (SVM)?

- SVM is a supervised learning algorithm used for classification (mainly binary classification).
- The main idea of SVM is to find the optimal decision boundary (hyperplane) that separates the classes with the maximum margin.
- It is a Maximum Margin Classifier.
- SVM works well even when there are outliers in the data.



3.2 Components of SVM

① Decision Boundary / Hyperplane

The boundary that separates the classes.

② Margin

The distance between the hyperplane and the nearest data points from both classes.

③ Support Vectors


The data points that lie closest to the decision boundary. These points define the position of the boundary.

④ Generalized Model

SVM finds the best boundary that works well on new, unseen data.


3.3 Types of Dataset

① Linearly Separable Data



Classes can be separated perfectly by a straight line / hyperplane.

② Non-Linearly Separable Data



Classes cannot be separated by a straight line / hyperplane. (Need Kernel Trick)

আউটলায়ারের বিরুদ্ধে প্রতিরোধ ক্ষমতা (Robustness against Outliers)

SVM আউটলায়ারের বিরুদ্ধে অত্যন্ত শক্তিশালী বা প্রতিরোধী (Robust to Outliers)। এর ডিসিশন বাউন্ডারি ডেটাসেটের সমস্ত বিন্দুর ওপর নির্ভর করে না; বরং এটি কেবল মার্জিনের প্রান্তে থাকা নির্দিষ্ট কিছু পয়েন্টের ওপর ভিত্তি করে তৈরি হয়। ফলে বাউন্ডারি থেকে দূরে থাকা কোনো আউটলায়ারের সামান্য পরিবর্তনে মূল সিদ্ধান্ত রেখার কোনো পরিবর্তন হয় listen না।

SVM-এর উপাদানসমূহ (Components of SVM)

ডিসিশন বাউন্ডারি (Decision Boundary)

দুই বা বহুমাত্রিক স্থানে বিভিন্ন ক্লাসের ডেটাকে পৃথক করার জন্য যে জ্যামিতিক রেখা, সমতল বা হাইপারপ্লেন ব্যবহার করা হয়, তাকে ডিসিশন বাউন্ডারি বলে। গাণিতিকভাবে একে $\pi = wx + b = 0$ সমীকরণ দ্বারা প্রকাশ করা হয়।

মার্জিন (Margin)

ডিসিশন বাউন্ডারি বা কেন্দ্রীয় হাইপারপ্লেন থেকে উভয় পাশের ক্লাসের নিকটবর্তী ডেটা পয়েন্টের মধ্যবর্তী মোট দূরত্বকে মার্জিন বলে ($M = d_1 + d_2$)। এটি মূলত একটি সুরক্ষিত অঞ্চল (Safe Zone) হিসেবে কাজ করে।

সাপোর্ট ভেক্টরস (Support Vectors)

ডেটাসেটের যে নির্দিষ্ট বিন্দু বা ডেটা ইনস্ট্যান্সগুলো মার্জিনের সীমানার ওপর অবস্থান করে এবং ডিসিশন বাউন্ডারির অবস্থান ও আকৃতি নির্ধারণে সরাসরি ভূমিকা রাখে, সেগুলোকে সাপোর্ট ভেক্টর বলে। এই ভেক্টরগুলো সরিয়ে নিলে পুরো মডেলের বাউন্ডারি পরিবর্তন হয়ে যায়।

জেনারেলাইজড মডেল (Generalized Model)

সাপোর্ট ভেক্টর ও ম্যাক্সিমাম মার্জিন ব্যবহারের মাধ্যমে তৈরি ডিসিশন বাউন্ডারিটি একটি জেনারেলাইজড বা সাধারণীকরণ মডেল তৈরি করে। এটি ট্রেনিং ডেটার পাশাপাশি সম্পূর্ণ নতুন বা টেস্ট ডেটার ওপরেও সমানভাবে নির্ভুল ফলাফল দিতে সক্ষম।

ডেটাসেটের প্রকারভেদ (Types of Dataset)

লিনিয়ারলি সেপারেবল ডেটা (Linearly Separable Data)

যেসব ডেটাসেটের ক্লাসগুলোকে একটিমাত্র সোজা সরলরেখা (2D-তে), সমতল (3D-তে) বা লিনিয়ার হাইপারপ্লেন দ্বারা সম্পূর্ণ আলাদা করা সম্ভব, সেগুলোকে লিনিয়ারলি সেপারেবল ডেটা বলে। এই ক্ষেত্রে কোনো ভুল বা ওভারল্যাপিং ছাড়া "Hard Margin" ব্যবহার করে নিখুঁত ক্লাসিফিকেশন করা যায়।

নন-লিনিয়ারলি সেপারেবল ডেটা (Non-Linearly Separable Data)

বাস্তব জীবনের যেসব জটিল ডেটাসেটকে কোনো সোজা লাইন বা সমতল হাইপারপ্লেন দিয়ে আলাদা করা যায় না, সেগুলোকে নন-লিনিয়ার ডেটা বলে। এই ধরনের ডেটা ক্লাসিফাই করার জন্য SVM-এ "Kernel Trick" ব্যবহার করে ডেটাকে উচ্চ মাত্রার ফিচার স্পেসে রূপান্তর করে আলাদা করা হয়।

হাইপারপ্লেনের প্রাথমিক সমীকরণসমূহ

ধরা যাক, একটি বহুমাত্রিক স্পেসে আমাদের কাছে দুই ধরনের ক্লাস রয়েছে—পজিটিভ (+1) এবং নেগেটিভ (-1)। এই দুই ক্লাসের মধ্যবর্তী স্থানে আমরা তিনটি সমান্তরাল হাইপারপ্লেন বা ডিসিশন বাউন্ডারি বিবেচনা করি:

1. কেন্দ্রীয় সিদ্ধান্ত রেখা (Optimal Hyperplane):

$$w^T x + b = 0$$

2. পজিটিভ মার্জিনাল হাইপারপ্লেন (π_+):

$$w^T x + b = +1$$

3. নেগেটিভ মার্জিনাল হাইপারপ্লেন (π_-):

$$w^T x + b = -1$$

এখানে, w হলো লম্ব ভেক্টর বা ওয়েট ভেক্টর (Weight Vector), x হলো ইনপুট ফিচার ভেক্টর এবং b হলো বায়াস (Bias)।

এখানে, $w = [w_1, w_2, w_3, \dots, w_n]$ হলো ওয়েট ম্যাট্রিক্স বা ভেক্টর এবং এর মান বা ম্যাগনিটিউড বের করার সূত্রটি:

$$|w| = \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}$$

7. HYPERPLANE EQUATION

$$\pi = w^T x + b \quad \text{or} \quad wx + b = 0$$

where,

w = weight vector (normal to the hyperplane)


x = input feature vector

b = bias

This equation represents the decision boundary that separates two classes.


8. PARALLEL HYPERPLANES

- Positive Hyperplane : $wx + b = +1$
- Decision Boundary : $wx + b = 0$
- Negative Hyperplane : $wx + b = -1$



9. SUPPORT VECTORS

- The data points that are closest to the decision boundary.
- They lie on the margin boundaries ($wx+b=+1$ or $wx+b=-1$).
- These points are called Support Vectors.
- They play a crucial role in defining the position and orientation of the hyperplane.



10. MARGIN CALCULATION

- Distance from a point x to the hyperplane $wx+b=0$ is


$$d = \frac{|wx+b|}{\|w\|}$$

For support vectors (on the margin boundaries),

$$|wx+b|=1 \Rightarrow d = \frac{1}{\|w\|}$$

Total Margin (distance between the two margin boundaries) is $\uparrow$

$$M = \frac{2}{\|w\|}$$



Larger margin = better generalization

11. WEIGHT VECTOR MAGNITUDE

The magnitude (or Euclidean norm) of the weight vector w is

$$\|w\| = \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}$$

where,

$$w = [w_1, w_2, \dots, w_n]^T \in \mathbb{R}^n$$

A smaller $\|w\|$ leads to a larger margin.

So, SVM tries to minimize $\|w\|$ to maximize the margin.

ডিসিশন বাউন্ডারি থেকে দুই পাশের মার্জিনাল লাইনের দূরত্ব পরস্পর সমান, অর্থাৎ:

$$d_1 = d_2$$

এখানে, কেন্দ্রীয় লাইন থেকে যেকোনো একপাশের দূরত্বের জ্যামিতিক সূত্রটি হলো:

$$\text{distance} = \frac{wx + b}{\|w\|}$$

এখন, পজিটিভ মার্জিনাল লাইনের সীমানার ওপর থাকা বিন্দুর জন্য স্কের $wx + b = +1$ । সুতরাং, কেন্দ্রীয় লাইন থেকে পজিটিভ লাইনের দূরত্ব:

$$d_1 = \frac{1}{\|w\|}$$

যেহেতু দুই পাশের দূরত্ব সমান ($d_1 = d_2$), তাই অপর পাশের দূরত্বটিও হবে:

$$d_2 = \frac{1}{\|w\|}$$

নোটের চিত্র ও সমীকরণ অনুযায়ী, মোট মার্জিন (M) হলো এই দুই দূরত্বের সমষ্টি:

$$\text{Margin}(M) = d_1 + d_2$$

$$M = 2 \times d_1$$

এখন d_1 -এর মান বসিয়ে আমরা পাই:

$$M = 2 \times \frac{1}{|w|} = \frac{2}{|w|}$$

- " $|w|$ যত ছোট হবে, M তত বড় হবে"
- "Target Margin maximize করা"

গাণিতিক নিয়ম অনুযায়ী, ভগ্নাংশের হর ($|w|$) যত ছোট বা ডিক্রিজ করা যাবে, সম্পূর্ণ ভগ্নাংশের মান অর্থাৎ মার্জিন (M) তত বড় বা ম্যাক্সিমাইজ হবে। যেহেতু SVM-এর প্রধান লক্ষ্যই হলো দুই ক্লাসের মধ্যকার দূরত্ব বা মার্জিন সর্বোচ্চ করা (Target Margin Maximize), তাই মডেলটি সর্বদা $|w|$ -এর মানকে সর্বনিম্ন (Minimize) করার চেষ্টা করে।

মার্জিন সর্বোচ্চকরণ (Maximize Margin)

সাপোর্ট ভেক্টর মেশিনের প্রধান গাণিতিক লক্ষ্য হলো পজিটিভ এবং নেগেটিভ ক্লাসের মধ্যবর্তী দূরত্ব বা মার্জিন (M) সর্বোচ্চ করা। জ্যামিতিক প্রতিপাদন থেকে প্রাপ্ত মার্জিনের গাণিতিক রূপটি হলো:

$$M = \frac{2}{|w|}$$

সমতুল্য সর্বনিম্নকরণ সমস্যা (Equivalent Minimization Problem)

বীজগণিতীয় নিয়ম অনুযায়ী, কোনো ভগ্নাংশের মানকে সর্বোচ্চ (Maximize) করতে হলে তার হর-এর মানকে সর্বনিম্ন করতে হয়। অর্থাৎ, মার্জিন $M = \frac{2}{|w|}$ কে সর্বোচ্চ করার অর্থ হলো ওয়েট ভেক্টরের ম্যাগনিচিউড $|w|$ কে সর্বনিম্ন (Minimize) করা।

ক্যালকুলাস এবং ডিফারেনশিয়েশনের সুবিধার্থে (বিশেষ করে বর্গমূলের জটিলতা এড়াতে) এই সর্বোচ্চকরণের সমস্যাটিকে একটি সমতুল্য সর্বনিম্নকরণ সমস্যা হিসেবে নিচে রূপান্তর করা হয়:

$$\min \frac{1}{2} |w|^2$$

হিঞ্জ লস (Hinge Loss)

বাস্তব জীবনের ডেটাসেটে সম্পূর্ণ নিখুঁতভাবে ডেটা আলাদা করা সবসময় সম্ভব হয় না। মডেলের এই ত্রুটি বা ভুলের পরিমাণ গাণিতিকভাবে গণনা করার জন্য Hinge Loss ফাংশন ব্যবহার করা হয়। এর গাণিতিক সূত্রটি নিম্নরূপ:

$$\text{Hinge Loss} = \max\{0, 1 - y_i(wx + b)\}$$

এখানে, y_i হলো ডেটার প্রকৃত ক্লাস বা লেবেল (+1 অথবা -1) এবং $(wx + b)$ হলো মডেল দ্বারা প্রাপ্ত প্রেডিকশন স্কোর।

বিভিন্ন ক্ষেত্রে হিঞ্জ লসের মান (Different Hinge Loss Cases)

ডিসিশন বাউন্ডারির সাপেক্ষে কোনো ডেটা পয়েন্ট কোথায় অবস্থান করছে, তার ওপর ভিত্তি করে হিঞ্জ লসের মানকে ৩টি সুনির্দিষ্ট ক্ষেত্রে বিভক্ত করা যায়:

ক. সঠিক ক্লাসিফিকেশন (Correct Classification)

যখন কোনো ডেটা পয়েন্ট সম্পূর্ণ সঠিকভাবে মার্জিনের সুরক্ষিত অঞ্চলের বাইরে ক্লাসিফাই হয় (অর্থাৎ, $y_i(wx + b) \geq 1$), তখন সমীকরণের ভেতরের মানটি ঋণাত্মক বা শূন্য হয়ে যায়।

- **গাণিতিক উদাহরণ:** যদি $y_i(wx + b) = 2$ হয়, তবে $1 - 2 = -1$ ।
- **লস গণনা:** $\max(0, -1) = 0$ ।
- **সিদ্ধান্ত:** সঠিকভাবে ক্লাসিফাইড এবং মার্জিনের বাইরের বিন্দুর জন্য মডেলে কোনো পেনাল্টি বা লস যুক্ত হয় না।

খ. সঠিক কিন্তু মার্জিনের ভেতরে (Correct but Inside Margin)

যখন কোনো পয়েন্ট সঠিকভাবে সঠিক ক্লাসে অবস্থান করে, কিন্তু সেটি মার্জিনের সীমানার ভেতরে ঢুকে পড়ে (অর্থাৎ, $0 \leq y_i(wx + b) < 1$), তখন মডেলের জন্য পেনাল্টি তৈরি হয়।

- **গাণিতিক উদাহরণ:** যদি $y_i(wx + b) = 0.5$ হয়, তবে $1 - 0.5 = 0.5$ ।
- **লস গণনা:** $\max(0, 0.5) = 0.5$ ।
- **সিদ্ধান্ত:** যদিও পয়েন্টটি সঠিক ক্লাসেই আছে, তবুও মার্জিন লঙ্ঘন করার অপরাধে মডেলটিকে কিছুটা লস বা পেনাল্টি গুনতে হয়।

গ. ভুল ক্লাসিফিকেশন (Misclassified)

যখন কোনো ডেটা পয়েন্ট সম্পূর্ণ ভুল ক্লাসে চলে যায় এবং ডিসিশন বাউন্ডারি পার হয়ে অন্য পাশে অবস্থান করে (অর্থাৎ, $y_i(wx + b) < 0$), তখন লসের মান ধনাত্মকভাবে বৃদ্ধি পায়।

- **গাণিতিক উদাহরণ:** যদি $y_i(wx + b) = -0.5$ হয়, তবে $1 - (-0.5) = 1 + 0.5 = 1.5$ ।
- **লস গণনা:** $\max(0, 1.5) = 1.5$ ।
- **সিদ্ধান্ত:** ভুল ক্লাসিফিকেশনের জন্য মডেলকে সর্বোচ্চ পেনাল্টি দেওয়া হয়। ডিসিশন বাউন্ডারি থেকে পয়েন্টটি যত দূরে ভুল দিকে যাবে, লসের পরিমাণও তত রৈখিকভাবে বাড়তে থাকবে।

চূড়ান্ত কস্ট ফাংশন (Final Cost Function)

SVM-এর মূল উদ্দেশ্য (মার্জিন সর্বোচ্চ করা) এবং হিঞ্জ লস (ভুলের পেনাল্টি সর্বনিম্ন করা)—এই দুটি ভিন্ন লক্ষ্যকে একটি একক সমীকরণে যুক্ত করে চূড়ান্ত কস্ট ফাংশন J গঠন করা হয়:

$$J = \frac{1}{2} \|w\|^2 + \sum \text{Hinge Loss}$$

এই সমীকরণের প্রথম অংশ ($\frac{1}{2} \|w\|^2$) মার্জিনকে বড় করার চেষ্টা করে (যা রেগুলারাইজেশন হিসেবে কাজ করে) এবং দ্বিতীয় অংশ ($\sum \text{Hinge Loss}$) মডেলের ক্লাসিফিকেশন ভুলগুলোকে দমন করার চেষ্টা করে। একটি আদর্শ মডেল এই দুটি বিষয়ের মধ্যে একটি নিখুঁত গাণিতিক ভারসাম্য বজায় রাখে।

কোয়াদ্রেটিক প্রোগ্রামিং (Quadratic Programming - QP)

অপটিমাইজেশন টেকনিক (Optimization Technique)

চূড়ান্ত কস্ট ফাংশন J -এর মান সর্বনিম্ন করার জন্য এবং নির্দিষ্ট শর্তসাপেক্ষে (Constraints) অপটিমাল প্যারামিটার খোঁজার জন্য যে গাণিতিক ও কম্পিউটেশনাল পদ্ধতি ব্যবহার করা হয়, তাকে কোয়াদ্রেটিক প্রোগ্রামিং (QP) বলা হয়।

উত্তল অপটিমাইজেশন (Convex Optimization)

যেহেতু SVM-এর এই কস্ট ফাংশনটি একটি **উত্তল ফাংশন** বা **Convex Function**, সেহেতু এর জ্যামিতিক গ্রাফে কেবল একটিমাত্র সর্বনিম্ন বিন্দু বা **Global Minima** থাকে। কোয়াদ্রেটিক প্রোগ্রামিং টেকনিক ব্যবহারের মাধ্যমে কোনো লোকাল মিনিমামে (Local Minima) না আটকে সরাসরি বৈশ্বিক বা নিখুঁত অপটিমাল সলিউশন খুঁজে পাওয়া নিশ্চিত করা সম্ভব হয়।

হার্ড মার্জিন ও সফট মার্জিন (Hard Margin & Soft Margin)

বাস্তব জীবনের ডেটাসেটগুলোর গঠন এবং জটিলতার ওপর ভিত্তি করে সাপোর্ট ভেক্টর মেশিনের ডিসিশন বাউন্ডারি নির্ধারণের পদ্ধতিকে প্রধানত দুটি ভাগে ভাগ করা যায়। নিচে এই দুটি মার্জিন পদ্ধতি এবং তাদের নিয়ন্ত্রণকারী প্যারামিটার বিস্তারিতভাবে আলোচনা করা হলো:

হার্ড মার্জিন এসভিএম (Hard Margin SVM)

কোনো ভুল ক্লাসিফিকেশন নয় (No Misclassification)

হার্ড মার্জিন এসভিএম-এর প্রধান বৈশিষ্ট্য হলো এটি ডিসিশন বাউন্ডারি বা মার্জিনের ভেতরে কোনো ধরনের ভুল ক্লাসিফিকেশন বা ডেটা পয়েন্টের অনুপ্রবেশ অনুমোদন করে না। অর্থাৎ, প্রতিটি ডেটা পয়েন্টকে অবশ্যই মার্জিনের সঠিক পাশে এবং বাইরে অবস্থান করতে হবে।

নিখুঁতভাবে পৃথকীকরণযোগ্য ডেটা (Perfectly Separable Data)

এই পদ্ধতিটি কেবল তখনই সফলভাবে কাজ করে, যখন ডেটাসেটটি লিনিয়ারলি নিখুঁতভাবে পৃথকীকরণযোগ্য (Perfectly Separable Data) হয়। যদি ডেটার মধ্যে কোনো নয়েজ (Noise) বা ওভারল্যাপিং থাকে, তবে হার্ড মার্জিন মডেল কোনো গাণিতিক সমাধানে পৌঁছাতে পারে না এবং ব্যর্থ হয়।


সফট মার্জিন এসভিএম (Soft Margin SVM)

ভুল ক্লাসিফিকেশন অনুমোদন (Allows Errors)

বাস্তবসম্মত সমাধানের জন্য সফট মার্জিন এসভিএম ডিসিশন বাউন্ডারি নির্ধারণের ক্ষেত্রে কিছুটা শিথিলতা প্রদর্শন করে। এই পদ্ধতিতে মডেলটি মার্জিনের ভেতরে বা ভুল পাশে কিছু সীমিত সংখ্যক ডেটা পয়েন্টের উপস্থিতি বা ত্রুটি অনুমোদন (Allows Errors) করে।


5.1 Hard Margin SVM

- Used when data is **linearly separable**.
- No misclassification allowed.
- Finds the maximum margin hyperplane that separates the two classes perfectly.



5.2 Soft Margin SVM

- Used when data is **not perfectly linearly separable**.
- Allows some misclassifications.
- More flexible and better generalization to real-world data.



5.3 Penalty Parameter (C)

In soft margin SVM, we use a penalty parameter C to control the **trade-off** between margin size and classification error.

Soft Margin SVM Objective:

$$\text{Minimize } J = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

- $\frac{1}{2} \|w\|^2 \rightarrow$ Maximizes the margin
- $C \sum_{i=1}^n \xi_i \rightarrow$ Penalty for misclassification
- $\xi_i \rightarrow$ Slack variable ($\xi_i \geq 0$)

5.4 Effect of C (Penalty Parameter)


Large C ($C \uparrow$)

- High penalty on misclassification
- Tries to classify all points correctly
- Margin becomes smaller
- Behaves like **Hard Margin**



Small C ($C \downarrow$)

- Low penalty on misclassification
- Allows more errors
- Margin becomes larger
- Behaves like **Soft Margin**



Summary


- Hard Margin $\rightarrow$ No error, smaller flexibility.
- Soft Margin $\rightarrow$ Allows error, better generalization.
- C controls the balance between margin size and training error.

Key Points

- C is a very important hyperparameter in SVM.
- Proper choice of C improves the performance of the model.
- Use **cross-validation** to select the best C .

উন্নত সাধারণীকরণ ক্ষমতা (Better Generalization)

কিছু ভুল বা ওভারল্যাপিং মেনে নেওয়ার কারণে সফট মার্জিন এসভিএম-এর ডিসিশন বাউন্ডারিটি খুব বেশি জটিল বা ওভারফিটেড হয় না। ফলে, এটি নতুন এবং অজানা টেস্ট ডেটার ওপর অনেক উন্নত সাধারণীকরণ ক্ষমতা (Better Generalization) বা নির্ভুল ফলাফল প্রদর্শন করতে পারে।



বাস্তব জীবনের ডেটা (Real World Data)

বাস্তব জীবনের প্রায় প্রতিটি ডেটাসেটই নয়েজ, আউটলায়ার এবং জটিল ওভারল্যাপিংয়ে পূর্ণ থাকে। এই ধরনের বাস্তবসম্মত ডেটা (Real World Data) অত্যন্ত সফলভাবে পরিচালনা করার জন্য সফট মার্জিন এসভিএম একটি আদর্শ ও অপরিহার্য পদ্ধতি।

পেনাল্টি প্যারামিটার (Penalty Parameter - C)

সফট মার্জিন এসভিএম-এ মডেলটি কতটা ভুল ক্লাসিফিকেশন মেনে নেবে, তা একটি নির্দিষ্ট হাইপারপ্যারামিটার দ্বারা নিয়ন্ত্রিত হয়, যাকে পেনাল্টি প্যারামিটার বা C বলা হয়।

বড় সি-এর প্রভাব (Large C)

- কম ভুল ক্লাসিফিকেশন (Less Misclassification):** C -এর মান অনেক বড় হলে মডেলটি ভুলের জন্য উচ্চ পেনাল্টি বা শাস্তি নির্ধারণ করে। ফলে মডেলটি যেকোনো মূল্যে ভুল ক্লাসিফিকেশন এড়ানোর চেষ্টা করে এবং হার্ড মার্জিনের মতো আচরণ করে।

- **ছোট মার্জিন (Small Margin):** প্রতিটি বিন্দুকে নিখুঁতভাবে ক্লাসিফাই করার প্রয়াসে ডিসিশন বাউন্ডারির দুই পাশের মার্জিনটি অত্যন্ত সংকুচিত বা ছোট (Small Margin) হয়ে যায়।

ছোট সি-এর প্রভাব (Small C)

- **অধিক সহনশীলতা (More Tolerance):** C -এর মান ছোট হলে ভুল ক্লাসিফিকেশনের ওপর পেনাল্টির কঠোরতা অনেক কমে যায়। এর ফলে মডেলটি মার্জিনের ভেতরে বা ভুল পাশে ডেটা পয়েন্টের উপস্থিতির প্রতি অধিক সহনশীলতা (More Tolerance) প্রদর্শন করে।

বড় মার্জিন (Large Margin): ব্যক্তিগত বা বিচ্ছিন্ন কিছু ভুলকে উপেক্ষা করার কারণে মডেলটি দুই ক্লাসের মাঝে একটি সুপারিসর এবং বড় মার্জিন (Large Margin) তৈরি করতে সক্ষম হয়, যা মডেলের সাধারণীকরণ ক্ষমতাকে আরও মজবুত করে।

কার্নেল ট্রিক (Kernel Trick)

কার্নেলের প্রয়োজনীয়তা (Need for Kernel)

নন-লিনিয়ার ডেটা (Non-linear Data)

বাস্তব ক্ষেত্রের অধিকাংশ ডেটাসেটই সরলরৈখিকভাবে বিন্যস্ত থাকে না। যখন বিভিন্ন ক্লাসের ডেটা পয়েন্টগুলো একে অপরের সাথে এমনভাবে মিশ্রিত বা আবর্তিত অবস্থায় থাকে যে তাদেরকে কোনো সোজা সরলরেখা বা সমতল হাইপারপ্লেন দ্বারা আলাদা করা অসম্ভব হয়ে পড়ে, তখন তাকে নন-লিনিয়ার ডেটা বলা হয়। এই ধরনের ডেটা ক্লাসিফাই করার জন্য সাধারণ লিনিয়ার এসভিএম (Linear SVM) কার্যকর হয় না।

উচ্চ-মাত্রার ম্যাপিং (High-dimensional Mapping)

নন-লিনিয়ার ডেটার এই জটিলতা দূর করার একটি জ্যামিতিক উপায় হলো ডেটা পয়েন্টগুলোকে বর্তমান মাত্রা থেকে আরও উচ্চ মাত্রার (Higher Dimension) কোনো স্পেসে স্থানান্তরিত বা ম্যাপিং করা। কম মাত্রার স্পেসে যে ডেটা লিনিয়ারলি সেপারেবল নয়, উচ্চ মাত্রার স্পেসে ম্যাপিং করার পর সেখানে একটি সরলরৈখিক হাইপারপ্লেন দ্বারা তাদেরকে খুব সহজেই আলাদা করা সম্ভব হয়।

ফিচার ম্যাপিং (Feature Mapping)

ফিচার ম্যাপিং হলো নিম্ন-মাত্রার ইনপুট স্পেস থেকে উচ্চ-মাত্রার ফিচার স্পেসে ডেটা রূপান্তরের একটি গাণিতিক প্রক্রিয়া।

[ইনপুট স্পেস] ----- (ফিচার ম্যাপিং: $\phi(x)$) -----> [ফিচার স্পেস]

(নন-লিনিয়ার ডেটা)

(লিনিয়ারলি সেপারেবল ডেটা)

ইনপুট স্পেস (Input Space)

এটি হলো ডেটার মূল বা প্রাথমিক ডাইমেনশন, যেখানে ফিচারগুলো সরাসরি ইনপুট হিসেবে অবস্থান করে। এই স্পেসে ডেটা পয়েন্টগুলো সাধারণত নন-লিনিয়ার বা গোলকধাঁধার মতো বিন্যাসে থাকে।

ফিচার স্পেস (Feature Space)

ইনপুট স্পেসের ডেটাকে গাণিতিক রূপান্তরের মাধ্যমে যখন একটি নতুন এবং উচ্চ-মাত্রার ডাইমেনশনে নিয়ে যাওয়া হয়, তখন সেই নতুন স্থানটিকে ফিচার স্পেস বলা হয়। এই স্পেসে জটিল ডেটাও লিনিয়ার ডিসিশন বাউন্ডারি দ্বারা বিভাজনযোগ্য হয়ে ওঠে।

$\phi(x)$ ফাংশন

ইনপুট স্পেসের একটি সাধারণ ভেক্টর x -কে উচ্চ-মাত্রার ফিচার স্পেসে রূপান্তরিত করার জন্য যে ম্যাপিং ফাংশন ব্যবহার করা হয়, তাকে $\phi(x)$ দ্বারা প্রকাশ করা হয়। তবে সরাসরি উচ্চ-মাত্রার ফিচার গণনা করা কম্পিউটেশনালি অত্যন্ত ব্যয়বহুল। এসভিএম-এ এই উচ্চ-মাত্রার রূপান্তরের ডট গুণফলকে সরাসরি এবং সহজে গণনা করার গাণিতিক কৌশলকেই মূলত **কার্নেল ট্রিক (Kernel Trick)** বলা হয়।

বিভিন্ন প্রকার কার্নেল (Types of Kernels)

লিনিয়ার কার্নেল (Linear Kernel)

যখন ডেটা পয়েন্টগুলো ইতিমধ্যে সরলরৈখিকভাবে পৃথকীকরণযোগ্য অবস্থায় থাকে, তখন লিনিয়ার কার্নেল ব্যবহার করা হয়। এটি ডেটার ওপর কোনো উচ্চ-মাত্রার রূপান্তর প্রয়োগ না করে সরাসরি মূল ইনপুট স্পেসেই ডিসিশন বাউন্ডারি তৈরি করে।

পলিনোমিয়াল কার্নেল (Polynomial Kernel)

পলিনোমিয়াল কার্নেল ইনপুট ফিচারের বিভিন্ন ঘাত বা শক্তির সংমিশ্রণ তৈরি করে ডেটাকে উচ্চ মাত্রায় নিয়ে যায়। এটি একটি নির্দিষ্ট সীমার মধ্যে ফিচারগুলোর মধ্যকার পারস্পরিক সম্পর্ক বা ইন্টারঅ্যাকশন বিবেচনা করতে সাহায্য করে।

- **হাইপারপ্যারামিটার - Degree:** পলিনোমিয়াল কার্নেলের প্রধান হাইপারপ্যারামিটার হলো এর ডিগ্রি (Degree)। ডিগ্রির মান নির্ধারণ করে যে ডেটাকে কত উচ্চ-মাত্রার পলিনোমিয়াল স্পেসে রূপান্তর করা হবে। ডিগ্রির মান যত বেশি হবে, ডিসিশন বাউন্ডারি তত বেশি জটিল আকার ধারণ করবে।

গাউসিয়ান / আরবিএফ কার্নেল (Gaussian / RBF Kernel)

রেডিয়াল বেসিস ফাংশন (RBF) বা গাউসিয়ান কার্নেল হলো এসভিএম-এর সবচেয়ে জনপ্রিয় এবং শক্তিশালী কার্নেলগুলোর একটি। এটি ডেটা পয়েন্টগুলোকে একটি অসীম-মাত্রার (Infinite-dimensional) ফিচার স্পেসে ম্যাপিং করতে পারে, যার ফলে অত্যন্ত জটিল এবং বৃত্তাকার ডেটা বিন্যাসকেও নিখুঁতভাবে আলাদা করা সম্ভব হয়।

- **হাইপারপ্যারামিটার - Gamma:** আরবিএফ কার্নেলের আচরণ নিয়ন্ত্রণ করার প্রধান হাইপারপ্যারামিটার হলো গামা (γ)। গামার মান নির্ধারণ করে একটি একক ট্রেনিং পয়েন্টের প্রভাব ডিসিশন বাউন্ডারির ওপর কতদূর পর্যন্ত বিস্তৃত থাকবে।

অধ্যায়: হাইপারপ্যারামিটার টিউনিং (Hyperparameter Tuning)

সাপোর্ট ভেক্টর ক্লাসিফায়ারের প্যারামিটারসমূহ (Support Vector Classifier Parameters)

একটি সাপোর্ট ভেক্টর ক্লাসিফায়ার (SVC) মডেলের কার্যকারিতা এবং বাউন্ডারির আকৃতি মূলত ৪টি প্রধান হাইপারপ্যারামিটারের ওপর নির্ভর করে:

- **C:** এটি হলো সফট মার্জিনের পেনাল্টি প্যারামিটার, যা ক্লাসিফিকেশন ভুল এবং মার্জিনের আকারের মধ্যে ভারসাম্য বজায় রাখে।
- **Kernel:** এটি মডেলের জন্য উপযুক্ত কার্নেল টাইপ (যেমন: 'linear', 'poly', 'rbf') নির্বাচন করে জটিল ডেটা প্রসেস করার পথ নির্ধারণ করে।
- **Gamma:** এটি মূলত RBF কার্নেলের জন্য ব্যবহৃত প্যারামিটার, যা ডিসিশন বাউন্ডারির বক্রতা ও স্পর্শকাতরতা নিয়ন্ত্রণ করে।
- **Degree:** এটি পলিনোমিয়াল কার্নেলের জন্য প্রযোজ্য প্যারামিটার, যা রূপান্তরকারী পলিনোমিয়ালের সর্বোচ্চ ঘাত নির্ধারণ করে।

অধ্যায়: ব্যবহারিক সারাংশ (Practical Summary)

মডেল নির্বাচন (Model Selection)

- **Linear Kernel কখন ব্যবহার করবেন:** যখন ডেটাসেটে ফিচারের সংখ্যা নমুনার সংখ্যার তুলনায় অনেক বেশি থাকে (যেমন: টেক্সট ক্লাসিফিকেশন) অথবা ডেটা যখন স্বভাবগতভাবেই সরলরৈখিক বিন্যাসে থাকে।
- **Polynomial Kernel কখন ব্যবহার করবেন:** যখন ডেটার ফিচারগুলোর মধ্যে একটি সুনির্দিষ্ট এবং সীমিত মাত্রার ঘাতভিত্তিক সম্পর্ক বিদ্যমান থাকে।

- **RBF Kernel কখন ব্যবহার করবেন:** বাস্তব জীবনের অধিকাংশ জটিল, ওভারল্যাপড এবং সম্পূর্ণ নন-লিনিয়ার ডেটাসেটের জন্য RBF কার্নেলকে প্রথম পছন্দ হিসেবে বিবেচনা করা হয়।

হাইপারপ্যারামিটার নির্বাচন (Choosing Hyperparameters)

Large C বনাম Small C

- **Large C (উচ্চ পেনাল্টি):** মডেলটি কোনো ভুল ক্লাসিফিকেশন মেনে নিতে চায় না, ফলে মার্জিন ছোট হয়ে যায়। এটি ট্রেনিং ডেটাকে নিখুঁতভাবে ফিট করলেও মডেলটিতে ওভারফিটিং (Overfitting)-এর ঝুঁকি তৈরি হয়।
- **Small C (কম পেনাল্টি):** মডেলটি কিছু ভুল ক্লাসিফিকেশন উপেক্ষা করে একটি বড় মার্জিন তৈরি করে। এর ফলে মডেলটির সাধারণীকরণ ক্ষমতা বৃদ্ধি পায় এবং ওভারফিটিং রোধ হয়।

Large Gamma বনাম Small Gamma

- **Large Gamma:** গামার মান বড় হলে প্রতিটি ডেটা পয়েন্টের প্রভাবের ব্যাসার্ধ কমে যায়। ডিসিশন বাউন্ডারিটি কেবল তার খুব কাছের পয়েন্টগুলোর ওপর ভিত্তি করে তৈরি হয়, যা বাউন্ডারিকে অত্যন্ত আঁকাবাঁকা ও জটিল করে তোলে এবং ওভারফিটিং ঘটায়।
- **Small Gamma:** গামার মান ছোট হলে দূরবর্তী পয়েন্টগুলোর প্রভাবও বাউন্ডারি গণনায় অন্তর্ভুক্ত হয়। এর ফলে ডিসিশন বাউন্ডারিটি অনেক মসৃণ (Smooth) এবং বিস্তৃত হয়, যা মডেলের জেনারেলাইজেশন উন্নত করে।

ডিগ্রি নির্বাচন (Degree Selection)

পলিনোমিয়াল কার্নেলের ক্ষেত্রে ডিগ্রির মান নির্বাচনের সময় সতর্কতা অবলম্বন করতে হয়। কম ডিগ্রি (যেমন: 2 বা 3) মডেলকে সরল ও কার্যকর রাখে। ডিগ্রির মান অতিরিক্ত বেশি হলে মডেলটি কম্পিউটেশনালি অত্যন্ত ধীরগতির হয়ে পড়ে এবং ট্রেনিং ডেটার গোলমালের প্রতি অতিরিক্ত সংবেদনশীল হয়ে ওভারফিট করে ফেলে।

হাইপারপ্যারামিটার বিশ্লেষণ (Hyperparameters)

C

- **Default:** 1.0
- **কাজ কী:** এটি হলো রেগুলারাইজেশন (Regularization) বা পেনাল্টি প্যারামিটার। মডেলটি ট্রেনিং ডেটায় কোনো ভুল বা মিস-ক্লাসিফিকেশন করলে তাকে কতটা কঠোর গাণিতিক শাস্তি (Penalty) দেওয়া হবে, তা এটি নিয়ন্ত্রণ করে।
- **অন্যান্য অপশন:** যেকোনো ধনাত্মক ফ্লোট সংখ্যা (যেমন: 0.1, 10, 100)।
- **কখন কোনটি ব্যবহার করব:**
 - **C-এর মান অনেক বেশি হলে (যেমন: ১০০):** মডেল কোনো ভুল সহ্য করবে না (Hard Margin-এর মতো কাজ করবে)। এটি ট্রেনিং ডেটার প্রতিটি পয়েন্ট নিখুঁতভাবে মেলানোর চেষ্টা করবে, যা মডেলকে জটিল করে এবং **Overfitting (High Variance)**-এর ঝুঁকি বাড়ায়।
 - **C-এর মান অনেক কম হলে (যেমন: 0.1):** মডেল কিছুটা ভুল বা মার্জিন ওভারল্যাপ করার অনুমতি দেবে (**Soft Margin**)। এটি মডেলকে সরল রাখে এবং **Underfitting (High Bias)**-এর দিকে নিয়ে যেতে পারে। ডেটাতে নয়েজ বেশি থাকলে C-এর মান কমিয়ে দেওয়া উচিত।

kernel

- **Default:** 'rbf' (Radial Basis Function / Gaussian Kernel)
- **কাজ কী:** ইনপুট ডেটাকে কোন গাণিতিক ফাংশনের মাধ্যমে উচ্চতর মাত্রায় (Higher Dimension) রূপান্তর করা হবে, তা এটি ঠিক করে।
- **অন্যান্য অপশন:** 'linear', 'poly', 'sigmoid', অথবা কাস্টম কোনো ফাংশন।
- **কখন কোনটি ব্যবহার করব:**
 - **'linear':** আপনার ডেটা যদি অলরেডি সরলরেখায় বিভাজনযোগ্য (Linearly Separable) হয়, তবে এটি ব্যবহার করা উচিত। এটি সবচেয়ে ফাস্ট কাজ করে।
 - **'poly':** উপাত্তের মধ্যে যদি বহুপদী বা বাঁকা কোনো প্যাটার্ন থাকে।
 - **'rbf':** বাস্তব জীবনের বেশিরভাগ জটিল এবং অরৈখিক (Non-linear) ডেটার জন্য এটি ডিফল্ট এবং সেরা চয়েস। এটি ডেটাকে অসীম মাত্রায় কল্পনা করে বৃত্তাকার বা গোলকধাঁধার মতো সীমানা তৈরি করতে পারে।

gamma

- **Default: 'scale'**
- **কাজ কী:** এটি শুধুমাত্র 'rbf', 'poly', এবং 'sigmoid' কার্নেলের ক্ষেত্রে কাজ করে। একটি একক সাপোর্ট ভেক্টরের প্রভাব বা বিস্তার কত দূর পর্যন্ত ছড়াবে, তা এটি নির্ধারণ করে।
- **অন্যান্য অপশন:** 'auto' অথবা যেকোনো ধনাত্মক দশমিক সংখ্যা বা ফ্লোট মান (যেমন: 0.01, 1.0)।
- **কখন কোনটি ব্যবহার করব:**
 - মান অনেক বেশি হলে (High Gamma): সাপোর্ট ভেক্টরের প্রভাব শুধু তার খুব কাছের সীমানায় সীমাবদ্ধ থাকে। ফলে সিদ্ধান্ত রেখাটি অত্যন্ত আঁকাবাঁকা ও জটিল হয়, যা মডেলে Overfitting তৈরি করতে পারে।
 - মান অনেক কম হলে (Low Gamma): সাপোর্ট ভেক্টরের প্রভাব অনেক দূর পর্যন্ত বিস্তৃত হয়। এর ফলে সিদ্ধান্ত রেখাটি অনেক বেশি সোজা ও মসৃণ (Smooth) হয়ে যায়, যা ডেটার সূক্ষ্ম প্যাটার্ন মিস করে Underfitting ঘটাতে পারে।

epsilon (শুধুমাত্র SVR-এর জন্য)

- **Default: 0.1**
- **কাজ কী:** এটি সাপোর্ট ভেক্টর রিগ্রেশনের (SVR) একটি অত্যন্ত অনন্য প্যারামিটার। এটি হাইপারপ্লেনের উভয় পাশে একটি অদৃশ্য টিউব বা মার্জিন তৈরি করে। এই টিউবের ভেতরে থাকা কোনো ভুলের জন্য মডেল কোনো পেনাল্টি বা শাস্তি গণনা করে না।
- **অন্যান্য অপশন:** যেকোনো অ-ঋণাত্মক ফ্লোট সংখ্যা।
- **কখন কোনটি ব্যবহার করব:** যদি আপনি চান আপনার রিগ্রেশন মডেলটি ছোটখাটো নয়েজ বা ছোট ভুলগুলোকে সম্পূর্ণ ইগনোর করুক, তবে এর মান বাড়িয়ে দেওয়া যায়। আর যদি আপনি চান প্রতিটি ডেটা পয়েন্টের জন্য মডেল চরম নিখুঁত হোক, তবে এর মান কমিয়ে শূন্যের কাছাকাছি নিয়ে আসতে হবে।

degree

- **Default: 3**
- **কাজ কী:** এটি শুধুমাত্র তখনই কাজ করে যখন আপনি kernel='poly' (Polynomial) সিলেক্ট করেন। এটি বহুপদী সমীকরণের সর্বোচ্চ পাওয়ার বা ডিগ্রি নির্ধারণ করে।
- **অন্যান্য অপশন:** যেকোনো পূর্ণসংখ্যা (যেমন: 2, 4, 5)।

- **কখন কোনটি ব্যবহার করব:** যদি ডেটার বক্রতা বা প্যাটার্ন অনেক বেশি জটিল হয়, তবে ডিগ্রি বাড়িয়ে ৪ বা ৫ করা যায়। তবে ডিগ্রি অতিরিক্ত বাড়ালে কম্পিউটেশনাল কস্ট এবং ওভারফিটিংয়ের সম্ভাবনা মারাত্মকভাবে বেড়ে যায়।

coef0

- **Default:** 0.0
- **কাজ কী:** এটি শুধুমাত্র 'poly' এবং 'sigmoid' কার্ণেলের ক্ষেত্রে কাজ করে। এটি উচ্চ মাত্রার সমীকরণে একটি স্বাধীন ধ্রুবক বা বায়াস (Independent term) যোগ করে, যা উচ্চ মাত্রার ম্যাপিংকে কিছুটা শিফট বা নিয়ন্ত্রণ করতে সাহায্য করে।

shrinking

- **Default:** True
- **কাজ কী:** এটি একটি অস্টিমাইজেশন ট্রিক। ট্রেনিং প্রক্রিয়ার শুরুতে যে ডেটা পয়েন্টগুলো সিদ্ধান্ত সীমানা থেকে অনেক দূরে থাকে এবং যেগুলো সাপোর্ট ভেক্টর হওয়ার কোনো সম্ভাবনাই নেই, সেগুলোকে ব্যাকএন্ডের বড় গাণিতিক হিসাব থেকে আগেই বাদ দিয়ে দেওয়া হয়। এর ফলে মডেল অনেক দ্রুত ট্রেন হয়। এটি সাধারণত সর্বদা True রাখাই স্ট্যান্ডার্ড।

probability (SVC-এর জন্য)

- **Default:** 'deprecated' (পুরোনো সংস্করণে এটি False থাকত)
- **কাজ কী:** এটি True করা হলে মডেলটি শুধু সরাসরি ক্লাস (যেমন: +1 বা -1) প্রেডিক্ট না করে, প্রতিটি ক্লাসের নিখুঁত সম্ভাব্যতা বা প্রোবাবিলিটি (Probability Scores) হিসাব করতে পারে (যেমন: এই ডেটাটি পজিটিভ হওয়ার সম্ভাবনা ৮৫%)।
- **কখন ব্যবহার করব:** আপনার প্রজেক্টে যদি predict_proba() ফাংশন ব্যবহার করার দরকার পড়ে (যেমন: ROC-AUC কার্ভ আঁকার জন্য), তখন এটি True করতে হবে। তবে এটি অন করলে ব্যাকএন্ডে **Platt Scaling** নামের একটি ৫-ফোল্ড ক্রস-ভ্যালিডেশন লুপ চলে, যা মডেলের ট্রেনিং টাইম মারাত্মকভাবে বাড়িয়ে দেয়।

tol

- **Default:** 0.001 (অর্থাৎ 10^{-3})
- **কাজ কী:** এটি হলো অস্টিমাইজেশন থামানোর জন্য সহনশীলতার মাত্রা বা Tolerance। ব্যাকএন্ডে লুপ চলার সময় ভুলের উন্নতির হার যদি এই মানের চেয়ে কম হয়ে যায়, তবে মডেল ধরে নেয় সে তার বেস্ট হাইপারপারামেটার পেয়ে গেছে এবং ট্রেনিং স্টপ করে দেয়।

cache_size

- **Default:** 200 (মেগাবাইট)
- **কাজ কী:** SVM ব্যাকএন্ডে প্রচুর ম্যাট্রিক্স ডট প্রোডাক্ট হিসাব করে। র‍্যামের (RAM) ঠিক কত মেগাবাইট জায়গা এই হিসাবের ক্যাশ মেমোরি হিসেবে লক করে রাখা হবে, তা এটি ঠিক করে। বড় ডেটাসেটে ট্রেনিং স্পিড বাড়াতে এটিকে বাড়িয়ে ৫০০ বা ১০০০ করা যেতে পারে।

class_weight (শুধুমাত্র SVC-এর জন্য)

- **Default:** None
- **কাজ কী:** প্রবল ইমব্যালেন্সড ডেটাসেটের ক্ষেত্রে ছোট ক্লাসকে অতিরিক্ত গাণিতিক গুরুত্ব দেওয়ার জন্য ব্যবহৃত হয়। class_weight='balanced' দিলে মডেল স্বয়ংক্রিয়ভাবে মাইনোরিটি ক্লাসের ভুলের জন্য পেনাল্টি বাড়িয়ে দেয়।

verbose

- **Default:** False
- **কাজ কী:** এটি True করে দিলে ব্যাকএন্ডে অপটিমাইজেশনের ক্যালোকেশনের লাইভ লগ বা টেক্সট টার্মিনালে প্রিন্ট করে দেখায়। সাধারণত এটি রিগ্রেশন বা ক্লাসিফিকেশনের সাধারণ প্রজেক্টে False-ই রাখা হয়।

max_iter

- **Default:** -1 (অর্থাৎ কোনো নির্দিষ্ট সীমা নেই, যতক্ষণ না অপটিমাইজেশন শেষ হচ্ছে চলতেই থাকবে)
- **কাজ কী:** ব্যাকএন্ডের কোয়ান্ট্রটিক প্রোগ্রামিং সলভার সর্বোচ্চ কতবার লুপ বা ইটারেশন চালাবে, তা বেঁধে দেওয়া। যদি মডেলটি বিশাল ডেটাসেটে আটকে গিয়ে অনন্তকাল ধরে চলতে থাকে, তবে এখানে একটি নির্দিষ্ট সংখ্যা (যেমন: ৫০০০) সেট করে ট্রেনিং ফোর্স-স্টপ করা যায়।

decision_function_shape (শুধুমাত্র SVC-এর জন্য)

- **Default:** 'ovr' (One-vs-Rest)
- **কাজ কী:** মাল্টি-ক্লাস ক্লাসিফিকেশনের ক্ষেত্রে (যেমন: ৩ বা তার বেশি ক্লাস থাকলে) মডেলটি ব্যাকএন্ডে কীভাবে কাজ করবে তা ঠিক করে। 'ovr' প্রতিটি ক্লাসের বিপরীতে বাকি সব ক্লাসকে ধরে আলাদা আলাদা বাইনারি মডেল বানায়। অন্য অপশনটি হলো 'ovo' (One-vs-One), যা প্রতি দুটি ক্লাসের জোড়া জোড়া নিয়ে আলাদা মডেল তৈরি করে (এটি কম্পিউটেশনালি অনেক ভারী)।

break_ties (শুধুমাত্র SVC-এর জন্য)

- **Default:** False
- **কাজ কী:** এটি শুধুমাত্র তখনই কাজ করে যখন `decision_function_shape='ovr'` থাকে এবং ক্লাসের সংখ্যা ২-এর বেশি হয়। যদি কোনো টেস্ট ডেটার ক্ষেত্রে দুটি ক্লাসের প্রোবাবিলিটি স্কোর হুবহু এক চলে আসে (টাই হয়), তখন True দেওয়া থাকলে মডেল তার ভেতরের গাণিতিক ডিসিশন ভ্যালুর সূক্ষ্ম ব্যবধান দেখে সেই টাই ভেঙে একটি চূড়ান্ত ক্লাস ঘোষণা করে।

random_state

- **Default:** None
- **কাজ কী:** যদিও SVM একটি ডিটারমিনিস্টিক (নির্দিষ্ট) মডেল, কিন্তু যখন `probability=True` করা হয়, তখন ব্যাকএন্ডের বুটস্ট্র্যাপ এবং প্ল্যাট স্কেলিং প্রক্রিয়ার র্যান্ডমনেসকে লক করার জন্য একটি নির্দিষ্ট গাণিতিক বীজ (Seed) বা সংখ্যা (যেমন: 42) এখানে ব্যবহার করা হয়, যাতে প্রতিবার অবিকল একই রেজাল্ট আসে।

Code:

```
import pandas as pd
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC
from sklearn.metrics import accuracy_score, classification_report

cancer = load_breast_cancer()
X = pd.DataFrame(cancer.data, columns=cancer.feature_names)
y = pd.Series(cancer.target)

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

numeric_features = X.columns.tolist()
preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), numeric_features)
    ]
)

svm_pipeline = Pipeline(
    steps=[
        ('preprocessor', preprocessor),
        ('model', SVC(random_state=42))
    ]
)

param_grid = {
    'model__C': [0.1, 1, 10],
    'model__kernel': ['linear', 'rbf'],
    'model__gamma': ['scale', 'auto']
}
```

```
grid_search = GridSearchCV(
    estimator=svm_pipeline,
    param_grid=param_grid,
    cv=5,
    scoring='accuracy',
    n_jobs=-1
)

grid_search.fit(X_train, y_train)

print("--- GridSearchCV Tuning Results ---")
print("Best Parameters Found:", grid_search.best_params_)
print(f"Best CV Accuracy: {grid_search.best_score_:.4f}\n")

best_svm_model = grid_search.best_estimator_
y_pred = best_svm_model.predict(X_test)

print("--- Final Model Performance on Test Set ---")
print(f"Test Accuracy: {accuracy_score(y_test, y_pred):.4f}\n")
print(classification_report(y_test, y_pred))
```

Code:

```
wine = load_wine()
X = pd.DataFrame(wine.data, columns=wine.feature_names)
y = pd.Series(wine.target)

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42, stratify=y
)

numeric_features = X.columns.tolist()
preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), numeric_features)
    ]
)

svm_pipeline = Pipeline(
    steps=[
        ('preprocessor', preprocessor),
        ('model', SVC(random_state=42))
    ]
)
```

```
grid_param = [
    {
        "model__kernel": ['linear'],
        "model__C": [0.01, 0.1, 1, 10, 50, 100]
    },
    {
        "model__kernel": ['rbf'],
        "model__C": [0.01, 0.1, 1, 100],
        "model__gamma": [0.01, 0.1, 5, 10, 'scale', 'auto']
    },
    {
        "model__kernel": ['poly'],
        "model__C": [0.01, 0.1, 1, 100],
        "model__degree": [2, 3]
    }
]
```

```
grid_search = GridSearchCV(
    estimator=svm_pipeline,
    param_grid=grid_param,
    cv=5,
    scoring='accuracy',
    n_jobs=-1
)

grid_search.fit(X_train, y_train)

print("--- GridSearchCV Tuning Results ---")
print("Best Parameters Found:", grid_search.best_params_)
print(f"Best CV Accuracy: {grid_search.best_score_:.4f}\n")

best_svm_model = grid_search.best_estimator_
y_pred = best_svm_model.predict(X_test)

print("--- Final Model Performance on Test Set ---")
print(f"Test Accuracy: {accuracy_score(y_test, y_pred):.4f}\n")
print(classification_report(y_test, y_pred, target_names=wine.target_names))
```

Code:

```
preprocessor = ColumnTransformer(  
    transformers=[  
        ('num', StandardScaler(), X_train.select_dtypes(include=np.number).columns)  
    ]  
)  
  
pipeline = Pipeline(steps=[  
    ('preprocessor', preprocessor),  
    ('classifier', SVC())  
)  
  
param_grid = {  
    'classifier__C': [0.1, 0.5, 1, 5, 10],  
    #'classifier__penalty': ['l1', 'l2'],  
    'classifier__kernel': ['rbf', 'linear', 'poly', 'sigmoid'],  
    #'classifier__epsilon': [0.1, 0.2, 0.5, 1, 2, 5, 10],  
    'classifier__shrinking': [True, False]  
}  
  
grid_search = GridSearchCV(  
    estimator = pipeline,  
    param_grid = param_grid,  
    scoring = 'accuracy',  
    cv = 5,  
    n_jobs = -1  
)
```

```
grid_search.fit(X_train, y_train)  
grid_search.best_params_  
grid_search.best_score_  
best_model = grid_search.best_estimator_  
y_pred = best_model.predict(X_test)
```

Q1: SVM-এ ফিচার স্কেলিং (Feature Scaling) করা কেন বাধ্যতামূলক, যেখানে র‍্যান্ডম ফরেস্ট এর প্রয়োজন হয় না?

- **Answer:** SVM মূলত একটি জ্যামিতিক দূরত্ব-ভিত্তিক (Distance-based) অ্যালগরিদম। এটি বিভিন্ন ক্লাসের মধ্যকার দূরত্ব বা মার্জিন সর্বোচ্চ করার জন্য সাপোর্ট ভেক্টরগুলোর ইউক্লিডিয়ান দূরত্ব (Euclidean Distance) গণনা করে। যদি কোনো একটি ফিচারের রেঞ্জ অনেক বড় হয় (যেমন: Income = ৫০,০০০) এবং অন্যটির রেঞ্জ ছোট হয় (যেমন: Age = ২), তবে দূরত্বের হিসাবে বড় রেঞ্জের ফিচারটি পুরো মডেলকে ডমিনেট করবে এবং ছোট ফিচারের গুরুত্ব হারিয়ে যাবে। তাই সব ফিচারকে সমান গুরুত্ব দিতে স্কেলিং বাধ্যতামূলক। অন্যদিকে, র‍্যান্ডম ফরেস্ট ডিসিশন ট্রির রুলস মেনে নোড স্প্লিট করে, যা দূরত্বের ওপর নির্ভর করে না।

Q2: 'Kernel Trick' বলতে কী বোঝায়? এটি কি আসলেই ডেটার ডাইমেনশন বাড়িয়ে দেয়?

- **Answer:** যখন কোনো ডেটাসেটকে লিনিয়ার লাইনে আলাদা করা যায় না, তখন কার্নেল ট্রিক ব্যবহৃত হয়। তাত্ত্বিকভাবে এটি ডেটাকে একটি উচ্চতর মাত্রায় (Higher Dimension) ট্রান্সফর্ম করে যেন সেখানে একটি লিনিয়ার হাইপারপ্লেন দিয়ে ক্লাসগুলোকে আলাদা করা যায়। তবে এটি বাস্তবে বা ফিজিক্যালি ডেটার কোনো নতুন কলাম তৈরি করে না বা উচ্চ মাত্রায় ডেটা রিলোড করে না। এটি একটি গাণিতিক শর্টকাট ফাংশন, যা মূল লো-ডাইমেনশনে বসেই উচ্চ ডাইমেনশনের ডট প্রোডাক্টের $(x_i \cdot x_j)$ চূড়ান্ত ফলাফল সরাসরি গণনা করে দেয়। এর ফলে মেমোরি এবং কম্পিউটেশনাল সময় মারাত্মকভাবে বেঁচে যায়।

Q3: SVM-এর C প্যারামিটারটি কীভাবে Bias এবং Variance-এর ভারসাম্য (Trade-off) নিয়ন্ত্রণ করে?

- **Answer:** C প্যারামিটারটি মূলত রেগুলারাইজেশন এবং ট্রেইনিং এররের পেনাল্টি নিয়ন্ত্রণ করে:
 - **C -এর মান খুব বেশি হলে:** মডেল ট্রেইনিং সেটে কোনো ভুল করতে চায় না (Hard Margin)। এটি প্রতিটি নয়েজ পয়েন্টকে মেলানোর জন্য সিদ্ধান্ত সীমানাকে অনেক জটিল ও আঁকাবাঁকা করে তোলে। এর ফলে মডেলের **Bias কমে (Low Bias)** কিন্তু **Variance মারাত্মক বাড়ে (High Variance)**, যা ওভারফিটিং ঘটায়।
 - **C -এর মান খুব কম হলে:** মডেল কিছুটা ভুল বা মার্জিন ওভারল্যাপ করার ছাড় দেয় (Soft Margin)। সিদ্ধান্ত সীমানাটি খুব সরল বা মসৃণ হয়। এর ফলে মডেলের **Variance কমে (Low Variance)** কিন্তু **Bias বেড়ে যায় (High Bias)**, যা আন্ডারফিটিং ঘটাতে পারে।

Q4: SVM-এর প্রধান সীমাবদ্ধতা বা ডিসঅ্যাডভান্টেজগুলো কী কী?

- **Answer:** শক্তিশালী মডেল হলেও SVM-এর কিছু বড় সীমাবদ্ধতা রয়েছে:
 - **বৃহৎ ডেটাসেটে ধীরগতি:** ডেটার সংখ্যা (*Rows*) অনেক বেশি হলে (যেমন: ১ লাখের উপরে) এর ব্যাকএন্ডের কোয়াদ্রেটিক প্রোগ্রামিং হিসাব করতে প্রচুর সময় ও কম্পিউটেশনাল পাওয়ার লাগে।
 - **নয়েজি ডেটায় দুর্বলতা:** ডেটাসেটে যদি ক্লাসের সীমানাগুলো একে অপরের ভেতর অতিরিক্ত ঢুকে থাকে (*High Overlapping Noise*), তবে SVM ভালো মার্জিন তৈরি করতে পারে না।
 - **প্রোবাবিলিটি স্কেরের অভাব:** এটি লজিস্টিক রিগ্রেশনের মতো স্বয়ংক্রিয়ভাবে কোনো সম্ভাব্যতা স্কের (*predict_proba*) দেয় না। এটি অন করতে গেলে প্ল্যাট স্কেলিং মেথড ব্যবহার করতে হয় যা মডেলকে আরও ধীরগতির করে তোলে।

Q5: 'Support Vectors' বলতে কী বোঝায় এবং মডেলের প্রেডিকশনে এদের ভূমিকা কী?

- **Answer:** ট্রেনিং ডেটাসেটের যে নির্দিষ্ট বিন্দু বা স্যাম্পলগুলো সিদ্ধান্ত সীমানার (*Hyperplane*) সবচেয়ে কাছাকাছি অবস্থান করে এবং মার্জিনাল লাইন লক করতে সরাসরি অংশ নেয়, সেগুলোকে **Support Vectors** বলে। ট্রেনিং শেষ হওয়ার পর, SVM বাকি সব সাধারণ ডেটা পয়েন্ট মেমোরি থেকে সম্পূর্ণ ডিলিট করে দেয় এবং শুধুমাত্র এই সাপোর্ট ভেক্টরগুলোকে ধরে রাখে। নতুন কোনো অজানা টেস্ট ডেটা আসলে, মডেলটি কেবল এই সাপোর্ট ভেক্টরগুলোর সাপেক্ষে দূরত্ব মেপে তার ক্লাস নির্ধারণ করে।

সাপোর্ট ভেক্টর মেশিন (SVM) — সারসংক্ষেপ

১. মূল দর্শন ও জ্যামিতিক উপাদান (Core Philosophy & Geometry)

- হাইপারপ্লেন (Hyperplane):** SVM হলো একটি সুপারভাইজড লার্নিং অ্যালগরিদম, যার মূল লক্ষ্য হলো বহুমাত্রিক উপাত্ত ক্ষেত্রে (n -Dimensional Space) একটি লিনিয়ার সিদ্ধান্ত সীমানা বা হাইপারপ্লেন ($w^T x + b = 0$) তৈরি করা।
- জ্যামিতিক রূপান্তর:** মাত্রাভেদে এই বাউন্ডারিটি ভিন্ন রূপ নেয়; যেমন—দ্বিমাত্রিকে (2D) এটি একটি সরলরেখা, ত্রিমাত্রিকে (3D) একটি সমতল পৃষ্ঠ বা প্লেন, এবং তার অধিক মাত্রায় এটি একটি হাইপারপ্লেন।
- সাপোর্ট ভেক্টরস (Support Vectors):** সিদ্ধান্ত রেখার সবচেয়ে নিকটে এবং মার্জিনাল বাউন্ডারির ($w^T x + b = \pm 1$) ওপর অবস্থিত যে বিশেষ বিন্দুগুলো হাইপারপ্লেনের অবস্থান ও অভিযোজন (Orientation) সরাসরি নির্ধারণ করে, তাদের সাপোর্ট ভেক্টর বলে।

২. মার্জিন সর্বোচ্চকরণ ও গাণিতিক ভিত্তি (Margin Maximization & Mathematics)

- ম্যাক্সিমাম মার্জিন ক্লাসিফায়ার:** SVM কেবল ডেটা আলাদাই করে না, বরং দুই ক্লাসের মধ্যবর্তী সম্ভাব্য সবচেয়ে চওড়া রাস্তা বা সর্বোচ্চ মার্জিন (Maximum Margin) তৈরি করে।
- গাণিতিক সমীকরণ:** জ্যামিতিক প্রতিপাদন অনুযায়ী মোট মার্জিনের দূরত্ব হলো:

$$\text{Margin } (M) = \frac{2}{\|w\|}$$

- অপটিমাইজেশন লজিক:** গাণিতিক নিয়ম অনুযায়ী, ভগ্নাংশের হর $\|w\|$ যত হ্রাস পাবে, মোট মার্জিন (M) তত বৃদ্ধি পাবে। তাই ক্যালকুলাসের সুবিধার্থে SVM-এর মূল অপটিমাইজেশন সমস্যাটিকে একটি সমতুল্য সর্বনিম্নকরণ সমস্যা হিসেবে রূপ দেওয়া হয়:

$$\min \frac{1}{2} \|w\|^2 \quad \text{subject to} \quad y_i(w^T x_i + b) \geq 1$$

৩. লস ফাংশন এবং আউটলায়ার প্রতিরোধ ক্ষমতা (Loss Function & Robustness)

- হিঞ্জ লস (Hinge Loss):** লজিস্টিক রিগ্রেশনের ক্রমাগত পরিবর্তনশীল 'লগ-লস'-এর বিপরীতে SVM ব্যবহার করে হিঞ্জ লস:

$$\text{Hinge Loss} = \max(0, 1 - y_i(w^T x + b))$$

- পেনাল্টি মেকানিজম:** যদি কোনো ডেটা পয়েন্ট সঠিকভাবে ক্লাসিফাইড এবং মার্জিনের বাইরে থাকে ($y_i(w^T x + b) \geq 1$), তবে তার লস সরাসরি ০ (Zero) হয়।

- **Robust to Outliers:** সিদ্ধান্ত সীমানাটি শুধুমাত্র অল্প কিছু সাপোর্ট ভেক্টরের ওপর নির্ভর করে। মার্জিনের বাইরে অবস্থিত অন্য হাজারটি বিন্দু পরিবর্তন বা অপসারণ করলেও হাইপারপ্লেন স্থানচ্যুত হয় না, যা একে আউটলায়ারের বিরুদ্ধে অত্যন্ত শক্তিশালী (Robust) করে তোলে।

৪. কার্নেল ট্রিক ও ডেটাসেটের প্রকারভেদ (Kernel Trick & Dataset Types)

- **লিনিয়ারলি সেপারেবল ডেটা:** ডেটা সোজা লাইনে ভাগ করা সম্ভব হলে কোনো ভুল বা ওভারল্যাপিং ছাড়া "Hard Margin" ব্যবহার করে নিখুঁত শ্রেণীবিভাগ করা যায়।
- **অরৈখিক উপাত্ত বিন্যাস (Non-Linear Data):** বাস্তব জীবনের জটিল ডেটা সোজা লাইনে আলাদা করা না গেলে SVM তার বিখ্যাত **Kernel Trick** (যেমন: Polynomial, RBF কার্নেল) ব্যবহার করে। এটি মূল ইনপুট স্পেসের ডেটাকে কোনো বাস্তব রূপান্তর ছাড়াই উচ্চ মাত্রার ফিচার স্পেসে (Higher Dimensional Space) গাণিতিক শর্টকাটের মাধ্যমে নিখুঁতভাবে পৃথক করে।

৫. অন্যান্য মডেলের তুলনায় SVM-এর অপরিহার্যতা (Why We Need SVM)

- **লজিস্টিক রিগ্রেশন বনাম SVM:** লজিস্টিক রিগ্রেশনে মার্জিনের ওপর কোনো সুনির্দিষ্ট জ্যামিতিক নিয়ন্ত্রণ থাকে না এবং এটি আউটলায়ার দ্বারা প্রভাবিত হয়। SVM মার্জিন সর্বোচ্চ করে এবং হিঞ্জ লসের মাধ্যমে অপ্রয়োজনীয় বিন্দুর প্রভাব মুক্ত রেখে লজিস্টিক রিগ্রেশনের চেয়ে অনেক বেশি স্থিতিশীল (Robust) সিদ্ধান্ত বাউন্ডারি দেয়।
- **KNN বনাম SVM:** KNN একটি অলস শিক্ষণ পদ্ধতি (Lazy Learner), যা টেস্ট টাইমে প্রতিটি ডেটার জন্য পুরো ডেটাসেটের দূরত্ব মাপে (ধীরগতির ও মেমোরি সাপেক্ষ)। পক্ষান্তরে, SVM ট্রেনিং শেষে শুধু অল্প কিছু সাপোর্ট ভেক্টর মেমোরিতে রাখে, ফলে এর প্রেডিকশন স্পিড অত্যন্ত ফাস্ট।
- **Decision Tree / Random Forest বনাম SVM:** বৃক্ষ-ভিত্তিক মডেলগুলো অক্ষ-বরাবর লম্বালম্বিভাবে উপাত্ত খণ্ডিত করে বৃত্তাকার বা জটিল প্যাটার্নে ওভারফিটিং তৈরি করে। কিন্তু SVM তার আরবিএফ (RBF) কার্নেল দিয়ে অতি সহজেই আঁকাবাঁকা বৃত্তাকার সিদ্ধান্ত সীমানা চিহ্নিত করতে পারে।

আনসুপারভাইজড লার্নিং

মেশিন লার্নিং (Machine Learning) বিজ্ঞানের যে শাখায় কোনো পূর্বনির্ধারিত লক্ষ্য-ভেরিয়েবল বা উত্তরসূচক লেবেল (Target Labels) ব্যতিরেকেই উপাত্তের ভেতরের অদৃশ্য বিন্যাস, গাণিতিক সম্পর্ক এবং অন্তর্নিহিত কাঠামো উন্মোচন করা হয়, তাকে আনসুপারভাইজড লার্নিং (Unsupervised Learning) বলা হয়।


সুপারভাইজড লার্নিংয়ের মতো এখানে কোনো কৃত্রিম নির্দেশিকা বা "শিক্ষক" থাকে না। এই পদ্ধতিতে অ্যালগরিদমকে শুধুমাত্র ইনপুট ফিচার ভেক্টর সম্বলিত একটি লেবেলহীন ডেটাসেট প্রদান করা হয়।

$$\{x_i\}_{i=1}^N$$

গাণিতিক ও পরিসংখ্যানগত দৃষ্টিকোণ থেকে, আনসুপারভাইজড লার্নিংয়ের মূল উদ্দেশ্য হলো ইনপুট উপাত্তের সম্ভাব্যতা ঘনত্ব ফাংশন (Probability Density Function - PDF) অথবা উপাত্তের জ্যামিতিক বিস্তৃতি (Geometric Structure) বিশ্লেষণ করা।

বাস্তব উদাহরণ

- গ্রাহকদের কেনাকাটার ইতিহাস বিশ্লেষণ করে সমজাতীয় বৈশিষ্ট্যের ভিত্তিতে বিভিন্ন গ্রুপে বিভক্ত করা (Clustering)।
- নেটওয়ার্ক ট্রাফিকের স্বাভাবিক আচরণের বিন্যাস শিখে আকস্মিক অসঙ্গতি বা সাইবার আক্রমণ শনাক্ত করা (Anomaly Detection)।



সুপারভাইজড বনাম আনসুপারভাইজড লার্নিং (Supervised vs Unsupervised Learning)

মেশিন লার্নিংয়ে উপাত্তের গঠন, গাণিতিক অপ্টিমাইজেশন এবং ব্যবহারিক প্রয়োগের ভিত্তিতে এই দুই ধরনের লার্নিংয়ের মধ্যে গুরুত্বপূর্ণ পার্থক্য রয়েছে।

মূল্যায়নের ক্ষেত্র	সুপারভাইজড লার্নিং (Supervised Learning)	আনসুপারভাইজড লার্নিং (Unsupervised Learning)
উপাত্তের গাণিতিক রূপ (Data Structure)	লেবেলযুক্ত ডেটাসেট: $\{(x_i, y_i)\}_{i=1}^N$	লেবেলহীন ডেটাসেট: $\{x_i\}_{i=1}^N$
অ্যালগরিদমিক লক্ষ্য (Objective)	ইনপুট x থেকে আউটপুট y পূর্বাভাস দেওয়ার জন্য একটি গাণিতিক ফাংশন শেখা।	ডেটার ভেতরের অজানা বিন্যাস, ঘনত্ব এবং ফিচারগুলোর গোপন সম্পর্ক খুঁজে বের করা।
মডেলের নির্ভুলতা মূল্যায়ন (Evaluation)	MSE, Cross-Entropy ইত্যাদি Loss Function ব্যবহার করে সহজেই মূল্যায়ন করা যায়।	পূর্বনির্ধারিত সঠিক উত্তর না থাকায় নির্ভুলতা সরাসরি পরিমাপ করা কঠিন।
প্রধান ব্যবহার (Core Applications)	Regression এবং Classification।	Clustering, Dimensionality Reduction এবং Anomaly Detection।
কম্পিউটেশনাল জটিলতা (Computational Complexity)	Training তুলনামূলকভাবে ব্যয়বহুল হলেও Prediction দ্রুত হয়।	Distance ও Density বারবার গণনা করতে হওয়ায় Training ও Generalization উভয় ক্ষেত্রেই জটিলতা ও Memory Cost তুলনামূলকভাবে বেশি।

আনসুপারভাইজড লার্নিংয়ের প্রধান গাণিতিক রূপসমূহ (Core Problem Types)

বাস্তবমুখী গাণিতিক অপ্টিমাইজেশনের ওপর ভিত্তি করে আনসুপারভাইজড অ্যালগরিদম গুলোকে মূলত তিনটি প্রধান ভাগে বিভক্ত করা যায়।

ক্লাস্টারিং (Clustering)

একটি নির্দিষ্ট দূরত্ব পরিমাপক ম্যাট্রিক্সের (যেমন: Euclidean Distance বা Cosine Similarity) ওপর ভিত্তি করে সমধর্মী উপাত্ত বিন্দুগুলোকে স্বয়ংক্রিয়ভাবে এক একটি ক্লাস্টার বা গ্রুপে বিন্যস্ত করার পদ্ধতি।

ডাইমেনশনালিটি রিডাকশন (Dimensionality Reduction)

উপাত্ত ক্ষেত্রে বৈশিষ্ট্যের সংখ্যা বা ডাইমেনশন (D) যদি অত্যধিক বেশি হয়, তবে উপাত্তের ভেতরের মূল তথ্যগত বৈচিত্র্য (Variance) অক্ষুণ্ণ রেখে বৈশিষ্ট্যের সংখ্যা একটি সুনির্দিষ্ট নিম্ন মাত্রায় নামিয়ে আনার গাণিতিক কৌশল।

$$D_{\text{new}} < D$$

অ্যানোমালি ডিটেকশন (Anomaly Detection)

সমগ্র উপাত্ত ক্ষেত্রের স্বাভাবিক ঘনত্বের বিন্যাস থেকে বিচ্যুত বা বাউন্ডারির বাইরে অবস্থিত চরম Outlier বা ত্রুটিপূর্ণ নমুনাগুলোকে জ্যামিতিক দূরত্বের ভিত্তিতে পৃথক করার প্রক্রিয়া।

বাস্তব জীবনের প্রয়োগ ও সমস্যার ধরন

আনসুপারভাইজড লার্নিং অ্যালগরিদমগুলো কোনো পূর্বনির্ধারিত লেবেল ছাড়াই উপাত্তের অন্তর্নিহিত গঠন উন্মোচন করতে পারে। তাই বাস্তব জীবনের জটিল ও বহুমুখী সমস্যা সমাধানে এটি অত্যন্ত কার্যকর ভূমিকা পালন করে।

তাত্ত্বিক বিশ্লেষণ ও বাস্তব প্রয়োগের ভিত্তিতে আনসুপারভাইজড লার্নিংয়ের প্রধান সমস্যা ও প্রয়োগক্ষেত্রগুলোকে তিনটি ভাগে বিভক্ত করা যায়।

ক্লাস্টারিং (Clustering)

সমস্যার প্রকৃতি

এটি একটি নন-প্যারামেট্রিক (Non-parametric) পদ্ধতি, যার লক্ষ্য হলো কোনো লেবেলহীন ডেটাসেটের মধ্যে থাকা সদৃশ বৈশিষ্ট্যসম্পন্ন ডেটা পয়েন্টগুলোকে স্বয়ংক্রিয়ভাবে বিভিন্ন ক্লাস্টার (Cluster) বা গ্রুপে ভাগ করা।

সাধারণত **Euclidean Distance** অথবা **Cosine Similarity**-এর মতো Distance Metric ব্যবহার করে ডেটা পয়েন্টগুলোর মধ্যে সাদৃশ্য নির্ণয় করা হয়।

বাস্তব জীবনের প্রয়োগ

- গ্রাহক বিভাজন (Customer Segmentation): ই-কমার্স ও রিটেইল ব্যবসায় গ্রাহকদের কেনাকাটার ইতিহাস, পছন্দ এবং ব্যয়ের ধরন বিশ্লেষণ করে বিভিন্ন গ্রুপে ভাগ করা হয়, যেমন উচ্চ ব্যয়কারী, সাশ্রয়ী কিংবা নিষ্ক্রিয় গ্রাহক। এটি লক্ষ্যভিত্তিক মার্কেটিংয়ে সহায়তা করে।

- চিত্র বিভাজন (Image Segmentation): চিকিৎসাবিজ্ঞানে MRI অথবা X-ray ইমেজ বিশ্লেষণ করে সুস্থ টিস্যু এবং টিউমার বা ক্ষতিগ্রস্ত অংশকে স্বয়ংক্রিয়ভাবে আলাদা করতে ক্লাস্টারিং ব্যবহৃত হয়।
- সামাজিক নেটওয়ার্ক বিশ্লেষণ (Social Network Analysis): সামাজিক যোগাযোগমাধ্যমে ব্যবহারকারীদের পারস্পরিক যোগাযোগ, অভিন্ন আগ্রহ এবং সম্পর্কের ঘনত্ব বিশ্লেষণ করে স্বয়ংক্রিয়ভাবে বিভিন্ন কমিউনিটি বা গ্রুপ শনাক্ত করা হয়।

মাত্রিকতা হ্রাস (Dimensionality Reduction)

সমস্যার প্রকৃতি

বাস্তব জীবনের অনেক ডেটাসেটে বৈশিষ্ট্যের সংখ্যা (Features) অত্যন্ত বেশি থাকে। ফলে কম্পিউটেশনাল জটিলতা বৃদ্ধি পায় এবং নয়েজের পরিমাণও বেড়ে যায়। এই সমস্যাটিকে Curse of Dimensionality বলা হয়।

Dimensionality Reduction-এর মূল উদ্দেশ্য হলো উপাত্তের গুরুত্বপূর্ণ তথ্য (Information) ও বৈচিত্র্য (Variance) যতটা সম্ভব অক্ষুণ্ণ রেখে উচ্চমাত্রিক (High-dimensional) ডেটাকে নিম্নমাত্রিক (Low-dimensional) ডেটায় রূপান্তর করা।

বাস্তব জীবনের প্রয়োগ

- উপাত্ত দৃশ্যমানকরণ (Data Visualization): PCA বা UMAP-এর মতো অ্যালগরিদম ব্যবহার করে হাজার হাজার ডেটাকে 2D বা 3D-তে রূপান্তর করা হয়, যাতে মানুষ সহজে ডেটার গঠন পর্যবেক্ষণ করতে পারে।
- উপাত্ত সংকোচন ও মেমোরি সাশ্রয় (Data Compression): ইমেজ, অডিও বা টেক্সটের গুরুত্বপূর্ণ বৈশিষ্ট্য বজায় রেখে ফাইলের আকার কমাতে এটি ব্যবহৃত হয়। ফলে স্টোরেজের প্রয়োজন কমে এবং প্রসেসিং দ্রুত হয়।
- মডেলের কার্যদক্ষতা বৃদ্ধি (Feature Extraction): সুপারভাইজড লার্নিংয়ের আগে অপ্রয়োজনীয় ফিচার বাদ দিয়ে প্রয়োজনীয় বৈশিষ্ট্য নির্বাচন করা হয়, ফলে ট্রেনিং দ্রুত হয় এবং Overfitting-এর সম্ভাবনা কমে।

অ্যানোমালি ডিটেকশন (Anomaly Detection)

সমস্যার প্রকৃতি

এই ধরনের সমস্যায় ডেটাসেটের অধিকাংশ নমুনাই স্বাভাবিক (Normal), কিন্তু অস্বাভাবিক (Abnormal) বা ত্রুটিপূর্ণ নমুনা খুবই কম অথবা একেবারেই অনুপস্থিত থাকে।

অ্যালগরিদম প্রথমে স্বাভাবিক ডেটার ঘনত্ব (Density) ও গঠন (Structure) শিখে নেয়। এরপর নতুন কোনো ডেটা যদি সেই স্বাভাবিক প্যাটার্ন থেকে উল্লেখযোগ্যভাবে বিচ্যুত হয়, তাহলে সেটিকে **Anomaly** বা **Outlier** হিসেবে শনাক্ত করা হয়।

বাস্তব জীবনের প্রয়োগ

- ক্রেডিট কার্ড জালিয়াতি শনাক্তকরণ (Fraud Detection): গ্রাহকের স্বাভাবিক লেনদেনের ধরণ থেকে ভিন্ন কোনো সন্দেহজনক লেনদেন স্বয়ংক্রিয়ভাবে শনাক্ত করা হয়।
- শিল্প উৎপাদনে ত্রুটি নির্ণয় (Manufacturing Defect Detection): সেন্সর ডেটা বা পণ্যের ছবি বিশ্লেষণ করে ত্রুটিযুক্ত পণ্যকে স্বয়ংক্রিয়ভাবে আলাদা করা হয়।
- সাইবার নিরাপত্তা ও অনুপ্রবেশ শনাক্তকরণ (Intrusion Detection): নেটওয়ার্ক ট্রাফিকের স্বাভাবিক আচরণ বিশ্লেষণ করে হ্যাকিংয়ের চেষ্টা, ম্যালওয়্যার আক্রমণ অথবা অস্বাভাবিক নেটওয়ার্ক কার্যকলাপ শনাক্ত করা হয়।


K-Means Clustering

K-Means হলো একটি অত্যন্ত জনপ্রিয়, নন-প্যারামেট্রিক (Non-parametric) এবং সেন্ট্রয়েড-ভিত্তিক (Centroid-based) হার্ড ক্লাস্টারিং (Hard Clustering) অ্যালগরিদম।

সহজ ভাষায়, এটি এমন একটি গাণিতিক পদ্ধতি যা কোনো পূর্বনির্ধারিত লেবেলবিহীন (Unlabeled) ডেটাসেটের ডেটা পয়েন্টগুলোর পারস্পরিক জ্যামিতিক দূরত্ব পরিমাপ করে তাদের স্বয়ংক্রিয়ভাবে K সংখ্যক পৃথক ক্লাস্টার বা গ্রুপে বিভক্ত করে।

এই অ্যালগরিদমে দুটি গুরুত্বপূর্ণ উপাদান রয়েছে।

- **K (Number of Clusters):** এটি একটি User-defined Hyperparameter, যা নির্ধারণ করে ডেটাসেটকে মোট কতটি ক্লাস্টারে ভাগ করা হবে।
- **Mean (Centroid):** প্রতিটি ক্লাস্টারের অন্তর্ভুক্ত সকল ডেটা পয়েন্টের গাণিতিক গড় (Arithmetic Mean), যাকে Centroid বলা হয়। এই Centroid-ই ক্লাস্টারের কেন্দ্রবিন্দু হিসেবে কাজ করে।



Classification of K-Means

মেশিন লার্নিংয়ের গাঠনিক বিন্যাস অনুযায়ী K-Means-কে নিম্নোক্ত শ্রেণিতে বিভক্ত করা যায়।

- এটি একটি **Unsupervised Learning Model**, কারণ এটি কোনো Target Label বা শিক্ষক ছাড়াই ডেটার অন্তর্নিহিত গঠন (Hidden Structure) আবিষ্কার করে।
- এটি একটি **Instance-based Model**, কারণ এটি কোনো গ্লোবাল গাণিতিক সমীকরণ শেখে না; বরং ডেটা পয়েন্টগুলোর অবস্থান ও দূরত্বের ভিত্তিতে ক্লাস্টার তৈরি করে।
- এটি একটি **Hard Clustering Model**, কারণ প্রতিটি ডেটা পয়েন্ট শুধুমাত্র একটি ক্লাস্টারের সদস্য হতে পারে। একই ডেটা পয়েন্ট একাধিক ক্লাস্টারের অন্তর্ভুক্ত হতে পারে না। এই বৈশিষ্ট্য K-Means-কে Soft Clustering অ্যালগরিদম (যেমন Gaussian Mixture Model) থেকে আলাদা করে।

Problem Solved by K-Means

K-Means মূলত ক্লাস্টারিং (Clustering) সমস্যার সমাধান করে।

জ্যামিতিক দৃষ্টিকোণ থেকে, এটি Feature Space-কে একাধিক অঞ্চলে (Regions) ভাগ করে, যাতে একই ক্লাস্টারের ডেটা পয়েন্টগুলো একে অপরের যতটা সম্ভব কাছাকাছি থাকে এবং ভিন্ন ক্লাস্টারের ডেটা পয়েন্টগুলোর মধ্যকার দূরত্ব যতটা সম্ভব বেশি হয়।

বাস্তব জীবনে K-Means নিম্নলিখিত সমস্যাগুলোর সমাধান করতে পারে।

- গ্রাহকের কেনাকাটার ধরণ, ব্যয়ের পরিমাণ এবং আচরণের ভিত্তিতে স্বয়ংক্রিয়ভাবে বিভিন্ন Customer Segment তৈরি করা।
- ডিজিটাল ছবির সমজাতীয় Pixel বা Color Value-গুলোকে একত্রিত করে Image Segmentation সম্পন্ন করা।

Importance of K-Means Clustering

বর্তমানে Linear Regression, Logistic Regression কিংবা Decision Tree-এর মতো শক্তিশালী Supervised Learning Model থাকা সত্ত্বেও K-Means-এর গুরুত্ব অত্যন্ত বেশি।

এর প্রধান কারণগুলো হলো:

- **লেবেলবিহীন ডেটা বিশ্লেষণ (Handling Unlabeled Data):** বাস্তব বিশ্বের অধিকাংশ ডেটার কোনো Label থাকে না। প্রতিটি ডেটাকে ম্যানুয়ালি Label করা সময়সাপেক্ষ এবং ব্যয়বহুল। K-Means কোনো Label ছাড়াই অর্থপূর্ণ গ্রুপ তৈরি করতে পারে।

- **উচ্চ কম্পিউটেশনাল দক্ষতা (High Computational Efficiency):** Hierarchical Clustering বা HDBSCAN-এর মতো অনেক ক্লাস্টারিং অ্যালগরিদমের তুলনায় K-Means অনেক দ্রুত কাজ করে এবং বৃহৎ ডেটাসেটও অল্প সময়ে প্রক্রিয়াকরণ করতে পারে।
- **সহজ ব্যাখ্যাযোগ্যতা (Interpretability):** প্রতিটি ক্লাস্টারের একটি নির্দিষ্ট Centroid থাকায় সহজেই বোঝানো যায় কেন নির্দিষ্ট ডেটা পয়েন্টগুলো একই ক্লাস্টারে রয়েছে। ফলে Business Analysis এবং Decision Making সহজ হয়।
- **Feature Engineering ও Data Preprocessing:** অনেক ক্ষেত্রে Supervised Learning Model ট্রেনিংয়ের আগে K-Means ব্যবহার করে Cluster Distance-এর মতো নতুন Feature তৈরি করা হয়, যা পরবর্তীতে মডেলের কার্যক্ষমতা এবং Accuracy বৃদ্ধি করতে সাহায্য করে।

Mathematical Foundation of K-Means Clustering

Feature Representation

K-Means অ্যালগরিদমে প্রতিটি ডেটা একটি Feature Vector হিসেবে প্রকাশ করা হয়। যদি কোনো ডেটাসেটে D টি Feature থাকে, তাহলে একটি ডেটা পয়েন্টকে লেখা যায়,

$$x_i = [x_{i1}, x_{i2}, x_{i3}, \dots, x_{iD}]$$

যেখানে,

- x_i = i -তম Data Point
- D = মোট Feature বা Dimension
- N = মোট Data Point-এর সংখ্যা

অর্থাৎ সম্পূর্ণ Dataset-কে প্রকাশ করা যায়,

$$X = \{x_1, x_2, \dots, x_N\}$$

Number of Clusters

K-Means-এ শুরুতেই একটি Hyperparameter নির্বাচন করতে হয়, যাকে K বলা হয়।

$$K = \text{Number of Clusters}$$

এটি নির্ধারণ করে Dataset-কে মোট কতটি Cluster-এ ভাগ করা হবে।

Centroid of a Cluster

প্রতিটি Cluster-এর একটি কেন্দ্রবিন্দু থাকে, যাকে **Centroid** বলা হয়।

Centroid হলো সেই Cluster-এর অন্তর্ভুক্ত সব Data Point-এর গাণিতিক গড় (Arithmetic Mean)।

$$c_j = \frac{1}{|A_j|} \sum_{x_i \in A_j} x_i$$

যেখানে,

- c_j = j -তম Cluster-এর Centroid
- A_j = j -তম Cluster
- $|A_j|$ = ঐ Cluster-এর মোট Data Point সংখ্যা

সহজভাবে,

$$\text{Centroid} = \frac{\text{Cluster-এর সব Data Point-এর যোগফল}}{\text{Cluster-এর মোট Data Point সংখ্যা}}$$

এই সমীকরণ প্রতিটি Iteration শেষে নতুন Centroid নির্ণয়ের জন্য ব্যবহৃত হয়।

Euclidean Distance

K-Means সাধারণত দুটি Data Point-এর মধ্যকার দূরত্ব নির্ণয়ের জন্য **Euclidean Distance** ব্যবহার করে।

$$d(x_i, c_j) = \sqrt{\sum_{k=1}^D (x_{ik} - c_{jk})^2}$$

যেখানে,

- x_i = একটি Data Point
- c_j = একটি Centroid
- D = মোট Feature

দ্বিমাত্রিক (2D) ক্ষেত্রে সমীকরণটি হয়,

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

এই Distance ব্যবহার করে প্রতিটি Data Point-কে সবচেয়ে নিকটবর্তী Centroid-এর Cluster-এ Assign করা হয়।

Objective Function (Within-Cluster Sum of Squares)

K-Means-এর মূল লক্ষ্য হলো প্রতিটি Cluster-এর ভেতরে থাকা Data Point-গুলোর Centroid থেকে মোট Squared Distance যতটা সম্ভব কমানো।

এই Objective Function-কে Within-Cluster Sum of Squares (WCSS) অথবা Sum of Squared Errors (SSE) বলা হয়।

$$J = \sum_{j=1}^K \sum_{x_i \in A_j} \|x_i - c_j\|^2$$

এখানে,

- J = Total Cost Function
- K = মোট Cluster সংখ্যা
- A_j = j -তম Cluster
- c_j = ঐ Cluster-এর Centroid

সহজভাবে,

$$\text{Total Cost} = \sum (\text{Point থেকে নিজের Centroid পর্যন্ত দূরত্ব})^2$$

K-Means Algorithm-এর প্রধান উদ্দেশ্য হলো,

$$\min J$$

অর্থাৎ Total Cost যতটা সম্ভব কমিয়ে আনা।

Why Does the Cost Always Decrease?

K-Means অ্যালগরিদমের Cost Function প্রতিটি Iteration-এ কখনো বৃদ্ধি পায় না; বরং এটি হয় কমে অথবা অপরিবর্তিত থাকে। এর কারণ হলো অ্যালগরিদমটি দুটি ধারাবাহিক অপ্টিমাইজেশন ধাপ অনুসরণ করে।

প্রথম ধাপে (Assignment Step), প্রতিটি Data Point-এর সঙ্গে সবগুলো Centroid-এর দূরত্ব গণনা করা হয় এবং পয়েন্টটিকে সবচেয়ে নিকটবর্তী Centroid-এর Cluster-এ স্থানান্তর করা হয়। যেহেতু প্রতিটি Data Point সর্বদা সর্বনিম্ন দূরত্বের Cluster-এ Assign করা হয়, তাই এই ধাপে মোট Squared Distance বা Cost কখনো বৃদ্ধি পায় না।

দ্বিতীয় ধাপে (Update Step), প্রতিটি Cluster-এর অন্তর্ভুক্ত সকল Data Point-এর গাণিতিক গড় (Arithmetic Mean) নির্ণয় করে নতুন Centroid গণনা করা হয়। গাণিতিকভাবে প্রমাণিত যে কোনো Cluster-এর Mean সেই অবস্থান, যেখানে ঐ Cluster-এর সকল Data Point থেকে Squared Distance-এর যোগফল সর্বনিম্ন হয়। ফলে নতুন Centroid নির্ধারণের পর মোট Cost আরও কমে যায় অথবা পূর্বের মতোই থাকে।

এই দুটি ধাপ পর্যায়ক্রমে পুনরাবৃত্তি হতে থাকে। প্রতিটি Iteration-এ Cost Function হয় কমে, নতুবা অপরিবর্তিত থাকে। যেহেতু Cost Function-এর একটি নিম্নসীমা (Lower Bound) রয়েছে এবং এটি কখনো ঋণাত্মক হতে পারে না, তাই একসময় অ্যালগরিদমটি এমন একটি অবস্থায় পৌঁছে যায় যেখানে আর কোনো পরিবর্তন ঘটে না। এই অবস্থাকেই **Convergence** বলা হয়।

Update Step

প্রতিটি Cluster-এর নতুন Mean নির্ণয় করে নতুন Centroid গণনা করা হয়।

এর ফলে নতুন Centroid Cluster-এর প্রকৃত কেন্দ্রের আরও কাছাকাছি চলে আসে এবং মোট Squared Distance আরও কমে যায়।

এই দুটি ধাপ পুনরাবৃত্তি হতে থাকে যতক্ষণ না আর কোনো পরিবর্তন ঘটে।

ফলে প্রতিটি Iteration-এ,

$$J_{\text{new}} \leq J_{\text{old}}$$

অর্থাৎ Cost Function হয় কমে, নতুবা অপরিবর্তিত থাকে। একসময় Algorithm একটি স্থিতিশীল অবস্থায় (Convergence) পৌঁছে যায়।

Determining the Optimal Number of Clusters

K-Means Algorithm চালানোর আগে উপযুক্ত K নির্বাচন করা অত্যন্ত গুরুত্বপূর্ণ।

বাস্তবে Optimal K নির্ধারণের জন্য বিভিন্ন পদ্ধতি ব্যবহৃত হয়, যেমন,

- Elbow Method
- Silhouette Score
- Gap Statistic
- Prediction Strength

এর মধ্যে **Elbow Method** এবং **Silhouette Score** সবচেয়ে বেশি ব্যবহৃত ও পাঠ্যবইয়ে আলোচিত পদ্ধতি।

K-Means অ্যালগরিদমের মূল উদ্দেশ্য হলো প্রতিটি ডেটা পয়েন্টকে তার নিকটবর্তী সেন্ট্রয়েডের (Centroid/Cluster Mean) সাথে যুক্ত করে ক্লাস্টারের ভেতরের বিশৃঙ্খলা বা ভুলের পরিমাণ সর্বনিম্ন করা। গাণিতিক ভাষায় একে Within-Cluster Sum of Squares (WCSS) বা Inertia বলা হয়।

ধরা যাক, আমাদের কাছে n সংখ্যক স্যাম্পল সংবলিত একটি ডেটাসেট $D = \{x_1, x_2, \dots, x_n\}$ আছে। আমরা এই ডেটাকে K সংখ্যক ক্লাস্টারে $S = \{S_1, S_2, \dots, S_K\}$ ভাগ করতে চাই। এর কস্ট ফাংশন (J) সমীকরণটি হলো:

$$J = \sum_{j=1}^K \sum_{x_i \in S_j} \|x_i - \mu_j\|^2$$

যেখানে:

- K : মোট ক্লাস্টারের সংখ্যা (User-defined Hyperparameter)।
- S_j : j -তম ক্লাস্টারের অন্তর্ভুক্ত ডেটা পয়েন্টগুলোর সেট।
- μ_j : j -তম ক্লাস্টারের সেন্ট্রয়েড বা গড় মান (Mean Vector)।
- $\|x_i - \mu_j\|^2$: ডেটা পয়েন্ট x_i এবং সেন্ট্রয়েড μ_j -এর মধ্যকার ইউক্লিডিয়ান দূরত্বের বর্গ (Squared Euclidean Distance)।

ব্যাকএন্ড ওয়ার্কফ্লো এবং অ্যালগরিদম

K-Means অ্যালগরিদমটি মূলত একটি ইটারেটিভ (Iterative) পদ্ধতি অনুসরণ করে গ্লোবাল মিনিমাম বা সর্বনিম্ন কস্টের দিকে এগিয়ে যায়। এর মূল ধাপগুলো নিচে দেওয়া হলো:

Input:

- Dataset X
- Number of Clusters K

Output:

- Final Clusters ($S_1, S_2, \dots, S_K$)
- Final Centroids ($\mu_1, \mu_2, \dots, \mu_K$)

Step 1: Centroid Initialization

ডেটাসেট থেকে র‍্যান্ডমভাবে (Randomly) K সংখ্যক ডেটা পয়েন্ট নির্বাচন করে সেগুলোকে প্রাথমিক সেন্ট্রয়েড হিসেবে নির্ধারণ করা হয়।

$$\mu_1, \mu_2, \dots, \mu_K$$

Step 2: Iterative Optimization

নিচের ধাপগুলো বারবার পুনরাবৃত্তি করা হয়, যতক্ষণ না অ্যালগরিদমটি স্থির (Converge) হয়।

A. Cluster Assignment (Expectation Step)

প্রতিটি ডেটা পয়েন্ট x_i -এর জন্য সকল Centroid-এর সাথে Euclidean Distance গণনা করা হয়।

এরপর x_i -কে যে Centroid-এর দূরত্ব সবচেয়ে কম, সেই Cluster-এ অন্তর্ভুক্ত করা হয়।

$$S_j = \{x_i : \|x_i - \mu_j\|^2 \leq \|x_i - \mu_l\|^2, \forall l\}$$

B. Centroid Update (Maximization Step)

প্রতিটি Cluster-এর অন্তর্ভুক্ত সকল ডেটা পয়েন্টের গাণিতিক গড় (Arithmetic Mean) নির্ণয় করে নতুন Centroid গণনা করা হয়।

$$\mu_j = \frac{1}{|S_j|} \sum_{x_i \in S_j} x_i$$

C. Convergence Check

নতুন Centroid এবং পূর্ববর্তী Centroid-এর মান তুলনা করা হয়।

যদি সকল Centroid-এর অবস্থান অপরিবর্তিত থাকে (অর্থাৎ নতুন ও পুরোনো Centroid একই হয়), তাহলে Iteration বন্ধ করা হয়। অন্যথায়, পুনরায় Cluster Assignment ধাপ থেকে একই প্রক্রিয়া শুরু হয়।

ধাপ ১: ডেটাসেট ও প্যারামিটার নির্ধারণ

ধরা যাক, আমাদের কাছে ২-ডাইমেনশনাল ($d = 2$) একটি ছোট ডেটাসেট আছে যেখানে $n = 4$ টি ডেটা পয়েন্ট রয়েছে:

- $A_1 = (1,1)$
- $A_2 = (2,1)$
- $A_3 = (4,3)$
- $A_4 = (5,4)$

আমরা চাই ডেটাগুলোকে $K = 2$ টি ক্লাস্টারে ভাগ করতে।

ধাপ ২: র‍্যান্ডম সেন্ট্রয়েড নির্বাচন (Initialization)

আমরা আন্দাজে ডেটাসেট থেকে প্রথম দুটি পয়েন্টকে প্রাথমিক সেন্ট্রয়েড হিসেবে ধরে নিলাম:

- সেন্ট্রয়েড ১ (μ_1) = (1,1)
- সেন্ট্রয়েড ২ (μ_2) = (2,1)

ইটারেশন ১ (Iteration 1)

অংশ A: দূরত্ব গণনা ও ক্লাস্টার অ্যাসাইনমেন্ট

আমরা প্রতিটি ডেটা পয়েন্ট $x_i = (x_{i1}, x_{i2})$ থেকে সেন্ট্রয়েড $\mu_j = (\mu_{j1}, \mu_{j2})$ এর ইউক্লিডিয়ান দূরত্বের বর্গ হিসাব করব। সূত্র: $\|x_i - \mu_j\|^2 = (x_{i1} - \mu_{j1})^2 + (x_{i2} - \mu_{j2})^2$

- পয়েন্ট $A_1(1,1)$ এর জন্য:
 - μ_1 থেকে দূরত্ব = $(1 - 1)^2 + (1 - 1)^2 = 0$
 - μ_2 থেকে দূরত্ব = $(1 - 2)^2 + (1 - 1)^2 = 1 + 0 = 1$
 - সিদ্ধান্ত: যেহেতু $0 < 1$, তাই $A_1 \rightarrow \text{Cluster 1}$
- পয়েন্ট $A_2(2,1)$ এর জন্য:
 - μ_1 থেকে দূরত্ব = $(2 - 1)^2 + (1 - 1)^2 = 1 + 0 = 1$
 - μ_2 থেকে দূরত্ব = $(2 - 2)^2 + (1 - 1)^2 = 0$
 - সিদ্ধান্ত: যেহেতু $0 < 1$, তাই $A_2 \rightarrow \text{Cluster 2}$
- পয়েন্ট $A_3(4,3)$ এর জন্য:

- μ_1 থেকে দূরত্ব = $(4 - 1)^2 + (3 - 1)^2 = 9 + 4 = 13$

- μ_2 থেকে দূরত্ব = $(4 - 2)^2 + (3 - 1)^2 = 4 + 4 = 8$

- সিদ্ধান্ত: যেহেতু $8 < 13$, তাই $A_3 \rightarrow \text{Cluster 2}$

• পয়েন্ট $A_4(5,4)$ এর জন্য:

- μ_1 থেকে দূরত্ব = $(5 - 1)^2 + (4 - 1)^2 = 16 + 9 = 25$

- μ_2 থেকে দূরত্ব = $(5 - 2)^2 + (4 - 1)^2 = 9 + 9 = 18$

- সিদ্ধান্ত: যেহেতু $18 < 25$, তাই $A_4 \rightarrow \text{Cluster 2}$

ইটারেশন ১ শেষে নতুন ক্লাস্টার গ্রুপ:

- $S_1 = \{A_1\}$

- $S_2 = \{A_2, A_3, A_4\}$

অংশ B: বর্তমান কস্ট বা WCSS হিসাব

$$J = \sum \|x_i - \mu_1\|^2 + \sum \|x_i - \mu_2\|^2$$

$$J = [0] + [0 + 8 + 18] = 26$$

অংশ C: নতুন সেন্ট্রয়েড গণনা (Centroid Update)

- নতুন সেন্ট্রয়েড μ_1 :

$$\mu_1 = \left(\frac{1}{1}, \frac{1}{1}\right) = (1,1)$$

- নতুন সেন্ট্রয়েড μ_2 :

$$\mu_2 = \left(\frac{2 + 4 + 5}{3}, \frac{1 + 3 + 4}{3}\right) = \left(\frac{11}{3}, \frac{8}{3}\right) \approx (3.67, 2.67)$$

ইটারেশন ২ (Iteration 2)

যেহেতু সেন্ট্রয়েডের মান পরিবর্তিত হয়েছে, তাই আমরা নতুন সেন্ট্রয়েড $\mu_1 = (1,1)$ এবং $\mu_2 = (3.67, 2.67)$ ব্যবহার করে আবার দূরত্ব হিসাব করব।

অংশ A: দূরত্ব গণনা ও ক্লাস্টার অ্যাসাইনমেন্ট

- পয়েন্ট $A_1(1,1)$ এর জন্য:

- μ_1 থেকে দূরত্ব = 0

- μ_2 থেকে দূরত্ব $= (1 - 3.67)^2 + (1 - 2.67)^2 = (-2.67)^2 + (-1.67)^2 \approx 7.13 + 2.79 = 9.92$
- সিদ্ধান্ত: $A_1 \rightarrow \text{Cluster 1}$
- পয়েন্ট $A_2(2,1)$ এর জন্য:
 - μ_1 থেকে দূরত্ব $= (2 - 1)^2 + (1 - 1)^2 = 1$
 - μ_2 থেকে দূরত্ব $= (2 - 3.67)^2 + (1 - 2.67)^2 = (-1.67)^2 + (-1.67)^2 \approx 2.79 + 2.79 = 5.58$
 - সিদ্ধান্ত: যেহেতু $1 < 5.58$, তাই A_2 ক্লাস্টার পরিবর্তন করে ১ নম্বর ক্লাস্টারে চলে গেল। ($A_2 \rightarrow \text{Cluster 1}$)
- পয়েন্ট $A_3(4,3)$ এর জন্য:
 - μ_1 থেকে দূরত্ব $= (4 - 1)^2 + (3 - 1)^2 = 13$
 - μ_2 থেকে দূরত্ব $= (4 - 3.67)^2 + (3 - 2.67)^2 = (0.33)^2 + (0.33)^2 \approx 0.11 + 0.11 = 0.22$
 - সিদ্ধান্ত: $A_3 \rightarrow \text{Cluster 2}$
- পয়েন্ট $A_4(5,4)$ এর জন্য:
 - μ_1 থেকে দূরত্ব $= 25$
 - μ_2 থেকে দূরত্ব $= (5 - 3.67)^2 + (4 - 2.67)^2 = (1.33)^2 + (1.33)^2 \approx 1.77 + 1.77 = 3.54$
 - সিদ্ধান্ত: $A_4 \rightarrow \text{Cluster 2}$

ইটারেশন ২ শেষে নতুন ক্লাস্টার গ্রুপ:

- $S_1 = \{A_1, A_2\}$
- $S_2 = \{A_3, A_4\}$

অংশ B: বর্তমান কস্ট বা WCSS হিসাব

$$J = [0 + 1] + [0.22 + 3.54] = 4.76$$

(দেখা যাচ্ছে কস্ট ২৬ থেকে কমে ৪.৭৬ এ নেমে এসেছে, অর্থাৎ মডেলটি সঠিক দিকে যাচ্ছে)

অংশ C: নতুন সেন্ট্রয়েড গণনা (Centroid Update)

- নতুন সেন্ট্রয়েড μ_1 :

$$\mu_1 = \left(\frac{1+2}{2}, \frac{1+1}{2} \right) = (1.5, 1)$$

- নতুন সেন্ট্রয়েড μ_2 :

$$\mu_2 = \left(\frac{4+5}{2}, \frac{3+4}{2} \right) = (4.5, 3.5)$$

ইটারেশন ৩ (Iteration 3)

এখন নতুন আপডেটেড সেন্ট্রয়েড হলো $\mu_1 = (1.5, 1.0)$ এবং $\mu_2 = (4.5, 3.5)$ ।

অংশ A: দূরত্ব গণনা ও ক্লাস্টার অ্যাসাইনমেন্ট

- পয়েন্ট $A_1(1,1)$: μ_1 থেকে দূরত্ব = 0.25 | μ_2 থেকে দূরত্ব = 18.5 $\rightarrow A_1 \rightarrow S_1$
- পয়েন্ট $A_2(2,1)$: μ_1 থেকে দূরত্ব = 0.25 | μ_2 থেকে দূরত্ব = 12.5 $\rightarrow A_2 \rightarrow S_1$
- পয়েন্ট $A_3(4,3)$: μ_1 থেকে দূরত্ব = 10.25 | μ_2 থেকে দূরত্ব = 0.5 $\rightarrow A_3 \rightarrow S_2$
- পয়েন্ট $A_4(5,4)$: μ_1 থেকে দূরত্ব = 21.25 | μ_2 থেকে দূরত্ব = 0.5 $\rightarrow A_4 \rightarrow S_2$

ইটারেশন ৩ শেষে ক্লাস্টার গ্রুপ:

- $S_1 = \{A_1, A_2\}$
- $S_2 = \{A_3, A_4\}$

Convergence Reached (স্থিরতা অর্জন): খেয়াল করে দেখুন, ইটারেশন ৩-এর ক্লাস্টার অ্যাসাইনমেন্ট এবং ইটারেশন ২-এর ক্লাস্টার অ্যাসাইনমেন্ট হুবহু একই এসেছে। এর মানে হলো ডেটা পয়েন্টগুলো আর তাদের দল পরিবর্তন করছে না। সেন্ট্রয়েড পুনর্গণনা করলেও মান একই থাকবে। অতএব, মডেলটি গ্লোবাল মিনিমাম বা সর্বনিম্ন কস্ট পয়েন্ট অর্জন করেছে এবং ট্রেনিং এখানেই সমাপ্ত।

চূড়ান্ত ফলাফল টেবিল (Final Model State)

ক্লাস্টার (Cluster)	আইডি অন্তর্ভুক্ত পয়েন্টসমূহ	ডেটা সেন্ট্রয়েড (Centroid)	ক্লাস্টার কস্ট (WCSS)
Cluster 1	$A_1(1,1), A_2(2,1)$	$\mu_1 = (1.5, 1.0)$	$0.25 + 0.25 = 0.50$
Cluster 2	$A_3(4,3), A_4(5,4)$	$\mu_2 = (4.5, 3.5)$	$0.50 + 0.50 = 1.00$

সর্বনিম্ন চূড়ান্ত কস্ট (Minimum Cost) $J = 0.50 + 1.00 = 1.50$

Parameters:

১. মোস্ট ইম্পোর্টেন্ট প্যারামিটারসমূহ (The Heavy Hitters)

মডেলের ক্লাস্টারিং পারফরম্যান্স, গতি এবং সেন্ট্রয়েডের সঠিক অবস্থান নির্ধারণে এই প্যারামিটারগুলো সবচেয়ে গুরুত্বপূর্ণ ভূমিকা পালন করে।

n_clusters

- **Default:** 8
- **প্যারামিটারটি কী কাজ করে:** এটি মূলত ডেটাসেটকে মোট কতটি ক্লাস্টারে ভাগ করা হবে এবং কতটি সেন্ট্রয়েডের স্থানাঙ্ক (Coordinates) তৈরি করা হবে তা নির্ধারণ করে।
- **অন্যান্য অপশনসমূহ এবং কখন ব্যবহার করবেন:** এটি যেকোনো ধনাত্মক পূর্ণসংখ্যা (Integer) গ্রহণ করে। বাস্তব প্রজেক্টে ব্যবসার লক্ষ্য বা ডেটার ধরনের ওপর ভিত্তি করে এটি সেট করা হয়। যদি সঠিক ক্লাস্টার সংখ্যা জানা না থাকে, তবে **Elbow Method** বা **Silhouette Analysis**-এর মতো গাণিতিক পদ্ধতি ব্যবহার করে সবচেয়ে নিখুঁত K বা ক্লাস্টার সংখ্যা খুঁজে বের করে এখানে ইনপুট দিতে হয়।

init

- **Default:** 'k-means++'
- **প্যারামিটারটি কী কাজ করে:** অ্যালগরিদমটি শুরু করার সময় প্রাথমিক সেন্ট্রয়েডের অবস্থান কীভাবে নির্বাচন করা হবে, এটি তা নিয়ন্ত্রণ করে। ডিফল্ট 'k-means++' পদ্ধতিটি ডেটা পয়েন্টগুলোর সামগ্রিক জড়তার (Inertia) ওপর ভিত্তি করে একটি প্রায়োগিক সম্ভাব্যতা বন্টন (Empirical probability distribution) ব্যবহার করে সেন্ট্রয়েডের বীজ (Seeds) বপন করে। এটি সাধারণ পদ্ধতির চেয়ে অনেক দ্রুত মডেলকে কনভার্জ (স্থির)

করতে সাহায্য করে। Scikit-Learn-এর এই ইমপ্লিমেন্টেশনটি প্রতিটি ধাপে বেশ কয়েকটি ট্রায়াল চালিয়ে সেরা সেন্ট্রয়েডটি বেছে নেয় (Greedy K-Means++)।

- **অন্যান্য অপশনসমূহ এবং কখন ব্যবহার করবেন:**

- 'random': এটি ডেটাসেট থেকে সম্পূর্ণ র্যান্ডমলি (আন্দাজে) K সংখ্যক সারি বা পর্যবেক্ষণ বেছে নিয়ে প্রাথমিক সেন্ট্রয়েড নির্ধারণ করে। এটি মূলত শিক্ষানবিস বা তাত্ত্বিক পরীক্ষার ক্ষেত্রে ব্যবহার করা হয়, তবে এটি ব্যবহার করলে মডেলটি প্রায়শই লোকাল মিনিমামে (Local Minima) আটকে যায়।
- array-like (ম্যাট্রিক্স): যদি আপনার আগে থেকেই সেন্ট্রয়েডের অবস্থান জানা থাকে, তবে তার স্থানাঙ্ক সরাসরি ($n_clusters$, $n_features$) শেপের একটি অ্যারে আকারে পাস করতে পারেন।
- callable (ফাংশন): কাস্টম কোনো শুরুকরণ কৌশল (Custom Initialization Strategy) তৈরি করতে চাইলে এখানে একটি পাইথন ফাংশন পাস করা যায়।

n_init

- **Default:** 'auto'
- **প্যারামিটারটি কী কাজ করে:** K-Means অ্যালগরিদমটি ভিন্ন ভিন্ন প্রাথমিক সেন্ট্রয়েড বীজ নিয়ে মোট কতবার নতুন করে রান (Run) করবে, এটি তা নির্ধারণ করে। একাধিকবার রান করার পর, যে রানটি সবচেয়ে সর্বনিম্ন জড়তা (Inertia/WCSS) প্রদান করে, মডেলটি সেটিকেই চূড়ান্ত ফলাফল হিসেবে গ্রহণ করে। এটি মডেলকে লোকাল মিনিমাম থেকে রক্ষা করতে অত্যন্ত সাহায্য করে।
- **অন্যান্য অপশনসমূহ এবং কখন ব্যবহার করবেন:** এটি যেকোনো পূর্ণসংখ্যা (যেমন: 5, 10, 20) গ্রহণ করতে পারে।
 - যখন এটি 'auto' থাকে, তখন এটি init-এর মানের ওপর ভিত্তি করে স্বয়ংক্রিয়ভাবে রানের সংখ্যা নির্ধারণ করে। যদি init='random' বা callable ফাংশন ব্যবহার করা হয়, তবে এটি **১০ বার** রান করে। আর যদি init='k-means++' বা কাস্টম অ্যারে দেওয়া হয়, তবে এটি মাত্র **১ বার** রান করে (কারণ k-means++ প্রথমবারেই চমৎকার সেন্ট্রয়েড খুঁজে পায়)।
 - উচ্চ-মাত্রার স্পার্স ডেটার (Sparse High-Dimensional Data) ক্ষেত্রে লোকাল মিনিমাম এড়াতে এখানে ম্যানুয়ালি বড় সংখ্যা (যেমন: 15 বা 20) ব্যবহার করা উচিত।

২. মিডিয়াম ইম্পর্টেন্ট প্যারামিটারসমূহ (Optimization & Execution)

মডেলের কনভার্জেন্সের গতিবেগ, কম্পিউটেশনাল সময় এবং মেমোরি অপ্টিমাইজেশনের জন্য এই প্যারামিটারগুলো ব্যবহার করা হয়।

max_iter

- **Default:** 300
- **প্যারামিটারটি কী কাজ করে:** এটি একটি একক রানের (Single Run) জন্য K-Means অ্যালগরিদমটি সর্বোচ্চ কতবার ইটারেশন বা চক্র (Centroid Update -> Assign Cluster) চালাবে তা নির্ধারণ করে দেয়।
- **অন্যান্য অপশনসমূহ এবং কখন ব্যবহার করবেন:** যেকোনো ধনাত্মক পূর্ণসংখ্যা পাস করা যায়। ডেটাসেট যদি অনেক বিশাল হয় এবং ৩০০ ইটারেশন হওয়ার আগেই যদি মডেল স্থির হয়ে যায়, তবে কোনো সমস্যা নেই। তবে ডেটা যদি খুব জটিল হয় এবং ৩০০ ইটারেশনের মধ্যেও সেন্ট্রয়েডগুলো স্থির হতে না পারে, তবে এই মান বাড়িয়ে 500 বা 1000 করা প্রয়োজন হতে পারে (যদিও বাস্তব ক্ষেত্রে ৩০০ ইটারেশনই যথেষ্ট)।

tol

- **Default:** 1e-4 (0.0001)
- **প্যারামিটারটি কী কাজ করে:** এটি হলো কনভার্জেন্স থ্রেশহোল্ড বা সহনশীলতার মাত্রা (Convergence Tolerance)। পরপর দুটি ইটারেশনে সেন্ট্রয়েডগুলোর অবস্থানের পার্থক্যের Frobenius Norm যদি এই tol-এর চেয়ে কম হয়, তবে অ্যালগরিদম ধরে নেয় যে মডেলটি পুরোপুরি কনভার্জ বা স্থির হয়ে গেছে এবং সর্বোচ্চ ইটারেশন (max_iter) পূর্ণ হওয়ার আগেই ট্রেনিং বন্ধ করে দেয়।
- **অন্যান্য অপশনসমূহ এবং কখন ব্যবহার করবেন:** এটি যেকোনো ফ্লোট (Float) সংখ্যা গ্রহণ করে। যদি ক্লাস্টারিং অত্যন্ত নিখুঁত এবং সুনির্দিষ্ট করতে হয়, তবে এই মান কমিয়ে 1e-5 বা 1e-6 করা যায় (এতে ট্রেনিং সময় একটু বেশি লাগবে)। আবার দ্রুত খসড়া ফলাফলের জন্য এটি বাড়িয়ে 1e-3 করা যেতে পারে।

algorithm

- **Default:** 'lloyd'
- **প্যারামিটারটি কী কাজ করে:** ক্লাস্টারিং গাণিতিক সমস্যাটি সমাধান করার জন্য ব্যাকএন্ডে কোন ক্লাসিক্যাল বা পরিবর্তিত অ্যালগরিদম মেকানিজম ব্যবহার করা হবে তা এটি নিয়ন্ত্রণ করে। ডিফল্ট 'lloyd' হলো চিরাচরিত Expectation-Maximization (EM) স্টাইল অ্যালগরিদম।

- **অন্যান্য অপশনসমূহ এবং কখন ব্যবহার করবেন:**

- 'elkan': এটি মূলত জ্যামিতিক ত্রিভুজ অসমতা (Triangle Inequality) ব্যবহার করে কাজ করে। যেসব ডেটাসেটে ক্লাস্টারগুলো খুব সুনির্দিষ্ট এবং পরিষ্কারভাবে আলাদা করা থাকে, সেখানে দূরত্ব গণনার অপ্ৰয়োজনীয় ধাপগুলো এড়িয়ে এটি লয়েডের চেয়ে অনেক দ্রুত কাজ করতে পারে। তবে এটি মেমোরির দিক থেকে বেশ ব্যয়বহুল, কারণ ব্যাকএন্ডে এটি (n_samples, n_clusters) শেপের একটি অতিরিক্ত অ্যারে মেমোরিতে ধরে রাখে। ডেটা সাইজ মাঝারি এবং ক্লাস্টার সুনির্দিষ্ট হলে এটি ব্যবহার করা দারুণ কার্যকর।

৩. লেস ইম্পর্টেন্ট প্যারামিটারসমূহ (System & Housekeeping)

এই প্যারামিটারগুলো মডেলের ক্লাস্টারিং পারফরম্যান্স বা একুরেসিতে কোনো পরিবর্তন আনে না, বরং এগুলো কোডের পুনরুৎপাদনযোগ্যতা (Reproducibility) এবং সিস্টেম রিসোর্স নিয়ন্ত্রণে ব্যবহৃত হয়।

random_state

- **Default:** None
- **প্যারামিটারটি কী কাজ করে:** সেন্ট্রয়েড শুরুকরণের (Centroid Initialization) সময় যে সুডোরাণ্ডম নম্বর জেনারেটর কাজ করে, এটি তার বীজ (Seed) নির্ধারণ করে।
- **অন্যান্য অপশনসমূহ এবং কখন ব্যবহার করবেন:** এখানে যেকোনো নির্দিষ্ট পূর্ণসংখ্যা (যেমন: 0, 42) ব্যবহার করা উচিত। অ্যাসাইনমেন্ট, একাডেমিক রিসার্চ বা 실험 ট্র্যাকিংয়ের সময় কোডটি যতবারই রান করা হোক না কেন, প্রতিবার যেন ছবছ একই প্রাথমিক সেন্ট্রয়েড এবং একই ক্লাস্টার ফলাফল পাওয়া যায়, তা নিশ্চিত করতে এটি লক করা বাধ্যতামূলক।

copy_x

- **Default:** True
- **প্যারামিটারটি কী কাজ করে:** দূরত্বের সংখ্যাসূচক নির্ভুলতা (Numerical Accuracy) বৃদ্ধির জন্য K-Means ব্যাকএন্ডে ডেটাকে প্রথমে সেন্ট্রালাইজ (Center) করে নেয়। এটি True থাকলে মূল ইনপুট ডেটাসেটটি অপরিবর্তিত থাকে এবং একটি কপি নিয়ে কাজ করা হয়।
- **অন্যান্য অপশনসমূহ এবং কখন ব্যবহার করবেন:** False দিলে মেমোরি সাশ্রয় হয় কারণ এটি সরাসরি মূল মেমোরির ডেটার ওপর অপারেশন চালায় এবং কাজ শেষে ডেটার গড় পুনরায় যোগ করে দেয়। তবে এর ফলে খুব সামান্য সংখ্যাসূচক মানের পার্থক্য (Small

Numerical Differences) তৈরি হতে পারে। ডেটার সাইজ যদি র‍্যামের তুলনায় অত্যন্ত বিশাল হয়, কেবল তখনই মেমোরি বাঁচাতে এটি False করা যেতে পারে।

verbose

- **Default: 0**
- **প্যারামিটারটি কী কাজ করে:** এটি ভার্সিটি মোড নিয়ন্ত্রণ করে, অর্থাৎ মডেল ট্রেনিং চলাকালে স্ক্রিনে ভেতরের বিস্তারিত লগ বা অগ্রগতি দেখাবে কি না।
- **অন্যান্য অপশনসমূহ এবং কখন ব্যবহার করবেন:** যেকোনো ধনাত্মক পূর্ণসংখ্যা দেওয়া যায়। verbose=1 বা তার বেশি দিলে প্রতি ইটারেশনে জড়তা বা কস্টের মান কত কমছে তা কনসোলে দেখা যায়, যা মূলত দীর্ঘ সময় ধরে চলা বড় মডেলগুলোর ডিবাগিংয়ে সাহায্য করে।

SciKit Learn Code:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import load_iris
from sklearn.model_selection import GridSearchCV
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans

iris = load_iris()
X = pd.DataFrame(iris.data, columns=iris.feature_names)
numeric_features = iris.feature_names

wcss_scores = []
k_range = range(1, 11)
```

```
iris = load_iris()
X = pd.DataFrame(iris.data, columns=iris.feature_names)
numeric_features = iris.feature_names

wcss_scores = []
k_range = range(1, 11)

for k in k_range:
    preprocessor = ColumnTransformer(
        transformers=[("num", StandardScaler(), numeric_features)]
    )

    current_pipeline = Pipeline(steps=[
        ("prep", preprocessor),
        ("model", KMeans(n_clusters=k, init='k-means++', n_init='auto',
            random_state=42, algorithm='lloyd'))
    ])

    current_pipeline.fit(X)
    wcss_scores.append(current_pipeline.named_steps["model"].inertia_)
```

```
plt.figure(figsize=(8, 5))
plt.plot(k_range, wcss_scores, marker='o', linestyle='--', color='teal')
plt.title('Elbow Curve via Automated Iteration')
plt.xlabel('Number of Clusters (K)')
plt.ylabel('Within-Cluster Sum of Squares (Inertia)')
plt.grid(True)
plt.show()
```

```
optimized_preprocessor = ColumnTransformer(
    transformers=[("num", StandardScaler(), numeric_features)]
)
```

```
final_pipeline = Pipeline(steps=[
    ("prep", optimized_preprocessor),
    ("model", KMeans(random_state=42))
])
```

```
param_grid = {
    "model__n_clusters": [2, 3, 4],
    "model__init": ["k-means++"],
    "model__n_init": ["auto"],
    "model__max_iter": [300],
    "model__tol": [1e-4],
    "model__algorithm": ["lloyd"]
}
```

```
grid_search = GridSearchCV(
    estimator=final_pipeline,
    param_grid=param_grid,
    cv=3,
    n_jobs=-1,
    verbose=0
)
```

```
grid_search.fit(X)
```

```
print("--- Optimal Model Configuration ---")
print(grid_search.best_params_, "\n")
```

```
best_model_pipeline = grid_search.best_estimator_
final_labels = best_model_pipeline.predict(X)
X['Cluster_Assigned'] = final_labels
```

```
print("--- Final Centroid Vectors (Normalized Space) ---")
print(best_model_pipeline.named_steps["model"].cluster_centers_)
```

প্রশ্ন ১: K-Means কীভাবে আউটলায়ার (Outliers) হ্যান্ডেল করে এবং কস্ট ফাংশনের ওপর এর প্রভাব কী?

- **উত্তর:** K-Means অ্যালগরিদম আউটলায়ার বা ব্যতিক্রমী ডেটা পয়েন্টের প্রতি অত্যন্ত সংবেদনশীল (Sensitive), কারণ এটি সেন্ট্রয়েড আপডেট করার জন্য গাণিতিক গড় (Mean) ব্যবহার করে।
- **প্রভাব:** যেহেতু কস্ট ফাংশনটি প্রতিটি পয়েন্ট থেকে সেন্ট্রয়েডের ইউক্লিডিয়ান দূরত্বের বর্গকে সর্বনিম্ন করার চেষ্টা করে $J = \sum \sum \|x_i - \mu_j\|^2$, তাই একটিমাত্র বিশাল দূরত্বের আউটলায়ার পয়েন্ট পুরো কস্ট ফাংশনকে ডমিনেট বা প্রভাবিত করতে পারে। এর ফলে সেন্ট্রয়েডটি আক্ষরিক অর্থেই আউটলায়ার পয়েন্টটির দিকে মারাত্মকভাবে সরে যায় এবং ক্লাস্টারের আসল জ্যামিতিক সীমানা নষ্ট হয়।

প্রশ্ন ২: Scikit-Learn-এর KMeans-এ n_init প্যারামিটারটির উদ্দেশ্য কী এবং এটি কীভাবে লোকাল মিনিমা রোধ করে?

- **উত্তর:** বাস্তব ক্ষেত্রে K-Means অ্যালগরিদমটি অত্যন্ত দ্রুত কাজ করলেও এটি প্রাথমিক সেন্ট্রয়েডগুলো শুরুতে ঠিক কোথায় বসানো হচ্ছে তার ওপর ভিত্তি করে প্রায়ই লোকাল মিনিমামে (Local Minima) আটকে যায়।
- **মেকানিজম:** n_init প্যারামিটারটি নির্ধারণ করে যে অ্যালগরিদমটি সম্পূর্ণ ভিন্ন ভিন্ন র্যান্ডম সেন্ট্রয়েড বীজ (Centroid seeds) নিয়ে মোট কতবার নতুন করে রান করবে। Scikit-Learn এই ধারাবাহিক রানগুলো সম্পন্ন করার পর যে রানের আউটপুট সবচেয়ে সর্বনিম্ন জড়তা বা কস্ট (inertia_) প্রদান করে, সেটিকেই চূড়ান্ত ক্লাস্টার মডেল হিসেবে বেছে নেয়। এর ফলে মডেলটির গ্লোবাল মিনিমাম (Global Minimum) বা সবচেয়ে সঠিক সমাধান খুঁজে পাওয়ার সম্ভাবনা বহুগুণ বেড়ে যায়।

প্রশ্ন ৩: K-Means ক্লাস্টারিং চালানোর আগে ফিচার স্কেলিং (Feature Scaling) করা কেন বাধ্যতামূলক?

- **উত্তর:** K-Means একটি দূরত্ব-ভিত্তিক (Distance-based) অ্যালগরিদম, যা ক্লাস্টারের সীমানা নির্ধারণের সময় প্রতিটি ফিচার বা ডাইমেনশনের দূরত্বকে সমান গুরুত্ব দেয়।
- **মেকানিজম:** যদি ডেটাসেটের ফিচারগুলোর স্কেল বা রেঞ্জ অসমান হয় (যেমন: Salary কলামের মান ০ থেকে ১,০০০,০০০ এবং Age কলামের মান ০ থেকে ১০০), তবে দূরত্ব গণনার পুরো প্রক্রিয়াটি সম্পূর্ণভাবে বড় স্কেলের ফিচারটি (Salary) দ্বারা নিয়ন্ত্রিত হবে এবং ছোট স্কেলের ফিচারের (Age) গুরুত্ব হারিয়ে যাবে। StandardScaler-এর মতো উপাদান ব্যবহার করে ফিচার স্কেলিং করলে সমস্ত ফিচারের ভ্যারিয়েন্স একই স্কেলে চলে আসে, যা প্রতিটি ফিচারকে ক্লাস্টার গঠনে সমানভাবে অবদান রাখার সুযোগ করে দেয়।

প্রশ্ন ৪: KMeans-এর ক্ষেত্রে লয়েড (Lloyd) এবং এলকান (Elkan) অ্যালগরিদমের মধ্যে মূল পার্থক্য কী?

- **উত্তর:** লয়েড এবং এলকান উভয় অ্যালগরিদমই ব্যাকঅ্যান্ডে একই K-Means গাণিতিক সমস্যার সমাধান করে, তবে তাদের কাজ করার অভ্যন্তরীণ কৌশল ভিন্ন।
- **লয়েড অ্যালগরিদম (Lloyd's):** এটি হলো চিরাচরিত Expectation-Maximization স্টাইলের অ্যালগরিদম, যা প্রতি ইটারেশনে প্রতিটি ডেটা পয়েন্ট থেকে প্রতিটি সেন্ট্রয়েডের দূরত্ব ম্যানুয়ালি গণনা করে।
- **এলকান অ্যালগরিদম (Elkan's):** এটি মূলত জ্যামিতিক ত্রিভুজ অসমতা (Triangle Inequality) ব্যবহার করে কাজ করে। যেসব ডেটাসেটে ক্লাস্টারগুলো খুব সুনির্দিষ্টভাবে আলাদা থাকে, সেখানে এটি দূরত্বের একটি উচ্চ ও নিম্ন সীমা ট্র্যাক করে অপয়োজনীয় দূরত্ব গণনা এড়িয়ে চলে। ফলে এটি লয়েডের চেয়ে অনেক দ্রুত কাজ করতে পারে, তবে ব্যাকঅ্যান্ডে একটি অতিরিক্ত দূরত্ব অ্যারে মেমোরিতে ধরে রাখার কারণে এটি অত্যন্ত র‍্যাম বা মেমোরি-সংবেদনশীল (Memory intensive)।

প্রশ্ন ৫: মডেলটি সম্পূর্ণ স্থির (Converge) হওয়ার আগেই যদি অ্যালগরিদমটি বন্ধ হয়ে যায়, তবে সেন্ট্রয়েড ও ক্লাস্টার অ্যাসাইনমেন্টের কী ঘটে?

- **উত্তর:** যদি KMeans অ্যালগরিদমটি পুরোপুরি স্থির বা কনভার্জ হওয়ার আগেই নির্ধারিত সর্বোচ্চ ইটারেশন সীমা (max_iter) স্পর্শ করে বা সহনশীলতার মাত্রা (tol) অতিক্রমের কারণে বন্ধ হয়ে যায়, তবে এর অভ্যন্তরীণ গাণিতিক অবস্থা সামঞ্জস্যহীন (Inconsistent) হয়ে পড়ে।
- **প্রভাব:** এমন পরিস্থিতিতে মেমোরিতে থাকা সেন্ট্রয়েডের স্থানাঙ্কগুলো (cluster_centers_) ওই ক্লাস্টারের অন্তর্ভুক্ত ডেটা পয়েন্টগুলোর প্রকৃত গাণিতিক গড়ের সাথে মিলবে না। তবে প্রডাকশনে কাজ সচল রাখার জন্য, এস্টিমেটরটি একদম শেষ ইটারেশনের পর পুনরায় ডেটা পয়েন্টগুলোর লেবেল রি-অ্যাসাইন করে দেয়, যাতে চূড়ান্ত labels_ অ্যাট্রিবিউটটি মূল ডেটার ওপর চালানো .predict() মেথডের ফলাফলের সাথে পুরোপুরি সামঞ্জস্যপূর্ণ থাকে।

K-Means ক্লাস্টারিংয়ের চূড়ান্ত সারসংক্ষেপ

পেশাদারী ইন্টারভিউ এবং পরীক্ষার কুইক রিভিশনের সুবিধার্থে পুরো অধ্যায়ের মূল গাণিতিক ও কাঠামোগত বিষয়গুলো নিচে সংক্ষেপে টেবিল এবং কী-পয়েন্টের মাধ্যমে উপস্থাপন করা হলো:

১. কুইক রিভিশন ম্যাট্রিক্স (Quick Revision Matrix)

ক্যাটাগরি	মূল আলোচ্য বিষয় ও গাণিতিক রূপ
মূল সমীকরণ (Core Formula)	$J = \sum_{j=1}^K \sum_{x_i \in S_j} \ x_i - \mu_j\ ^2$ (Within-Cluster Sum of Squares)
অ্যালগরিদমের ধরন	Unsupervised, Iterative Partitional Clustering, Eager Learner
জটিলতা (Complexity)	গড় সময় জটিলতা: $O(K \cdot n \cdot T)$; যেখানে T = Iterations
শুরুকরণ কৌশল (Init)	k-means++ (দ্রুত কনভার্জেন্স ও লোকাল মিনিমা এড়ানোর জন্য ডিফল্ট কৌশল)
স্থিরতার শর্ত (Convergence)	সর্বোচ্চ ইটারেশন সীমা (max_iter=300) অথবা সেন্ট্রয়েডের নড়াচড়া থ্রেশহোল্ডের নিচে নামা (tol=1e-4)
মূল মেথডসমূহ (API)	.fit(), .predict(), .transform(), .fit_predict(), .fit_transform()
প্রধান অ্যট্রিবিউটস	cluster_centers_ (সেন্ট্রয়েড), labels_ (ক্লাস্টার ইনডেক্স), inertia_ (WCSS কস্ট)

২. মূল জাস্টিফিকেশন ও টেকনিক্যাল ইনসাইটস (Core Structural Insights)

- ফিচার স্কেলিং বাধ্যতামূলক:** K-Means যেহেতু জ্যামিতিক ইউক্লিডিয়ান দূরত্বের ওপর ভিত্তি করে দল গঠন করে, তাই অসমান স্কেলের ফিচার থাকলে বড় স্কেলের ফিচারটি পুরো দূরত্বকে ডমিনেট করে ফেলে। এই কারণে মডেল ফিট করার পূর্বে StandardScaler ব্যবহার করা অপরিহার্য।
- লোকাল মিনিমা ও রিস্টার্ট লজিক:** অ্যালগরিদমটি শুরুতে র্যান্ডম সেন্ট্রয়েড নির্বাচনের ওপর অত্যন্ত নির্ভরশীল হওয়ায় প্রায়ই লোকাল মিনিমাতে আটকে যায়। এই সমস্যা দূর করতে n_init='auto' প্যারামিটার ব্যবহার করে ভিন্ন ভিন্ন সেন্ট্রয়েড বীজ নিয়ে ব্যাকঅ্যাভে একাধিকবার লুপ চালানো হয় এবং সর্বনিম্ন ইনোশিয়ার রানটি বেছে নেওয়া হয়।
- এলবো মেথড (Elbow Method):** ক্লাস্টারের সংখ্যা বা K -এর মান আগে থেকে জানা না থাকলে, প্রতিবার K -এর মান বাড়িয়ে ইনোশিয়া বা WCSS-এর ড্রপ রেট প্লট করা হয়।

গ্রাফের রেখাটি যে বিন্দুতে এসে হুট করে বাটির কনুইয়ের মতো (Elbow) বেঁকে যায় এবং কস্ট কমার গতি ধীর হয়ে যায়, সেটিকেই আদর্শ ক্লাস্টার সংখ্যা হিসেবে বিবেচনা করা হয়।

- **পাইপলাইন ইন্টিগ্রেশন:** প্রডাকশন কোডে ডেটা লিক (Data Leakage) সম্পূর্ণ বন্ধ করতে এবং ফিচার স্কেলিং ও মডেলিং মেকানিজমকে লিক-প্রুফ রাখতে সর্বদা ColumnTransformer এবং Pipeline ক্রমানুসারে সাজিয়ে GridSearchCV-এর ভেতর দিয়ে রান করা উচিত।